





A0

A0 · 三篇顶级范本逆向拆解与五轮思维 演练报告

A0 · Reverse Engineering Three Top Exemplar Papers and a
Five-Round Thinking Drill Report

TwinsEarth · 智能体宇宙论文系列



A0 • 三篇顶级范本逆向拆解与五轮思维 演练报告

UDOS 推演引擎 v7.5.0 · 房文新 · 2026-09-20

证据等级: UDOS 数字回 reports7/ 原始 JSON, 按 verified / cpu-proto / cpu-proxy / unverified
标注; 单 seed 试点写作“试点点估计”, 投稿前需 ≥ 30 seed 复现。

版本：UDOS_论文全文 v7.5.0 / 阶段 A（范本逆向） 生成日期：2026-09-20（Asia/Shanghai, UTC+8） 方法学声明：本报告**不是凭记忆复述**。三篇 PDF 均由 PyMuPDF (PyMuPDF 1.28.2 / MuPDF 1.28.2) 逐页 `get_text("text", sort=True)` 全文抽取，并对关键图表页做 `get_pixmap` 渲染后逐张读图核对（坐标轴、三线表、版式）。所有数字、章节号、图号均来自 PDF 原文，未做外推。抽取产物留存：`_work/kaplan.txt`（30 页 / 124,762 字符）、`_work/alexnet.txt`（9 页 / 37,959 字符）、`_work/nsa.txt`（24 页 / 76,441 字符），及渲染图 `_work/{alex,kap,nsa}_p*.png`。

0. 三篇范本速览（一句话定位）

简称	真实题录（PDF 实测）	篇幅/版式	在本报告中的角色
AlexNet	Krizhevsky, Sutskever, Hinton. ImageNet Classification with Deep Convolutional Neural Networks. NeurIPS 2012. 9 页	双栏会议版式	“工程细节即科学贡献”范式：每一个 trick 都配数值化消融 + 误差率对照表
Kaplan	Kaplan, McCandlish, Henighan et al. Scaling Laws for Neural Language Models. arXiv: 2001.08361v1, 2020. 30 页	单栏 arXiv + 显式目录 + A-D 附录	“控制变量 + 幂律拟合 + 趋势外推”范式：先抛结论、指数表收尾、专设 Caveats
NSA	Yuan, Gao, Dai ... Ruan, Zhang, Liang, Zeng. Native Sparse Attention: Hardware-Aligned and Natively Trainable Sparse Attention. arXiv: 2502.11089v1, 2025 (DeepSeek-AI × 北京大学 × U.W.) . 24 页	单栏 LaTeX 会议版式 + 三线表	“硬件约束→架构设计→端到端可训→逐层/逐任务对照”范式

重要勘误（按用户指令与 PDF 原件双重确认）：附件 `DeepSeek论文2502.11089v1.pdf` 实测题为 **Native Sparse Attention (NSA)**，**不是 DeepSeek-V3**，**也不是 DeepSeek-R1**。R1/V2/R1 仅出现在其参考文献与对比基线中。本报告与总库一律以 NSA 为准。

第一部分 · 逐篇逆向拆解

一、AlexNet (Krizhevsky/Sutskever/Hinton, NeurIPS 2012)

1.1 结构骨架与篇幅配比

全文 9 页、无显式目录、双栏。章节与篇幅实测如下：

节	标题	起止页	篇幅特征
—	Abstract	p1	单段，任务+头条数字+技术+战绩全塞一段
1	Introduction	p1–p2	从”小数据集时代”讲到”为什么要大模型+CNN”，结尾明确罗列 5 条 specific contributions
2	The Dataset	p2	数据划分、预处理（256×256 下采样、减均值）
3	The Architecture	p3–p5	3.1 ReLU / 3.2 Multi-GPU / 3.3 LRN / 3.4 Overlapping Pooling / 3.5 Overall。原文明说”3.1–3.4 按我们估计的重要性排序，最重要在前”
4	Reducing Overfitting	p5–p6	4.1 数据增强 / 4.2 Dropout
5	Details of learning	p6	SGD 超参、初始化、学习率调度
6	Results	p7	Table 1/2 + Fall2009；6.1 Qualitative Evaluations (Fig3/Fig4)
7	Discussion	p8	收束
—	References	p9	[1]–[26]，编号制

配比观察：方法（3+4+5）约占 45%，结果（6）约 15%，引言（1）约 20%。引言与方法几乎等量——这是”工程贡献型”论文的典型：贡献本身就是一串工程决策，需要用引言把”为什么每个决策都重要”讲清楚。

1.2 摘要写法（逐句拆）

摘要一段、约 200 词，固定七拍：1. 任务：“We trained a large, deep CNN to classify the 1.2 million … LSVRC-2010 … into 1000 classes.” 2. 头条数字：“top-1 and top-5 error rates of 37.5% and 17.0% … considerably better than the previous SOTA.” 3. 规模锚点：“60 million parameters and 650,000 neurons … 5 conv + 3 FC + 1000-way softmax.” 4. 提速手段：“non-saturating neurons and a very efficient GPU implementation.” 5. 抗过拟合手段：dropout。 6. 竞赛战绩（第二锤）：“ILSVRC-2012 winning top-5 15.3%, compared to 26.2% second-best.”

套路：任务 → 双指标头条数 → 规模参数 → 两个技术关键词 → 一记竞赛胜负。数字全部进摘要。

1.3 引言论证套路

- 趋势论证：小数据集（NORB/Caltech/CIFAR）→ 现实物体多变 → 必须更大数据 → ImageNet 15M/22k。
- 动机论证：任务复杂到无法靠数据全指定 → 需要先验 → CNN 的局部性/平稳性先验正好。
- 可行性论证：CNN 之前” prohibitively expensive” → 现代 GPU + 优化卷积使其可行。
- 贡献清单：结尾 “The specific contributions of this paper are as follows:” 引出 5 条（最大模型、开源 GPU 实现、新结构特征、抗过拟合、深度重要）。
- 诚实收尾：“network’ s size is limited mainly by GPU memory and training time … All of our experiments suggest results can be improved simply by waiting for faster GPUs and bigger datasets.”

1.4 相关工作组织

AlexNet 没有独立的 **Related Work** 章节——相关工作被打散进引言与每个技术小节的”我们不是第一个”段落（如 3.1 引 Jarrett et al. 并区分他们观察的是防过拟合、我们观察的是提速）。这是 2012 年会议论文的常见做法，与 Kaplan/NSA 的独立 Related Work 形成对照。

1.5 方法/实验/结果/讨论分工

- 方法=贡献清单：3.1–3.4 每个 trick 一节，每节末尾必跟一句该 trick 带来的误差下降（见 1.6）。
- 实验：第 5 节只写”怎么训”（超参），不写结果；结果集中到第 6 节。
- 结果：用对照表（Table 1/2）+ 一个跨数据集（Fall2009）+ 定性评估。
- 讨论：两段，强调”深度真的重要”（删任一卷积层 -2%）与”没用无监督预训练但预期有用”。

1.6 可迁移论证范式（本篇提炼 9 条）

1. 工程细节即科学贡献：ReLU、双 GPU 分裂、LRN、重叠池化、dropout、PCA 颜色扰动——全部包装成 novel feature，每条都有名字。
2. 每个 trick 配一个数值化消融（原文逐字）：
 - 双 GPU 分裂：“reduces top-1/top-5 by 1.7% and 1.2%”；
 - LRN：“reduces by 1.4% and 1.2%”；CIFAR-10 上 13%→11%；
 - 重叠池化（s=2,z=3 vs s=z=2）：“reduces by 0.4% and 0.3%”；
 - PCA 颜色增强：“reduces top-1 by over 1%”；
 - dropout：“roughly doubles the number of iterations to converge”（成本也照写）。
3. 公平性自曝：脚注 2 主动承认 one-GPU 对比”is biased in favor of the one-GPU net, since it is bigger”——主动披露对自己不利的偏倚，换取审稿信任。

4. 以消融证明”深度不可少”：“removing any convolutional layer (each $\leq 1\%$ of params) resulted in inferior performance”，讨论里再量化为”中间层删除 $\approx -2\%$ top-1”。
5. 误差率对照表双列制：Table 1/2 同时给 top-1 与 top-5；他人结果用斜体，自己用正体；跨数据集分表（2010 / 2012 / Fall2009）。
6. 定性图补定量之不足：Fig3 展示学到的卷积核（GPU1 颜色无关 vs GPU2 颜色相关，且与初始化无关）；Fig4 用 4096 维特征做最近邻检索，证明”高层特征是语义的，不是像素的”。
7. 训练细节完整到可复现：batch 128、momentum 0.9、weight decay 0.0005、权重初始化高斯 std=0.01、ReLU 偏置=1、LR 0.01 手动除以 10 三次、~90 epochs、2×GTX580 跑 5–6 天。
8. 反直觉发现写成卖点：“weight decay here is **not merely a regularizer**: it reduces the training error”。
9. 测试期集成零额外训练成本：10-crop（四角+中心+水平翻转）平均，训练时 CPU 增广/GPU 训练并行=“computationally free”。

1.7 图表清单（逐张，含坐标轴与自治性）

图/表	传达什么	坐标轴/基线/置信	图注自治度
Fig 1	ReLU vs tanh 收敛速度	折线图，纵轴 training error rate，横轴 Epochs；实线 ReLU/虚线 tanh；图注明写”学习率各自独立调到最快、无正则化”	高：图注自带实验设置与适用边界（“effect varies with architecture”）
Fig 2	整体架构	三维等距示意图，标注各层神经元数 253440–186624–64896–64896–43264–4096–4096–1000；两 GPU 分工	高：图注解两 GPU 通信发生在哪些层
Fig 3	学到的滤波器	96 个 $11 \times 11 \times 3$ 卷积核可视化；上 48 GPU1 / 下 48 GPU2	高：直接对应 § 6.1 的 specialization 观察
Fig 4	定性评估	左：8 图+top-5 预测；右：5 查询图+6 个最近邻训练图	高：说明相似度度量（4096 维欧氏距离）
Table 1	ILSVRC-2010 测试集对比	三行：Sparse coding 47.1/28.2、SIFT+FVs 45.7/25.7、CNN 37.5/17.0；斜体他人最佳	高：图注说明斜体含义
Table 2	ILSVRC-2012 验证+测试	列：Top-1(val)/Top-5(val)/Top-5(test)；1CNN/ 5CNNs/1CNN/7CNNs	高：*号预训练有脚注解

注意：AlexNet 的表格是朴素双栏小表，不是现代 booktabs 三线表。它靠”斜体=他人、正体=自己、数字列对齐”传达对比。这与 NSA 的三线表形成时代对照。

1.8 数据验证方法怎么写

- 划分: ILSVRC = ~120 万训练 / 5 万验证 / 15 万测试; 明说” ILSVRC-2010 是唯一有测试标签的版本, 故主要实验在 2010 上做”。
- 指标定义: top-5 error 当场定义 (正确标签不在预测前五的比例)。
- 计算预算: 2×GTX580 3GB、5–6 天、90 epochs。
- 复现配置: 见 1.6 第 7 条, 全部写明。
- 对照: 以同期 SOTA (sparse coding 集成、Fisher Vector) 为基线, 而非自比。

1.9 排版规范

双栏 NeurIPS proceedings; 章节阿拉伯数字 (1–7); 参考文献编号制 [n]、按出现顺序; 公式行内 (如 LRN 公式、SGD 更新式); 脚注用当页数字 (脚注 1 给代码链接、脚注 2 披露偏倚、脚注 3 指向参数文件)。

二、Kaplan 2020 《Scaling Laws for Neural Language Models》

2.1 结构骨架与篇幅配比

全文 30 页、单栏 arXiv、正文前显式印出 Contents (目录)。章节实测:

节	标题	页	特征
1	Introduction (1.1 Summary=8 条结论 bullet; 1.2 Summary of Scaling Laws=公式; 1.3 Notation)	p1–6	先给全部结论, 正文再证明
2	Background and Methods (2.1 参数量/算力; 2.2 训练过程; 2.3 数据集)	p6–7	
3	Empirical Results and Basic Power Laws	p7–10	形状无关、N 标度、LSTM 对比、跨分布泛化、D/C
4	Infinite Data Limit & Overfitting	p10–12	L(N,D) 方程+三条构造原理
5	Scaling with Model Size & Training Time	p12–14	Bcrit 修正、L(N,Smin)、早停下界
6	Optimal Allocation of Compute Budget	p14–17	理论推导 vs 实证对照; 6.3 自己找矛盾
7	Related Work	p18	独立一节
8	Discussion	p18–19	ideal gas law 类比收尾

节	标题	页	特征
A-D	附录: A 幂律汇总 / B 算力 前沿推导 / C Caveats (6 条) / D 补充图	p20-30	专门的”局限”附录

配比观察：方法与实证（2-5）约占正文 60%，但引言（含 1.1/1.2）本身就把全部定量结论讲完了。附录（A-D）占 10 页、约 1/3 篇幅，承载全部汇总表与补充实验——主文”干净”、附录”扎实”。

2.2 摘要写法

单段约 150 词，核心句：“The loss scales as a **power-law** with model size, dataset size, and compute ... with some trends spanning **more than seven orders of magnitude** ... architectural details ... minimal effects ... **Larger models are significantly more sample-efficient** ... optimally compute-efficient training involves training very large models on a relatively modest amount of data and stopping significantly before convergence.”

套路：一句话范式（power-law）+ 一句话量程（>7 数量级）+ 一句话反直觉结论（大模型更省、不必训到收敛）。

2.3 引言论证套路（1.1 是范本中的范本）

1.1 Summary 用 8 条 **bullet** 先把 headline 结论全抛出来，**每条结尾括号标注出处小节**（如 “(Section 3)”），形成”结论地图”：- Performance depends strongly on scale, weakly on model shape; - Smooth power laws (>6 数量级、上端无偏离迹象)；- Universality of overfitting ($N^{0.74}/D$ 决定罚分)；- Universality of training (早期曲线外推预测长训)；- Transfer improves with test performance (常数 offset)；- Sample efficiency (大模型更省样本)；- Convergence is inefficient (应早停)；- Optimal batch size ($\approx 1-2M$ tokens)。

1.2 立刻给出全部闭式方程 (1.1) – (1.8)，1.3 集中定义符号 (L,N,C,D,Bcrit,Cmin,Smin, αX)。

2.4 相关工作组织

第 7 节独立成节，按”思想源头”聚类：幂律的多种来源、早期 dataset-size 幂律、与 [HNA+17] 的**显式分歧**（对方是超线性、本方是次线性 $D \propto N^{0.74}$ ）、EfficientNet 对比、over-parameterized generalization (jamming transition, 本方未观察到)。**敢点名分歧**。

2.5 方法/实验/结果/讨论/局限分工

- 方法=工程记账：Table 1 逐层算参数与 FLOPs；明确”excluding embeddings 才得到 clean trend”。
- 结果=图+拟合：每张图都是”散点+幂律拟合线”。
- 讨论=类比与展望：ideal gas law / “more is different”。
- 局限=C 节专设：6 条 Caveats 全部 bullet 化。

2.6 可迁移论证范式（本篇提炼 10 条）

1. 控制变量 + 幂律拟合 + 趋势外推：固定 N 变 shape (Fig5) , 固定 shape 变 N; $L(N)=(N_c/N)^{\alpha}$ 。
2. 以”量程”为核心卖点：>7 数量级、>6 数量级反复出现，用跨度增强可信度。
3. 结论前置（结论地图）：1.1 八条 bullet + 括号指节，正文是”证明地图”。
4. 参数表驱动可复现：Table 1 逐层参数/FLOPs; 附录 A 的 Table 4/5/6 把所有指数与标度常数 ($\alpha_N=0.076$, $\alpha_D=0.095$, $\alpha_C=0.057$, $\alpha_{min}=0.050$, $\alpha_B=0.21$, $\alpha_S=0.76$; $N_c=8.8e13$ 等) **集中成查表**。
5. 理论→实证双向对账：从 $L(N, S_{min})$ 解析推出 $\alpha_{minC} \approx 0.054$ (式 6.4) , 再与实测 ≈ 0.050 对照 (“excellent agreement to within a few percent”) 。
6. 反常识结论放大： “Big models may be more important than big data.” ; compute-efficient 训练只需在”收敛损失上方 $\sim 10\%$ “ ($\alpha_N/\alpha_S \approx 0.1$) 处停; 数据次线性增长 $D \propto N^{0.74}$ 。
7. 主动找自己的矛盾：6.3 指出 $L(C_{min})$ 与 $L(D)$ 在 $C \sim 10^4$ PF-days、 $N \sim 10^{12}$ 、 $L^* \sim 1.7$ nats 处必然相交=定律将失效，并明说”数值高度不确定，量级上下浮动一个数量级”。
8. 专设 Caveats: ① 无理论; ② Bcrit 外推无信心; ③ 小数据区拟合差 (epoch 仅 40 step) ; ④ 算力估计忽略 nctx 项; ⑤ 可能漏调初始化/动量; ⑥ 学习率对目标损失敏感。
9. 符号与定义纪律：1.3 集中定义; 强调 N 为” non-embedding parameters” , 并用 Fig6 左右对比证明”含 embedding 时趋势被污染” —— **把度量定义本身做成一张方法学图**。
10. 诚实的拟合质量自评： “the fits are imperfect ... quite compelling given the simplicity of Equation (5.6)” ; 明确 1 层网络在拟合中被排除 (Fig13 的” lump”) 。

2.7 图表清单（约 21 图 / 6 表，挑核心）

图/表	传达什么	坐标轴/基线
Fig 1 (hero)	损失随 算力/数据/参数 三面板下降	log-log; 色标=参数数
Fig 4 左	$L(N,D)$ 随数据与模型	多曲线，对应式(1.5)
Fig 4 右	学习曲线统一	以 S_{min} 归一后各模型叠成一条
Fig 5	形状不敏感	固定 N, 变 dff/dmodel、head dim、aspect ratio, loss 仅变几个百分点
Fig 6	方法学对比: 含/不含 embedding	左乱/右收敛成一条 —— 证明度量选择的重要性
Fig 7	Transformer vs LSTM	随参数; LSTM 在长上下文后段掉队
Fig 9	过拟合与 $N^{0.74}/D$ 归一塌缩	多 D 曲线按比例叠合
Fig 13	$L(C_{min})$ 拟合	标注” lump=1 层→2 层过渡，已剔除”
Fig 15	矛盾交点	$L(C_{min})$ 与 $L(D(C_{min}))$ 相交=外推失效点

图/表	传达什么	坐标轴/基线
Table 1	逐层参数/FLOPs	工程记账
Table 2/3	L(N,D)、L(N,S) 拟合参数	指数+标度常数
Table 4/5/6	全部幂律汇总、拟合值、最优分配	查表用

图注自治：每张图注自带”横轴是什么、色标是什么、对应的方程是哪一个”，几乎可脱离正文读懂。

2.8 数据验证方法怎么写

- 数据：WebText2（96GB、2.29e10 tokens、预留 6.6e8 测试 token）；另在 Books/CC/Wikipedia/Internet Books 上测泛化。
- 训练：Adam、固定 2.5e5 步、batch=512×1024；>1B 参数用 Adafactor；3000 步线性 warmup + cosine 归零；10% dropout；按 test loss 早停。
- 样本量跨度：N=768→1.5e9、D=22M→23B。
- 随机种子噪声：“~0.02”，并据此推出防过拟合阈值 $D \geq 5e3 \cdot N^{0.74}$ （式 4.4）。
- 复现口径： $C \approx 6NBS$ （前向 2×+反向 2×+…），1 PF-day=8.64e19 FLOP 当场定义。

2.9 排版规范

单栏 arXiv；正文前印目录；章节 1–8 两级（1.1/1.2…）；公式统一编号 (1.1)–(6.8) 与附录 (A.x)/(B.x)；引用用作者缩写+年份数字键（[VSP+17]、[RWC+19]、[MKAT18]）；附录分 A/B/C/D 四块，C 节是”局限”的标准位置。

三、NSA (DeepSeek 2502.11089, 2025)

3.1 结构骨架与篇幅配比

24 页、单栏 LaTeX（NeurIPS 风格，章节编号 “1. 2. 3.”）。章节实测：

节	标题	页	特征
—	Abstract	p1	问题→gap→贡献→结果
1	Introduction	p1–3	64k 解码 attention 占 70–80% 延迟；两大挑战；Figure 1 双轴
2	Rethinking Sparse Attention Methods	p3–5	2.1 The Illusion of Efficient Inference; 2.2 The Myth of Trainable Sparsity; 2.3 Native Sparsity as Imperative
3	Methodology	p5–9	

节	标题	页	特征
			3.1 背景(attention+算术强度); 3.2 总框架(三支门控); 3.3 算法(压缩/选择/滑动); 3.4 Kernel 设计
4	Experiments	p9-13	4.1 预训练配置; 4.2 基线; 4.3 性能(通用/长文/CoT)
5	Efficiency Analysis	p13-14	5.1 训练速度; 5.2 解码速度
6	Discussion	p14-15	6.1 替代策略失败史; 6.2 注意力可视化
7	Related Works	p16	固定稀疏/动态剪枝/查询感知 三类
8	Conclusion	p16	
—	References / Appendix A	p17-24	附录 A=AIME 样例输出

配比观察：方法+系统（3）与实验+效率（4+5）几乎 1:1；第 2 节”批判前人”独立成节，把设计空间的推导前置——这是 NSA 最值得抄的结构动作。

3.2 摘要写法

问题（长上下文、attention 计算贵）→ 已有方向（sparse attention）→ **gap 双点**（理论加速≠实际延迟；多只做推理、缺训练支持）→ **两点创新**（① 算术强度平衡的硬件对齐；② 端到端可训）→ 结果（不劣于/超过 Full Attention；64k decode/forward/backward 全面加速）。

3.3 引言与”批判式立论”套路

- **第 2 节命名式批判：**“The Illusion of Efficient Inference”（幻象）与”The Myth of Trainable Sparsity”（神话）。每个名字下拆两条具体罪状：
 - 幻象：① Phase-Restricted Sparsity（H2O 只在 decode 稀疏、prefill 仍全量；MInference 相反，总有一阶段不省）；② 与 MQA/GQA 不兼容（Quest 每头独立选 KV，GQA 下取并集→内存访问不省）。
 - 神话：① 事后稀疏偏离预训练轨迹（top-20% 只覆盖 70% 注意力）；② 不可训练组件（k-means/SimHash 切断梯度）；③ 反向传播低效（token 级选择破坏连续内存访问）。
- **把约束翻译成设计公理：**要硬件对齐→blockwise 连续内存+Tensor Core；要端到端可训→选择必须可微。

3.4 方法/实验/效率/讨论分工

- **方法=三支：**compression（块聚合 MLP，全局粗）+ selection（复用压缩分支的 attention score 当块重要性，top-n，可微、零额外开销）+ sliding window（局部）；各自独立 K/V 防 shortcut，gate 融合。

- 效率单独成节（第 5 节）：性能归第 4 节，延迟归第 5 节，避免混淆。
- 讨论=失败史：6.1 把试过的 key-clustering、aux-loss 选择、heuristic 选择、cold-start 全部列出并画 loss 曲线（Fig7），证明“为什么不是那些”。

3.5 可迁移论证范式（本篇提炼 9 条）

1. 硬件对齐约束 → 架构设计：先讲算术强度/roofline（prefill/fwd 是 compute-bound、decode 是 memory-bound），让算法服从各阶段瓶颈——blockwise 连续访存、GQA 组内共享 KV 块。
2. 端到端可训练作为核心卖点：批判 k-means/SimHash 不可微 → NSA 用压缩分支的中间 attention score 直接导出选择重要性（式 8-10），**复用计算、可微、零额外参数**。
3. “幻象/神话”式命名批判：用第 2 节两个标题把前人方法钉死，逼出自己的设计空间。
4. 三分支模块化 + 门控：全局粗 / 局部细 / 邻域近，可单独消融；独立 K/V 防梯度串扰。
5. 三层基线 + 统一预算：Full Attention（能力上限）/ Exact-Top（oracle 上界）/ H2O·InFLLM·Quest（SOTA）；所有稀疏方法统一激活 token 预算（2560）以保证公平；**短序列上 sparse 基线≈Full，就不比**（诚实说明在哪比、为什么）。
6. 质量×效率双轴报告：性能表（Table1 通用 / Table2 LongBench / Table3 AIME）+ 速度图（Fig6 fwd 9.0×/bwd 6.0×）+ 理论内存访问表（Table4 decode 11.6×，线性于访存量）。
7. 直觉可视化反推设计：Fig8 注意力热力图呈 blockwise 聚簇 → 论证 blockwise 选择合理；Fig7 三策略 loss 对比。
8. **Figure 1 一图双结论**：左”更准”、右”更快”，hero 图直接背书”既省又好”。
9. 复现配置全写（见 3.8）。

3.6 图表清单（逐张）

图/表	传达什么	坐标轴/基线
Fig 1 (hero)	左：General/LongBench/Reasoning Full vs NSA；右：Decode/Forward/Backward 加速 11.6×/9.0×/6.0×	分组柱状+加速比
Fig 2	三分支架构+三类注意力掩码	绿=需算、白=跳过；query/activated/evicted/ignored 图例
Fig 3	Kernel 设计	按 GQA 组载 Q（Grid Loop）、inner loop 拉 KV 块、SRAM(绿)/HBM(蓝)
Fig 4	预训练 loss 曲线	step 0-60k, Full vs NSA 双线，NSA 更低
Fig 5	大海捞针 64k	深度×位置热力图，全绿（100% 检索）
Fig 6	Fwd/Bwd 时延随长度	8k-64k 柱状，标注 2.1×…9.0×/6.3×
Fig 7	替代策略 loss 对比	

图/表	传达什么	坐标轴/基线
		Full / aux-loss / heuristic / NSA 四线
Fig 8	注意力图	blockwise 聚簇可视化
Table 1	通用基准 9 指标+Avg	MMLU…HumanEval; 三线表, NSA 多数加粗
Table 2	LongBench 11 子集+Avg	H2O/InfLLM/Quest/Exact-Top/Full/NSA 六行
Table 3	AIME 8k/16k	Full-R 0.046/0.092; NSA-R 0.121/0.146
Table 4	解码访存 token 数与预期加速	8192…65536; Expected Speedup 4×…11.6×

3.7 数据验证方法怎么写

- 底座：GQA+MoE，总 27B/激活 3B，30 层，hidden 2560，GQA 4 组 64 头，dq=dk=192、dv=128；DeepSeekMoE 72 路由+2 共享专家 top-6，首层换 SwiGLU MLP。
- 稀疏超参：压缩块 l=32、stride d=16、选择块 l’ =64、选块数 n=16（固定激活 1 初始块+2 局部块）、滑窗 w=512。
- 训练：270B token、8k 长度，再用 YaRN 续训+SFT 到 32k；双方都训到 full convergence 以保证公平。
- 公平性纪律：稀疏基线统一激活 2560 token（StreamLLM 口径：前 128+512 局部）；速度对比双方都用 Triton（NSA kernel vs FlashAttention-2）；AIME 每问采样 16 条、temp 0.7、top-p 0.95 取平均。
- 硬件：8×A100。

3.8 排版规范

单栏 LaTeX；章节编号式”1. 2. 3.”；booktabs 三线表（顶/表头下/底三条横线，正是本卷 P0–P12 应对齐的样式）；作者一年制引用（“DeepSeek-AI, 2025”）；公式行号 (1)–(12)；无独立 Limitations 节（局限散在 6.1 失败史与各处”we defer…”）；附录 A 放可复核的 AIME 完整推理样例。

第二部分 · 五轮思维演练（强制留痕）

每轮固定写：方法 / 输入 / 产出 / 对后续改写的具体影响。

演练① 逻辑推演：还原每篇论证链

- 方法：把每篇拆成”前提→机制→证据→结论”四元组，逐环问”上一环缺了会怎样”。
- 输入：三篇 PDF 正文+图表。
- 产出：
 - **AlexNet 链**：小数据不够（前提）→ 大数据+大模型需要可训练结构（CNN 先验，机制）→ 但大模型过拟合/太慢（矛盾）→ ReLU 提速、dropout/增广防过拟合、GPU 实现落地（手段）→ 对照表证明碾压 SOTA（证据）→ 深度不可删（升华）。
 - **Kaplan 链**：loss 随尺度变（前提）→ 固定变量测单变量幂律（机制）→ 幂律在 >6 数量级不拐弯（证据）→ 合并成 $L(N,D)$ 与 $L(N,S)$ （综合方程）→ 求导得最优分配（推论）→ 自指相交=外推边界（收口）。
 - **NSA 链**：长上下文 attention 贵（前提）→ 前人稀疏理论快但实际不快、且不能训（批判）→ 硬件对齐+可微选择=三支（机制）→ 同预算对照证明”更准且更快”（证据）→ blockwise 聚簇可视化背书（机制自治）。
- 对后续改写的影响：UDOS 每篇必须能一句话写出”前提→矛盾→机制→证据”闭环；若某篇缺”矛盾”一环，就是 P0 级结构缺陷。Kaplan 的”自指相交”示范了如何主动给结论划边界。

演练② 逆向思维：从结论倒推它必须证明什么、最怕什么反例

- 方法：假设结论为真，反推”审稿人要不要掉它，会拿什么数据攻击”。
- 输入：三篇 headline 结论。
- 产出：
 - **AlexNet 结论**”深度重要”→ 必须证明”删层掉点”且”不是数据/初始化偶然”。最怕的反例：删某层不掉点（若真，则深度叙事崩塌）。作者的防御=Fig3 指出 specialization 与初始化无关、讨论里量化”中间层删 $\approx -2\%$ ”。→ **教训：凡主张”X 重要”，必须给”移除 X 的代价”。**
 - **Kaplan 结论**”幂律可外推”→ 必须证明多数量级不弯。最怕的反例：上端拐弯/换分布就塌。作者的防御=Fig8 跨分布平行平移、6.3 自曝相交点、C 节 6 条 Caveats。→ **教训：外推型论文的可信度来自”主动报告失效点”，不是”声称永远成立”。**
 - **NSA 结论**”稀疏不损能力还更快”→ 必须证明同稀疏预算下不劣于 Full、且 kernel 真快。最怕的反例：① 偷加更多激活 token；② 只比短序列；③ 速度靠不公平后端。作者防御=统一 2560 token 预算、双方都用 Triton、把 Exact-Top 当 oracle 上界。→ **教训：“更快”必须同硬件同后端同预算；“不损能力”必须有 oracle 上界作天花板。**
- 对后续改写的影响：UDOS 每篇结论句后，必须补一行”最可能的反例 + 本文明怎么防”（P0/P0b/P9 这类 scale/饱和律论文尤其需要 Kaplan 式失效点）。

演练 ③ 发散思考：范式 → 本卷 15 篇逐篇映射表

- 方法：把三篇提炼的范式，逐条映射到 UDOS 的 P0c / P0 / P0b / P1-P12。
- 输入：本卷目录（P0c 元认知、P0 空间结构、P0b 结构加规模 ScalingLaws；P1 分层混合拓扑百万级外推；P2 BFT-lite 停止决策；P3 熔断 RCT；P4 子模主动采集；P5 共形预测；P6 可辨识性；P7 具身接管率；P8 高斯泼溅 Sim2Real；P9 质量饱和律；P10 TransferBundle 交接损失；P11 任务市场拜占庭罚没；P12 证据分级可复现）。
- 产出（逐篇映射）：

篇目	最该抄的范式	具体动作
P0c 元认知/边界校准	Kaplan ①结论地图 + ⑧Caveats	引言先抛 N 条”自我认知边界”结论 bullet（带节号）；专设”校准失效区”小节，明说哪些情形边界估计会崩
P0 空间结构即智能	AlexNet ①工程即贡献 + ⑤消融	把”空间约束”每个设计决策当贡献，逐个给移除代价；用 Fig6 式”含/不含某结构”对照
P0b 结构+规模 ScalingLaws	Kaplan 全套（控制变量+幂律+指数表+Caveats）	直接抄：N/D/C 三因子幂律、附录指数汇总表、6 条局限；这是本卷与 Kaplan 同构度最高的一篇
P1 分层混合拓扑百万级外推	Kaplan ①控制变量外推 + ⑤理论↔实证对账	固定拓扑变规模拟合协调复杂度幂律；先推解析式再用实测对照
P2 BFT-lite 停止决策	NSA ③命名批判 + AlexNet ③公平自曝	先命名现有停止规则的”幻象”；主动披露本方协议在何种网络分区下偏置
P3 熔断 RCT	AlexNet ②每 trick 数值消融 + ⑥定性图	每个熔断策略给收口率增量（±x%）；配故障注入前后对比可视化
P4 子模主动采集	AlexNet ②消融 + NSA ⑤三层基线	对比随机/启发式/子模三种采样，统一预算；给采样率-收益曲线
P5 共形预测扇形	Kaplan ⑦主动找失效 + ②量程卖点	扇形随不确定度量程展开；明说分布漂移时覆盖概率何时失效
P6 可观测性/可辨识性	Kaplan ⑨符号定义纪律 + ⑥理论对账	先集中定义隐藏/观测变量与 Fisher 信息；解析式可辨识条件 vs 数值实验对照
P7 具身接管率	NSA ⑥质量×效率双轴 + ⑨复现配置	单侧”语义层/动作先验”两路消融；接管率表+复现参数全写
P8 高斯泼溅 Sim2Real	NSA ④模块化分支 + ⑦直觉可视化	多视角泼溅各组件可消融；渲染-实拍裕量热力图
P9 质量饱和律/同质化失效	Kaplan ⑦自指矛盾 + ⑧Caveats	画出”扩招收益递减/饱和交点”，明说该交点对指数误差敏感；局限单列
P10 TransferBundle 交接损失	AlexNet ④删层代价 + NSA ⑦机制可视化	移除交接信道测信息损失；交接前后特征相似度热力图

篇目	最该抄的范式	具体动作
P11 任务市场拜占庭罚没	NSA ③命名批判 + ⑤同预算基线	命名”无罚没”市场的失效模式；诚实节点/拜占庭比例统一对照
P12 证据分级可复现	Kaplan ④参数表 + NSA ⑨复现配置 + AlexNet ⑤对照表	把证据分级做成查表；系统配置、种子、算力全部写明

- 对后续改写的影响：此表即阶段 B/C 改稿时的”范式分配清单”——每篇改稿先查表，确认已落实对应范式再进入语言润色。

演练 ④ 批判思考：每篇方法局限、可质疑处、我们误用风险

- 方法：站在审稿人位置，逐条挑硬伤。
- 输入：三篇全文 + 图表。
- 产出：
 - AlexNet 局限与误用风险：① 双 GPU 对比”biased in favor of one-GPU”（作者自曝脚注 2），即 1.7% 的提升可能被不公平比较夸大；② ReLU 提速结论只在 CIFAR-10 一个小网络上演示，外推到 ImageNet 是”叙事外推”；③ LRN 后来被证明用处不大（BN 取代）——历史上被淘汰的 trick 不应照抄为”必备组件”；④ 误用风险：UDOS 若把”某个工程小 trick 带来 $\pm 0.x\%$ “当核心贡献而无消融，会显得单薄。
 - Kaplan 局限与误用风险（其自身 Caveats 已列，但仍有残留）：① 幂律只有 $N \leq 1.5B$ 、 $D \leq 23B$ 的观测，外推到 GPT-4 级是激进外推（作者自承相交点 $C^* \sim 1e4$ PF-days 上下浮动一个数量级）；② 后来 Chinchilla 证明其”大模型更重要”在数据配比上有偏差——纯 loss 标度不等于下游任务最优；③ 拟合对”剔除 1 层网络、剔除最小数据集”等人为清洗敏感；④ 误用风险：UDOS 若把 Kaplan 的具体指数（0.076 等）当成跨领域常数搬运，是硬伤；指数必须自拟合，只能借方法不借数值。
 - NSA 局限与误用风险：① 没有独立 Limitations 节——27B/260B token 单点验证，未在 7B 以下或 100B 以上复现；② “NSA 超过 Full Attention”仅在自家 27B GQA+MoE 底座上成立，跨架构泛化未知；③ AIME 提升（+0.075/+0.054）基于 16 条采样、题量小（AIME 24 仅 30 题级），方差极大却未给误差棒；④ speedup 是 Triton 实现，换 CUDA 后端未必保持；⑤ 误用风险：UDOS 若照搬”稀疏/压缩无损能力”而不做同预算消融，会陷入 NSA 第 2 节自己批判的”幻象”。
- 对后续改写的影响：UDOS 15 篇每篇必须有显式局限节（哪怕学 NSA 也要比它更老实），且凡引用指数/加速比/分数，必须标注样本量、硬件、方差，禁止无误差棒的单点提升被写成结论。

演练 ⑤ 总结复盘：提炼统一的《UDOS 论文写作与排版规范 v2》

- 方法：把前四轮的可执行项合并成一条阶段 B/C 的硬标准。
- 输入：三篇 + 四轮演练结论。

· **产出规范**（这就是阶段 B/C 的执行标准）：

A. 结构 1. 摘要固定五拍：任务 → 头条数字 → 规模锚点 → 技术关键词 → 一句反直觉结论。 2. 引言结尾必须有” **N 条 specific contributions**” 清单，每条括号标注出处小节（Kaplan 式结论地图）。 3. 方法按” 作者自估重要性” 排序，最重要的决策放最前（AlexNet 3.1–3.4 排序惯例）。 4. **必须有显式局限/失效点小节**（学 Kaplan C 节；NSA 缺这节是反面教材）。

B. 论证 5. 主张” X 重要/有效”，必须给” 移除 X 的代价”（AlexNet 删层）或” 同预算对照”（NSA 统一 token 预算）。 6. 外推型结论必须给” 失效点/交点 + 数量级不确定性”（Kaplan 6.3）。 7. 理论推导与实测**双向对账**，一致要写” excellent agreement”，不一致要写原因。 8. 主动披露对自己不利的偏倚（AlexNet 脚注 2）。

C. 图表 9. 三张必配图：hero 双轴图（能力×效率，NSA Fig1）、机制可视化图（注意力/特征/热力图）、对照表（三线表，斜体=他人、加粗=自己最优）。 10. 图注自治：横轴、色标、对应方程、适用边界都写进图注，可脱离正文读懂。 11. 对照表用 booktabs 三线表（NSA 样式），不用朴素小表。

D. 数据与复现 12. 复现配置全写：底座规模/层数/维度/超参/数据量/硬件/优化器/学习率/种子/随机噪声量级。 13. 凡提升数值标注样本量、硬件、方差或误差棒；单点小样本结果不得写成定论。 14. 跨数据集/跨分布泛化要单独测（Kaplan Fig8 式平行平移）。

E. 排版 15. 单栏 LaTeX；两级章节编号；公式统一编号；参考文献编号制或作者年制二选一全卷统一；附录集中放” 汇总表 + 补充实验 + 局限”。

· **对后续改写的影**响：本规范 15 条 = 阶段 B 改稿 checklist、阶段 C 定稿验收标准；任何一篇不满足第 4/6/9/13 条即打回。

第三部分 · 交付说明

- 本报告全部内容来自对三篇 PDF 的 PyMuPDF 全文抽取 + 页面渲染读图，未凭记忆。
- 三篇提炼的可迁移范式条数：**AlexNet 9 条 / Kaplan 10 条 / NSA 9 条**。
- 五轮演练各自一句话结论：①逻辑推演——UDOS 每篇必须有” 前提→矛盾→机制→证据” 闭环，缺矛盾环即 P0；②逆向思维——凡主张” X 重要/可外推”，必须自报” 最可能的反例与本文明如何防”；③发散思考——已产出 15 篇逐篇范式映射表（P0c/P0/P0b/P1–P12）；④批判思考——指数/加速比/分数必须带样本量与方差，UDOS 每篇都要有比 NSA 更老实的局限节；⑤总结复盘——已固化为 15 条《UDOS 写作与排版规范 v2》作为阶段 B/C 验收标准。
- 同步动作：三篇题录已按” 来源=用户附件 PDF 原件、核验日期 2026-09-20” 追加进《参考文献总库.md》（见该文件末尾新增块，仅追加、未改其他内容）。