




P5

小型动力学世界模型的共形预测可信度 与参数不确定性扇形

Conformal Prediction Credibility and Parametric Uncertainty
Fans for a Small Kinematic World Model

TwinsEarth · 智能体宇宙论文系列



小型动力学世界模型的共形预测可信度与 参数不确定性扇形

UDOS 推演引擎 v7.5.0 · 房文新 · 2026-09-20

证据等级: UDOS 数字回 reports7/ 原始 JSON, 按 verified / cpu-proto / cpu-proxy / unverified
标注; 单 seed 试点写作“试点点估计”, 投稿前需 ≥ 30 seed 复现。

Conformal Prediction Credibility and Parametric Uncertainty Fans for a Small Kinematic World Model

中文摘要

小型可微动力学世界模型在边缘端做长程预测时，最容易被高估的是“预测有多可信”。本文报告一个约 96.8 万参数的残差循环世界模型（UDOS v7.0.3，单 CPU、固定 seed），在严格轨迹级四分（训练/验证/测试/校准，独立 seed、无相邻窗口泄漏）下，将**校准概率与熵置信度严格解耦**：按显著性水平 α （0.2/0.1/0.05）单独取分位数的 split conformal 区间，在 held-out 测试集 80/90/95 三水平上，oracle 边际覆盖为 0.784/0.898/0.958，blind 为 0.776/0.900/0.956，全部落入 ± 0.05 容差；盲路径整体 MSE 0.0104（v7.0.1 基线 0.0459）。参数不确定性以蒙特卡洛自助扇形给出 p10/p50/p90，经两步膨胀后经验覆盖 0.859（名义 0.80，偏保守）。21 项门禁全过。本文不主张共形方法创新，贡献在于：给出一个**可复现、证据分级、负结果不遮掩**的小型动力学世界模型可信度工程基准，并明确区分“偶然不确定性（共形区间）”“与”参数不确定性（蒙特卡洛扇形）“两类带宽。

关键词：共形预测；世界模型；不确定性量化；时间序列预测；可复现性；边缘端 AI

Abstract

Small differentiable kinematic world models deployed on edge devices most often overclaim how credible their long-horizon predictions are. This paper reports a residual recurrent world model of about 0.97M parameters (UDOS v7.0.3, single CPU, fixed seeds), under a strict trajectory-level four-way split (train/val/test/calibration with independent seeds and no adjacent-window leakage), in which **calibrated probability is strictly decoupled from entropy confidence**. Split-conformal intervals whose nonconformity score is quantile-taken per α (0.2/0.1/0.05) achieve, on held-out test, oracle marginal coverage of 0.784/0.898/0.958 and blind coverage of 0.776/0.900/0.956 at the 80/90/95 nominal levels—all within the ± 0.05 tolerance. Blind overall MSE is 0.0104 versus a v7.0.1 baseline of 0.0459. Parametric uncertainty is exposed as a Monte-Carlo bootstrap fan (p10/p50/p90) that, after two-stage inflation, reaches empirical coverage 0.859 at nominal 0.80 (conservative). All 21 gates pass. We do not claim a conformal-method novelty; the contribution is a reproducible, evidence-graded, no-hidden-failure engineering benchmark for small kinematic world models, and an explicit separation between aleatoric interval width and parametric fan width.

Keywords: conformal prediction; world models; uncertainty quantification; time-series forecasting; reproducibility; edge AI

结构化摘要（背景/问题 → 方法 → 证据/结果 → 贡献）

- **背景与问题：**小型可微动力学世界模型在边缘端做长程预测时，最容易被高估的是”预测有多可信”。神经网络前向输出的熵、能量或 logit 温度在未校准时只是相对量纲的排序信号，不能被当作”我有 90% 把握”来驱动下游安全决策；在边缘端又必须小、快、可解释，不能靠堆参数与 GPU 集成换稳健。
- **方法：**在一个 967,796 参数的残差循环世界模型（UDOS v7.0.3, 单 CPU、固定 seed）上，采用严格轨迹级独立 seed 四分（train/val/test/calib, 无相邻窗口泄漏），将校准概率与熵置信度严格解耦：按显著性水平 α (0.2/0.1/0.05) 单独取分位数的 split conformal 区间刻画偶然不确定性，校准集参数残差经验自助 (M=64) 加两步膨胀的蒙特卡洛扇形刻画参数不确定性，两类带宽分对象交付、分容差验收。
- **证据与结果：**held-out 测试集六组（oracle/blind $\times$ 80/90/95）边际覆盖落在 0.7758–0.9577 区间，全部进入 ± 0.05 容差；盲路径整体 MSE 0.0104（v7.0.1 基线 0.0459）；参数扇形经两步膨胀后经验覆盖 0.8592（名义 0.80，偏保守）；21 项自动门禁全过。负结果不遮掩：spring 类 blind MSE 0.0186 为四类最高、blind 80% 覆盖 0.7758 贴近容差下沿。
- **贡献：**本文不主张共形方法创新，贡献在于——(i) 把”偶然不确定性（共形区间）”与”参数不确定性（蒙特卡洛扇形）”作为两个互不冒充的对象分别交付与验收；(ii) 一套可复现、证据分级（verified/cpu-proto/unverified 三级）、负结果不遮掩的小型动力学世界模型可信度工程基准。全部数字为 CPU 固定 seed 单次试点估计，未做 ≥ 30 seed 重复，不报告 p 值/CI；外部产业数字标 unverified。

1 引言

把”预测区间”当成”概率”，是学习型动力学系统在工程化阶段最常见的失败模式之一。一个神经网络前向输出的熵、能量或 logit 温度，在未校准时只是相对量纲的排序信号，不能被当作”我有 90% 把握”来驱动下游的安全决策。当世界模型被用于机器人、仿真推演或控制回路时，这种把不确定性误读为概率的做法会直接转化为过度自信的规划——而在边缘端，模型又必须小、快、可解释，不能靠堆参数和 GPU 上的大规模集成来换稳健。

本文面对的就是这样一个小模型场景：UDOS 推演引擎 v7.5.0 中的核心预测内核 `WorldModelCore` 仅 967,796 个可训练参数（隐藏维 256、2 层 GRU、场景维 32），在两颗 CPU 线程上完成训练与推理。我们关心的不是”它把 MSE 压到多低”，而是：在不知道场景隐藏物理参数（blind 路径）时，它给出的预测区间能否在真正的 held-out 数据上达到名义覆盖率？区间带宽是否随 α 单调、随滚动步合理增长？参数不确定性能否单独刻画，而不是和偶然不确定性混在一个熵值里？

这三个问题背后是一个更朴素的工程立场：可信度不是点预测准度的附属品，而是一个需要单独验收的一等指标。一个 MSE 很低但覆盖率飘忽的模型，和一个 MSE 稍高但区间可靠的模型，在控制回路里的价值完全不同——后者可以被下游安全地”打折使用”，前者则会在分布外样本上突然失效。本文的全部工程设计（独立校准集、分 α 取分位数、区间与扇形分别设容差、21 项自动门禁）都服务于这一立场。

需要先交代外部动机的证据等级。近年业界关于”通用世界模型””实时视频预测””具身基础模型”的进展快速，但相关数字（例如更大规模视频预测模型的参数、帧率、基准成绩）多为厂商或报道口径，未在本研究中独立核验（下文凡涉及此类外部数字，一律标注 unverified，仅作动机，不与本仓实测数字互证）。

我们刻意把研究范围收敛到一个真值已知的合成动力学世界：匀速、匀加速、简谐振动、一维弹性碰撞四类运动，三维方向、一维碰撞，状态为 6 维向量 $[px, py, pz, vx, vy, vz]$ 。真值已知既是软肋（外部效度受限于合成数据，见第 8 章），也是我们能把“覆盖率”“可辨识性”这类统计量算准、把负结果如实报告的前提。

本文的具体贡献如下：

1. **方法-工程解耦的可信度流水线**：以真实源码模块 `udos7/uncertainty.py` 中的 `ConformalCalibrator`（按 α 单独取分位数的有限样本修正 split conformal）与 `MonteCarloParamFan`（校准集参数残差经验自助 + 两步膨胀）为核心，把偶然不确定性（预测区间）与参数不确定性（参数扇形）分成两个独立对象，互不冒充。
2. **严格数据划分与门禁**：轨迹级独立 seed 四分（train/val/test/calib），校准集不参与梯度、不与 val/test 混；21 项自动门禁任何一项覆盖率越界即判 FAIL。
3. **诚实基准数字**：blind MSE 0.0104（v7.0.1 0.0459）；三水平六组覆盖率全部达标；参数扇形经验覆盖 0.859（偏保守，如实讨论）；并报告已知短板——spring 类 blind MSE 0.0186 为四类最高、blind 80% 覆盖 0.776 接近容差下沿。

边界声明：本文全部数字来自 CPU 固定 seed 的单次验证运行（`reports7/v7_verification.json`，证据等级 verified）。这是**试点点估计**；除特别说明外，未做 ≥ 30 seed 的多次重复，因此本文不报告 p 值、置信区间或显著性结论，相关位置保留 `[RESULT NEEDED]`。

2 相关工作

共形预测（conformal prediction）为黑箱预测提供有限样本、分布无关的边缘覆盖保证。其核心机制是：把校准集上的非一致性分数排序，取名义水平 $1 - \alpha$ 对应的分位数作为带宽，于是在“校准与测试样本可交换”的假设下，无需对数据分布作任何参数假设，即可给出约 $1 - \alpha$ 的有限样本边缘覆盖（Angelopoulos & Bates, 2021, arXiv:2107.07511）。这一保证的边界同样由该综述点明：边缘覆盖不等于对每个条件子群都成立的条件覆盖，且非交换、非平稳数据需要专门修正 [CITATION NEEDED: split conformal prediction 原始出处 Vovk 2005]。把它用到时间序列与自回归滚动上，需要处理两类非平凡问题：一是多步滚动的自回归误差累积，二是分布漂移下的覆盖衰减 [CITATION NEEDED: conformal time series; conformal prediction under distribution shift; envelope conformal]。世界模型/可微仿真器（differentiable simulator、neural ODE、latent dynamics）的不确定性量化则通常区分偶然不确定性（aleatoric，数据/过程噪声）与认知不确定性（epistemic，模型参数/结构未知）[CITATION NEEDED: epistemic vs aleatoric uncertainty; uncertainty in world models/neural forecasting]。

与本文最接近的工作有三条线。其一，**分类别/加权共形**（class-conditional / weighted conformal）应对协变量漂移 [CITATION NEEDED: class-conditional conformal; weighted conformal for covariate shift]；我们的 oracle 路径相当于把类别作为显式条件，blind 路径则不使用类别——这种“知道/不知道场景类别”的对照，正好量化了条件化对覆盖率与带宽的影响。其二，**蒙特卡洛 dropout / 深度集成**近似认知不确定性 [CITATION NEEDED: Monte Carlo dropout Gal Ghahramani; deep ensembles Lakshminarayanan]；我们不用 dropout，而用**校准集参数残差的经验自助**，因为我们的隐藏参数只有 4 个槽位（初速度幅值、加速度幅值、弹簧角频率、碰撞对速度），自助采样能显式保留槽位间相关性，且不需要多份训练好的模型。其三，**世界模型的可信度基准** [CITATION NEEDED: world model benchmark; calibrated uncertainty for learned dynamics]。

在时间序列共形这一支上，自回归滚动带来的非可交换性是核心难点：第 h 步的预测依赖前 $h-1$ 步的预测误差，误差沿轨迹累积，因此”逐步覆盖率”通常随 h 衰减，这也是我们同时报告边际与逐步两套带宽的原因。学术界已有 envelope conformal、conformalized quantile regression、自适应（ACI）等处理漂移的方法 [CITATION NEEDED: adaptive conformal prediction; conformalized quantile regression Romano]，本文暂未引入自适应机制，而是把”漂移下衰减”作为已知局限与未来工作，以保证当前协议简单、可复现。

我们的定位是**方法应用 + 工程基准**，不主张共形方法本身的创新。新颖性主要来自三点工程诚实：(i) 严格轨迹级四分与独立校准 seed；(ii) 区间覆盖率与参数扇形覆盖率分别验收、分别设容差；(iii) 把一个 0.97M 参数、单 CPU 可复跑的完整流水线连同源码、checkpoint、报告 JSON 一并开放。

需要特别区分的一组概念是：**共形区间刻画的是”给定点预测真值落在何处”的偶然不确定性**（无论参数对错，残差多大就兜多宽），而**参数扇形刻画的是”隐藏参数估计不准会让点预测摆动多大”的认知不确定性**。二者不能互相替代：一个模型可以点预测很准（偶然残差小、区间窄），但参数估计很偏（认知扇形宽）；反之亦然。本流水线把二者分别交付、分别验收，正是为了避免工程上常见的”用一个熵值同时回答这两个问题”。

3 问题定义与假设

3.1 记号与问题设定

状态向量 $s_t \in \mathbb{R}^6$ ，约定 $[p_x, p_y, p_z, v_x, v_y, v_z]$ （`contracts.py` 中 `STATE_DIM=6`）。给定观测窗 $X = (s_{t-W+1}, \dots, s_t)$ （窗长 $W=6$ ），世界模型输出 H 步滚动 $\hat{Y} = (\hat{s}_{t+1}, \dots, \hat{s}_{t+H})$ ， $H=4$ 。场景隐藏参数 $P \in \mathbb{R}^4$ ，槽序固定为 $(v0, accel_a, spring_omega, other_v2)$ （`contracts.py` 的 `SCENE_PARAM_NAMES`）。

- **oracle 路径**：前向时显式注入真值 P （`explicit=P`）。
- **blind 路径**：不提供 P ，由 `SceneEstimator` 从窗口估计 P 并回退（`scene.py`）。

对一条测试样本，点预测为 $\hat{Y}$ ，共形区间给出 $[L, U]$ （逐步带宽广播到 6 个状态维）。经验覆盖率定义为

$$\text{text}\{\text{cov}\} = \frac{\sum_{n,h,d} \mathbf{1}\{L_{n,h,d} \leq Y_{n,h,d} \leq U_{n,h,d}\}}{N \cdot H \cdot d},$$

另有逐步（per-step）与分模式口径。**边际带宽** q 是该 α 下非一致性分数的有限样本分位数。

需要说明”分模式”的含义：oracle 与 blind 各自用自己的校准集残差拟合自己的带宽，而不是共用一个带宽。这是因为两条路径的非一致性分布不同——oracle 知道类别，残差更集中；blind 估计参数，残差更分散。若共用带宽，要么 oracle 过宽、要么 blind 过窄。本实现为每条路径各建一个 `ConformalCalibrator` 实例，分别 `fit`，这也是表 2 有六行而非三行的原因。

3.2 可证伪假设

- **H1（边际覆盖达标）**：在容差 ± 0.05 内，80/90/95 三个名义水平下 oracle 与 blind 的边际经验覆盖都落在容差带内。可证伪：任一 (mode, α) 组合 $|\text{cov} - \text{nominal}| > 0.05$ 即拒。
- **H2（带宽随 α 单调、blind 宽于 oracle）**：带宽随名义覆盖率升高（ α 减小）而增大；同一 α 下 blind 带宽不窄于 oracle。可证伪： $\exists \alpha$ 使带宽不单调，或 blind 带宽 $<$ oracle 带宽。

- **H3（参数扇形达到名义）**：盲路径参数扇形经两步膨胀后，[p10,p90] 中心带在测试上的经验覆盖在名义 0.80 的 ± 0.10 容差内。可证伪： $|\text{cov}_{\text{fan}} - 0.80| > 0.10$ 。
- **H4（熵置信度不是概率）**：确定性核不输出概率；任何把 entropy 当覆盖率的做法未校准、且随分布漂移恶化。本文以“不提供 entropy 概率、只交付共形/扇形”作为工程执行，漂移下的覆盖衰减作为未来实验（见第 9 章）。

4 方法与系统设计

4.1 预测内核：残差循环世界模型

`udos7/model.py` 的 `WorldModelCore` 是单一推理图，无第二引擎、无 LoRA。其结构为：观测逐帧经 `obs_encoder`（Linear-LayerNorm-GELU 两段，输入维 `STATE_DIM=6` → 隐藏维 256）编码，每帧注入统一场景上下文 `ctx`（由 `SceneChannel` 产出，维 32→256 经 `ctx_proj`），再送入 2 层 GRU 时序核（`hidden=256`, `num_layers=2`, `batch_first=True`），残差解码（`decoder: Linear-GELU-Linear`, 256→256→6） $s_{t+1} = s_t + \Delta(h_t)$ 。残差形式使“匀速延续”成为零学习成本的基线，模型只需学习加速度/振动/碰撞偏差；这相对旧 CTM tick 堆叠的优势，在 `improvement_vs_v701` 中体现为 blind overall MSE 从 0.0459 降到 0.0104。解码器末层零初始化，使初始模型严格预测”状态不变”，训练从稳定点起步。

v7.0.3 还加入一个只吃确定性运动学特征的独立小门 `kin_gate`（`Linear(KIN_DIM=11,32)-GELU-Linear(32,6)`，末层零初始化），把解析恒加速度积分按 `ca_conf`（恒定加速度一致性置信， $\in [0,1]$ ）软混合进预测： $s_{t+1} = (1-g)\text{learned} + g\text{analytic}$ ， $g = \text{ca_conf} \cdot \tanh(\text{MLP}(\text{kin})/2)$ ，其中 `analytic` 用初始窗固定的可观测加速度向量 $a \in \mathbb{R}^3$ 做 $v_{t+1} = v_t + a \, dt$ 、 $p_{t+1} = p_t + v_t \, dt + \frac{1}{2} a \, dt^2$ 。该门不读共享 GRU 隐状态——这一设计意图是避免门在 uniform/accel 饱和后改变共享表征梯度、拖累 spring 的学习路径。`ca_conf` 本身由 `kinematics.py` 给出：速度对时间线性拟合的逐窗 R^2 ，再乘以 $(1-\text{spring_valid})(1-\text{jump_valid})$ ，使 uniform/accel ≈ 1 、spring/collision ≈ 0 。实测门均值（`improvement_vs_v703.gate_mean_by_kind`）：uniform 0.634、accel 0.662、spring 0.0、collision 0.154，与设计意图一致——门在 spring 上完全关闭，在 collision 上谨慎（窗内尚未观测到跳变但视界内将碰撞）。

4.2 共形校准器：按 α 单独取分位数

`udos7/uncertainty.py` 的 `ConformalCalibrator` 修复了旧版”名义 80/90/95 经验覆盖全是同一常数、 α 被忽略”的缺陷。这个旧 bug 值得记录，因为它在工程上并不罕见：如果实现时把所有 α 共用同一个分位数、或把非一致性分数一次性池化后对每个 α 都用相同的经验分位查表，名义水平就形同虚设——表面上报了三个覆盖率，实际它们是同一个数。本实现的纪律是” α 不同带宽必须不同”，并由 `widths_depend_on_alpha()` 探针在 CI 里强制：把 α 降序排列后，边际带宽必须严格递增（ $0.2 \rightarrow 0.0430 < 0.1 \rightarrow 0.0858 < 0.05 \rightarrow 0.1612$ ），否则探针失败。

校准流程为：

1. 在校准集上跑模型 H 步滚动，收集绝对残差 $R = |\hat{Y} - Y|$ ，形状 $[N, H, 6]$ ；
2. 对每个 $\alpha \in \{0.2, 0.1, 0.05\}$ ，分别取标量池化 q_{marginal} 与逐步 q_h 分位数，使用有限样本修正

$$q_{\text{level}} = (1 - \alpha) \frac{n+1}{n}, q = \text{Quantile}(R, q_{\text{level}});$$

3. 推理时 $\hat{Y} \pm q$ 给出区间。

`widths_depend_on_alpha()` 探针强制” α 越小（覆盖越高）带宽越大”。关键纪律：校准集来自 `CALIB_SEED=314` 的独立轨迹，不参与梯度，也不与 `val/test` 混；`contracts.py` 明确四个 `seed`（`TRAIN_SEED=42` / `VAL_SEED=1337` / `TEST_SEED=2026` / `CALIB_SEED=314`）。

4.3 蒙特卡洛参数扇形：参数不确定性

`MonteCarloParamFan` 刻画参数不确定性而非偶然不确定性。其思想是：盲路径下隐藏参数估计有残差，我们把校准集上”真值-估计值”的参数残差 $r \in \mathbb{R}^4$ 做经验自助（保留槽位相关性），对一个新窗口：

1. 由模型估计 P ，有放回地抽取 $M = 64$ 份残差 $P^{(m)} = P + r^{(m)}$ ；
2. 每份 $P^{(m)}$ 跑一次 H 步滚动，得 $\{Y^{(m)}\}_{m=1}^M$ ；
3. 沿 `draw` 维取 0.1/0.5/0.9 分位，得 `p10/p50/p90`。

裸扇形只覆盖参数不确定性，覆盖不了自回归结构误差，因此做**两步膨胀**（`calibrate_inflation`）：(i) 逐步乘法膨胀因子，让扇形贴合校准残差；(ii) 取与纯残差 conformal 带 q_{floor} 的包络，使 `[p10,p90]` 覆盖率不低于有边际覆盖保证的残差带。伪代码如下：

```
fit(model, calib):
    residuals = P_true - P_hat(model.scene(X_calib))          # [Ncal,4]

sample(model, window, H):
    lo0,p50,up0 = raw_fan(model, window, H)                  # 自助 M 次
    half = (up0-lo0)/2
    band = inflate[h] * (half + eps)                          # 乘法膨胀
    lower, upper = p50 - band, p50 + band
    lower = min(lower, p50 - q_floor[h]); upper = max(upper, p50 + q_floor[h])
    return ParamFan(lower, p50, upper, draws=64)
```

4.4 证据分级与门禁

`contracts.py` 定义 `EvidenceGrade` 枚举：`verified`（本仓可复现脚本+固定 `seed` 实测）、`cpu-proto`（CPU 原型已跑通、未在 GPU/生产规模验证）、`unverified`（无 benchmark，仅主张，禁止写进性能结论）。`scripts7/verify_v7.py` 跑完后，21 个布尔门禁（含 5 个运动学恢复门禁、3 个对 v7.0.1 改进门禁、6 个对 v7.0.3 门控门禁、6 个覆盖率门禁、1 个扇形门禁）全部 `all_pass=true` 才输出通过。

4.5 为什么校准集必须独立：防泄漏设计

共形预测的覆盖保证依赖”校准样本与测试样本可交换”（exchangeability）。一旦校准集与测试集来自同一条轨迹的相邻窗口，两者在时间上高度相关，覆盖保证就被悄悄破坏——表面上覆盖率达标，实际分布已泄漏。本仓在 `dynamics.py` 中把这件事做到轨迹级：`build_split` 先按独立 `seed` 生成整条长度 $T = W + H + \text{margin}$ 的轨迹，再在轨迹内切窗；`traj_id_offset` 让四个划分的轨迹 ID 全局不重叠，`TrajectoryDataset.trajectories()` 可审计去重后轨迹数。也就是说，`calib` 集的 128 条轨迹与 `test` 集的 128 条轨迹，是用不同 `seed` 独立抽样的不同物理场景（不同初速度、不同方向、不同弹簧相位），而非同一轨迹的平移窗口。这一设计是”覆盖率可信”的前提，也是本文把覆盖率数字敢写成 `verified` 的根本原因。

此外, `ConformalCalibrator.fit` 与 `MonteCarloParamFan.fit` 都在 `model.eval()` 下、`torch.no_grad()` 下运行, 校准不更新任何权重, 也不参与梯度; `CALIB_SEED=314` 与 `TEST_SEED=2026` 物理隔离。

5 实验设置

5.1 数据

合成动力学由 `udos7/dynamics.py` 生成。四类运动 `KINDS=(uniform, accel, spring, collision)`: 匀速 $p = x_0 + v_0 dt$; 匀加速 $p = x_0 + v_0 dt + \frac{1}{2} a dt^2$; 简谐 $p = x_0 + A \cos(\omega t + \phi) d$; 等质量两体一维弹性碰撞 (记录质点 1, y/z 恒 0, 指标中诚实标注)。参数采样域: $v_0 \in [-2, 2]$ 、 $a \in [-1.5, 1.5]$ 、 $\omega \in [0.6, 1.6]$ 、碰撞 $v_1 \in [1, 2.5]$ 、 $v_2 \in [-0.5, 0.5]$ 。每个运动类只在自己”有意义”的槽位上有非零参数 (`dynamics.py` 的 `ACTIVE_SLOTS`): `uniform` 只在 `v0` 槽、`accel` 在 `v0` 与 `accel_a`、`spring` 只在 `spring_omega`、`collision` 在 `v0` (承载观测到的 v_1) 与 `other_v2` (承载窗口不可见的被撞质点速度)。这种”有效槽位掩码”设计意味着参数辨识损失只在有效槽上计算——`uniform` 轨迹不会因为弹簧槽恒为 0 而被错误惩罚。

轨迹级四分: 先按独立 `seed` 生成整条轨迹再切窗, 杜绝同轨迹相邻窗口跨集合泄漏; `traj_id` 全局不重叠。 `build_split` 默认每类 64 条轨迹, `three_way_splits` 派生 `train/val/test/calib`。实测规模 (`v7_verification.json`):

划分	窗口数	轨迹数	seed
train	1280	256	42
val	640	128	1337
test	640	128	2026
calib	640	128	314

5.2 模型与训练

`WorldModelCore(window=6, hidden=256, n_layers=2, scene_dim=32, use_kinematics=True)`, 可训练参数 967,796。数据划分 $dt = 0.5$, $W = 6$, $H = 4$ 。模型尺寸选择规则 (`model_size_convergence.json`) 为”最小且 `val` 准则在最优 $1+3\%$ 内的 `hidden`”。硬件指纹: PyTorch 2.14.0+cpu、device=cpu、`torch.set_num_threads(2)`、Python 3.12.11。单次训练时长: `hidden=64` 约 53.3 s、128 约 83.2 s、256 约 199.6 s。

训练损失为滚动多步 MSE (`rollout_grad` 保留梯度自回归展开 $H = 4$ 步)。`model_size_convergence.json` 中三档 `hidden` 各跑 80 epoch, `best_epoch` 分别为 62/73/73, 说明 80 epoch 已足够收敛、未出现明显过拟合回跳; `val_blind_curve` 末段 (epoch 70–80) 在 0.009 附近平台, 进一步支持”256 在 80 epoch 内已收敛”。需要强调: **val 准则用于选 hidden 与早停, 从不用于校准**; 校准带宽只从 `calib` 集取, 避免把选择偏差泄漏进覆盖率。

5.3 评估协议与证据等级

所有指标在 `scripts7/verify_v7.py` 中对落盘 checkpoint `checkpoints7/worldmodel_v7.0.3.pt` 重算，输出 `reports7/v7_verification.json` (evidence_grade=verified)。覆盖率门禁容差：共形区间 ± 0.05 、参数扇形 ± 0.10 。本文为单 seed 试点点估计；[RESULT NEEDED: 覆盖率/带宽的 ≥ 30 seed Wilson CI 与等效性检验]、[RESULT NEEDED: 分 seed 方差与带宽配对比较] 待投稿前补。

报告中每个数字都可回链到 `verify_v7.py` 的具体代码行：MSE 来自 `metrics.evaluate`，覆盖率来自 `empirical_coverage`，扇形覆盖来自前 256 窗的 `((truth>=p10)&(truth<=p90)).mean()`，门禁来自 `gates` 列表的布尔聚合。这种”报告 JSON $\leftrightarrow$ 脚本 $\leftrightarrow$ 源码”三段式可追溯，是本文把数字标 verified 而非 cpu-proto 的依据。

6 结果

本章展开顺序 (v2 规范)：先在第 5 章给出实验设置 (数据/模型/训练/评估协议)，本章按”对照 $\rightarrow$ 消融/敏感性 $\rightarrow$ 效度威胁”组织。对照：6.1–6.2 做 oracle (显式注入真值参数) vs blind (估计参数) 的点预测与覆盖率对照，隔离”知道/不知道场景类别”的影响；消融/敏感性：6.1b 为跨版本门禁消融 (v7.0.1 $\rightarrow$ v7.0.2 $\rightarrow$ v7.0.3 逐级收紧)，6.4 为模型尺寸敏感性 (hidden 64/128/256)；6.3 为参数扇形、6.5 为延迟与运动学恢复。所有数字来自 `reports7/v7_verification.json` (evidence_grade=verified, 单 seed 试点)。效度威胁单独成第 8 章。

6.1 点预测精度：blind 与 oracle

表 1 给出测试集 (640 窗) 整体、分类别、oracle/blind 两种口径的 MSE。

表 1 测试集 MSE (verified, v7.0.3, hidden=256)

口径	overall	uniform	accel	spring	collision
oracle (显式参数)	0.00663	0.00389	0.01090	0.00935	0.00238
blind (估计参数)	0.01037	0.00573	0.01410	0.01862	0.00304
blind 相对 v7.0.1	0.0459 $\rightarrow$ 0.01037	—	0.1053 $\rightarrow$ 0.01410	0.0637 $\rightarrow$ 0.01862	—

盲路径整体 MSE 0.01037，较 v7.0.1 的 0.0459 下降约 77%；accel 类从 0.1053 降到 0.01410。但 **spring** 类 **blind** MSE **0.01862** 为四类最高，是已知短板 (oracle 下 spring 仅 0.00935，说明差距主要来自 blind 下 ω 估计不准，而非模型学不会弹簧)。分轴看，blind 下 v_x 误差 0.0158 略高于其余轴，与碰撞沿 x 轴、y/z 在碰撞类平凡一致。

表 1b 分轴 MSE (verified, blind 口径)

状态维	pos_x	vel_x	pos_y	vel_y	pos_z	vel_z
oracle	0.01060	0.00993	0.00831	0.00232	0.00668	0.00192

状态维	pos_x	vel_x	pos_y	vel_y	pos_z	vel_z
blind	0.01423	0.01582	0.01256	0.00632	0.00943	0.00387

分轴揭示了一个值得记录的结构：无论 oracle 还是 blind，速度分量 (v_y, v_z) 的 MSE 都低于位置分量，这与”残差头预测的是位置/速度的一步增量、速度由位置差分得到”的自回归误差累积机制一致——位置误差会通过积分放大，速度误差则相对直接。 v_x 在 blind 下偏高 (0.0158) 进一步指向沿运动主轴的振动/碰撞残差，而非均匀噪声。

6.1b 消融①：版本门禁演进 (v7.0.1 → v7.0.2 → v7.0.3)

这套可信度流水线不是一次到位的，而是三代硬门禁收紧的结果，表 1c 复盘这一过程（基线数字来自仓内 `improvement_vs_v701 / improvement_vs_v703`，均为 verified）。

表 1c blind MSE 的版本演进与门禁 (verified)

版本	blind overall	blind accel	blind spring	blind collision	关键改动
v7.0.1	0.0459	0.1053	0.0637	—	基线（盲参数估计弱）
v7.0.2	0.02482	0.06926	0.01933	0.00334	确定性运动学反演通道
v7.0.3	0.01037	0.01410	0.01862	0.00304	解析积分门控软混合

每代门禁都是”相对上一代不放宽”的硬约束：v7.0.2 要求 $accel \leq 0.075$ 、spring 不劣于 v7.0.1；v7.0.3 要求 $accel \leq 0.035$ 、spring/collision 不劣于 $v7.0.2 \times 1.15$ 。值得注意的是 **spring 在 v7.0.3 几乎没有继续下降 (0.01933→0.01862)**，因为解析积分门控在 spring 上被 `ca_conf` 确定性关闭（门均值 0.0），spring 完全交给 GRU 学习路径；这反过来说明 accel 的大幅改善来自”把解析积分接回来”，而不是模型变大。这种”哪类交解析、哪类交学习”的显式分工，比端到端黑箱更可审计。

6.2 共形覆盖率：H1 与 H2

表 2 给出六个 (mode, α) 组合的边际覆盖、逐步覆盖与边际带宽。图 1 为名义 vs 经验覆盖对比，图 3 为逐步覆盖曲线。

表 2 共形区间覆盖率与带宽 (verified)

口径	名义	边际覆盖	逐步覆盖 $h = 1, 2, 3, 4$	边际带宽	门禁
oracle $\alpha=0.2$	0.80	0.7839	0.7901/0.7833/0.7836/0.7784	0.0430	pass
oracle $\alpha=0.1$	0.90	0.8984	0.9008/0.8995/0.8969/0.8966	0.0858	pass
oracle $\alpha=0.05$	0.95	0.9577	0.9534/0.9617/0.9570/0.9589	0.1612	pass
blind $\alpha=0.2$	0.80	0.7758	0.7831/0.7792/0.7737/0.7672	0.0504	pass
blind $\alpha=0.1$	0.90	0.9001	0.9039/0.8987/0.9010/0.8969	0.1081	pass

口径	名义	边际覆盖	逐步覆盖 $h = 1, 2, 3, 4$	边际带宽	门禁
blind $\alpha=0.05$	0.95	0.9559	0.9521/0.9568/0.9549/0.9599	0.2052	pass




图 1 共形区间边际覆盖率：名义水平 vs held-out 实测（640 测试窗）。横轴为六个 (mode, α) 组合 (oracle/blind $\times \alpha=0.2/0.1/0.05$)，纵轴为边际经验覆盖率；每对柱上方虚线标出名义水平 0.80/0.90/0.95，阴影带为 ± 0.05 容差。所有柱落入容差带 (H1)。数据来源 `reports7/v7_verification.json: coverage.*`，证据等级 verified，单 CPU 固定 seed 试点。

H1 成立：六组边际覆盖全部落在名义 ± 0.05 容差内。最紧的是 blind $\alpha=0.2$ ：经验 0.7758，距名义 0.80 为 -0.0242 ，距容差下沿 0.75 仍有 0.0258 裕量。**H2 成立：**带宽随 α 单调增大——oracle 0.0430/0.0858/0.1612, blind 0.0504/0.1081/0.2052；且同一 α 下 blind 带宽一致地宽于 oracle ($0.0504 > 0.0430$ 、 $0.1081 > 0.0858$ 、 $0.2052 > 0.1612$)，符合“不知道类别就买更宽的保险”。逐步覆盖显示：oracle 随滚动步略降 ($0.9008 \rightarrow 0.8966$)，blind 80% 档随步递减更明显 ($0.7831 \rightarrow 0.7672$)，自回归误差累积在低名义水平上更易暴露。

值得记录的一个细节是：blind 95% 档的逐步覆盖 ($0.9521/0.9568/0.9549/0.9599$) 不仅没有随步下降，末步反而最高 (0.9599)。这与 80% 档的单调下降形成对照，说明在高名义水平下，带宽足够宽，足以吸收自回归累积误差；而在低名义水平下，带宽偏紧，累积误差就暴露为覆盖下降。这一现象支持“低名义水平更需要类别条件化”的工程判断。




图 3 逐步（per-step）共形覆盖率随滚动步 $h=1,2,3,4$ 的衰减曲线。横轴为自回归步 h ，纵轴为该步经验覆盖率；六条线对应 oracle/blind $\times$ 80/90/95 三水平。可见低名义水平（blind 80%）随 h 单调下降（0.7831 $\rightarrow$ 0.7672），高名义水平（blind 95%）末步反升至 0.9599——自回归误差累积在低带宽档更易暴露。数据来源 `v7_verification.json: coverage.*.per_step`，verified，单 seed。

6.3 参数不确定性扇形：H3

盲路径参数扇形名义 0.80，在测试上前 256 窗上的经验覆盖为 0.8592，容差 ± 0.10 内，门禁通过。这是一个偏保守的结果：实测覆盖高于名义约 5.9 个百分点，意味着 [p10,p90] 带略宽于必要。我们不把它包装成”精确校准”，而按工程现实解释：两步膨胀中的 q_{floor} 包络保证了不劣于纯残差 conformal，但也可能在参数残差本身较准的样本上贡献了额外宽度。[RESULT NEEDED: 扇形经验覆盖的多种子 CI 与带宽/覆盖率帕累托曲线]。

拆解两步膨胀的作用是有意义的。第一步乘法膨胀 `inflate[h]` 沿逐步方向取共形分位数，把”参数扇形中位数 p_{50} 与真值的相对偏离”归一化后再放大，这处理的是参数残差的系统性偏差；第二步地板包络 `q_floor` 直接取纯残差 conformal 的逐步带宽，与膨胀后扇形取逐元素最大（`torch.minimum/maximum`）。因为纯残差 conformal 有边际覆盖保证，包络后扇形的覆盖在数学上不会低于残差带——这是 H3 能稳定通过的结构原因，而非运气。代价是：当参数已经估计得很准（残差小）时， q_{floor} 仍按”最坏残差”给宽度，扇形偏宽就来自这里。

6.4 消融②/敏感性：模型尺寸选择与收敛

表 3 与图 2 给出三档 hidden 的选择过程。选择规则要求”最小且 val 准则在最优 1+3% 内”。最优 val 准则为 hidden=256 的 0.008208，1+3% 带为 0.00845；hidden=128 的 0.009495 与 hidden=64 的 0.011899 均落在带外，故最小合规档即为 256。这是一个诚实的”没有更小模型够用”的结果，而非”256 恰好最优”。

表 3 模型尺寸选择 (verified)

hidden	参数量	best epoch	best val 准则	训练秒
64	95,348	62	0.011899	53.3
128	271,476	73	0.009495	83.2
256 (选中)	967,796	73	0.008208	199.6




图 2 模型尺寸敏感性：hidden=64/128/256 三档的 best val 准则与训练时长。横轴为 hidden 维，左纵轴为 best val 准则（越低越好），右纵轴为单次训练秒数；选中档 hidden=256（val 0.008208），64/128 均落在”最优 +3%“选择带外——这是”没有更小模型够用“的诚实结果，而非”256 恰好最优”。数据来源 `reports7/model_size_convergence.json`，verified，单 seed。

6.5 推理延迟与运动学恢复

CPU 单线程 batch=1 延迟：单步下一状态预测中位 **2.36 ms**，4 步 rollout 中位 **4.83 ms**（200 次计时取中位，预热 20 次）。这个数字对边缘部署的意义在于：共形区间与参数扇形都是**推理时**后处理，不增加训练成本；扇形的 $M = 64$ 次 rollout 会把推理时间放大约一个数量级，但在 batch=1、4.83 ms 基础上约为 300 ms 量级，仍可离线/准实时使用。运动学恢复（不依赖训练的确定性反演）：加速度向量对真值 MSE=0.0（相对均值预测器 0.2182，skill=1.0）；spring ω 召回 1.0、非弹簧误报 0；碰撞跳变检出 0.7437、非碰撞误报 0。这组数字与 P6（隐藏参数可辨识性）直接衔接：可观测量被精确反演，而弱可辨识量（见 P6 的加速度标量 skill）则诚实报告为负。

值得一提的是”零未来泄漏“纪律：`kinematic_features` 只吃观测窗 $W = 6$ 帧，rollout 每步用当前滑窗重测一次，从不偷看未来帧；无效特征置 0、有效性标志置 0，不编造。这种”可观测就精确、不可观测就置零“的诚实建模，是 blind 路径不至于比 oracle 差太多的原因——模型在该交给解析时交给解析，在该交给学习时交给学习，从不假装从短窗反推不可反推的量。

7 讨论

为什么 blind 80% 覆盖偏低却仍通过门禁。 0.7758 距名义 0.80 差 0.024，在 ± 0.05 容差内但接近下沿。根因与 H2 一致：blind 路径下 spring 类 ω 估计残差较大，把整体非一致性分数拉偏；当校准池把所有类别混在一起取分位数时，弱类（spring）的残差被强类稀释，低名义水平的覆盖率最易下滑。改进方向是**分类/类别条件共形**（oracle 已验证显式条件能把带宽压窄、覆盖更稳），但 blind 无法知道类别，这正是“盲可信度”的固有代价。

偏保守的扇形。 0.859 vs 0.80 不是缺陷，而是“宁可宽一点”的工程取舍： q_{floor} 包络保证扇形不劣于残差 conformal，代价是在参数已较准的样本上偏宽。若下游对带宽敏感，可单独优化膨胀系数而不动覆盖保证。

带宽的工程含义。 表 2 中 blind 95% 带宽 0.2052 已接近状态归一化量级，意味着在最宽区间上，模型对 95% 覆盖付出了“预测值 ± 0.2 ”的代价。这不是模型失败，而是 blind 路径下“不知道类别”的信息代价——oracle 同水平带宽仅 0.1612。在边缘部署中，这一差距可以转化为一个产品决策：如果场景类别可由上游规则低成本判定（例如传感器知道“现在是匀速段”），就走 oracle 式条件化以压窄区间；否则接受 blind 的宽区间。本文把这一权衡量化出来，而不是用一个笼统的“不确定性”数字掩盖它。

8 效度威胁与局限

本章为独立的效度威胁与局限章（v2 规范第 4/6 条）。外推纪律按 Kaplan 2020 的 Caveats 式写法：本仓覆盖率数字只在已观测量程内成立——四类合成运动、 $W = 6$ 、 $dt = 0.5$ 、 $H = 4$ 、CPU 固定 seed；超出该量程（更长 horizon、真实传感器、GPU 规模世界模型）的任何推广均为**激进外推**，其失效点与数量级不确定性不在本数据可断言范围内。

威胁有效性。 (i) 内部威胁：单 seed、单次验证，覆盖率的抽样波动未量化——把 640 窗当作独立单元时，二项比例在 $p \approx 0.9$ 的标准误约 ± 0.012 、95% Wilson 半宽约 ± 0.023 （沿 h 、状态维的池化会降低名义半宽，但同轨迹相邻窗不独立、有效样本量更接近轨迹数而非窗口数），该量级已与 ± 0.05 容差可比，故多种子重复是投稿前硬要求（[RESULT NEEDED]）。(ii) 构造威胁：合成动力学真值已知，分布简单；真实传感器噪声、非线性摩擦、未建模动力学都会破坏 exchangeability，共形覆盖会漂移。(iii) 外部威胁：967K 参数、CPU、 $dt = 0.5$ 等间隔采样，结论不能外推到大规模视频世界模型或高频控制。(iv) 测量威胁：碰撞类 y/z 恒 0，分轴指标在碰撞类上不非平凡，已在源码与表中如实标注。

与 P6 的关系。 本文只把“参数估计得准不准”当作一个影响带宽的因素来对待；P6 则专门逐参数量化隐藏参数的可辨识性。本文一个隐含事实是：blind 带宽之所以宽于 oracle，本质上是因为 4 个隐藏参数里有的可辨识（碰撞 v_2 skill 0.82）、有的不可辨识（加速度标量 skill -0.508，见 P6），混合估计把不可辨识项的残差传染到整段滚动。两篇合读，才能完整解释“为什么 blind 80% 覆盖贴近下沿”。

为什么不报告 p 值。 本文全部结果是单 seed 试点点估计。覆盖率本身是二项比例，原则上可算 Wilson 置信区间；但我们刻意不在本稿手算后写成“ $p < 0.05$ ”式结论，因为单一固定 seed 的二项 CI 只反映“这 640 个窗口的抽样波动”，不反映“训练随机性/数据生成随机性”的系统方差。后者必须靠 ≥ 30 seed 重训重校准才能给出诚实区间。这是本文与 P6、P11 共同的纪律。

9 资源闸门与适用边界

本文全部结论停在 `verified` (CPU 固定 seed) 与 `cpu-proto` 边界。以下升级点受资源闸门约束：

- **GPU/HPC** 解锁 0.5B+ 端到端世界模型、更长 rollout 与多种子 CI；当前不可达。
- **漂移实验** (训练匀速/加速，测试加弹簧/碰撞) 尚未跑，是 H4 的直接检验，属下一里程碑；[RESULT NEEDED: OOD 覆盖率衰减曲线与 OOD 检出 AUROC]。
- **校准方法对照** (split / class-conditional / weighted / ensemble quantile) 只在 oracle vs blind 间做了粗略对照，严格四方法消融待补。
- **适用边界**：本文方法适用于”小模型、真值可核验、需要有限样本覆盖保证”的边缘推理；不适用于需要点预测外的因果归因或真实金融/医疗决策 (无对应数据与监管验证)。

具体而言，资源闸门对结论强度的限制体现在三处。其一，**多种子**：当前 21 门禁虽全过，但”全过”是在一个 seed 上的断言；若换 seed，blind 80% 覆盖 0.7758 有一定概率跌破 0.75 下沿，这正是需要 ≥ 30 seed 给出”覆盖率落入容差带的频率”而非”单 seed 是否过”的原因。其二，**三维多体**：当前状态虽为 6 (真三维方向)，但碰撞仍是 x 轴两体、y/z 平凡；扩展到三体以上碰撞需要重写 `traj3d_collision` 与 `ACTIVE_SLOTS`，数据生成与校准协议都要重做。其三，**真实数据**：合成动力学的 exchangeability 较易满足，真实传感器漂移会让 split conformal 的边际覆盖随时间衰减，需要自适应/在线校准，这是另一条研究线。

10 结论

我们在一个 967,796 参数、单 CPU 可复跑的残差循环世界模型上，把预测可信度拆成两件互不冒充的事：按 α 取分位数的 split conformal 区间 (六组覆盖全过 ± 0.05 门禁)，与参数残差自助蒙特卡洛扇形 (经验覆盖 0.859，偏保守但有覆盖保证)。盲路径 MSE 从 v7.0.1 的 0.0459 降到 0.0104，21 项门禁全过。诚实的部分同样重要：spring 类误差最高、blind 80% 覆盖接近容差下沿、扇形偏宽。我们把全部数字挂到可复跑脚本与固定 seed 上，把未做完的统计量用 [RESULT NEEDED] 标出，把未核验的外部主张标为 unverified。可信度这件事，与其靠更大的模型，不如靠更严的门禁。

对后续工作，我们有三条明确路线：第一，把单 seed 试点扩展到 ≥ 30 seed，给出覆盖率落入容差带的频率与 Wilson CI，把”全过”升级为”在 X% 的 seed 上过”；第二，做分布漂移下的覆盖衰减实验，检验 H4 并引入自适应校准；第三，把分类别共形与盲路径结合，用 P6 得到的逐参数可辨识性先验来指导 blind 带宽的类别条件化——这正是 P5 与 P6 合读的工程落点。

最后需要重申本文的证据纪律：所有”达标””通过”的措辞都限定在”CPU 固定 seed、单次验证、容差 $\pm 0.05/\pm 0.10$ ”这一具体口径内。它不是”共形方法在任意世界模型上都有效”的普适结论，而是”在这个 967K 参数、四类合成运动、轨迹级四分的具体系统上，按 α 取分位数的 split conformal 与参数自助扇形达到了预设门禁”。超出这一口径的任何推广，都需要新的实验与新的证据。

参考文献

说明：本稿已引用的已核验文献字段照抄全卷《参考文献总库》(核验日期 2026-09-19)；其余为待核验检索式，不作已引用事实，投稿前须逐条经学术检索核验元数据与 DOI。

已核验引用 (✔ 总库 2026-09-19)

- Angelopoulos, A. N., & Bates, S. (2021). A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification. arXiv preprint, arXiv:2107.07511. <https://arxiv.org/abs/2107.07511> —— 分布无关、有限样本边缘覆盖保证；本文 § 2 共形区间机制与”边缘覆盖 ≠ 条件覆盖”边界的直接来源。

待核验文献检索式与候选方向

- 共形预测基础：
conformal prediction distribution-free Vovk 2005 原始 split conformal 出处。
- 时间序列/滚动共形：conformal prediction time series rolling forecast; conformal prediction under distribution shift; envelope conformal。
- 偶然/认知不确定性：
epistemic aleatoric uncertainty deep learning; Monte Carlo dropout Gal Ghahramani; deep ensembles Lakshminarayanan Pritzel Blundell。
- 世界模型/可微动力学：learned world model uncertainty; neural ODE latent dynamics; calibrated neural forecasting。
- 分类别/加权共形：class-conditional conformal; weighted conformal covariate shift。

附录 A 复现命令与测试索引

```
cd release-v5.4.4/udos-engine                # main, tag v7.5.0, commit 1a71270
python3 scripts7/verify_v7.py                # 重算 reports7/v7_verification.json
python3 scripts7/train_v7.py                  # 重训 (checkpoints7/worldmodel_v7.0.3.pt)
pytest tests7/test_m3_uncertainty.py tests7/test_v702_kinematics.py \
    tests7/test_v703_kin_gate.py -q
```

关键源码：`udos7/model.py` (WorldModelCore)、`udos7/uncertainty.py` (ConformalCalibrator / MonteCarloParamFan / empirical_coverage)、`udos7/dynamics.py` (three_way_splits 轨迹级四分)、`udos7/contracts.py` (seed/证据分级)、`udos7/scene.py` (SceneEstimator)、`udos7/kinematics.py` (确定性反演)。

附录 B 证据台账

数字	来源	证据等级
967,796 参数	v7_verification.json: params	verified
blind overall MSE 0.01037	test_metrics.blind.blind_overall	verified
v7.0.1 blind 0.0459	improvement_vs_v701.v701_baseline	verified (仓内基线)
oracle/blind 六组覆盖率	coverage.*	verified
参数扇形经验 0.8592	param_fan.empirical_coverage	verified

数字	来源	证据等级
延迟 2.36/4.83 ms	latency_ms	verified (CPU 单 seed)
21 门禁全过	gating.all_pass=true, checked=21	verified
外部产业规模数字	—	unverified (报道口径, 未独立核 验)

补充说明：表中” 仓内基线” v7.0.1/v7.0.2 数字来自 improvement_vs_v701 / improvement_vs_v703 段，是同一仓库历史版本在相同协议下的复跑结果，因此标 verified 而非 unverified；它们不是外部文献数字。

[RESULT NEEDED] 计数：覆盖率 Wilson CI 与等效性检验、多种子方差、漂移 OOD 衰减、校准方法四消融。 [CITATION NEEDED] 计数：见第 2 节五处候选方向。

附录 C 内审记录（投稿前五维自评，只看不改）

按 doubao-academic-evaluator 五维打分（0–10，单 seed 试点口径）：

1. 问题重要性 (novelty/importance): 5。共形方法成熟，故事不新；胜在工程诚实与小模型可复现基准。不主张方法创新是其诚实加分。
2. 技术正确性 (soundness): 7。分位数公式、残差自助、两步膨胀均与源码一致；主要扣分项是单 seed 无 CI、未做分布漂移检验。
3. 实验严谨度 (rigor): 5。21 门禁与轨迹级四分是硬贡献；但无多种子、无 Wilson CI、消融只到 oracle/blind 两档。
4. 新颖性 (novelty): 4。用户自评一致——方法成熟，新颖性在” 分离偶然/参数不确定性 + 负结果诚实” 。
5. 可复现性 (reproducibility): 9。checkpoint、脚本、seed、报告 JSON、证据等级齐全，CPU 可复跑。

致命缺陷检查：无虚构 p 值/CI/DOI/分区；负结果（spring 短板、blind 80% 贴近容差、扇形偏保守）已保留；单 seed 已显式声明。**结论：**当前为可投稿的扎实方法应用+基准初稿，投稿前必须补 ≥ 30 seed 多种子 CI 与漂移实验，否则只能投 workshop。

作者拟用声明

- 目标期刊/会议：候选 UAI / AISTATS / NeurIPS Workshop on Uncertainty；期刊 MLJ、Pattern Recognition、Engineering Applications of AI。分区/影响因子一律 [待核]，选刊阶段逐项联网核验。
- 预注册计划：主指标（六组覆盖率 ± 0.05 容差、扇形 ± 0.10 、blind MSE 三档门禁）已在 verify_v7.py 中硬编码为不可放宽的门禁；投稿前将登记多种子采样数与停止规则。
- 数据与代码可用性：Apache-2.0；仓库 tag v7.5.0、commit 1a71270；报告 reports7/v7_verification.json、reports7/model_size_convergence.json。报告 sha: [RESULT NEEDED: git blob sha256]。

- **AI 使用声明：** 本文由作者主导设计与实验，AI 助手协助结构化写作、图表生成与语言润色；全部数字经作者对照源码与报告 JSON 回源核验，AI 未参与产生实验数据。