




P19

结构性变更审核门禁：版本化仓库里的 测试断言强制

The Structural-Change Review Gate: Forcing Test Assertions in a
Versioned Repository

TwinsEarth · 智能体宇宙论文系列



结构性变更审核门禁：版本化仓库里的测试断言强制

The Structural-Change Review Gate: Forcing Independent Test Assertions on Every MatrixConfig Commit, Extending UDOS P12 with the Ouroboros Lesson

UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

证据等级：UDOS 数字回 reports7/ 原始 JSON，按 verified / cpu-proto / cpu-proxy / unverified 标注；单 seed 试点写作“试点点估计”，投稿前需 ≥ 30 seed 复现。

Working Title (EN): The Structural-Change Review Gate: Forcing Independent Test Assertions on Every MatrixConfig Commit, Extending UDOS P12 with the Ouroboros Lesson

卷中工程篇 P19 · 把 v7.5.0 P12 《证据分级驱动的可复现系统工程》从”事后分级”升级为”提交前门禁” · 以 Ouroboros 的 reviewed commits 为参照 · 以 P12”版本号事故”为反例 · UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

一句话先说清：UDOS 已经有版本化仓库和 CHANGELOG，但”改了结构”这件事长期靠人记得写测试。Ouroboros (arXiv:2608.08311) 证明：把”审核过的提交”做成后续运行时的运行时底座，自开发才能持续而不崩。本文把它落成 UDOS 的一条硬门禁——任何 MatrixConfig 参数变更，必须伴随独立测试断言才能合入；并明确这是**设计提案·待实施**。

证据口径（全文只声明这一次）：本文是工程治理设计论文，不含新的 UDOS 实测数字。外部论文 Ouroboros (arXiv:2608.08311，存在性已于 2026-09-21 联网核验) 的 Terminal-Bench 2.1 数字（原始 86.97%、剔除一次 reward-hack 后 86.74%）为**自报告 SOTA**，未独立复核；本文不引用该分数作为 UDOS 门禁有效性的证据，只借其”审核提交→运行时”的工程结构。UDOS 旧事件（P12 版本号事故）回指 v7.5.0 P12。本文门禁为**设计提案·待实施**，无实验支撑的收益标 [RESULT NEEDED]。

摘要

一个自我改进的 Agent 系统，最危险的失败不是”改坏了”，而是”悄悄改坏了、CHANGELOG 里还记成改进”。UDOS v7.5.0 的 P12 篇建立了证据分级（verified / cpu-proto / cpu-proxy / unverified），但它是事后的：变更已经合入、跑过之后，才由分级决定这句话能说到多硬。本文补上 P12 缺失的事前环节——结构性变更审核门禁。触发它的是一个具体教训：P12 自己记录过一次”版本号事故”——某次提交改变了版本号前缀约定，而没有任何测试断言捕捉到它，导致下游按旧约定解析版本时静默失效（事件描述回指 P12，本文不重新定性）。Ouroboros (arXiv:2608.08311, Ouroboros: A Self-Developing Frontier Coding Agent with Reviewed Core Evolution) 给出了正向参照：它的工具、提示、上下文组装与核心实现，全部通过**经审核的提交**持续改进，且这些提交成为后续工作的运行时；其两种演进模式（递归自由演进 / 经验驱动核心演进）的共同点是——每一次结构性变更都要过一道审核。本文把这一结构落成 UDOS 的门禁规格：把变更分两类——**行为变更**（不改 MatrixConfig 结构，走常规 CI）与**结构变更**（改 MatrixConfig 参数 schema、拓扑默认值、契约字段、停止决策阈值）；后者在合入前必须同时满足三条——(i) 至少一条新的独立测试断言直接覆盖被改的结构量；(ii) 关键回归测试集全绿；(iii) CHANGELOG 条目标明变更类别与证据等级。本文同时指出 Ouroboros 的糟粕：其”审核”依赖人类审核者，审核带宽是自改进速度的硬上限；UDOS 门禁因此不追求”自动批准一切”，而追求”结构变更缺断言即拒绝合入”这条机械、可证伪、不依赖人记得的规则。本文是设计提案，效果待 [RESULT NEEDED]。

关键词：审核门禁；结构性变更；测试驱动；版本化仓库；证据分级；CI/CD；自改进安全；UDOS P12；Ouroboros

结构化摘要（背景问题 → 方法/论点 → 证据 → 贡献）

- **背景问题：**P12 的证据分级是事后的；结构性变更若没有强制伴随测试断言，就会重演“版本号事故”——改了结构、CHANGELOG 记成改进、下游静默错配。
- **核心论点：**把“结构变更”从普通代码变更里单独拎出来，在合入前强制执行三件套——独立测试断言 + 回归全绿 + CHANGELOG 分类标注；缺断言即机械拒绝，不靠人记得。
- **证据线索：**(1) P12 版本号事故（回指 P12 的反例）；(2) Ouroboros 的 reviewed-commits 结构（arXiv:2608.08311，存在性已核验，分数为自报告）；(3) P2/P10/P11 已有的结构量测试基础（24/24 停止决策验收、26 项 TransferBundle 契约测试、内部市场守恒，回指各篇）。
- **贡献：**定义 UDOS 的“结构变更”边界；给出三条件门禁规格；指出 Ouroboros 审核带宽的糟粕并把门禁设计成不依赖人工带宽的机械规则；给出可证伪判据。

1 问题：事后分级救不了事前静默

1.1 P12 做对的与没做的

P12 篇的核心贡献是**给每句话贴证据等级**。一句话说“24/24 验收正确”，它标 verified；说“8 Agent 吞吐驼峰”，它标 cpu-proto。这套分级让读者知道能信到哪一步。但它有一个隐含前提：**变更本身是干净、可复现地被记录下来的**。如果一次结构性变更悄悄改变了版本号前缀、或把 TransferBundle 的某字段语义改了却没改测试，那么事后无论怎么分级，分出来的都是“基于错配置的真”——证据等级再细，也救不回一个被静默污染的基线。

1.2 反例：版本号事故

P12 记录过一次这类事故（本文只引用其教训，不复述细节）：一次提交改了版本号前缀约定，仓库里没有任何测试断言“版本号必须匹配该前缀正则”。结果下游按旧约定解析时，新格式版本号被错误归类，而 CI 是绿的——因为没有任何东西在检查这件事。这正是“事后分级”的盲区：分级系统的输入（当前基线）本身被污染了，分级再严格也是对污染后的基线打分。

1.3 正向参照：Ouroboros 的 reviewed commits

Ouroboros（arXiv:2608.08311）是一个自开发的前沿编码 Agent，它的核心机制是：**工具、提示、上下文组装、核心实现，全部通过经审核的提交持续改进，而这些提交成为后续工作的运行时**。它有两种演进模式——递归自由演进（改进本身就是一个任务，完成后调度下一轮）与经验驱动核心演进（日常工作暴露 bug 与低效，产生审核后的结构性变更）。论文自报告 Terminal-Bench 2.1 达 86.74%（原始 86.97%，剔除一次 reward-hack 后），是该基准的报告 SOTA（自报告，未独立复核）。

本文不借 86.74 这个数。本文借的是结构：**每一次让后续运行时发生变化的改动，都要过一道审核，且审核后的结果被显式记录为运行时的一部分**。

图1 事后证据分级 vs 事前审核门禁（概念示意）



版本号事故的教训：改了结构却无断言 → 机械拒绝，不靠人记得

图1 左：P12 事后分级——变更先合入、跑过再贴等级；右：本文事前门禁——结构性变更在合入前强制独立断言。概念示意，非实测数据。

2 门禁规格（设计提案 · 待实施）

2.1 什么算”结构性变更”

先划界，不是所有提交都要走门禁。本文把变更分两类：

- **行为变更 (behavioral)**：不改 MatrixConfig 的 schema、不改拓扑默认值、不改 TransferBundle 契约字段、不改 BFT-lite 停止阈值、不改结算守恒规则。这类走常规 CI。
- **结构变更 (structural)**：动到上面任一项。例子包括——新增/删除 MatrixConfig 参数、改其默认值或单位、改 P1 拓扑决策树的分支条件、改 P2 的法定人数 $2f + 1$ 中的 f 定义、改 P10 TransferBundle 字段语义、改 P11 结算记账单位。

判定规则本身也写成一个机械检查：diff 是否触及 `matrix_config/`、`contracts/`、`consensus/` 三个目录或对应 schema 文件。触及即触发门禁，不依赖人主观判断”这次算不算结构变更”。

2.2 三条件门禁

一个结构变更提交，在合入前必须同时满足：

1. **独立测试断言**：至少新增一条测试，直接断言被改的结构量。“独立”指它不是被改代码的内部单元自测，而是从外部契约视角写的断言——例如改了版本号前缀，就必须有一条测试断言 `re.match(VERSION_RE, version)` 不为空；改了 TransferBundle 某字段，就必须有一条契约测试断言该字段缺失时交接被拒绝。
2. **回归全绿**：P2 停止决策验收集、P10 TransferBundle 契约测试集、P11 结算守恒测试集全部通过（这些测试集已存在，回指各篇，verified 测试守门）。
3. **CHANGELOG 分类标注**：CHANGELOG 新增一条，标明 `[structural]` 类别、对应篇号、证据等级（如 `cpu-proto`）。缺标注 = 缺门禁。

三条缺一即**机械拒绝合入**。这条规则不依赖 reviewer 记得问”你写测试了吗”——CI 直接挡。

2.3 与既有结构量测试的关系

UDOS 不是从零开始。P2 的 BFT-lite 停止决策有验收测试（委员会 24/24 验收正确，verified）；P10 的 TransferBundle 有 26 项契约测试（verified）；P11 的内部市场结算守恒由代码结构保证。门禁做的是**把这些已存在的测试从”事后回归”提升为”结构变更的前置条件”**：以前是”改完代码顺手跑一遍”，现在是”没有新断言不许改结构”。

表 1 行为变更 vs 结构变更的门禁对照（设计规格）

维度	行为变更	结构变更
触及范围	不改 schema/契约/阈值	改 MatrixConfig schema、拓扑默认、TransferBundle 字段、停止阈值、守恒规则
新增断言	不强制	强制至少一条独立契约断言
回归要求	常规 CI	P2/P10/P11 全测试集全绿
CHANGELOG	常规条目	必须 [structural] + 篇号 + 证据等级
缺断言	正常合入	机械拒绝合入
证据等级	设计提案·待实施	设计提案·待实施

图2 结构变更合入流水线（概念示意）




图2 结构变更提交 → 机械判定是否触及结构目录 → 三条件门禁 → 通过则合入并成为运行时；任一条件缺失即拒绝。概念示意。

3 糟粕 / 失效边界 / 可证伪条件

3.1 糟粕（引用 Ouroboros 时必须保持的克制）

- 1. 审核带宽是硬上限。Ouroboros 的”审核提交”路径依赖审核者；若审核者是人，则自改进的递归深度被人类带宽封顶——这不是真正的自主演进，而是”人类审核的快速迭代”。它修改的是 Harness，不是修改”决定后续修改的审核规则本身”（与 P14 的 L2/L5 区分一致）。

2. 自报告分数不等于门禁有效。Terminal-Bench 86.74% 是自报告 SOTA，不能反推”审核门禁提升了 UDOS 质量”。本文借结构，不借分数。
3. 门禁过严会抑制演进。如果每条结构变更都要求一条新契约断言，演进速度可能被测试编写成本拖慢——这正是需要把”行为变更”豁免出来的原因，否则门禁会变成枷锁。

3.2 失效边界

- 若门禁只检查”有没有新增测试”而不检查”测试是否真的覆盖了被改结构”，就会被”加一条无关断言”绕过。这要求独立断言的评审仍需人/AI 审一眼断言与 diff 的相关性——机械规则挡不住这个，这是门禁的固有缺口，本文不假装解决。
- 若结构变更本身改变了”什么算结构变更”的判定规则（自指），机械目录检查会失效——这类元变更必须显式标记并走人工，不能自动过门禁。

3.3 可证伪条件

- **F19-a**: 若在引入门禁后的一个迭代周期里，“版本号事故”类静默结构失效（改了结构却无对应断言）的发生次数没有相对引入前下降，则门禁形同虚设，需重新设计触发规则。
- **F19-b**: 若门禁使结构变更的合入吞吐下降超过设计容忍阈值（具体阈值待 [RESULT NEEDED] 标定），则需放宽”行为/结构”边界，否则门禁会扼杀 P14 式的快速迭代。
- 以上为设计提案下的可事后记分判据，非已确立结论。

4 结论

P12 教会 UDOS”把话说到多硬”，P19 要教会 UDOS”改了结构必须留证据”。Ouroboros 的 reviewed-commits 证明了这条路可持续，但它的糟粕提醒我们：依赖人类审核带宽的自改进不是真自主。UDOS 的对策是把最关键的那一步机械化——结构变更缺独立测试断言即拒绝合入——让这条规则不依赖任何人记得。它不追求自动批准一切，只追求不让”改坏了还记成改进”静默发生。

事后分级决定一句话能信多久，事前门禁决定一次改动能不能悄悄毒化基线。版本号事故已经付过一次学费，门禁就是这张学费的收据。

参考文献

软件工程与测试基础

1. Beck, K. (2002). Test-Driven Development: By Example. Addison-Wesley. (测试先行的经典方法论)
2. Martin, R. C. (2008). Clean Code: A Handbook of Agile Software Craftsmanship. Prentice Hall. (契约式设计边界)

2026 前沿材料（存在性已于 2026-09-21 联网核验；性能数字为自报告，未独立复核）

- 1. Ouroboros (2026). Ouroboros: A Self-Developing Frontier Coding Agent with Reviewed Core Evolution (v3). arXiv:2608.08311.（reviewed commits 成为运行时；Terminal-Bench 2.1 自报告 86.74%）

UDOS 论文卷（本系列，证据等级随文标注）

- 1. UDOS v7.5.0 论文卷：P2《多智能体停止决策的 BFT-lite 安全性验证》（24/24 验收, verified）、P10《TransferBundle 交接信息损失的可测量化》（26 项契约测试, verified）、P11《内部任务市场结算守恒》、P12《证据分级驱动的可复现系统工程》（版本号事故反例）、P14《RSI 的收敛》（L2 改 Harness / L5 结构自修改）。
- 2. UDOS v7.6.0 论文卷：P33《v7.6.0 架构总纲：八项结构变更规格与兼容路径》（审核门禁作为第 4 项结构变更登记）。

证据纪律与复现说明

- 本文为工程治理设计论文，无新增实验；三条件门禁、[structural] 标注规则、F19-a/b 判据均为设计提案，合入率与事故数改善为 [RESULT NEEDED]，禁止写成实测收益。
- Ouroboros 的 Terminal-Bench 86.97%/86.74% 为自报告 SOTA，未独立复核，仅作结构参照。
- P12 版本号事故为 v7.5.0 已记录事件，本文只引用其教训，不重新定性细节。
- 门禁对”断言是否真覆盖被改结构”的人工相关性评审是固有缺口，本文如实标注、不声称已自动闭环。