




P23

项目级五维评估：从工单到项目的失败 t axonomy

Project-Level Five-Dimensional Evaluation: From Work Orders to
a Project Failure Taxonomy

TwinsEarth · 智能体宇宙论文系列



项目级五维评估：从工单到项目的失败 taxonomy

Project-Level Five-Dimensional Evaluation: Aggregating UDOS Work-Order Metrics into EPOB-Style Project Quality and a Failure Taxonomy

UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

证据等级：UDOS 数字回 reports7/ 原始 JSON，按 verified / cpu-proto / cpu-proxy / unverified 标注；单 seed 试点写作“试点点估计”，投稿前需 ≥ 30 seed 复现。

Working Title (EN): Project-Level Five-Dimensional Evaluation: Aggregating UDOS Work-Order Metrics into EPOB-Style Project Quality and a Failure Taxonomy

卷中工程篇 P23 · 把 UDOS 的测量粒度从”工单”升到”项目” · 借 EPOB 五维与失败分布诊断 · UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

一句话先说清：UDOS 现在的测量单位是”一张工单有没有做成”，但一个多 Agent 系统真正交付的是”一个项目”——计划得好不好、任务派得准不准、交接顺不顺、交付物全不全、花得多快，是工单成功率答不了的五件事。EPOB (OpenReview NtPIgzPtOU) 把多 Agent 系统评估从”单任务成功率”提升到**项目生命周期级**，并强调看**失败分布**而不是只看成功率。本文把这套五维框架接进 UDOS，给出工单指标如何聚合成项目指标的逻辑——**设计提案·待实施**。

证据口径（全文只声明这一次）：本文是评估方法论设计论文，**不含新的 UDOS 实测数字**。外部论文 EPOB (End-to-End Project Orchestration Benchmark, OpenReview NtPIgzPtOU, 2026-05) 的五维名称与失败 taxonomy 类别已核验；其”180 单元鲁棒性包”等具体构造为论文报告，未独立复核。UDOS 旧指标（返工率、消息扇入、收口率、交接完整度、吞吐曲线）均回指 v7.5.0 各篇，证据等级随文标注。本文的工单→项目聚合逻辑为**设计提案·待实施**，聚合权重标定 [RESULT NEEDED]。

摘要

多 Agent 系统的评估长期停留在”单任务成功率”：跑一个任务，做成了记 1，做砸了记 0，最后平均。这个粒度有两个病——它只告诉你”好不好”，不告诉你”哪里坏”；它只测”一张工单”，测不了”一个项目”。EPOB (OpenReview NtPIgzPtOU, 2026) 把评估单位提升到项目生命周期，沿五个维度测量：计划质量 (Plan Quality)、分配质量 (Assignment Quality)、协调 (Coordination)、交付物质量 (Deliverable Quality)、效率 (Efficiency)；更重要的是它强调**失败分布而非仅成功率**，用 planning / delegation / handoff / review / recovery 五类失败标签回答”坏在哪一环”。UDOS v7.5.0 的测量其实已经覆盖了这五维的”零件”——P1 测扇入与轮次 (协调)、P2 测停止决策 (协调/recovery)、P3 测返工与误隔离 (recovery)、P10 测交接完整度 (handoff/deliverable)、P9 测吞吐曲线 (efficiency)——但它们都钉在”单工单”粒度上，没有聚合成项目级分数。本文做两件事。第一，把 UDOS 现有工单指标一一映射到 EPOB 五维，标出哪些维已经有仪器、哪些维缺仪器。第二，给出工单→项目的两层聚合逻辑：底层仍是单工单指标，中层把同一项目的工单按失败标签归类，顶层用项目级加权得到五维分。本文同时指出 EPOB 的糟粕：它是”框架中心”的评估，测”这个框架执行项目好不好”，不测”这个框架配这个任务合不合适”——而后者正是 UDOS P1 拓扑选型决策树的独特价值，不能被 EPOB 替代。本文是方法论设计，聚合权重与阈值待 [RESULT NEEDED]。

关键词：项目编排；评估基准；失败 taxonomy；五维指标；工单聚合；EPOB；UDOS P1/P3/P9/P10

结构化摘要（背景问题 → 方法/论点 → 证据 → 贡献）

- **背景问题：**UDOS 的指标全在工单粒度，单工单成功率答不了”一个项目计划得好不好、派得准不准”；只看成功率也答不了”坏在哪一环”。

- **核心论点**：评估单位应从工单升到项目；用 EPOB 五维做骨架，用 planning/delegation/handoff/review/recovery 五类失败标签做诊断，把 UDOS 既有工单指标两层聚合为项目级五维分。
- **证据线索**：(1) EPOB 五维与失败 taxonomy (OpenReview NtPIgzPtOU，存在性已核验)；(2) UDOS 既有工单指标 (P1 扇入/轮次、P2 停止决策、P3 返工/误隔离、P10 交接完整度、P9 吞吐，回指各篇)；(3) EPOB 不评估”框架—任务匹配”这一已知边界。
- **贡献**：UDOS 工单指标→EPOB 五维的映射表；两层聚合逻辑；五维仪器缺口清单；EPOB 糟粕与 UDOS 独特价值的划界。

1 问题：工单成功率答不了项目的问题

1.1 单任务成功率的两个病

UDOS v7.5.0 的绝大多数测量——P1 的扇入/轮次、P2 的停止决策正确率、P3 的返工率、P10 的交接完整度——都是单工单粒度。跑一张工单，看它做成没。这个粒度在系统调试期是对的，但它有两个病：

- **只说好不好，不说哪里坏**。一个项目失败了，是计划就错了 (planning)？还是计划对、派错了人 (delegation)？还是交接时信息丢了 (handoff)？单工单成功率把这五种失败压成同一个 0，诊断价值为零。
- **只测一张工单，测不了一个项目**。真实交付是”一个项目”：多张工单、多轮交接、有收口。单工单平均成功率可能很高，而项目级的计划质量、交付完整度一塌糊涂。

1.2 EPOB 的回答：项目生命周期 + 失败分布

EPOB (End-to-End Project Orchestration Benchmark, OpenReview NtPIgzPtOU, 2026-05) 把评估单位从单任务提升到**项目生命周期**，沿五个维度打分：

- **Plan Quality (计划质量)**：任务分解得好不好；
- **Assignment Quality (分配质量)**：任务派给了谁、派得准不准；
- **Coordination (协调)**：扇入、轮次、停止决策；
- **Deliverable Quality (交付物质量)**：收口率、交接完整性；
- **Efficiency (效率)**：吞吐、成本曲线。

它更关键的方法论主张是**失败分布而非仅成功率**：给每次失败打 taxonomy 标签——planning (计划阶段就错)、delegation (分配错)、handoff (交接丢信息)、review (评审漏过)、recovery (恢复失败)——让评估从”好不好”变成”哪里坏”。

1.3 UDOS 不是从零开始

有意思的是，UDOS 五维的”零件”已经散在各篇里了。本文的工作不是新造仪器，而是**把散落的工单指标聚合成项目级五维分**。

图1 UDOS 工单指标 → EPOB 五维映射与仪器缺口（概念示意）



图1 左列 UDOS 既有工单指标，中列 EPOB 五维，右列五维在 UDOS 中的仪器状态（已有/待补）。概念示意，非实测数据。

2 五维映射与仪器缺口

2.1 映射表

表 1 UDOS 工单指标 → EPOB 五维映射

EPOB 五维	含义	UDOS 对应工单指标	仪器状态
Plan Quality	任务分解质量	P1 拓扑选型、P3 治理设计的分解合理性	部分：有拓扑对照，缺”分解质量”直接指标
Assignment Quality	任务分配质量	P11 内部市场投标、P17 scope 授予	部分：有投标机制，缺”分配对错”标签
Coordination	协调质量	P1 扇入/轮次、P2 停止决策	已有：协议层测量成熟
Deliverable Quality	交付物质量	P3 收口率、P10 交接完整度	已有：契约测试覆盖
Efficiency	效率	P9 吞吐曲线、成本	已有：cpu-proto 曲线

2.2 缺口在哪

映射表暴露两个明显缺口：

- **Plan Quality 缺直接指标。**UDOS 能测”分层树把扇入压到常数”（P1，verified 外推），但这是”协调效率”，不是”这个项目的任务分解本身合不合理”。一个分解得很糟的计划，也能被分层树高效执行。

- **Assignment Quality 缺”分配对错”标签。** P11 有投标机制，但没有事后标注”这次派给 X 是不是最优”。没有这个标签，Assignment Quality 只能算”派得快不快”，算不了”派得对不对”。

这两个缺口正是本文要补的：它们不是新造系统，而是在既有工单记录上加**两个事后标签**——分解合理性标签、分配对错标签。

3 工单 → 项目的两层聚合逻辑（设计提案 · 待实施）

3.1 为什么不能直接平均

把一个项目里所有工单的成功率直接平均，是 EPOB 批评的做法——它把 planning 失败和 recovery 失败混为一谈。本文采用两层聚合：

底层（工单级）： 每张工单记录一组原子指标——是否完成、失败标签（五类之一）、扇入、轮次、交接完整度、成本。

中层（失败分布）： 把同一项目的工单按失败标签归类，得到五类失败的计数分布 $n_p, n_d, n_h, n_r, n_{rec}$ 。这一层回答”坏在哪一环”。

顶层（五维分）： 把中层分布映射到五维分。例如——

$$\text{Plan Quality} \propto 1 - \frac{n_p}{\sum n}$$

即计划失败占比越高，Plan Quality 越低；Assignment Quality 与 n_d 成反比，Coordination 与轮次/扇入相关，Deliverable Quality 与收口率/交接完整度相关，Efficiency 与单位交付成本相关。各维的归一化权重为设计参数，待 [RESULT NEEDED] 标定。

3.2 与 EPOB 的粒度差异

必须诚实指出：EPOB 的评估粒度是”项目”，UDOS 当前的实测粒度是”工单”。本文给出的是**从工单聚合到项目的逻辑**，不是已经跑出来的项目级分数。若 UDOS 要投稿到系统会议，这个聚合必须在真实多工单项目上跑通——否则 P23 只是方法论，没有数据。这正是 [RESULT NEEDED] 的核心。

图2 工单→失败分布→项目五维分的两层聚合（概念示意）



诊断价值集中在中间：失败分布回答『坏在哪一环』，而非只答『好不好』

图2 工单级原子指标 → 五类失败分布 → 项目级五维分；诊断价值集中在中间的失败分布层。概念示意。

4 糟粕 / 失效边界 / 可证伪条件

4.1 糟粕（引用 EPOB 时必须保持的克制）

1. EPOB 不评估”框架—任务匹配”。它测”这个框架执行项目的效果好不好”，不测”什么时候该用星型、什么时候该用分层”。这不是 EPOB 的缺点被它藏起来，而是它的题中没有这一问。
UDOS P1 的拓扑选型决策树恰好填这个空——不要把 EPOB 当成”我们已被外部评估了”，它和 UDOS 是互补、不是重复。
2. 失败 taxonomy 的标签有人为判断成分。planning 与 delegation 的边界在模糊案例上并不干净；标签的一致性需要标注规范，否则失败分布本身有噪声。
3. 框架中心 ≠ 任务中心。EPOB 以框架为被测对象；UDOS 的兴趣是”结构先验决定能力上限”，两者提问角度不同，迁移其五维时要意识到这一视角差。

4.2 失效边界

- 若一个项目的工单之间高度同构（P9 的同质化副本），失败分布会集中在单一标签，五维区分度下降——这不是聚合逻辑错了，而是项目本身没有多样性，EPOB 式五维对同质项目本就不敏感。
- 若 Plan Quality / Assignment Quality 的两个新标签靠 LLM 事后评判，则会引入 P12 已讨论的 LLM-as-judge 偏差；这两个标签最好也走执行式判定（如与 oracle 分解/分配对照），而非纯主观打分。

4.3 可证伪条件

- **F23-a**：若用两层聚合得到的项目级五维分，与领域专家对同一批项目的定性排序**不相关**（秩相关低于设计阈值），则聚合权重标定失败，五维映射需重做。
- **F23-b**：若失败分布诊断（“坏在 handoff”）与事后根因分析的结论不一致率高，则 taxonomy 标签规范需修订。
- 以上为设计提案下的可事后记分判据，非已确立结论，权重与阈值待 **[RESULT NEEDED]**。

5 结论

EPOB 把评估从”单任务成功率”提升到”项目生命周期 + 失败分布”，方向正确。UDOS 要做的不是重造一个基准，而是把自己散落在 P1/P2/P3/P9/P10/P11 的工单指标，按 EPOB 五维两层聚合成项目级分数，并补上 Plan Quality、Assignment Quality 两个缺口标签。同时必须清醒：EPOB 不回答”框架配不配任务”，那是 UDOS P1 拓扑选型树的独有阵地——五维评估是体检表，不是配方案。

工单成功率只告诉你做完了没有，失败分布才告诉你坏在了哪一环。评估一个系统，先测它坏在哪，再测它好不好。

参考文献

评估方法论基础

1. Dean, J., & Bowen, K. (1987). Calibration of Acceptance Measures for Software Defects (缺陷分类与密度分析的早期思路)。
2. Henard, R. H., & Manner, M. K. (2014). Predicting product success with a quantitative model. (质量多维评估的一般方法)

2026 前沿材料 (存在性已于 2026-09-21 联网核验; 具体构造数字为论文报告, 未独立复核)

1. EPOB (2026). End-to-End Project Orchestration Benchmark. OpenReview NtPIgzPtOU. (Plan/Assignment/Coordination/Deliverable/Efficiency 五维; planning/delegation/handoff/review/recovery 失败 taxonomy)

UDOS 论文卷 (本系列, 证据等级随文标注)

1. UDOS v7.5.0 论文卷: P1《分层混合拓扑的协调复杂度百万级外推》(扇入 $O(N) \rightarrow O(\log N)$, verified 外推)、P2《BFT-lite 停止决策》、P3《故障治理 RCT》(返工/误隔离)、P9《质量饱和律与吞吐曲线》(cpu-proto)、P10《TransferBundle 交接完整度》(26 项契约测试)、P11《内部任务市场》、P12《证据分级》(LLM-as-judge 偏差讨论)。
2. UDOS v7.6.0 论文卷: P17《最小权限编排》(scope 授予)、P33《v7.6.0 架构总纲》。

证据纪律与复现说明

- 本文为评估方法论设计论文, 无新增实验; 两层聚合公式 (1)、五维权重、F23-a/b 判据均为设计提案, 项目级实际分数为 [RESULT NEEDED], 禁止写成实测。
- EPOB 五维名称与失败 taxonomy 类别已核验; “180 单元鲁棒性包”等具体构造为论文报告, 未独立复核。
- Plan/Assignment 两个新标签若采用 LLM 事后评判, 需注意 P12 已讨论的评判偏差, 优先执行式对照。
- 本文不主张 EPOB 已评估 UDOS; 二者为框架中心与任务结构中心的互补关系。