





P26

加权 BFT 与声誉：从等权 $2f+1$ 到按可信度赋权的停止决策设计方向

Weighted BFT and Reputation: From Equal-Weight $2f+1$ to Credibility-Weighted Stop Decisions — A Design Direction

TwinsEarth · 智能体宇宙论文系列



加权 BFT 与声誉：从等权 $2f+1$ 到按可信度赋权的停止决策设计方向

Weighted BFT and Reputation: From Equal-Weight $2f+1$ Quorums to Credibility-Weighted Stop Decisions — A Design Direction, Not an Implementation

UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

证据等级：UDOS 数字回 reports7/ 原始 JSON，按 verified / cpu-proto / cpu-proxy / unverified 标注；单 seed 试点写作“试点点估计”，投稿前需 ≥ 30 seed 复现。

Working Title (EN): Weighted BFT and Reputation: From Equal-Weight $2f+1$ Quorums to Credibility-Weighted Stop Decisions — A Design Direction, Not an Implementation

共识治理篇 P26 · v7.5.0 P2 《BFT-lite 停止决策》的权重维度 · 与 P16（类型化最终性）、P31（故障安全恢复）互为姊妹篇 · UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

一句话先说清：v7.5.0 P2 的委员会是一人一票、等权的 $2f+1$ 法定人数——7 个 QA 里谁的票都一样重。这在”所有成员能力相当、错票独立”时是对的；但真实 LLM 委员会里，成员质量参差、历史表现有迹可循。本文讨论一个设计方向：把”等权法定人数”升级为”按历史可信度赋权的法定人数”，并盘点近期加权 BFT / 联盟治理 / 思维证明共识三条线索——但明确声明：**UDOS 当前没有实现加权投票，所有收益为设计假设，标 [RESULT NEEDED]**。

证据口径（全文只声明这一次）：UDOS 侧数字全部回 v7.5.0 P2 (cpu-proto / verified)。本文提到的近期工作——加权 BFT (WBFT 类)、CP-WBFT、COALITION-VAST、BlockAgents (Proof-of-Thought) ——均来自用户提供的研究线索，其精确数字未在 **v7.6.0** 证据台账 (EVIDENCE_LEDGER_v76.md) 中逐条核验，凡引用具体百分比/阈值一律标注”线索口径·未核验”或 [CITATION NEEDED]，不作为事实。等权 $2f+1$ 与 view change 的安全性来自经典 PBFT (Castro & Liskov, 1999)。核验日 2026-09-21。

摘要

v7.5.0 P2 用等权 BFT-lite 守住了 LLM 验收委员会的”不错停”底线： $n \geq 3f+1$ 、法定人数 $q = 2f+1$ 、equivocation 整轮作废、超 f 沉默转 view change。等权设计有一个干净的安全性证明——诚实票只有 $n - f \geq 2f+1 = q$ 张，不可能让 STOP 与 CONTINUE 各自凑齐 q 。但这个证明隐含一个假设： **f 个拜占庭成员是”最坏情况下均匀分布的少数派”**，且所有诚实成员投票权重相同。真实 LLM 委员会不满足后者：有的 QA 历史准确率高，有的经常越权或模棱两可；把这两类成员的票算得一样重，等于浪费了”谁更可信”这一免费信号。

本文沿三个方向盘点”等权 $\rightarrow$ 加权”的设计空间，而非实现它。第一，**按历史可信度赋权** (WBFT 类思路)：把每个成员的投票权重绑定到它过往的验收准确率，使不可靠成员的票对法定人数贡献更小；其代价是引入了”权重如何更新、如何防止权重被操纵”的新攻击面。第二，**联盟治理与定向审计** (COALITION-VAST 类思路)：当拜占庭行为不是单点作恶、而是少数成员**结盟**诱导一致时，等权多数票恰恰是被结盟利用的目标；这类工作用联盟博弈+链上规则演化+信任驱动的定向审计来发现”共谋的一致”。第三，**把思维过程变成共识对象** (BlockAgents 的 Proof-of-Thought)：不只对最终标签投票，而是对”推理过程”做投票与质押，使中毒/后门攻击更难隐藏。

本文的结论是克制的：**加权与声誉是 P2 等权设计的自然下一维，但它是设计方向而非已实现**。等权 $2f+1$ 的证明之所以干净，正因为它不依赖任何”权重估计”的正确性；一旦引入权重，安全性就从”纯组合”变成”组合 $\times$ 权重估计质量”两个变量的乘积，H-CSC v2 的撤回教训（学习型模块在公平基线下更糟）恰好警告我们：不要急于把”看起来更聪明”的加权逻辑塞进安全关键路径。所有加权方案的收益一律 [RESULT NEEDED]。

关键词：加权 BFT；声誉权重；法定人数；联盟治理；思维证明；停止决策；设计方向

结构化摘要（背景问题 → 论点 → 证据 → 贡献）

- **背景问题：** P2 的等权 $2f + 1$ 假设”所有诚实成员等权、拜占庭均匀分布”，但真实 LLM 委员会成员质量参差，“谁更可信”这一信号被等权设计浪费；同时拜占庭行为可能从单点作恶升级为**结盟诱导一致**，等权多数票反而是结盟的目标。
- **核心论点：** 把等权法定人数升级为按历史可信度赋权，是 P2 的自然下一维；但加权把”纯组合安全性”变成”组合 $\times$ 权重估计”，新增了权重更新与权重操纵的攻击面，因此它应作为**设计方向**被谨慎探索，而非立即替换已验证的等权委员会。
- **证据线索：** (1) 经典 PBFT 的等权 $2f + 1$ 安全性（Castro & Liskov, 1999）；(2) UDOS P2 在 $n = 7, f = 2$ 下 10 项属性测试与 24 工单端到端（cpu-proto / verified）；(3) WBFT / CP-WBFT / COALITION-VAST / BlockAgents 三条近期线索（**数字未核验**）；(4) H-CSC v2 的自我撤回（加权/聚合模块须过钢铁人对照）。
- **贡献：** (i) 形式化”等权 → 加权”的设计空间与代价；(ii) 把拜占庭威胁从”单点作恶”扩展到”结盟诱导一致”；(iii) 明确列出加权方案的安全性质清单与 **[RESULT NEEDED]**；(iv) 声明 UDOS 当前不实现加权，仅作方向登记。

1 起点：等权 $2f + 1$ 的干净证明与它的假设

1.1 为什么 P2 选等权

v7.5.0 P2 的安全性证明之所以能写成 10 项可 CI 的属性测试，是因为它故意选了**最简单的投票模型**——等权一人一票。其核心证明（verified）：

$$\text{诚实票数} = n - f \geq 3f + 1 - f = 2f + 1 = q$$

在 $n \geq 3f + 1$ 下，诚实票最多只有 q 张，因此 STOP 与 CONTINUE **不可能各自凑齐 q 张诚实票**——这就是”最多一个决定值”的安全性。这个证明不依赖任何关于”谁更准”的估计，它是纯组合的。P2 主动披露：它的签名是 SHA-256 哈希占位、不抗真实伪造，且**语义共因故障会击穿多数票**。

1.2 等权浪费了什么

等权假设”所有诚实成员一样可信”。但在真实 LLM 委员会里，这个假设常不成立：

- 成员 A 历史验收准确率高、从不模棱两可；
- 成员 B 经常给出”勉强通过”、偶尔越权把不该停的工单勾成通过；
- 成员 C 是新加入的，没有历史。

等权设计把 A 与 B 的票算得一样重。这意味着：要凑齐 $q = 2f + 1$ ，你必须”信任足够多的人”，哪怕其中一部分已知不可靠。**权重是一个免费信号——它告诉你”凑 q 时，不必把每个人都算进去”**。这正是加权 BFT 的直觉来源。

但请同时注意第 1.1 节的证明为什么干净：它**不需要任何关于权重的估计**。这是一个交易——用”安全性证明的简洁”换”利用可信度信号的能力”。本文剩下的篇幅，就是把这笔交易的两边都算清楚。

2 方向一：按历史可信度赋权（WBFT 类）

2.1 设计直觉

设成员 v_i 的历史可信度为 $w_i \geq 0$ ，法定人数从”票数”改为”权重和”：

$$\sum_{i \in S} w_i \geq Q, \quad Q = 2f + 1 \text{ 权重单位 (设计提案)}$$

直觉上，不可靠成员的 w_i 小，凑齐 Q 时主要靠高可信度成员的票；这样一来，同样的 n 下，需要被”说服”的高可信度成员更少，拜占庭更难操纵停止决定。近期的加权 BFT 线索（用户研究中称为 WBFT 类，IEEE TCCN 方向，具体算法细节与数字未在本台账核验，[CITATION NEEDED]）正是把投票权重绑定到每个 LLM 的历史响应质量与可信度，以激励可靠行为、降低恶意节点影响。另有线索称 CP-WBFT (AAAI 2026 方向) 可容忍高比例故障节点——其”85.7% 故障率”等说法为用户线索转述、未核验，本文不采信为事实。

图3 等权法定人数 → 按可信度赋权（概念示意，非实测）



图3 P2 一人一票（左）与按历史可信度赋权（右）的对比；权重引入权重更新/冷启动/equivocation 交互三个新攻击面。概念示意，非实测数据。

2.2 这笔交易的代价

加权不是免费的。引入 w_i 后，安全性从”纯组合”变成：

安全性 = 组合正确性 × 权重估计正确性

具体新增三个攻击面：

- 权重更新的操纵：**拜占庭成员可以”前期表现良好刷权重、关键时刻作恶”——权重是历史，作恶可以滞后。
- 冷启动：**新成员 w_i 未定，要么给 0（无法参与）要么给默认值（等于等权）。
- 权重与 equivocation 的交互：**P2 的 equivocation 整轮作废是纯规则的；加权后”整轮作废是否清零其权重贡献”需要重新定义。

UDOS 的立场：权重更新**必须用规则谓词**（如滚动窗口内与委员会最终决定的一致率），不能用学习模型动态估计权重——这直接来自 P32 的红线（H-CSC v2 证明学习编码器在对抗场景被规则谓词击败）。在 P2 的属性测试套件扩展、并跑通钢铁人对照之前，UDOS **不实现**加权投票。

3 方向二：结盟治理与定向审计（COALITION-VAST 类）

3.1 从”单点作恶”到”结盟诱导一致”

P2 的故障模型假设 f 个拜占庭成员是**独立作恶的少数派**。但 H-CSC v2 与 P2 的”语义共因故障”警告指向一个更危险的形态：**少数成员结盟，共同诱导多数成员对同一个错误结果达成”看起来一致”的标签**。此时等权多数票**恰恰是被利用的目标**——结盟者要做的不是阻止凑齐 q ，而是**帮着凑齐 q** ，让系统把错误结果高置信收口。

这正是为什么 P2 二元决策危险：它只问”有没有凑齐 STOP”，不问”这个 STOP 是诚实的一致还是被诱导的一致”。P16 的三级类型化最终性给了”语义核心是否真一致”一个出口；但如果结盟者连语义核心都伪造得一致呢？

3.2 联盟博弈 + 定向审计

近期的联盟治理线索（用户研究中称 COALITION-VAST, IEEE 2026-08 方向，**数字未核验**, [CITATION NEEDED]) 针对的正是这种”联盟偏离、治理捕获、仓促规则变更”。其思路：用联盟博弈识别”哪些成员的投票存在合谋模式”，用链上规则演化防止治理被仓促篡改，用信任驱动的**定向审计**（只审最可疑的子集，而非全量重审）把审计成本压下来。用户线索称其在医疗资源分配、自主蜂群、多利益相关方金融三场景下对齐度约 0.90 对比基线 0.69、未检出联盟偏离减少约 98%——**这些数字为线索转述、未在本台账核验，不作为事实**。

对 UDOS 的借鉴不是”抄一个治理框架”，而是一个**可证伪的设计原则**：停止决策的审计不能只看”是否凑齐法定人数”，还要看”凑法定人数的那些票，其投票者组合是否呈现合谋特征”。这一原则的实现需要 P16 的 C_1 （语义核心指纹）与 P3 的 Trace 哈希链作为底座，目前全部为 [RESULT NEEDED]。

4 方向三：把思维过程变成共识对象（BlockAgents / Proof-of-Thought）

4.1 不只对标签投票，对推理过程投票

等权 BFT 投票的对象是**最终标签**（STOP/CONTINUE）。一个更深层的线索是：把**推理过程本身**变成共识对象。用户研究中称 BlockAgents（上海交通大学团队，ACM Turing Award Celebration China 2024 方向）提出 Proof-of-Thought (PoT) 共识：结合基于质押（stake）的投票者指定与多轮辩论式投票，把中毒攻击对准确率的干扰压到低水平、后门攻击成功率压到低水平（**用户线索称 $<3\%$ / $<5\%$ ，未核验**, [CITATION NEEDED])。

直觉上，对”推理过程”投票比只对”结论”投票更难作弊——因为作恶者不仅要伪造结论，还要伪造一条”看似合理的推理链”，而链上各步可被独立检验。这与 P16 的 semantic_commit（对语义核心而非仅标签提交）在哲学上同源：**提交粒度越细，作弊成本越高，但聚合成本也越高**。

4.2 与 P16 的分工

P16 已经把”对语义核心提交”作为三级最终性的一级；BlockAgents 类的 PoT 则把”对推理链的每一步提交”推向更细。UDOS 的边界是：**细到哪一步才值得？** 对每一步推理做 $2f + 1$ 背书，成本是扇入的 $O(\text{步骤数})$ 倍，与 P1 的拓扑复杂度直接耦合。在实测证明”对推理链投票”相对”对标签投票”的错停率改善大于其成本之前，UDOS 只把它登记为方向，不实施。

5 三个方向的对照与取舍

表 1 等权 vs 三个加权/细粒度方向

方向	投票对象	新增信号	新增攻击面	安全性依赖	UDOS 立场
P2 等权 $2f + 1$	最终标签	无	最少	纯组合 (verified)	当前实现
方向一 WBFT 加权	标签 + 历史权重 w_1	成员可信度	权重操纵、冷启动	组合 $\times$ 权重估计	设计方向，不实现
方向二 COALITION-VAST	标签 + 合谋检测	投票者组合模式	审计成本	组合 $\times$ 合谋识别	设计方向，不实现
方向三 BlockAgents PoT	推理链各步	推理过程	扇入成本 $O(\text{steps})$	组合 $\times$ 过程检验	设计方向，不实现

图4 等权与三个加权/细粒度方向的取舍（概念示意）



图4 每个方向的投票对象、新增信号、新增攻击面与安全性依赖一览；每加一个信号，作弊成本与攻击面同增。概念示意。

表 1 传达的核心判断是：**每增加一个信号（可信度、合谋模式、推理过程），都在换取更高的作弊成本，同时引入新的攻击面与新的成本；安全性从”纯组合”退化为”组合 $\times$ 新信号的估计质量”。** UDOS 当前选择停在第一行（已被 10 项测试验证），把后三行登记为方向——这不是保守，而是因为 P2 的干净证明恰恰是它最宝贵的资产。

6 糟粕 / 失效边界 / 可证伪条件

糟粕（哪些不要做）：

1. 不要在安全关键路径上用学习模型动态估计权重。H-CSC v2 已证明学习编码器在对抗场景被规则谓词击败（AUROC 0.621–0.744 vs 0.865–0.982）；权重必须用规则谓词（滚动一致率）计算。
2. 不要把”加权更安全”写成已实现。UDOS 没有加权投票；任何收益都是设计假设，标 [RESULT NEEDED]。
3. 不要把用户线索里的百分比当事实。WBFT/CP-WBFT/COALITION-VAST/BlockAgents 的具体数字均未在 v7.6.0 台账核验，引用时必须带”线索口径·未核验”。

失效边界：

- 当历史权重 w_i 被”先刷后作恶”操纵时，加权委员会对滞后的作恶失去防御——权重是后视镜，看不见未来的背叛；
- 当结盟者连语义核心都伪造得一致时，“对过程投票”与”对标签投票”同样失效——PoT 只能提高作弊成本，不能消除共谋；
- 加权与细粒度过程投票的成本随委员会规模与步骤数增长，在超大规模下可能击穿 P1 的扇入预算。

可证伪条件：

- 若在钢铁人基线下，规则加权委员会的错停率不低於 P2 等权委员会，则方向一的收益假设被推翻；
- 若合谋识别在注入的结盟攻击上召回率不显著高于随机猜测，则方向二的设计原则不成立；
- 若对推理链投票的错停率改善幅度不足以覆盖其扇入成本，则方向三在 UDOS 场景下不具工程价值。

7 结论

P2 的等权 $2f+1$ 是一个被 10 项属性测试守住的”最小且干净”的停止委员会。本文沿三个方向（可信度加权、结盟治理、过程共识）盘点了它的自然下一维，却把结论写成”设计方向，不实现”。原因是一个朴素但常被忽略的判断：一个安全机制的证明有多干净，取决于它依赖了多少外部估计；等权 $2f+1$ 之所以能写成纯组合证明，正因为它不假设任何成员更可信。一旦引入权重或过程，安全性就变成”组合 × 新信号估计质量”的乘积——而 H-CSC v2 的撤回刚刚提醒过我们：那个新信号的估计，很可能在公平基线下比最简单的对手更糟。

先把已验证的等权委员会用稳，再用钢铁人对照谨慎地、一步一步地引入可信度信号；在那之前，加权是写在设计文档里的方向，不是跑在 consensus.py 里的代码。

参考文献

经典文献

1. Castro, M., & Liskov, B. (1999). Practical Byzantine Fault Tolerance. OSDI 1999. (等权 $n \geq 3f + 1$ 、 $2f + 1$ 法定人数、view change 的经典骨架；BFS 仅比未复制 NFS 慢约 3%)
2. Yin, M., Malkhi, D., Reiter, M. K., et al. (2019). HotStuff: BFT Consensus in the Lens of Blockchain. PODC 2019. arXiv:1803.05069.

2026 前沿线索（存在性/精确数字均未在 v7.6.0 台账核验；下列为用户研究线索转述，非事实）

1. 加权 BFT（WBFT 类，IEEE TCCN 方向）：按成员响应质量与可信度自适应分配投票权重。
[CITATION NEEDED: 精确算法与数字待核验]
2. CP-WBFT（AAAI 2026 方向）：用户线索称可容忍高比例故障；“85.7% 故障率”等说法未核验。[CITATION NEEDED]
3. COALITION-VAST（IEEE 2026-08 方向）：联盟博弈 + 链上规则演化 + 信任驱动定向审计；用户线索称对齐度 0.90 vs 0.69、联盟偏离 -98%。[CITATION NEEDED: 数字待核验]
4. BlockAgents（上海交通大学，2024 方向）：Proof-of-Thought 共识 + 质押指定投票者；用户线索称中毒 <3%、后门 <5%。[CITATION NEEDED: 数字待核验]

UDOS 论文卷（证据等级随文标注）

1. UDOS v7.5.0 P2《多智能体停止决策的 BFT-lite》（等权 $n \geq 3f + 1$ 、 $q = 2f + 1$ ，10 项属性测试 verified； $n = 7, f = 2$ ，24 工单 cpu-proto）。
2. UDOS v7.6.0 P16《类型化最终性》、P32《规则优先于学习》（姊妹篇；加权/聚合模块须过钢铁人对照，权重用规则谓词）。

证据纪律与复现说明

- 本文为设计方向登记论文，无新实验、无新实现；UDOS 当前 `udos7/topology/consensus.py` 仅实现等权 BFT-lite，未实现任何加权/合谋检测/过程投票。
- 三条近期线索（WBFT/CP-WBFT、COALITION-VAST、BlockAgents）均来自用户研究提供的线索，其精确数字未在 v7.6.0 证据台账逐条核验，一律标注“线索口径·未核验 / [CITATION NEEDED]”，不作为本文论证的事实基础。
- 所有加权方案的错停率/返工率/成本改善均为设计假设，标 [RESULT NEEDED]；未来若实施，必须先 P2 的 10 项属性测试套件上扩展、并跑通钢铁人对照（等权 vs 规则加权），投稿前需 ≥ 30 seed。
- P2 既有边界（SHA-256 哈希占位签名非密码学安全、未建模网络分区与自适应攻击者、语义共因故障击穿多数票）对本文三个方向全部成立且更严重——加权/过程投票不消除共因故障，只提高作弊成本。