





P29

测试时规模化协同：工具集成与极端分解投票

Test-Time Scaling of Multi-Agent Collaboration: The Diversity Axis and the Decomposition Axis, with TUMIX and MAKER

TwinsEarth · 智能体宇宙论文系列



测试时规模化协同：工具集成与极端分解 投票

Test-Time Scaling of Multi-Agent Collaboration: The Diversity Axis and the
Decomposition Axis, with TUMIX and MAKER

UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

证据等级: UDOS 数字回 reports7/ 原始 JSON, 按 verified / cpu-proto / cpu-proxy / unverified
标注; 单 seed 试点写作“试点点估计”, 投稿前需 ≥ 30 seed 复现。

Working Title (EN): Test-Time Scaling of Multi-Agent Collaboration: The Diversity Axis and the Decomposition Axis, with TUMIX and MAKER

卷中工程篇 P29 · 把”测试时扩展”拆成**多样性与分解**两个正交轴 · 对接 P9 质量饱和律 · UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

一句话先说清：模型不训练、只在推理时多跑几遍，为什么能变强？2025–2026 的三个工作把答案拆成两件事——TUMIX (arXiv:2510.01279) 证明**多样性**（并行用不同工具策略）有效；MAKER (arXiv:2511.09030) 证明**极端分解 + 逐步投票**（把百万步任务切到 microagent、每步多数投票纠错）能做到零错误。本文主张：这是两个正交的扩展轴，不是同一件事的两种说法；而 UDOS P9 的”独立信息”条件是这两条轴共同的隐藏前提。

证据口径（全文只声明这一次）：本文是方法综合论文，不含新的 UDOS 实测数字。外部三篇论文存在性已于 2026-09-21 联网核验；TUMIX 的”+3.55% “、MAKER 的”约 1,048,575 步零错误”、Thinking vs Doing 的”Gemma 3 12B 在 WebVoyager/WebArena 达开源 SOTA”均为**论文报告**，未独立复核；本文用它们说明”哪条轴在起作用”，不把数字当作 UDOS 预期收益。UDOS P9 质量饱和律回指 v7.5.0。

摘要

测试时扩展 (test-time scaling) 是 2025–2026 年大模型能力提升的第三条轴——不改权重、不堆参数，只在推理时花更多计算。本文主张：多 Agent 测试时扩展其实有两条**正交**的轴。第一条是**多样性轴**：并行跑多个 Agent、各自采用不同工具/策略，再集成。TUMIX (arXiv:2510.01279) 沿这条轴工作——并行多 Agent 用不同工具策略、迭代共享精炼，在 Gemini-2.5-Pro 上平均准确率最高 +3.55%，且近等推理成本（论文报告）。第二条是**分解轴**：把一个长任务极端分解到聚焦的 microagent，每步用多数投票纠错。MAKER (arXiv:2511.09030) 沿这条轴工作——极端分解 + k=3 多数投票，首次以零错误完成约 1,048,575 步（百万级）LLM 任务（论文报告）。Thinking vs Doing (arXiv:2506.07976, NeurIPS 2025) 则提示第三条、与前两条不同的轴——**交互长度轴**：通过课程式在线 RL 自适应调整 Agent 与环境的交互轮数，用仅 12B 的 Gemma 3 在 WebVoyager/WebArena 达开源 SOTA（论文报告）。本文的核心论点是：多样性轴受 P9 质量饱和律约束——多个并行 Agent 若工具策略同构、不携带独立信息，则集成收益迅速饱和；分解轴受”投票能否纠错”约束——k=3 多数投票只在单步错误率独立且低于阈值时有效，共因故障下投票失效。两条轴因此不是”越多 Agent 越好”，而是”多样性 × 分解深度”的联合设计。本文给出 UDOS 把两轴工程化的规格，效果待 [RESULT NEEDED]。

关键词：测试时扩展；多 Agent 集成；工具混合；极端分解；多数投票；独立信息；P9；TUMIX；MAKER

结构化摘要（背景问题 → 方法/论点 → 证据 → 贡献）

- **背景问题：**测试时扩展为什么能变强？业界常把”多跑几个 Agent”当成单一杠杆，但这掩盖了两个正交机制。
- **核心论点：**多 Agent 测试时扩展 = 多样性轴（异质工具策略集成）× 分解轴（极端分解+逐步投票纠错），外加交互长度轴；P9 的”独立信息”是前两轴共同的隐藏前提。

- **证据线索：**(1) TUMIX 工具混合 +3.55% (arXiv:2510.01279, 论文报告)；(2) MAKER 百万步零错误极端分解 (arXiv:2511.09030, 论文报告)；(3) Thinking vs Doing 交互长度扩展 (arXiv:2506.07976, 论文报告)；(4) P9 质量饱和律 $mse(k)=a+b/k$ (cpu-proto)。
- **贡献：**把测试时多 Agent 扩展拆成正交双轴；指出每轴各自的失效条件；把两轴对接 P9 的独立信息要求。

1 问题：测试时扩展不是单一杠杆

1.1 第三条扩展轴

训练时扩展（堆参数、堆数据、堆算力）之外，2025–2026 年出现了第三条轴：**测试时扩展**——冻结权重，只在推理时花更多计算。这条轴对多 Agent 系统尤其关键，因为它直接问”并行跑多个 Agent 为什么有用”。

1.2 常被混淆的两种”多 Agent”

直觉上”多跑几个 Agent 投票”和”把任务切成很多小步”像是同一件事的两种说法。本文主张它们不是：

- **多样性轴：**同一任务、并行多解、再集成。变量是”并行 Agent 的策略是否异质”。
- **分解轴：**单一任务、串行切步、逐步纠错。变量是”任务被切得多细、每步如何纠错”。

一个是横向铺，一个是纵向切。它们正交，可以叠加，也各自有失效条件。




图1 横轴多样性（并行异质 Agent）、纵轴分解深度（任务切分粒度+逐步投票）；三个代表工作各占位置。概念示意，非实测数据。

2 多样性轴：TUMIX 与独立信息条件

2.1 TUMIX 做了什么

TUMIX (arXiv:2510.01279, TUMIX: Multi-Agent Test-Time Scaling with Tool-Use Mixture) 并行运行多个 Agent, 各自采用不同的工具策略, 再迭代共享精炼。论文报告在 Gemini-2.5-Pro/Flash 上平均准确率较最佳基线最高 +3.55%, 且近等推理成本 (论文报告, 未独立复核)。

它的关键不是”多跑”, 而是”各用不同工具”。如果并行 Agent 用完全相同的工具与提示, 它们会给出高度相关的答案——这正是 P9 警告的同质化副本。

2.2 P9 条件：多样性必须携带独立信息

P9 的质量饱和律 ($mse(k)=a+b/k$, cpu-proto) 把多样性轴的代价写死了。设集成 k 个成员的均方误差:

$$mse(k) = a + \frac{b}{k}$$

其中 a 是不可约误差, b 由成员间的**独立度**决定。TUMIX 的 +3.55% 之所以成立, 正是因为”不同工具策略”抬高了 b (成员独立性); 如果把工具策略换成同质的, b 塌缩, 加再多并行 Agent 也只是把同一个错答案投 k 遍。

白话: 多样性轴的收益上限, 取决于你的并行 Agent 到底有多不一样, 而不是有多少个。

3 分解轴：MAKER 与逐步投票纠错

3.1 MAKER 做了什么

MAKER (arXiv:2511.09030, Solving a Million-Step LLM Task with Zero Errors) 把一个超长任务**极端分解** (MAD, Massive Decomposition) 到聚焦的 microagent, 每一步用多 Agent **多数投票**纠错, 并丢弃带红旗的相关错误。论文报告这是首个以**零错误**完成超过百万 LLM 步任务的系统 (约 1,048,575 步, k=3 多数投票; 论文报告, 未独立复核)。

它的关键不是”切得细”, 而是”**每一步都有独立纠错**”——单点 LLM 的持续错误率会随步数累积爆炸; 逐步多数投票把长程错误率压回可控。

3.2 投票何时有效、何时失效

多数投票的有效性有一个经典前提: 各步错误**近似独立**。若单步错误率为 p, k = 3 多数投票把错误率降到约 $3p^2(1-p) + p^3$, 当 $p < 0.5$ 时显著下降。但——

- **共因故障下投票失效**: 若所有 microagent 被同一个误导性输入带偏 (P2 识别的语义共因故障), k=3 会一致地错, 多数投票变成”一致地错得更自信”。这是分解轴的硬边界。
- **分解引入切分错误**: 切得太粗, microagent 仍面对长程依赖; 切得太细, microagent 之间的交接误差累积。最优分解粒度是设计参数。

白话：分解轴把”单点错误率”变成”逐步错误率”，但它救不了所有 Agent 一起被骗的情况。

4 第三条轴：交互长度（Thinking vs Doing）

Thinking vs. Doing (arXiv:2506.07976, NeurIPS 2025 SEA Workshop) 沿第三条轴工作——**测试时交互长度**：用课程式在线 RL 自适应调整 Agent 与环境的交互轮数（探索、回溯、动态重规划），论文报告仅用 12B 的 Gemma 3 在 WebVoyager/WebArena 达开源/公开数据 SOTA（较非微调 Agent 分别约 +9%/+8%，论文报告）。

这条轴既不是”并行几个”（多样性），也不是”切几步”（分解），而是”**同一个 Agent 与环境来回交互多久**”。它提醒我们：测试时扩展至少有三个可调维度——宽度（并行）、深度（分解）、时长（交互）。

表 1 测试时多 Agent 扩展的三轴对照

轴	变量	代表工作	失效条件	受谁约束
多样性（宽度）	并行 Agent 策略异质度	TUMIX (+3.55%)	工具策略同质 → 独立度 b 塌缩	P9 质量饱和律
分解（深度）	任务切分粒度 + 逐步投票	MAKER（百万步零错误）	共因故障 → 投票一致地错	P2 语义共因故障
交互（时长）	与环境交互轮数	Thinking vs Doing (Gemma3 12B)	交互长度无自适应 → 浪费或欠探索	课程调度设计

5 糟粕 / 失效边界 / 可证伪条件

5.1 糟粕（把测试时扩展神化的三个误读）

1. **+3.55% 不是普适提升**。TUMIX 的增益依赖任务类型与基线选择，换任务可能更小甚至消失；不要把单基准增量当成”多 Agent 万能”。
2. **百万步零错误 ≠ 长任务通用**。MAKER 的零错误建立在”每步可被 microagent 独立判定对错”的高度结构化任务上；语义验收型工单（含隐藏真值）没有这样的逐步 oracle，逐步投票无从落地。
3. **便宜小模型 SOTA ≠ 小模型够强**。Thinking vs Doing 用 12B 达开源 SOTA，靠的是测试时交互调度，不是模型本身变小了；把这读成”不用大模型”是误读。

5.2 失效边界

- 多样性轴与 P9 同质副本是同一枚硬币：**没有独立信息，宽度扩展无效**。
- 分解轴在**无逐步 oracle**的任务上无法纠错——UDOS 的语义验收工单恰恰缺逐步 oracle，这是分解轴在 UDOS 上落地的最大障碍。

5.3 可证伪条件

- **F29-a**: 若在 UDOS 工单上, 把并行 Agent 的工具策略从”异质”改成”同质”, 集成质量的下降幅度与 P9 的 b 塌缩预测一致, 则本文”多样性=独立信息”的论点成立; 若无关, 则需修正。
- **F29-b**: 若在引入共因故障注入后, 分解轴的多数投票纠错优势消失, 则”投票受共因故障击穿”的边界成立。
- 以上为设计提案下的可事后记分判据, UDOS 实际数字待 [RESULT NEEDED]。

6 结论

测试时扩展不是”多跑几个 Agent”这一个旋钮。它至少有三个轴: 宽度(多样性)、深度(分解)、时长(交互)。TUMIX 证明宽度轴靠”工具异质”换收益, MAKER 证明深度轴靠”极端分解+逐步投票”压错误, Thinking vs Doing 证明时长轴靠”自适应交互轮数”提表现。而 UDOS 的贡献是给这三条轴各自配上失效条件: 宽度受 P9 独立信息约束, 深度受 P2 共因故障约束。

测试时扩展不是”堆更多 Agent”, 而是在多样性 × 分解 × 交互三个方向上, 各自确认”这些 Agent 真的携带独立信息、真的能逐步被纠错”。堆人不解决问题, 堆得有区分度才解决。

参考文献

集成与测试时计算

1. Hansen, J. N., et al. (2024). Let's Verify Step by Step. OpenAI. (逐步推理/过程奖励的经典工作)
2. Brown, T. B., et al. (2020). Language Models are Few-Shot Learners (test-time prompting 的背景)。

2026 前沿材料 (存在性已于 2026-09-21 联网核验; 数字为论文报告, 未独立复核)

1. TUMIX (2025). TUMIX: Multi-Agent Test-Time Scaling with Tool-Use Mixture. arXiv: 2510.01279. (异构工具策略并行, Gemini-2.5-Pro 最高 +3.55%)
2. MAKER (2025). Solving a Million-Step LLM Task with Zero Errors. arXiv:2511.09030. (极端分解 + k=3 多数投票, 约 1,048,575 步零错误)
3. Thinking vs. Doing (2025). Agents that Reason by Scaling Test-Time Interaction. arXiv: 2506.07976, NeurIPS 2025 SEA Workshop. (Gemma 3 12B 在 WebVoyager/WebArena 达开源 SOTA)

UDOS 论文卷 (本系列, 证据等级随文标注)

1. UDOS v7.5.0 论文卷: P2 《BFT-lite 停止决策》(语义共因故障识别)、P9 《质量饱和律与同质化扩招失效边界》($mse(k)=a+b/k$, cpu-proto)。
2. UDOS v7.6.0 论文卷: P20 《异构性红利与同质性饱和》、P33 《v7.6.0 架构总纲》。

证据纪律与复现说明

- 本文为方法综合论文，无新增实验；三轴划分、失效条件、F29-a/b 判据为分析框架，UDOS 上的实际增益为 [RESULT NEEDED]，禁止写成实测。
- TUMIX +3.55%、MAKER 百万步零错误、Thinking vs Doing 的 Gemma3 12B SOTA 均为论文报告，未独立复核，仅用于说明”哪条轴在起作用”。
- $mse(k)=a+b/k$ 回指 P9 (cpu-proto)；共因故障边界回指 P2。
- 本文不主张测试时扩展可替代训练扩展；三轴是并列杠杆，不是替代关系。