



P32

# 规则优先于学习：对抗场景下确定性谓词与学习编码器的鲁棒性边界

Rules Before Learning: The Robustness Boundary Between  
Deterministic Predicates and Learned Encoders in Adversarial  
Safety-Critical Paths

---

TwinsEarth · 智能体宇宙论文系列



# 规则优先于学习：对抗场景下确定性谓词 与学习编码器的鲁棒性边界

---

Rules Before Learning: The Robustness Boundary Between Deterministic  
Predicates and Learned Encoders in Adversarial Safety-Critical Paths

UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

证据等级: UDOS 数字回 reports7/ 原始 JSON, 按 verified / cpu-proto / cpu-proxy / unverified  
标注; 单 seed 试点写作“试点点估计”, 投稿前需  $\geq 30$  seed 复现。

## Working Title (EN): Rules Before Learning: The Robustness Boundary Between Deterministic Predicates and Learned Encoders in Adversarial Safety-Critical Paths

共识治理篇 P32 · 全卷批判性旗舰 · 把 H-CSC v2 的自我撤回教训一般化为 UDOS 各校验点的设计原则 · 与 P16（类型化最终性）、P26（加权 BFT）、P31（故障安全恢复）互为姊妹篇 · UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

一句话先说清：在”决定要不要信一份 Agent 产物”的安全关键路径上，**不要默认”用神经网络做语义判断”比”用规则做机械校验”更高级**。H-CSC v2 的对抗实验证明：确定性词法一致性谓词的 AUROC（0.865–0.982）显著优于学习型语义编码器（0.621–0.744）。本文把这一负结果一般化为一条设计原则——**规则为底、学习为补**：所有安全关键校验（P2 停止、P10 交接、P12 证据分级）先用可解释、可复现、可 CI 的规则谓词打底，学习模型只能在规则已经守住底线之后作为”补充”，且必须过钢铁人对照才能进安全路径。

**证据口径（全文只声明这一次）**：核心外部证据为 H-CSC (arXiv:2606.07316, v2 改题 Certifiable Semantic Agreement Among LLM Agents: What the Admissibility Instrument Decides)，其”词法谓词 AUROC 0.865–0.982 胜学习 CRSE 编码器 0.621–0.744”与”主动撤回诚实保留优势（聚合距离 5.32°/5.48° vs 4.27°/4.32°、诚实保留 0.6475 vs 0.7325）”均为**论文报告、未独立复核**。UDOS 侧数字回 v7.5.0 P2/P10/P12 (cpu-proto / verified)。本文不新造实测；”规则优先”是设计原则，不是已在所有校验点跑过的对照实验。核验日 2026-09-21。

### 摘要

2026 年的多 Agent 工程有一种直觉性偏好：面对”两份自然语言到底语义一不一致”“这份交接到底完不完整”这类问题，第一反应是”训练/调用一个语义编码器来判断”——因为神经网络”更懂语义”。H-CSC v2 的对抗实验给出了一个**反直觉但关键的负结果**：在该文的对抗场景里，决定两份文本是否语义一致时，**朴素的确定性词法一致性谓词**（按约定关键词/短语集合做机械比对）AUROC 为 **0.865–0.982**，而**学习型 CRSE 语义编码器**（把文本编码到向量空间再算相似度）AUROC 仅 **0.621–0.744**。那个”更懂语义”的工具，在对抗条件下反而更差。

H-CSC v2 还做了一件更值得记录的事：它用更严格的钢铁人基线重检后，**主动撤回了自己 v1”过滤聚合保留了更多诚实内容”的主张**——其核心聚合距诚实中心 5.32°/5.48°，而钢铁人基线仅 4.27°/4.32°；对钢铁人 M3 的诚实保留率 0.6475 对比 0.7325，作者明文 “we withdraw it”。这两个负结果合在一起，指向一个 UDOS 必须写进设计纪律的判断：**在安全关键路径上，“学习型模块”不是默认更优解；它必须先证明自己在公平基线下、在对抗条件下，真的赢过最简单的规则对手。**

本文把这一判断一般化为”**规则为底、学习为补**”原则，并落到 UDOS 三个已存在的安全校验点：(1) P2 停止决策——equivocation 整轮作废、2f + 1 法定人数是纯规则，正确；若引入”学习型语义一致判断”来决定 stop 等级，必须先用规则词法谓词打底；(2) P10 TransferBundle——六字段机械校验本身就是规则谓词，这正是其 26 项契约测试 verified 的原因，**不要用学习模型”近似”替代六字段非空校验**；(3) P12 证据分级——verified / cpu-proto / cpu-proxy / unverified 的分级标准是规则，学习模型只能在分级完成后做”补充提示”，不能决定分级。本文同时划出这条原则的边界：**规则优先不是”规则万能”**——规则谓词

的覆盖范围有限，对规则看不懂的开放语义判断，学习模型是必要补充；原则是”规则守住安全底线，学习处理规则之外的灵活性”，而非”一切都用规则”。

**关键词：**规则谓词；学习编码器；对抗鲁棒性；钢铁人基线；负结果；安全关键路径；证据分级

## 结构化摘要（背景问题 → 论点 → 证据 → 贡献）

- **背景问题：**多 Agent 工程默认”语义判断用神经网络、规则只处理结构化字段”；但 H-CSC v2 的对抗实验显示，在对抗条件下学习语义编码器被朴素词法谓词显著击败（AUROC 0.621–0.744 vs 0.865–0.982），且其学习聚合模块在钢铁人基线下主动撤回了正面主张。
- **核心论点：**安全关键路径上应”规则为底、学习为补”——先用可解释、可复现、可 CI 的确定性规则谓词守住底线，学习模型只在规则守住底线后作为补充，且必须过钢铁人对照才能进入安全路径。
- **证据线索：**(1) H-CSC v2 的词法谓词 vs 学习编码器 AUROC 对比与主动撤回（论文报告）；(2) UDOS P2（equivocation 整轮作废为纯规则，verified）、P10（TransferBundle 六字段机械校验，26 项契约测试 verified）、P12（证据分级为规则标准）的现有设计。
- **贡献：**(i) 把 H-CSC 的单点负结果一般化为跨校验点的设计原则；(ii) 落到 P2/P10/P12 三个具体校验点给出”哪里必须纯规则、哪里可以补学习”；(iii) 划出”规则优先 ≠ 规则万能”的边界与可证伪条件。

## 1 一个被默认的直觉：语义判断就该用神经网络

### 1.1 直觉从哪来

在 LLM 工程里，有一种近乎默认的判断：“判断两份文本语义是否一致”是一个**语义理解问题**，而语义理解是神经网络的强项、规则的弱项。于是面对这类问题，工程上的第一反应几乎总是”上一个语义编码器”——把两段文本编码成向量，算余弦相似度，超过阈值就算一致。

这个直觉在**非对抗**场景里往往成立：训练分布内、没有攻击者刻意构造”字面不同但语义诱导一致”或”字面相同但语义被污染”的样本时，学习编码器确实比关键词匹配更懂语义。

### 1.2 但安全关键路径是对抗场景

问题在于：决定”要不要信一份 Agent 产物”的路径，恰恰是攻击者最想操纵的路径。攻击者不会按训练分布出牌——他会刻意构造”字面关键词都对、但语义被悄悄偏移”的文本，让学习编码器（它见过太多”关键词对=语义对”的样本）误判为一致。此时，那个”更懂语义”的学习模型，恰恰因为它学了太多统计关联，而对攻击者精心设计的样本更不敏感。

H-CSC v2 的实验正是在这个对抗场景里做的。它的结论对上述直觉是一记反转。

## 2 H-CSC v2 的两个负结果：本文的证据底座

### 2.1 词法谓词击败学习编码器

H-CSC v2 (arXiv:2606.07316v2, 论文报告、未独立复核) 在对抗场景下比较了两种”判断两份自然语言是否语义一致”的工具：

- **确定性词法一致性谓词**：按约定的关键词/短语集合做机械、确定性的比对；
- **学习型 CRSE 语义编码器**：用神经网络把文本编码到向量空间，再算相似度。

结果（论文报告数字）：词法谓词 AUROC **0.865–0.982**，学习编码器 AUROC **0.621–0.744**。朴素的规则工具，在对抗条件下显著优于”更懂语义”的学习模型。

为什么？一个合理的解释是：学习编码器的判断依据是**统计关联**，而攻击者的目标正是破坏这些关联——让”关键词对”与”语义对”解耦；词法谓词的判断依据是**显式约定的谓词**，攻击者要么满足谓词、要么不满足，没有”统计上接近”的模糊空间。在对抗博弈里，**明确、可预测、可被攻击者精确计算的规则**，反而比”模糊但看起来聪明”的学习模型更难被钻空子。

### 2.2 主动撤回：钢铁人基线下更糟

H-CSC v2 的第二个负结果比第一个更重要，因为它不是”别人的工具不行”，而是**作者对自己工具的自我否定**。v1 曾主张其”过滤聚合”在保留诚实内容上优于简单多数；v2 用**钢铁人基线**（给对比方一个更强、更公平的对手）重检后发现（论文报告）：

- 核心聚合距诚实中心：H-CSC **5.32°/5.48°**，钢铁人基线 **4.27°/4.32°**——更糟；
- 诚实保留率：对钢铁人 M3 为 **0.6475 vs 0.7325**——更糟；
- 作者明文：“**we withdraw it**”。

这个撤回的方法论价值在于：它示范了一个**学习型/聚合型模块**，在公平基线下可能不仅没收益，反而更糟。如果 H-CSC v2 没有做钢铁人对照、直接沿用 v1 的”我们更好”结论，这个负结果就永远不会被记录。UDOS 从这里学到的不是”别用学习模型”，而是——**引入任何学习型模块之前，必须先问：它的钢铁人对手是谁？它真的赢了吗？**

## 3 一般化：规则为底、学习为补

### 3.1 原则的表述

把 H-CSC v2 的两个负结果一般化为一条设计原则：

**规则为底、学习为补 (Rules as base, Learning as supplement)**

1. 安全关键路径（决定”信不信、停不停、收不收”的路径）的**底线**，必须由确定性、可解释、可复现、可 CI 的规则谓词承担；
2. 学习模型只在规则谓词已经守住底线之后，作为**补充**处理规则看不懂的开放语义判断；

3. 任何学习型模块若要进入安全关键路径，必须先在**钢铁人对照**下、在**对抗条件**下证明它优于最简单的规则对手；证明不了，就留在规则外面。

这条原则的理由不是”学习模型不好”，而是**可审计性与对抗鲁棒性的工程权衡**：规则谓词的每一次判断都能被人眼复盘、被 CI 复跑、被攻击者精确计算其边界；学习模型的判断是黑箱，在对抗条件下其失败模式难以预测。安全关键路径的第一要求不是”最聪明”，而是”出了问题能查到、能复现、能回归”。

图7 规则为底、学习为补：分层防护架构（概念示意）

安全关键路径：决定信不信 / 停不停 / 收不收




图7 底层为确定性规则谓词（安全底线），上层为学习模型补位，进入安全路径需过钢铁人对照门槛。概念示意。

## 3.2 为什么不是”一切都用规则”

这条原则有一个常被误读的对立面，必须先挡住：**规则优先不是规则万能**。规则谓词的覆盖范围有限——它只能判断”事先约定的那些谓词是否成立”；对规则看不懂的开放语义（比如”这份方案的论证是否自治”），学习模型是必要补充。原则不是”禁止学习模型”，而是”把学习模型放在规则防线的后面，而不是前面”。

## 4 落到 UDOS 三个校验点

### 4.1 P2 停止决策：纯规则部分是对的

v7.5.0 P2 的核心安全机制——equivocation 整轮作废、 $n \geq 3f + 1$ 、 $2f + 1$  法定人数、超  $f$  沉默转 view change——全部是**确定性规则谓词**。这正是它能写成 10 项可 CI 属性测试（verified）的原因：每一条都是”给定投票组合，规则机械地决定”。

P16 提议的三级类型化最终性（strong\_stop / weak\_stop / abort）在引入”语义核心是否一致”的判断时，**必须用规则词法谓词打底**，不能直接用学习语义编码器——H-CSC v2 已证明后者在对抗条件下 AUROC 更低。也就是说：P16 的 strong\_stop 判定，应优先用”语义核心指纹的规则比对”，学习模型只作为”规则不确定时的补充提示”，且不得单独决定 stop 等级。

4.2 P10 TransferBundle：六字段机械校验就是规则谓词

v7.5.0 P10 的 TransferBundle 交接契约要求六个字段非空且机械可校验，26 项契约测试 verified。这本身就是”规则为底”的范例——交接是否完整，不靠”语义上看起来传清楚了”，而靠”六个字段都在、格式都对”。

P10 的纪律应被明确写为：不要学习模型”近似”替代六字段非空校验。一个学习模型说”这份交接语义上完整”，无法替代”六个字段都在”这条可 CI 的硬断言。学习模型可以用来提示”这份交接虽然字段齐全、但语义上可能丢了上下文”，但它不能决定”交接是否合规”——合规与否是规则。

4.3 P12 证据分级：分级标准是规则

v7.5.0 P12 把证据分为 verified / cpu-proto / cpu-proxy / unverified 四级，分级标准是规则（跑没跑过 CI、是不是单 seed、是不是 cpu-proto）。这是规则为底的第三个落点：

- 学习模型可以用来”补充提示”——“这条证据的措辞看起来像 unverified，要不要复核”；
- 但分级本身必须是规则——verified 就是”跑过 CI 且  $\geq 30$  seed”，不接受”语义上感觉很可靠”。

P12 的版本号事故（v 前缀漏写导致的静默失败）之所以是反面教材，正因为它绕过了规则断言——如果分级是纯规则，“版本号格式不对”应当被机械拦截，而不是靠人眼发现。

5 规则与学习的分工表

表 1 UDOS 安全校验点：哪里纯规则、哪里补学习

| 校验点       | 安全底线（规则谓词，必须纯规则）                                | 学习模型可补位（规则之后）            | 依据                                           |
|-----------|-------------------------------------------------|--------------------------|----------------------------------------------|
| P2 停止     | equivocation 整轮作废、 $2f + 1$ 法定、 $n \geq 3f + 1$ | 规则不确定时提示 stop 等级         | H-CSC 词法谓词 AUROC 0.865–0.982 胜学习 0.621–0.744 |
| P16 三级最终性 | 语义核心指纹的规则比对                                     | 规则模糊时提示 strong/weak      | 同上；学习聚合须过钢铁人                                 |
| P10 交接    | TransferBundle 六字段非空 + 格式                       | 提示”字段齐但语义可能丢上下文”         | 26 项契约测试 verified                            |
| P12 证据分级  | verified/cpu-proto/cpu-proxy/unverified 规则标准    | 提示”措辞疑似 unverified，建议复核” | 版本号事故反例                                      |
| P3 故障治理   | 三级熔断阈值、kill-switch 规则                           | 提示”指标正常但方向可能跑偏”          | 规则可 CI、可复现                                   |

图8 UDOS 三个校验点：哪里纯规则、哪里补学习（概念示意）



决定 = 规则；学习只提示。版本号事故反例：绕过规则断言 → 静默失败

图8 P2/P10/P12 三个校验点：安全底线由纯规则承担，学习模型只做补位提示。概念示意。

表 1 的判断：所有”决定信不信、停不停、收不收”的硬判断，都由规则谓词承担；学习模型的位置在”提示”，不在”决定”。

## 6 糟粕 / 失效边界 / 可证伪条件

糟粕（哪些不要做）：

1. 不要把”规则优先”理解成”拒绝一切学习模型”。规则有覆盖范围，规则看不懂的开放语义必须靠学习模型补位；本原则是”学习在规则之后”，不是”不要学习”。
2. 不要在没做钢铁人对照的情况下，就把学习模块塞进安全路径。H-CSC v2 的撤回证明：学习模块在公平基线下可能更糟；不做对照就上，等于赌博。
3. 不要把”规则可解释”与”规则正确”混为一谈。规则谓词本身可能设计得太松（把攻击样本误判为通过）；规则优先要求规则被对抗测试覆盖，不是规则写了就算数。

失效边界：

- 当攻击者学会了精确模仿规则谓词的满足条件（字面全对、语义被污染），规则谓词同样会被钻空子——规则优先降低了”统计性操纵”的风险，但不消除”精确满足规则”的攻击；
- 学习编码器在非对抗、训练分布内场景可能确实优于规则；本原则只在安全关键、对抗路径上主张规则优先，不一般化到所有语义任务；
- H-CSC 的 AUROC 对比是该文对抗实验的结果，换一个攻击族、换一个谓词定义，结论可能不同——本原则是”设计纪律”，不是”学习模型在一切对抗场景都不如规则”的定理。

可证伪条件：

- 若在 UDOS 的对抗注入实验中，学习语义编码器在 stop 等级判定上的 AUROC 显著且稳定地高于规则词法谓词（在钢铁人对照下），则”P16 用语谓词打底”的假设被削弱，需重估；
- 若 TransferBundle 的学习式语义完整性判断，在 26 项契约测试之外能稳定检出规则漏过的交接丢失，则”六字段纯规则足够”的边界需扩展；

- 若证据分级的学习式自动分级在  $\geq 30$  seed 复现中错误率低于规则人工分级，则”分级必须纯规则”需松绑。

## 7 结论

H-CSC v2 给 UDOS 的最宝贵遗产不是它的类型化提交设计（那是 P16 的素材），而是它的两个负结果：在对抗场景下，朴素词法谓词击败了学习语义编码器；用钢铁人基线一照，作者自己的学习聚合模块被撤回。这两个负结果合在一起，比任何正面结论都更值得写进 UDOS 的设计纪律——因为它纠正了一个会被默认、却会在安全关键路径上付出代价的直觉：“语义判断就该用神经网络”。

本文的结论因此是克制而明确的：**规则为底、学习为补**。安全关键路径的底线，由可解释、可复现、可 CI、可被攻击者精确计算边界的规则谓词承担；学习模型在规则守住底线之后补位；任何学习模块想进入安全路径，必须先由钢铁人对照下、在对抗条件下证明它真的赢过最简单的规则对手。P2 的 equivocation 整轮作废、P10 的六字段机械校验、P12 的证据分级标准，已经是这条原则的具体实现——P16/P26/P31 引入的任何新机制，都必须先过这一关。

在决定”要不要信一份 Agent 产物”的地方，最聪明的工具不一定是安全的工具；一个能被复跑、能被复盘、能被 CI 回归的朴素规则，比一个黑箱里”更懂语义”的神经网络，更配站在安全关键路径上。

## 参考文献

### 经典文献

1. Castro, M., & Liskov, B. (1999). Practical Byzantine Fault Tolerance. OSDI 1999.（安全关键路径上规则化多数判断的经典骨架）
2. Vaswani, A., et al. (2017). Attention Is All You Need. arXiv:1706.03762.（学习型语义表示的来源；本文论点不是否定其能力，而是限定其在对抗安全路径上的位置）

### 2026 前沿材料（存在性已核验；数字为论文报告、未独立复核）

1. H-CSC 作者团队 (2026). Certifiable Semantic Agreement Among LLM Agents: What the Admissibility Instrument Decides (v2) . arXiv:2606.07316v2.（对抗场景下确定性词法谓词 AUROC 0.865–0.982 胜学习 CRSE 编码器 0.621–0.744；钢铁人基线下主动撤回诚实保留优势——聚合距离  $5.32^\circ/5.48^\circ$  vs  $4.27^\circ/4.32^\circ$ 、诚实保留 0.6475 vs 0.7325）

### UDOS 论文卷（证据等级随文标注）

1. UDOS v7.5.0 P2 《多智能体停止决策的 BFT-lite》（equivocation 整轮作废、 $2f+1$  法定为纯规则，10 项属性测试 verified）。
2. UDOS v7.5.0 P10 《AgentAsTool 与 TransferBundle 交接信息损失的可测量化》（六字段机械校验，26 项契约测试 verified）。
3. UDOS v7.5.0 P12 《证据分级驱动的可复现 Agent 系统工程》（verified / cpu-proto / cpu-proxy / unverified 规则分级；版本号事故反例）。

4. UDOS v7.6.0 P16《类型化最终性》、P26《加权 BFT 与声誉》、P31《故障安全与恢复》（引入新机制前须过规则谓词打底与钢铁人对照）。

## 证据纪律与复现说明

- 本文为设计原则论文，无新实验；H-CSC 的全部数字（AUROC 区间、聚合距离、诚实保留率）均为论文报告、未独立复核，且为 v2 主动撤回口径，本文严格采用 v2。
- “规则为底、学习为补”是一条**设计纪律**，不是“学习模型在一切对抗场景都不如规则”的定理；其失效边界（攻击者精确模仿规则、非对抗场景、换攻击族）已在第 6 节明确。
- UDOS P2/P10/P12 的现有规则设计为 cpu-proto / verified；本文提出的”P16 用语谓词打底、P10 不被学习近似替代、P12 分级纯规则”均为设计约束，其相对学习方案的优劣需在钢铁人对照下实测，标 **[RESULT NEEDED]**；投稿前需  $\geq 30$  seed。