



A0

Three Exemplar Reverse-Engineering Walkthroughs and Five Rounds of Thinking Drills

A0 · Reverse Engineering Three Top Exemplar Papers and a Five-Round Thinking Drill Report

TwinsEarth · 智能体宇宙论文系列

Three Exemplar Reverse-Engineering Walkthroughs and Five Rounds of Thinking Drills

Abstract — This report reverse-engineers three top-tier exemplar papers rather than summarizing from memory. Each source PDF was extracted page by page with PyMuPDF (get_text with sorting), and key figure and table pages were rendered to images and read directly to verify axes, three-line tables, and layout. Every number, section, and figure identifier comes from the source PDFs without extrapolation, and extracted artifacts are retained for audit. The goal is to internalize the structure of high-quality papers as reusable writing and analysis patterns.

Keywords: reverse engineering; exemplar analysis; PDF extraction; methodology; writing patterns; verification

孪生地球

A0 • 三篇顶级范本逆向拆解与五轮思维演练报告

版本：UDOS_论文全文 v7.5.0 / 阶段 A（范本逆向） 生成日期：2026-09-20（Asia/Shanghai, UTC+8） 方法学声明：本报告**不是凭记忆复述**。三篇 PDF 均由 PyMuPDF（PyMuPDF 1.28.2 / MuPDF 1.28.2）逐页 get_text("text", sort=True) 全文抽取，并对关键图表页做 get_pixmap 渲染后逐张读图核对（坐标轴、三线表、版式）。所有数字、章节号、图号均来自 PDF 原文，未做外推。 抽取产物留存：_work/kaplan.txt（30 页 / 124,762 字符）、_work/alexnet.txt（9 页 / 37,959 字符）、_work/nsa.txt（24 页 / 76,441 字符），及渲染图 _work/{alex,kap,nsa}_p*.png。

0. 三篇范本速览（一句话定位）

简称	真实题录（PDF 实测）	篇幅/版式	在本报告中的角色
AlexNet	Krizhevsky, Sutskever, Hinton. ImageNet Classification with Deep Convolutional Neural Networks. NeurIPS 2012. 9 页	双栏会议版式	"工程细节即科学贡献"范式：每一个 trick 都配数值化消融 + 误差率对照表
Kaplan	Kaplan, McCandlish, Henighan et al. Scaling Laws for Neural Language Models. arXiv:2001.08361v1, 2020. 30 页	单栏 arXiv + 显式目录 + A-D 附录	"控制变量 + 幂律拟合 + 趋势外推"范式：先抛结论、指数表收尾、专设 Caveats
NSA	Yuan, Gao, Dai ... Ruan, Zhang, Liang, Zeng. Native Sparse Attention: Hardware-Aligned and Natively Trainable Sparse Attention. arXiv:2502.11089v1, 2025（DeepSeek-AI × 北京大学 × U.W.）. 24 页	单栏 LaTeX 会议版式 + 三线表	"硬件约束→架构设计→端到端可训→逐层/逐任务对照"范式

重要勘误（按用户指令与 PDF 原件双重确认）：附件 DeepSeek论文2502.11089v1.pdf 实测题为 **Native Sparse Attention (NSA)**，**不是 DeepSeek-V3，也不是 DeepSeek-R1**。R1/V2/R1 仅出现在其参考文献与对比基线中。本报告与总库一律以 NSA 为准。

第一部分 · 逐篇逆向拆解

一、AlexNet (Krizhevsky/Sutskever/Hinton, NeurIPS 2012)

1.1 结构骨架与篇幅配比

全文 9 页、无显式目录、双栏。章节与篇幅实测如下：

节	标题	起止页	篇幅特征
—	Abstract	p1	单段，任务+头条数字+技术+战绩全塞一段
1	Introduction	p1–p2	从"小数据集时代"讲到"为什么要大模型+CNN"，结尾明确罗列 5 条 specific contributions
2	The Dataset	p2	数据划分、预处理（256×256 下采样、减均值）
3	The Architecture	p3–p5	3.1 ReLU / 3.2 Multi-GPU / 3.3 LRN / 3.4 Overlapping Pooling / 3.5 Overall。原文明说"3.1–3.4 按我们估计的重要性排序，最重要在前"
4	Reducing Overfitting	p5–p6	4.1 数据增强 / 4.2 Dropout
5	Details of learning	p6	SGD 超参、初始化、学习率调度
6	Results	p7	Table 1/2 + Fall2009; 6.1 Qualitative Evaluations (Fig3/Fig4)
7	Discussion	p8	收束
—	References	p9	[1]–[26]，编号制

配比观察：方法（3+4+5）约占 45%，结果（6）约 15%，引言（1）约 20%。**引言与方法几乎等量**——这是"工程贡献型"论文的典型：贡献本身就是一串工程决策，需要用引言把"为什么每个决策都重要"讲清楚。

1.2 摘要写法（逐句拆）

摘要一段、约 200 词，固定七拍：1. **任务**："We trained a large, deep CNN to classify the 1.2 million ... LSVRC-2010 ... into 1000 classes." 2. **头条数字**："top-1 and top-5 error rates of **37.5% and 17.0%** ... considerably better than the previous SOTA." 3. **规模锚点**："60 million parameters and 650,000 neurons ... 5 conv + 3 FC + 1000-way softmax." 4. **提速手段**："non-saturating neurons and a very efficient GPU implementation." 5. **抗过拟合手段**：dropout。 6. **竞赛战绩（第二锤）**："ILSVRC-2012 winning top-5 **15.3%**, compared to **26.2%** second-best."

套路：任务 → 双指标头条数 → 规模参数 → 两个技术关键词 → 一记竞赛胜负。数字全部进摘要。

1.3 引言论证套路

- **趋势论证**：小数据集（NORB/Caltech/CIFAR）→ 现实物体多变 → 必须更大数据 → ImageNet 15M/22k。
- **动机论证**：任务复杂到无法靠数据全指定 → 需要先验 → CNN 的局部性/平稳性先验正好。
- **可行性论证**：CNN 之前"prohibitively expensive" → 现代 GPU + 优化卷积使其可行。

- **贡献清单**：结尾 "The specific contributions of this paper are as follows:" 引出 5 条（最大模型、开源 GPU 实现、新结构特征、抗过拟合、深度重要）。
- **诚实收尾**："network's size is limited mainly by GPU memory and training time ... **All of our experiments suggest results can be improved simply by waiting for faster GPUs and bigger datasets.**"

1.4 相关工作组织

AlexNet **没有独立的 Related Work 章节**——相关工作被打散进引言与每个技术小节的"我们不是第一个"段落（如 3.1 引 Jarrett et al. 并区分他们观察的是防过拟合、我们观察的是提速）。这是 2012 年会议论文的常见做法，与 Kaplan/NSA 的独立 Related Work 形成对照。

1.5 方法/实验/结果/讨论分工

- **方法=贡献清单**：3.1–3.4 每个 trick 一节，**每节末尾必跟一句该 trick 带来的误差下降**（见 1.6）。
- **实验**：第 5 节只写"怎么训"（超参），不写结果；结果集中到第 6 节。
- **结果**：用对照表（Table 1/2）+ 一个跨数据集（Fall2009）+ 定性评估。
- **讨论**：两段，强调"深度真的重要"（删任一卷积层 -2%）与"没用无监督预训练但预期有用"。

1.6 可迁移论证范式（本篇提炼 9 条）

1. **工程细节即科学贡献**：ReLU、双 GPU 分裂、LRN、重叠池化、dropout、PCA 颜色扰动——全部包装成 novel feature，每条都有名字。
2. **每个 trick 配一个数值化消融**（原文逐字）：- 双 GPU 分裂："reduces top-1/top-5 by **1.7% and 1.2%**"; - LRN："reduces by **1.4% and 1.2%**"; CIFAR-10 上 13%→11%; - 重叠池化 (s=2,z=3 vs s=z=2)："reduces by **0.4% and 0.3%**"; - PCA 颜色增强："reduces top-1 by **over 1%**"; - dropout："roughly doubles the number of iterations to converge"（成本也照写）。
3. **公平性自曝**：脚注 2 主动承认 one-GPU 对比"is biased in favor of the one-GPU net, since it is bigger"——**主动披露对自己不利的偏倚**，换取审稿信任。
4. **以消融证明"深度不可少"**："removing any convolutional layer (each $\leq 1\%$ of params) resulted in inferior performance"，讨论里再量化为"中间层删除 $\approx -2\%$ top-1"。
5. **误差率对照表双列制**：Table 1/2 同时给 top-1 与 top-5；他人结果用斜体，自己用正体；跨数据集分表（2010 / 2012 / Fall2009）。
6. **定性图补定量之不足**：Fig3 展示学到的卷积核（GPU1 颜色无关 vs GPU2 颜色相关，**且与初始化无关**）；Fig4 用 4096 维特征做最近邻检索，证明"高层特征是语义的，不是像素的"。
7. **训练细节完整到可复现**：batch 128、momentum 0.9、weight decay 0.0005、权重初始化高斯 std=0.01、ReLU 偏置=1、LR 0.01 手动除以 10 三次、~90 epochs、2×GTX580 跑 5–6 天。
8. **反直觉发现写成卖点**："weight decay here is **not merely a regularizer**: it reduces the training error"。
9. **测试期集成零额外训练成本**：10-crop（四角+中心+水平翻转）平均，训练时 CPU 增广/GPU 训练并行="computationally free"。

1.7 图表清单（逐张，含坐标轴与自治性）

图/表	传达什么	坐标轴/基线/置信	图注自治度
Fig 1	ReLU vs tanh 收敛速度	折线图，纵轴 training error rate，横轴 Epochs；实线 ReLU/虚线 tanh； 图注明写"学习率各自独立调到最快、无正则化"	高：图注自带实验设置与适用边界（"effect varies with architecture"）
Fig 2	整体架构	三维等距示意图，标注各层神经元数 253440–186624–64896–64896–43264–4096–4096–1000；两 GPU 分工	高：图注解解释两 GPU 通信发生在哪些层
Fig 3	学到的滤波器	96 个 $11 \times 11 \times 3$ 卷积核可视化；上 48 GPU1 / 下 48 GPU2	高：直接对应 § 6.1 的 specialization 观察
Fig 4	定性评估	左：8 图+top-5 预测；右：5 查询图+6 个最近邻训练图	高：说明相似度度量（4096 维欧氏距离）
Table 1	ILSVRC-2010 测试集对比	三行：Sparse coding 47.1/28.2、SIFT+FVs 45.7/25.7、 CNN 37.5/17.0 ；斜体他人最佳	高：图注说明斜体含义
Table 2	ILSVRC-2012 验证+测试	列：Top-1(val)/Top-5(val)/Top-5(test)；1CNN/5CNNs/1CNN/7CNNs	高：*号预训练有脚注解解释

注意：AlexNet 的表格是朴素双栏小表，**不是现代 booktabs 三线表**。它靠"斜体=他人、正体=自己、数字列对齐"传达对比。这与 NSA 的三线表形成时代对照。

1.8 数据验证方法怎么写

- **划分**：ILSVRC = ~120 万训练 / 5 万验证 / 15 万测试；明说"ILSVRC-2010 是唯一有测试标签的版本，故主要实验在 2010 上做"。
- **指标定义**：top-5 error 当场定义（正确标签不在预测前五的比例）。
- **计算预算**：2×GTX580 3GB、5–6 天、90 epochs。
- **复现配置**：见 1.6 第 7 条，全部写明。
- **对照**：以同期 SOTA（sparse coding 集成、Fisher Vector）为基线，而非自比。

1.9 排版规范

双栏 NeurIPS proceedings；章节阿拉伯数字（1–7）；参考文献编号制 [n]、按出现顺序；公式行内（如 LRN 公式、SGD 更新式）；脚注用当页数字（脚注 1 给代码链接、脚注 2 披露偏倚、脚注 3 指向参数文件）。

二、Kaplan 2020 《Scaling Laws for Neural Language Models》

2.1 结构骨架与篇幅配比

全文 30 页、单栏 arXiv、正文前显式印出 Contents（目录）。章节实测：

节	标题	页	特征
1	Introduction (1.1 Summary=8 条结论 bullet; 1.2 Summary of Scaling Laws=公式; 1.3 Notation)	p1-6	先给全部结论，正文再证明
2	Background and Methods (2.1 参数量/算力; 2.2 训练过程; 2.3 数据集)	p6-7	
3	Empirical Results and Basic Power Laws	p7-10	形状无关、N 标度、LSTM 对比、跨分布泛化、D/C
4	Infinite Data Limit & Overfitting	p10-12	L(N,D) 方程+三条构造原理
5	Scaling with Model Size & Training Time	p12-14	Bcrit 修正、L(N,Smin)、早停下界
6	Optimal Allocation of Compute Budget	p14-17	理论推导 vs 实证对照; 6.3 自己找矛盾
7	Related Work	p18	独立一节
8	Discussion	p18-19	ideal gas law 类比收尾
A-D	附录: A 幂律汇总 / B 算力前沿推导 / C Caveats (6 条) / D 补充图	p20-30	专门的"局限"附录

配比观察：方法与实证（2-5）约占正文 60%，但引言（含 1.1/1.2）本身就把全部定量结论讲完了。附录（A-D）占 10 页、约 1/3 篇幅，承载全部汇总表与补充实验——主文"干净"、附录"扎实"。

2.2 摘要写法

单段约 150 词，核心句："The loss scales as a **power-law** with model size, dataset size, and compute ... with some trends spanning **more than seven orders of magnitude** ... architectural details ... minimal effects ... **Larger models are significantly more sample-efficient** ... optimally compute-efficient training involves training very large models on a relatively modest amount of data and stopping significantly before convergence."

套路：一句话范式 (power-law) + 一句话量程 (>7 数量级) + 一句话反直觉结论 (大模型更省、不必训到收敛)。

2.3 引言论证套路 (1.1 是范本中的范本)

1.1 Summary 用 **8 条 bullet** 先把 headline 结论全抛出来，**每条结尾括号标注出处小节**（如 "(Section 3)"），形成"结论地图"：- Performance depends strongly on scale, weakly on model shape; - Smooth power laws (>6 数量级、上端无偏离迹象)；- Universality of overfitting ($N^{0.74}/D$ 决定罚分)；- Universality of training (早期曲线外推预测长训)；- Transfer improves with test performance (常数 offset)；- Sample efficiency (大模型更省样本)；- Convergence is inefficient (应早停)；- Optimal batch size ($\approx 1-2M$ tokens)。

1.2 立刻给出**全部闭式方程** (1.1) - (1.8)，1.3 集中定义符号 (L,N,C,D,Bcrit,Cmin,Smin, α_X)。

2.4 相关工作组织

第 7 节独立成节，按"思想源头"聚类：幂律的多种来源、早期 dataset-size 幂律、与 [HNA+17] 的**显式分歧**（对方是超线性、本方是次线性 $D \propto N^{0.74}$ ）、EfficientNet 对比、over-parameterized generalization (jamming transition, 本方未观察到)。**敢点名分歧**。

2.5 方法/实验/结果/讨论/局限分工

- 方法=工程记账：Table 1 逐层算参数与 FLOPs；明确"excluding embeddings 才得到 clean trend"。
- 结果=图+拟合：每张图都是"散点+幂律拟合线"。
- 讨论=类比与展望：ideal gas law / "more is different"。
- 局限=C 节专设：6 条 Caveats 全部 bullet 化。

2.6 可迁移论证范式（本篇提炼 10 条）

1. **控制变量 + 幂律拟合 + 趋势外推**：固定 N 变 shape (Fig5)，固定 shape 变 N； $L(N) = (N_c/N)^{\alpha}$ 。
2. 以**"量程"**为核心卖点：>7 数量级、>6 数量级反复出现，用跨度增强可信度。
3. **结论前置（结论地图）**：1.1 八条 bullet + 括号指节，正文是"证明地图"。
4. **参数表驱动可复现**：Table 1 逐层参数/FLOPs；附录 A 的 Table 4/5/6 把所有指数与标度常数（ $\alpha_N=0.076$, $\alpha_D=0.095$, $\alpha_C=0.057$, $\alpha_{min}=0.050$, $\alpha_B=0.21$, $\alpha_S=0.76$ ； $N_c=8.8e13$ 等）**集中成查表**。
5. **理论→实证双向对账**：从 $L(N, S_{min})$ 解析推出 $\alpha_{minC} \approx 0.054$ （式 6.4），再与实测 ≈ 0.050 对照（"excellent agreement to within a few percent"）。
6. **反常识结论放大**："Big models may be more important than big data."；compute-efficient 训练只需在"收敛损失上方 ~10%"（ $\alpha_N/\alpha_S \approx 0.1$ ）处停；数据次线性增长 $D \propto N^{0.74}$ 。
7. **主动找自己的矛盾**：6.3 指出 $L(C_{min})$ 与 $L(D)$ 在 $C \sim 10^4$ PF-days、 $N \sim 10^{12}$ 、 $L^* \sim 1.7$ nats 处必然相交=定律将失效，并明说"数值高度不确定，量级上下浮动一个数量级"。
8. **专设 Caveats**：① 无理论；② Bcrit 外推无信心；③ 小数据区拟合差（epoch 仅 40 step）；④ 算力估计忽略 nctx 项；⑤ 可能漏调初始化/动量；⑥ 学习率对目标损失敏感。
9. **符号与定义纪律**：1.3 集中定义；强调 N 为"non-embedding parameters"，并用 Fig6 左右对比证明"含 embedding 时趋势被污染"——**把度量定义本身做成一张方法学图**。
10. **诚实的拟合质量自评**："the fits are imperfect ... quite compelling given the simplicity of Equation (5.6)"; 明确 1 层网络在拟合中被排除 (Fig13 的"lump")。

2.7 图表清单（约 21 图 / 6 表，挑核心）

图/表	传达什么	坐标轴/基线
Fig 1 (hero)	损失随 算力/数据/参数 三面板下降	log-log；色标=参数数
Fig 4 左	L(N,D) 随数据与模型	多曲线，对应式(1.5)
Fig 4 右	学习曲线统一	以 Smin 归一后各模型叠成一条
Fig 5	形状不敏感	固定 N，变 dff/dmodel、head dim、aspect ratio，loss 仅变几个百分点
Fig 6	方法学对比 ：含/不含 embedding	左乱/右收敛成一条——证明度量选择的重要性
Fig 7	Transformer vs LSTM	随参数；LSTM 在长上下文后段掉队
Fig 9	过拟合与 $N^{0.74}/D$ 归一塌缩	多 D 曲线按比例叠合
Fig 13	L(Cmin) 拟合	标注"lump=1 层→2 层过渡，已剔除"
Fig 15	矛盾交点	L(Cmin) 与 L(D(Cmin)) 相交=外推失效点
Table 1	逐层参数/FLOPs	工程记账
Table 2/3	L(N,D)、L(N,S) 拟合参数	指数+标度常数
Table 4/5/6	全部幂律汇总、拟合值、最优分配	查表用

图注自洽：每张图注自带"横轴是什么、色标是什么、对应的方程是哪一个"，几乎可脱离正文读懂。

2.8 数据验证方法怎么写

- **数据**：WebText2（96GB、2.29e10 tokens、预留 6.6e8 测试 token）；另在 Books/CC/Wikipedia/Internet Books 上测泛化。
- **训练**：Adam、固定 2.5e5 步、batch=512×1024；>1B 参数用 Adafactor；3000 步线性 warmup + cosine 归零；10% dropout；按 test loss 早停。
- **样本量跨度**：N=768→1.5e9、D=22M→23B。
- **随机种子噪声**："~0.02"，并据此推出防过拟合阈值 $D \geq 5e3 \cdot N^{0.74}$ （式 4.4）。
- **复现口径**：C≈6NBS（前向 2×+反向 2×+…），1 PF-day=8.64e19 FLOP 当场定义。

2.9 排版规范

单栏 arXiv；正文前印目录；章节 1–8 两级（1.1/1.2…）；公式统一编号 (1.1)–(6.8) 与附录 (A.x)/(B.x)；引用用作者缩写+年份数字键（[VSP+17]、[RWC+19]、[MKAT18]）；附录分 A/B/C/D 四块，**C 节是"局限"的标准位置**。

三、NSA（DeepSeek 2502.11089, 2025）

3.1 结构骨架与篇幅配比

24 页、单栏 LaTeX（NeurIPS 风格，章节编号 "1. 2. 3."）。章节实测：

节	标题	页	特征
—	Abstract	p1	问题→gap→贡献→结果
1	Introduction	p1-3	64k 解码 attention 占 70-80% 延迟；两大挑战；Figure 1 双轴
2	Rethinking Sparse Attention Methods	p3-5	2.1 The Illusion of Efficient Inference；2.2 The Myth of Trainable Sparsity；2.3 Native Sparsity as Imperative
3	Methodology	p5-9	3.1 背景(attention+算术强度)；3.2 总框架(三分支门控)；3.3 算法(压缩/选择/滑窗)；3.4 Kernel 设计
4	Experiments	p9-13	4.1 预训练配置；4.2 基线；4.3 性能(通用/长文/CoT)
5	Efficiency Analysis	p13-14	5.1 训练速度；5.2 解码速度
6	Discussion	p14-15	6.1 替代策略失败史；6.2 注意力可视化
7	Related Works	p16	固定稀疏/动态剪枝/查询感知 三类
8	Conclusion	p16	
—	References / Appendix A	p17-24	附录 A=AIME 样例输出

配比观察：方法+系统（3）与实验+效率（4+5）几乎 1:1；第 2 节"批判前人"独立成节，把设计空间的推导前置——这是 NSA 最值得抄的结构动作。

3.2 摘要写法

问题（长上下文、attention 计算贵）→ 已有方向（sparse attention）→ **gap 双点**（理论加速≠实际延迟；多只做推理、缺训练支持）→ **两点创新**（① 算术强度平衡的硬件对齐；② 端到端可训）→ 结果（不劣于/超过 Full Attention；64k decode/forward/backward 全面加速）。

3.3 引言与"批判式立论"套路

- **第 2 节命名式批判：**"The Illusion of Efficient Inference"（幻象）与"The Myth of Trainable Sparsity"（神话）。每个名字下拆两条具体罪状：
- 幻象：① Phase-Restricted Sparsity（H2O 只在 decode 稀疏、prefill 仍全量；Minference 相反，总有一阶段不省）；② 与 MQA/GQA 不兼容（Quest 每头独立选 KV，GQA 下取并集→内存访问不省）。
- 神话：① 事后稀疏偏离预训练轨迹（top-20% 只覆盖 70% 注意力）；② 不可训练组件（k-means/SimHash 切断梯度）；③ 反向传播低效（token 级选择破坏连续内存访问）。
- **把约束翻译成设计公理：**要硬件对齐→blockwise 连续内存+Tensor Core；要端到端可训→选择必须可微。

3.4 方法/实验/效率/讨论分工

- **方法=三支：**compression（块聚合 MLP，全局粗）+ selection（复用压缩分支的 attention score 当块重要性，top-n，可微、零额外开销）+ sliding window（局部）；各自独立 K/V 防 shortcut，gate 融合。
- **效率单独成节（第 5 节）：**性能归第 4 节，延迟归第 5 节，避免混淆。
- **讨论=失败史：**6.1 把试过的 key-clustering、aux-loss 选择、heuristic 选择、cold-start 全部列出并画 loss 曲线（Fig7），证明"为什么不是那些"。

3.5 可迁移论证范式（本篇提炼 9 条）

- 1. 硬件对齐约束 → 架构设计：先讲算术强度/roofline（prefill/fwd 是 compute-bound、decode 是 memory-bound），让算法服从各阶段瓶颈——blockwise 连续访存、GQA 组内共享 KV 块。
- 2. 端到端可训练作为核心卖点：批判 k-means/SimHash 不可微 → NSA 用压缩分支的中间 attention score 直接导出选择重要性（式 8-10），**复用计算、可微、零额外参数**。
- 3. "幻象/神话"式命名批判：用第 2 节两个标题把前人方法钉死，逼出自己的设计空间。
- 4. 三分支模块化 + 门控：全局粗 / 局部细 / 邻域近，可单独消融；独立 K/V 防梯度串扰。
- 5. 三层基线 + 统一预算：Full Attention（能力上限）/ Exact-Top（oracle 上界）/ H2O • InfLLM • Quest（SOTA）；所有稀疏方法统一激活 token 预算（2560）以保证公平；**短序列上 sparse 基线≈Full，就不比**（诚实说明在哪比、为什么）。
- 6. 质量×效率双轴报告：性能表（Table1 通用 / Table2 LongBench / Table3 AIME）+ 速度图（Fig6 fwd 9.0×/bwd 6.0×）+ 理论内存访问表（Table4 decode 11.6×，线性于访存量）。
- 7. 直觉可视化反推设计：Fig8 注意力热力图呈 blockwise 聚簇 → 论证 blockwise 选择合理；Fig7 三策略 loss 对比。
- 8. **Figure 1 一图双结论**：左"更准"、右"更快"，hero 图直接背书"既省又好"。
- 9. 复现配置全写（见 3.8）。

3.6 图表清单（逐张）

图/表	传达什么	坐标轴/基线
Fig 1 (hero)	左：General/LongBench/Reasoning Full vs NSA；右：Decode/Forward/Backward 加速 11.6×/9.0×/6.0×	分组柱状+加速比
Fig 2	三分支架构+三类注意力掩码	绿=需算、白=跳过；query/activated/evicted/ignored 图例
Fig 3	Kernel 设计	按 GQA 组载 Q（Grid Loop）、inner loop 拉 KV 块、SRAM(绿)/HBM(蓝)
Fig 4	预训练 loss 曲线	step 0-60k, Full vs NSA 双线, NSA 更低
Fig 5	大海捞针 64k	深度×位置热力图，全绿（100% 检索）
Fig 6	Fwd/Bwd 时延随长度	8k-64k 柱状，标注 2.1×…9.0×/6.3×
Fig 7	替代策略 loss 对比	Full / aux-loss / heuristic / NSA 四线
Fig 8	注意力图	blockwise 聚簇可视化
Table 1	通用基准 9 指标+Avg	MMLU...HumanEval； 三线表 ，NSA 多数加粗
Table 2	LongBench 11 子集+Avg	H2O/InfLLM/Quest/Exact-Top/Full/NSA 六行
Table 3	AIME 8k/16k	Full-R 0.046/0.092；NSA-R 0.121/0.146
Table 4	解码访存 token 数与预期加速	8192...65536；Expected Speedup 4×... 11.6×

3.7 数据验证方法怎么写

- 底座：GQA+MoE，总 27B/激活 3B，30 层，hidden 2560，GQA 4 组 64 头，dq=dk=192、dv=128；DeepSeekMoE 72 路由+2 共享专家 top-6，首层换 SwiGLU MLP。

- **稀疏超参**：压缩块 $l=32$ 、stride $d=16$ 、选择块 $l'=64$ 、选块数 $n=16$ （固定激活 1 初始块+2 局部块）、滑窗 $w=512$ 。
- **训练**：270B token、8k 长度，再用 YaRN 续训+SFT 到 32k；**双方都训到 full convergence 以保证公平**。
- **公平性纪律**：稀疏基线统一激活 2560 token（StreamLLM 口径：前 128+512 局部）；速度对比双方都用 Triton（NSA kernel vs FlashAttention-2）；AIME 每问采样 16 条、temp 0.7、top-p 0.95 取平均。
- **硬件**：8×A100。

3.8 排版规范

单栏 LaTeX；章节编号式"1. 2. 3."；**booktabs 三线表**（顶/表头下/底三条横线，正是本卷 P0-P12 应对齐的样式）；作者一年制引用（"DeepSeek-AI, 2025"）；公式行号 (1)-(12)；**无独立 Limitations 节**（局限散在 6.1 失败史与各处 "we defer..."）；附录 A 放可复核的 AIME 完整推理样例。

第二部分 · 五轮思维演练（强制留痕）

每轮固定写：**方法 / 输入 / 产出 / 对后续改写的具体影响**。

演练 ① 逻辑推演：还原每篇论证链

- **方法**：把每篇拆成"前提→机制→证据→结论"四元组，逐环问"上一环缺了会怎样"。
- **输入**：三篇 PDF 正文+图表。
- **产出**：
- **AlexNet 链**：小数据不够（前提）→ 大数据+大模型需要可训练结构（CNN 先验，机制）→ 但大模型过拟合/太慢（矛盾）→ ReLU 提速、dropout/增广防过拟合、GPU 实现落地（手段）→ 对照表证明碾压 SOTA（证据）→ 深度不可删（升华）。
- **Kaplan 链**：loss 随尺度变（前提）→ 固定变量测单变量幂律（机制）→ 幂律在 >6 数量级不拐弯（证据）→ 合并成 $L(N,D)$ 与 $L(N,S)$ （综合方程）→ 求导得最优分配（推论）→ 自指相交=外推边界（收口）。
- **NSA 链**：长上下文 attention 贵（前提）→ 前人稀疏理论快但实际不快、且不能训（批判）→ 硬件对齐+可微选择=三支（机制）→ 同预算对照证明"更准且更快"（证据）→ blockwise 聚簇可视化背书（机制自洽）。
- **对后续改写的影响**：UDOS 每篇必须能一句话写出"前提→矛盾→机制→证据"闭环；**若某篇缺"矛盾"一环，就是 P0 级结构缺陷**。Kaplan 的"自指相交"示范了如何主动给结论划边界。

演练 ② 逆向思维：从结论倒推它必须证明什么、最怕什么反例

- **方法**：假设结论为真，反推"审稿人要不要掉它，会拿什么数据攻击"。
- **输入**：三篇 headline 结论。
- **产出**：
- **AlexNet 结论**"深度重要"→ 必须证明"删层掉点"且"不是数据/初始化偶然"。最怕的反例：**删某层不掉点**（若真，则深度叙事崩塌）。作者的防御=Fig3 指出 specialization 与初始化无关、讨论里量化"中间层删 $\approx -2\%$ "。→ **教训：凡主张"X 重要"，必须给"移除 X 的代价"**。

- **Kaplan** 结论"幂律可外推"→ 必须证明多数量级不弯。最怕的反例：**上端拐弯/换分布就塌**。作者的防御=Fig8 跨分布平行平移、6.3 自曝相交点、C 节 6 条 Caveats。→ **教训：外推型论文的可信度来自"主动报告失效点"，不是"声称永远成立"**。
- **NSA** 结论"稀疏不损能力还更快"→ 必须证明**同稀疏预算**下不劣于 Full、且 kernel 真快。最怕的反例：① 偷加更多激活 token；② 只比短序列；③ 速度靠不公平后端。作者防御=统一 2560 token 预算、双方都用 Triton、把 Exact-Top 当 oracle 上界。→ **教训："更快"必须同硬件同后端同预算；"不损能力"必须有 oracle 上界作天花板**。
- **对后续改写的影响**：UDOS 每篇结论句后，必须补一行**"最可能的反例 + 本文明怎么防"**（P0/P0b/P9 这类 scale/饱和律论文尤其需要 Kaplan 式失效点）。

演练 ③ 发散思考：范式 → 本卷 15 篇逐篇映射表

- **方法**：把三篇提炼的范式，逐条映射到 UDOS 的 P0c / P0 / P0b / P1-P12。
- **输入**：本卷目录（P0c 元认知、P0 空间结构、P0b 结构加规模 ScalingLaws；P1 分层混合拓扑百万级外推；P2 BFT-lite 停止决策；P3 熔断 RCT；P4 子模主动采集；P5 共形预测；P6 可辨识性；P7 具身接管率；P8 高斯泼溅 Sim2Real；P9 质量饱和律；P10 TransferBundle 交接损失；P11 任务市场拜占庭罚没；P12 证据分级可复现）。
- **产出（逐篇映射）**：

篇目	最该抄的范式	具体动作
P0c 元认知/边界校准	Kaplan ①结论地图 + ⑧Caveats	引言先抛 N 条"自我认知边界"结论 bullet（带节号）；专设"校准失效区"小节，明说哪些情形边界估计会崩
P0 空间结构即智能	AlexNet ①工程即贡献 + ⑤消融	把"空间约束"每个设计决策当贡献，逐个给移除代价；用 Fig6 式"含/不含某结构"对照
P0b 结构+规模 ScalingLaws	Kaplan 全套（控制变量+幂律+指数表+Caveats）	直接抄：N/D/C 三因子幂律、附录指数汇总表、6 条局限；这是本卷与 Kaplan 同构度最高的一篇
P1 分层混合拓扑百万级外推	Kaplan ①控制变量外推 + ⑤理论 ↔ 实证对账	固定拓扑变规模拟合协调复杂度幂律；先推解析式再用实测对照
P2 BFT-lite 停止决策	NSA ③命名批判 + AlexNet ③公平自曝	先命名现有停止规则的"幻象"；主动披露本方协议在何种网络分区下偏置
P3 熔断 RCT	AlexNet ②每 trick 数值消融 + ⑥定性图	每个熔断策略给收口率增量（±x%）；配故障注入前后对比可视化
P4 子模主动采集	AlexNet ②消融 + NSA ⑤三层基线	对比随机/启发式/子模三种采样，统一预算；给采样率-收益曲线
P5 共形预测扇形	Kaplan ⑦主动找失效 + ②量程卖点	扇形随不确定度量程展开；明说分布漂移时覆盖概率何时失效
P6 可观测性/可辨识性	Kaplan ⑨符号定义纪律 + ⑥理论对账	先集中定义隐藏/观测变量与 Fisher 信息；解析式可辨识条件 vs 数值实验对照
P7 具身接管率	NSA ⑥质量×效率双轴 + ⑨复现配置	单侧"语义层/动作先验"两路消融；接管率表+复现参数全写
P8 高斯泼溅 Sim2Real	NSA ④模块化分支 + ⑦直觉可视化	多视角泼溅各组件可消融；渲染-实拍裕量热力图
P9 质量饱和律/同质化失效	Kaplan ⑦自指矛盾 + ⑧Caveats	画出"扩招收益递减/饱和交点"，明说该交点对指数误差敏感；局限单列
P10 TransferBundle 交接损失	AlexNet ④删层代价 + NSA ⑦机制可视化	移除交接信道测信息损失；交接前后特征相似度热力图
P11 任务市场拜占庭罚没	NSA ③命名批判 + ⑤同预算基线	命名"无罚没"市场的失效模式；诚实节点/拜占庭比例统一对照
P12 证据分级可复现	Kaplan ④参数表 + NSA ⑨复现配置 + AlexNet ⑤对照表	把证据分级做成查表；系统配置、种子、算力全部写明

- **对后续改写的影响：**此表即阶段 B/C 改稿时的"范式分配清单"——每篇改稿先查表，确认已落实对应范式再进入语言润色。

演练 ④ 批判思考：每篇方法局限、可质疑处、我们误用风险

- **方法：**站在审稿人位置，逐条挑硬伤。
- **输入：**三篇全文 + 图表。
- **产出：**
- **AlexNet 局限与误用风险：**① 双 GPU 对比"biased in favor of one-GPU"（作者自曝脚注 2），即 1.7% 的提升可能被不公平比较夸大；② ReLU 提速结论只在 CIFAR-10 一个小网络上演示，外推到 ImageNet 是"叙事外推"；③ LRN 后来被证明用处不大（BN 取代）——**历史上被淘汰的 trick 不应照抄为"必备组件"**；④ 误用风险：UDOS 若把"某个工程小 trick 带来 ±0.x%"当核心贡献而无消融，会显得单薄。

- **Kaplan 局限与误用风险**（其自身 Caveats 已列，但仍有残留）：① 幂律只有 $N \leq 1.5B$ 、 $D \leq 23B$ 的观测，外推到 GPT-4 级是**激进外推**（作者自承相交点 $C \sim 1e4$ PF-days 上下浮动一个数量级）；② 后来 Chinchilla 证明其"大模型更重要"在数据配比上有偏差——纯 loss 标度不等于下游任务最优；③ 拟合对"剔除 1 层网络、剔除最小数据集"等人为清洗敏感；④ 误用风险：UDOS 若把 Kaplan 的具体指数（0.076 等）当成跨领域常数搬运，是硬伤；指数必须自拟合，只能借方法不借数值*。
- **NSA 局限与误用风险**：① **没有独立 Limitations 节**——27B/260B token 单点验证，未在 7B 以下或 100B 以上复现；② "NSA 超过 Full Attention" 仅在自家 27B GQA+MoE 底座上成立，跨架构泛化未知；③ AIME 提升 (+0.075/+0.054) 基于 16 条采样、题量小（AIME 24 仅 30 题级），**方差极大却未给误差棒**；④ speedup 是 Triton 实现，换 CUDA 后端未必保持；⑤ 误用风险：UDOS 若照搬"稀疏/压缩无损能力"而不做同预算消融，会陷入 NSA 第 2 节自己批判的"幻象"。
- **对后续改写的影响**：UDOS 15 篇**每篇必须有显式局限节**（哪怕学 NSA 也要比它更老实），且**凡引用指数/加速比/分数，必须标注样本量、硬件、方差**，禁止无误差棒的单点提升被写成结论。

演练 ⑤ 总结复盘：提炼统一的《UDOS 论文写作与排版规范 v2》

- **方法**：把前四轮的可执行项合并成一条阶段 B/C 的硬标准。
- **输入**：三篇 + 四轮演练结论。
- **产出规范**（这就是阶段 B/C 的执行标准）：

A. 结构 1. 摘要固定五拍：任务 → 头条数字 → 规模锚点 → 技术关键词 → 一句反直觉结论。2. 引言结尾必须有"**N 条 specific contributions**"清单，每条括号标注出处小节（Kaplan 式结论地图）。3. 方法按"作者自估重要性"排序，最重要的决策放最前（AlexNet 3.1-3.4 排序惯例）。4. **必须有显式局限/失效点小节**（学 Kaplan C 节；NSA 缺这节是反面教材）。

B. 论证 5. 主张"X 重要/有效"，必须给"移除 X 的代价"（AlexNet 删层）或"同预算对照"（NSA 统一 token 预算）。6. 外推型结论必须给"失效点/交点 + 数量级不确定性"（Kaplan 6.3）。7. 理论推导与实测**双向对账**，一致要写"excellent agreement"，不一致要写原因。8. 主动披露对自己不利的偏倚（AlexNet 脚注 2）。

C. 图表 9. 三张必配图：hero 双轴图（能力×效率，NSA Fig1）、机制可视化图（注意力/特征/热力图）、对照表（三线表，斜体=他人、加粗=自己最优）。10. 图注自洽：横轴、色标、对应方程、适用边界都写进图注，可脱离正文读懂。11. 对照表用 booktabs 三线表（NSA 样式），不用朴素小表。

D. 数据与复现 12. 复现配置全写：底座规模/层数/维度/超参/数据量/硬件/优化器/学习率/种子/随机噪声量级。13. 凡提升数值标注样本量、硬件、方差或误差棒；单点小样本结果不得写成定论。14. 跨数据集/跨分布泛化要单独测（Kaplan Fig8 式平行平移）。

E. 排版 15. 单栏 LaTeX；两级章节编号；公式统一编号；参考文献编号制或作者年制二选一全卷统一；附录集中放"汇总表 + 补充实验 + 局限"。

- **对后续改写的影响**：本规范 15 条 = 阶段 B 改稿 checklist、阶段 C 定稿验收标准；任何一篇不满足第 4/6/9/13 条即打回。

第三部分 · 交付说明

- 本报告全部内容来自对三篇 PDF 的 PyMuPDF 全文抽取 + 页面渲染读图，未凭记忆。
- 三篇提炼的可迁移范式条数：**AlexNet 9 条 / Kaplan 10 条 / NSA 9 条**。
- 五轮演练各自一句话结论：① 逻辑推演——UDOS 每篇必须有"前提→矛盾→机制→证据"闭环，缺矛盾环即 P0；② 逆向思维——凡主张"X 重要/可外推"，必须自报"最可能的反例与本文明如何防"；③ 发散思考——已产出 15 篇逐篇范式映射表（P0c/P0/P0b/P1-P12）；④ 批判思考——指数/加速比/分数必须带样

本量与方差，UDOS 每篇都要有比 NSA 更老实的局限节；⑤总结复盘——已固化为 15 条《UDOS 写作与排版规范 v2》作为阶段 B/C 验收标准。

- 同步动作：三篇题录已按"来源=用户附件 PDF 原件、核验日期 2026-09-20"追加进《参考文献总库.md》（见该文件末尾新增块，仅追加、未改其他内容）。