



P4

Coverage-Aware Egocentric Data Flywheel: Yield and State-Coverage Active Collection via Submodular Greedy Selection

A Coverage-Aware Egocentric Data Flywheel:
Submodular-Greedy Active Acquisition for Yield and State
Coverage

Coverage-Aware Egocentric Data Flywheel: Yield and State-Coverage Active Collection via Submodular Greedy Selection

Abstract — All measured numbers come from fixed-seed CPU deterministic prototypes (cpu-proto); a few contract-level test assertions are verified, and external industry numbers are motivation only (unverified). The paper builds an egocentric data flywheel that actively chooses what to collect next using a submodular greedy objective, jointly improving yield and state coverage over naive or random collection. The mechanism shows diminishing but positive returns characteristic of submodular maximization, quantifying how coverage-aware collection beats collecting more of the same.

Keywords: data flywheel; active learning; submodular; coverage; greedy selection; egocentric data

孪生地球

Coverage-aware 第一人称数据飞轮：基于子模贪心的良率与状态覆盖主动采集

证据等级声明：本文全部实测数字来自 UDOS 推演引擎 tag **v7.5.0** (main 分支 commit 1a71270) reports7/egodata_flywheel_demo.json 与 udos7/egodata/ 源码，固定 seed、Linux CPU 确定性原型，统一标注为 cpu-proto；少数契约级测试断言标注为 verified。外部产业数字仅作动机，一律标 unverified。本文不与厂商数字互证。

结构化摘要（背景与问题 → 方法 → 证据与结果 → 贡献）

【背景与问题】 具身基础模型的新兴 scaling 轴是第一人称 (egocentric) 人类经验数据，但固定预算下长期"上量不上质"：被动连续采集陷入少数重复场景，缺陷与冗余片段拉低良率；而"Coverage-aware 采集""Yield 良率"目前只是行业口号，良率分母、覆盖单位、是否偷看缺陷真值均无公开约定，数字不可比（详见 § 1）。

【方法】 把口号形式化为带 oracle 真值的可复现对照实验框架：以离散状态单元 (task×位置×速度×接触) 刻画覆盖，以盲检 QC（不用注入缺陷真值标签）定义良率，以覆盖函数上的子模贪心驱动主动采集；并设第三臂"在偏态池上只换贪心"做归因消融（详见 § 3、§ 4）。

【证据与结果】 在固定 seed=0、候选池 160 片段、预算 48 片段（每片段 3 原始分钟，共 144 原始分钟）、25% 合成缺陷注入的 CPU 原型上：Coverage-aware 主动 vs 被动偏态，Yield 0.8542 vs 0.6667，oracle 覆盖 0.951 vs 0.695 (215 vs 157 单元，oracle=226)，经验密度 11.38 vs 7.80；同池贪心消融为 0.889 覆盖、0.7917 良率，表明增益同时来自"选片策略"与"采集池去偏"（详见 § 6）。

【贡献】 (i) 良率的可操作盲检定义；(ii) 可复现对照协议；(iii) 预注册分析计划 (≥30 seed 配对 + Wilcoxon + bootstrap CI)。所有差异为单 seed 试点估计，不宣称统计显著；纯合成世界的外部效度边界与真实数据闸门如实声明（详见 § 7、§ 8）。

中文摘要

具身基础模型 (embodied foundation model) 的一个新兴 scaling 轴是**第一人称人类经验数据** (egocentric data)，但其采集在固定预算下长期面临"上量不上质"的问题：被动连续采集容易陷入少数重复场景，缺陷片段与冗余片段拉低数据良率 (Yield)。本文把工程团队口耳相传的"Coverage-aware 采集""Yield 良率"概念，形式化为一个**带 oracle 真值的可复现对照实验框架**：以离散状态单元 (task $\times$ 位置 $\times$ 速度 $\times$ 接触) 刻画经验覆盖，以盲检 QC (不使用缺陷真值标签) 定义良率，以**覆盖函数上的子模贪心**驱动主动采集。在固定 seed=0、候选池 160 片段、预算 48 片段 (每片段折算 3 原始分钟，共 144 原始分钟)、25% 合成缺陷注入的 CPU 原型上，Coverage-aware 主动采集相对被动偏态采集取得：Yield 0.8542 vs 0.6667, oracle 状态覆盖 0.951 vs 0.695 (终值 215 vs 157 单元, oracle=226)，经验密度 11.38 vs 7.80 单元/有效分钟。同池贪心消融 (0.889 覆盖、0.7917 良率) 表明增益同时来自"选片策略"与"采集池去偏"。本文的贡献是给出良率的可操作定义、可复现对照协议与预注册分析计划，并诚实标注纯合成数据的外部效度边界与解锁真实数据所需的资源闸门。需要强调，本文报告的所有差异均为单 seed 试点估计，不宣称统计显著；其价值在于把一套行业口号转化为可在 CPU 上逐位复现、可证伪、可归因的实验台。

为什么这件事值得在"纯合成"上先做。 一种常见质疑是：既然最终要靠真实第一人称视频，为什么不直接上真实数据？我们的理由是方法学上的：真实世界没有 oracle 真值，你无法知道"还有哪些状态单元没采到"，也就无法严格度量"覆盖"。合成试验台的唯一价值，恰恰是让覆盖成为一个**可计算、可证伪、可归因**的量。先在能看清楚的地方把度量和协议做对，再把它搬到看不清的真实世界——这比一上来就在黑箱里比较良率数字更负责任。本文因此把自己定位为"度量与协议论文"，而非"真实数据规模论文"。

关键词：第一人称数据；主动数据采集；子模优化；数据良率；经验覆盖；具身智能

English Abstract

A rising scaling axis for embodied foundation models is egocentric human-experience data, yet fixed-budget collection routinely suffers from "volume without quality": passive continuous sampling collapses into a few repetitive scenes, while defective and duplicated clips depress data yield. This paper formalizes the engineering folklore of "coverage-aware collection" and "yield" into a **reproducible, oracle-annotated controlled benchmark**. We define experience coverage over discrete state cells (task $\times$ position $\times$ speed $\times$ contact), define yield by a **blind quality-control** stage that never uses injected ground-truth defect labels, and drive active selection by a **submodular greedy** over the monotone coverage function. On a fixed-seed (seed=0), Linux-CPU deterministic prototype (pool=160 clips, budget=48 clips, 3 raw minutes per clip = 144 raw minutes, 25% synthetic defect injection), coverage-aware active collection achieves yield 0.8542 vs 0.6667 passive-skewed, oracle state coverage 0.951 vs 0.695 (215 vs 157 cells; oracle=226), and experience density 11.38 vs 7.80 cells per effective minute. A same-pool greedy ablation (0.889 coverage, 0.7917 yield) shows gains come jointly from the selection policy and from de-biasing the pool. Contributions are an operational yield definition, a reproducible controlled protocol, and a pre-registered analysis plan, with honest bounds on external validity under purely synthetic data.

Keywords: egocentric data; active data acquisition; submodular optimization; data yield; experience coverage; embodied AI

1 引言

具身智能的数据困境与计算机视觉/大语言模型并不相同。在后两者中，互联网级图文语料已近饱和；而机器人操作所需的“人在物理世界中如何手到擒来”的第一视角经验，几乎没有现成语料。因此，一个被反复提及的新方向是**规模化采集第一人称（egocentric）人类操作视频**，并把它作为具身策略与世界模型的训练燃料。

需要明确：本文作者**不掌握**任何厂商的私有采集流水线，也不与其数字互证。据公开媒体转述口径（**报道口径，未独立核验，unverified**）：有数据供应商宣称累计完成百万小时级“精品”第一人称数据、提出“数据良率 Yield 高达 98%”的说法，并主张“Coverage-aware Collection：由 Agent 反向诊断数据盲区并定向补采”，以及“Task Coverage 应升级为 State Coverage、经验规模与密度并重”的主张（见本仓 `reports7/egodata_flywheel_demo.json` 的 `external_reference` 字段，来源标注为“Maxinsights 媒体报道 / Dyna Robotics Dyna-2 技术报告（转述）”）。这些数字**没有公开的方法学**，本文只把它们当作研究动机，不把它们当证据，也不用我们的数字去“对标”或“反驳”它们。

真正的研究空白在于：“良率”和“覆盖感知采集”目前是经验口号，缺乏可操作、可复现、可证伪的定义。一个团队说“我的良率高”，另一个团队说“我的覆盖全”，但二者：(i) 良率的分母是什么（原始分钟？片段数？有效分钟？）；(ii) 覆盖的单位是什么（任务类别？轨迹片段？还是离散状态？）；(iii) 是否使用了“事后才知道的缺陷真值”来挑选数据（这会严重高估良率）——这些都没有公开约定。不同团队的数字因此不可比较。

本文的立场是：**与其追逐一个无法核验的绝对良率数字，不如先把这套概念做成一个可复现的实验台**。我们在 UDOS 推演引擎 `udos7/egodata/` 模块中实现了一个 CPU 确定性的“第一人称经验数据飞轮”原型，并主张四点：

1. **良率应是盲检的**。QC 只能基于可观测信号（轨迹长度、相机系抖动、量化签名重复），不能偷看注入的缺陷真值标签，否则会产生“上帝视角”式的高估。
2. **覆盖应是状态级的，而非任务级的**。仅记录“见过 reach 类任务”无法区分同任务下不同空间/速度/接触状态；我们用离散状态单元刻画覆盖。
3. **主动采集是子模优化问题**。覆盖函数单调、次模，贪心选择有经典的 $1-1/e$ 近似保证，适合在线、增量的补采。
4. **增益要做归因消融**。必须用“同一偏态池上只换选片策略”的消融，把“选片策略的功劳”和“采集池分布去偏的功劳”分开，否则无法回答 RQ2。

本文其余部分组织如下：第 2 节相关工作；第 3 节问题定义与可证伪假设；第 4 节方法与系统设计（结合真实源码类与函数）；第 5 节实验设置；第 6 节结果；第 7 节讨论与威胁有效性；第 8 节资源闸门与适用边界；第 9 节结论；参考文献与附录。

2 相关工作

本文处于三条成熟线的交叉点，但三者此前较少在“第一人称训练数据的良率与覆盖”这一具体问题上被组合成可复现实验。

主动数据选择与“数据节食”。从池中按可计算的重要性分数挑选/剔除样本，是数据高效学习的成熟范式。最贴近本文的已核验工作是 Paul、Ganguli 与 Dziugaite 在 NeurIPS 2021 的《Deep Learning on a Data Diet》（arXiv:2106.00278）：他们用早期梯度范数评分（GraNd/EL2N）对训练数据打分，证明按分数剪枝掉约半数数据不损精度。这与本文“用可计算的边际覆盖分在预算内选片”同属“数据加权/数据选点”思想，但落点不同：Data Diet 在**训练集内部**做事后剪枝，本文在**采集阶段**做事前的预算分配。另一支更老的根是 Krogh 与 Vedelsby 在 NeurIPS 1995 的集成/主动学习工作：其 bias-variance-ambiguity 分解与 query-by-committee 思想，把“用集成分歧选最有信息量样本”形式化，这正是本文“边际新状态作为信息量代理”的理论祖先。覆盖函数贪心的 $1-1/e$ 近似保证本身是经典次模结论，具体原始出处待补核验 [CITATION NEEDED: submodular coverage greedy $1-1/e$ Nemhauser/Wolsey]；机器人学习中的轨迹 coreset 选择亦待补 [CITATION NEEDED: coreset selection robot learning trajectory]。

第一人称/具身数据。 已有工作构建第一视角活动/操作数据集并讨论数据规模对策略学习的影响 [CITATION NEEDED: egocentric video dataset robot manipulation, 待核验]。产业界近期提出 Coverage-aware / Yield 等概念（见第 1 节 unverified 转述），但缺乏公开方法学。本文不与这些转述数字互证。

数据质量与清洗。 盲检去重、去噪、拒绝低质样本是 ML 数据流水线的标准环节 [CITATION NEEDED: data filtering deduplication ML pipeline, 待核验]。本文把它显式建模为"不可见缺陷真值"的盲检，并据此定义良率分母——这与 Data Diet"用分数而非真值筛选"的取向一致，但本文的分数是可计算的覆盖/QC 信号，不偷看注入缺陷标签。

我们不声称在任一子领域取得新算法；本文贡献是**工程化的问题重构** + **可复现对照**。把已核验文献（Data Diet 的数据节食、Krogh&Vedelsby 的 query-by-committee）与本仓可复现对照相结合，是本文相关工作的立足点；未核验的子模/coreset/egocentric 出处保留占位，待后续补检。

与相关工作的差异定位。 需要把本文与三类已有工作明确切开，以免被误读为重复：第一，与经典 coreset 工作相比，我们选择的对象不是"已采集好的数据点"，而是"尚未发生的采集动作"——选择器在采集预算分配阶段就介入，决定下一段第一人称经验应该去哪个任务、哪个空间位置、哪种接触状态去补，这是一个**在线采集规划**问题而非事后压缩。第二，与数据清洗工作相比，我们刻意让 QC 保持"盲"：清洗工作通常在拿到全量数据后才决定丢弃谁，而我们要求良率定义在选择决策发生的同一时刻就是可计算的，且不允许使用事后才知道的真值。第三，与产业 Coverage-aware 叙事相比，我们不提供一个无法核验的良率数字，而是提供一个任何人都能在自己 CPU 上跑一遍的对照协议，把"主动是否优于被动"这件事从宣传话术变成可重复实验。这种"把口号变成实验台"的定位，是本文在方法学上最想守住的立场。

3 问题定义与假设

3.1 记号与良率定义

设原始候选池 $\mathcal{P}$ ，采集预算 $\mathcal{B}$ （以片段数计）。每个片段 e 折算原始采集时长 $m(e)$ （本文每片段 $m=3.0$ 分钟）。QC 阶段对 e 给出盲检判决 $\text{accept}(e) \in \{0,1\}$ ，**不使用** e 的缺陷真值标签。

- **良率 Yield**： $Y = \frac{\sum_{e \in \text{accepted}} m(e)}{\sum_{e \in \text{selected}} m(e)}$ 。即通过盲检 QC 的有效时长占被选原始时长的比例（实现见 `udos7/egodata/processing.py` 的 `YieldLedger.yield_rate`）：

$$Y = \frac{\sum_{e \in \text{accepted}} m(e)}{\sum_{e \in \text{selected}} m(e)} \tag{1}$$

- **状态单元**：片段 e 映射为离散单元集合 $\mathcal{C}(e) = \{(task, x, y, v, contact)\}$ ，其中位置按 12×12 分箱、速度按 3 档分箱（见 `coverage.py`，`X_BINS=12`，`Y_BINS=12`，`SPEED_BINS=3`，`BOUND=2.5`）。
- **状态覆盖**： $\mathcal{C}(S) = \bigcup_{e \in S} \mathcal{C}(e)$ ；**oracle 覆盖率** $= |\mathcal{C}(S_{\text{accepted}})| / |\mathcal{C}_{\text{oracle}}|$ ，其中 oracle 为同世界全量合格片段并集（本文 $|\mathcal{C}_{\text{oracle}}|=226$ ）：

$$\text{Coverage}_{\text{oracle}} = \frac{|\mathcal{C}(S_{\text{accepted}})|}{|\mathcal{C}_{\text{oracle}}|}, \quad |\mathcal{C}_{\text{oracle}}|=226 \tag{2}$$

- **经验密度**：合格片段平均 `density_score`，其定义为 $(\text{cells} + 8 \cdot \text{contacts} + 6 \cdot \text{transitions} + 0.5 \cdot \text{path}) / \text{minutes}$ （`processing.py: experience_density`）：

$$\text{Density} = \frac{\text{cells} + 8 \cdot \text{contacts} + 6 \cdot \text{transitions} + 0.5 \cdot \text{path}}{\text{minutes}} \tag{3}$$

密度公式的系数体现了一种工程判断：一个片段的"经验价值"不只在于它覆盖了多少空间状态单元，还在于它经历了多少次接触事件（`contacts` 权重 8，因为接触是操作中最稀缺、信息量最高的事件）、多少次子任务切换（`transitions` 权重 6，因为阶段切换刻画了任务结构），以及它在单位时间内走了多长的手部路径（`path` 权重 0.5，纯位移）。把这些除以时长，就得到"单位时间的经验浓度"。这组权重是启发式的，我们不把它说成最优——它的作用是让"高接触、高切换"的片段在排序时优先于"长距离滑动"的片段。

`test_density_contact_rich_above_static` 断言接触丰富片段密度高于同参数静态片段，正是把这一方向性固定下来。 - **冗余率**： $\$1 - \sum_e \Delta_{\{\text{new}\}}(e) / \sum_{\{e \mid \text{accepted}\}} |C(e)|$ ，刻画合格片段间的重复程度。

3.2 假设（可证伪）

- **H1（覆盖优势）**：在同预算下，Coverage-aware 主动采集的 oracle 覆盖率显著高于被动偏态采集。本文实测点估计为 0.951 vs 0.695（seed=0）。**证伪方式**：若 ≥ 30 seed 的配对检验中主动覆盖率不优于被动，H1 被推翻。
- **H2（边际新状态衰减更慢）**：主动采集的累计覆盖曲线上升更陡、下凹更晚，即边际新状态衰减更慢。本文以覆盖曲线与末段边际（图 P4-1）描述。
- **H3（偏态放大）**：当采集池高度偏态（重复场景集中）时，主动策略优势扩大。同池贪心消融（0.889 覆盖）介于被动（0.695）与均匀池主动（0.951）之间，支持“池子去偏仍有额外增益”。

统计纪律：当前全部为 **单 seed 试点点估计**（seed=0）。按预注册要求，投稿前主对比需 ≥ 30 独立 seed 的配对设计（同池对比各臂），用 Wilcoxon 配对检验 + bootstrap CI。本文所有差异量在补齐前均为试点点估计，不报告 p 值/置信区间。

4 方法与系统设计

4.1 合成第一人称片段生成（`episodes.py`）

"第一人称视频"在此为**代理量**，不包含真实图像：每个片段记录末端（手）轨迹、接触事件、子任务边界与任务/参数标签。`TASK_NAMES = (reach_free, ordered_sort, contact_gate, disturb_recover)` 四类任务，每类有若干参数变体（环境/物体/受力差异），共同构成状态覆盖空间。三类真实采集中常见的缺陷可被可控注入：

- `static`：静止/无效片段（手部轨迹被置零）；
- `drift`：相机系位姿漂移（对手轨迹叠加随机游走噪声，步长 0.07）；
- `duplicate`：重复摆拍（复刻池中已有片段，制造量化签名碰撞）。

`generate_pool(n, seed, defect_rate, task_skew)` 在给定 `task_skew` 时按偏态抽任务，模拟"被动采集偏好简单动作"。

4.2 盲检 QC（`processing.py`）

QC 只看可观测信号，不用注入真值：

```
quality_control(e, seen_signatures):
    path = 手部轨迹总长(e.hand_track)          # 总位移米数
    jerk = 相机系轨迹二阶差分中位数           # 抖动/漂移代理
    sig = 量化签名(参数key, 长度, 起点, 终点)
    reasons = []
    if path < MIN_PATH_M(=0.6): reasons += "static_or_empty"
    if jerk > MAX_JERK(=0.115): reasons += "camera_drift"
    if sig in seen_signatures: reasons += "duplicate"
    accept = (len(reasons)==0)
```

这一设计刻意"看不见"缺陷真值：即使注入的是 `drift`，QC 也只能从抖动代理推断；这正是避免良率高估的关键。

4.3 状态覆盖图（`coverage.py`）

`state_cells(e)` 把每一步映射到 `(task, x_bin, y_bin, speed_bin, contact)` 单元集合。`CoverageMap` 维护已覆盖单元与分任务覆盖；`fraction_of(reference)` 直接给出对 oracle 的覆盖率。

4.4 子模贪心主动采集（`collection.py`）

被动臂直接取池前缀 `passive_select = pool[:budget]`（按偏态生成顺序上量）。主动臂为子模贪心：

```
active_select(pool, budget):
    chosen = []; covered = ∅
    for _ in range(budget):
        best = argmax_{i not used} |C(e_i) - covered| # 边际新单元
        if best.gain <= 0: break
        chosen.append(e_best); covered |= C(e_best)
    return chosen
```

覆盖函数 $f(S) = |\bigcup_{e \in S} C(e)|$ 单调次模，每轮选边际最大者，是标准的次模贪心，具备 $1 - 1/e$ 近似保证（对最优预算覆盖）。被动臂使用的偏态为 `PASSIVE_SKEW = {reach_free:0.60, contact_gate:0.25, ordered_sort:0.10, disturb_recover:0.05}`，模拟"满屏固定搬运/简单 reach"。

4.5 三臂与消融（`benchmark.py: run_flywheel_benchmark`）

基准函数在**同一世界、同一缺陷率**下生成两个候选池：偏态被动池（`seed=0`）与均匀主动池（`seed=1`），oracle 取两池全量合格并集的较大者。三臂为：①被动偏态；②Coverage-aware（均匀池+贪心）；③**消融：在偏态被动池上直接跑贪心**（隔离"选片策略"的纯贡献）。每臂输出良率、终值单元、oracle 占比、冗余率、密度、覆盖/边际曲线、拒绝原因。

4.6 子模性的形式化与近似保证

把状态覆盖写成集合函数。令全集 $\mathcal{U}$ 为所有可能状态单元，每个片段 e 对应一个子集 $C(e) \subseteq \mathcal{U}$ 。给定已选集合 S ，覆盖函数 $f(S) = |\bigcup_{e \in S} C(e)| = |\{u: \exists e \in S, u \in C(e)\}|$ 。单调性显然：加入片段只会扩大或保持并集。次模性来自集合并的边际递减性质——对任意 $S \subseteq T$ 与任意 $e \notin T$ ，有 $f(S \cup \{e\}) - f(S) \geq f(T \cup \{e\}) - f(T)$ ，因为 e 能新贡献的单元只会被已选更多单元"吃掉"得更多。

预算约束下的最大化问题 $\max_{|S| \leq B} f(S)$ 是 NP 难的（集合覆盖型），但贪心每步选边际最大者的算法，对单调次模函数有经典的 $1 - 1/e$ 近似保证，即贪心解 $\hat{S}$ 满足 $f(\hat{S}) \geq (1 - 1/e)f(S^*)$ ，其中 S^* 为最优预算解：

$$f(\hat{S}) \geq \left(1 - \frac{1}{e}\right) f(S^*)$$

`collection.py: active_select` 严格实现了这一贪心：每轮在线维护 `covered` 集合，对所有未用片段计算 `len(cells - covered)`，取最大者，边际为 0 即提前终止。需要诚实指出：这一保证针对的是**覆盖函数**本身，而我们的良率还额外乘上了盲检 QC 的接受率——QC 拒绝可能让"贪心选到的片段"部分作废，因此 $1 - 1/e$ 是对"理想无 QC"上界的近似，不是对端到端良率的严格保证。

4.7 偏态机制的刻意设计

被动臂的偏态不是随机噪声，而是对真实采集失败模式的刻意建模。PASSIVE_SKEW 把 60% 任务预算压到 reach_free（最简单的自由移动到目标点），只有 5% 给 disturb_recover（带外力扰动的恢复）。这对应真实团队的常见困境：操作员反复做最熟练、最出片、最不容易失败的动作，而对需要鲁棒性的扰动恢复类经验严重欠采。偏态池的后果在结果中清晰可见——被动臂在约 132 单元处提前平台，因为反复 reach 早已把 reach 的状态单元采满，再采只是重复。主动臂通过把 25% 预算让渡给均匀分布，并用贪心优先补稀疏单元，打破了这一提前饱和。

4.8 与范本范式的对照（NSA 三层基线 / AlexNet 消融表）

本文的三臂设计与两篇逆向拆解范本同构：

- **对照 NSA"三层基线 + 统一预算"**：NSA 在同一激活 token 预算（2560）下并置 Full Attention（能力上限）、Exact-Top（oracle 上界）、稀疏方法（H2O/Quest），以保证"既省又好"不是偷加预算。本文对偶地在同一预算（48 片段 / 144 原始分钟）、同一缺陷率（25%）下并置三臂：被动偏态（基线）、Coverage-aware 主动（本文方法）、同池贪心消融（隔离归因）。三臂预算与缺陷率严格对齐，因此"主动优于被动"不是靠多给预算换来的。
- **对照 AlexNet"每个 trick 配数值消融表"**：AlexNet 把双 GPU/LRN/重叠池化各自配"移除后误差掉多少"。本文的第三臂"在偏态池上只换贪心"正是这一范式的移植：它移除了"池子去偏"这一变量、只保留"选片策略"，于是把总增益（0.695→0.951）拆成"选片策略贡献（0.695→0.889）"与"池子去偏贡献（0.889→0.951）"两层——这就是"主动 vs 被动 子模消融"的归因逻辑。
- **诚实边界（对照 NSA 自曝）**：本文同样主动披露不利事实——(i) $\$1-1/e\$$ 近似保证（式 4）只对覆盖函数本身成立，端到端良率还乘盲检 QC 接受率，故非对端到端良率的严格保证；(ii) 全部差异为单 seed 点估计，未报 CI/p 值。

5 实验设置

- **数据**：合成点质量具身环境上的混合策略片段，池大小 160，预算 48 片段，每片段折算 3.0 原始分钟（预算原始分钟 144.0），缺陷注入率 25%（reports7/egodata_flywheel_demo.json config）。
- **硬件指纹**：Linux CPU；Python 3.12.11、torch 2.14.0+cpu、CPU 线程 2（reports7/agent_scaling.json environment 节同款运行环境）。飞轮基准单次墙钟约 4889 ms（trace 7a8ca2ca4ce94bf0，latency_ms=4889.419，token_usage=0，无真实 LLM 调用）。
- **随机种子**：seed=0（偏态池）/ seed=1（均匀池），确定性可复跑。
- **证据等级**：cpu-proto（合成世界、代理视频量）；契约断言（QC 拒绝静态/漂移/重复、active≥passive）由 tests7/test_v740_flywheel.py 共 10 项 verified。
- **统计**：当前单 seed 试点；主对比预注册为 ≥30 seed 配对设计 + Wilcoxon + bootstrap CI（见第 8 节预注册计划）。
- **复现**：python scripts7/egodata_flywheel_demo.py（详见附录 C）。

QC 阈值的来源说明。 盲检阈值 MIN_PATH_M=0.6 与 MAX_JERK=0.115 是在合成世界上调出的，而非从真实视频统计得到。static 缺陷被刻意构造为手部轨迹置零，因此轨迹总长必然接近 0，远低于 0.6 米；drift 缺陷对手部轨迹叠加步长 0.07 的随机游走，其二阶差分中位数会显著高于干净片段，从而越过 0.115。这两个阈值在合成世界上是"可分离"的，但我们不声称它们在真实视频上同样有效——真实手部抖动与镜头漂移的分布需要真实数据标定。tests7/test_v740_flywheel.py 的 test_qc_rejects_static / drift / duplicate_pair 三项，正是把"盲检能把注入缺陷分出来"这一性质固定为回归断言（verified），防止后续改动悄悄放宽 QC。

6 结果

6.1 主对比 (seed=0, 试点估计)

表 P4-1 三臂核心指标 (来源 reports7/egodata_flywheel_demo.json)

指标	被动偏态采集	Coverage-aware 主动	同池贪心消融
Yield 良率	0.6667	0.8542	0.7917
终值状态单元	157	215	201
oracle 覆盖率	0.695	0.951	0.889
冗余率	0.599	0.692	—
平均经验密度(单元/有效分钟)	7.80	11.38	—
oracle 单元总数	226	226	226

读表：主动臂相对被动臂，良率绝对提升 +0.1875 (相对 +28.1%)，oracle 覆盖绝对提升 +0.256 (+36.8%)，经验密度 +3.58 (+45.9%)。这三个方向一致，且密度提升说明主动采到的不仅是"更多不同单元"，更是"单位有效分钟内含更丰富接触/子任务切换的经验"。

6.2 覆盖曲线 (H2)

图 P4-1 绘制两臂的累计新状态单元随合格片段序号的变化。被动臂 (红) 早期快速冲到约 132 单元后**长期平台**，此后只零星补到 157，反映偏态池反复采样 reach 类导致边际趋零；主动臂 (蓝) 几乎全程保持正斜率，平稳爬升至 215，接近 oracle 226。边际曲线佐证：被动臂后段大量 0 边际，主动臂末段仍有 1 单元/片段的新贡献。

图 P4-1 状态覆盖累积曲线

图 P4-1 (重述) 累计新状态单元随合格片段序号变化 (覆盖曲线, H2)。 横轴为合格片段序号 (1 → 48, 线性刻度)；纵轴为累计已覆盖状态单元数 (线性刻度)，两条曲线：红线=被动偏态采集、蓝线=Coverage-aware 主动采集；水平线标注 oracle 单元总数 226。被动臂约在第 27-38 片进入长期平台 (约 132 单元后仅零星补到 157)，主动臂全程保持正斜率爬升至 215。曲线序列逐值来自 reports7/egodata_flywheel_demo.json 的 passive_collection.coverage_curve 与 coverage_aware_collection.coverage_curve (cpu-proto, 单 seed=0)。

6.3 三臂柱状对比

图 P4-2 三臂核心指标

图 P4-2 (重述) 三臂核心指标柱状对照。 横轴为指标分组 (Yield 良率、oracle 覆盖、经验密度)，纵轴为各指标数值；每组分三根柱：被动偏态 (0.6667 / 0.695 / 7.80)、Coverage-aware 主动 (0.8542 / 0.951 / 11.38)、同池贪心消融 (0.7917 / 0.889 / 密度 N/A)。注意冗余率不在本图三指标内：主动臂冗余率 0.692 反高于被动 0.599，是覆盖趋于饱和 (215/226) 的预期伴生信号而非缺陷。数据逐值来自 reports7/egodata_flywheel_demo.json 三臂字段 (cpu-proto, 单 seed=0)。

图 P4-2 把 Yield、oracle 覆盖、密度三项并排 (消融臂未报告密度, 标 N/A)。注意冗余率这一项看似反常：主动臂冗余率 0.692 高于被动臂 0.599。这**不是**缺陷——在覆盖被推高到接近 oracle (215/226) 后，剩余片段自然高度重叠，冗余率上升是覆盖趋于饱和的**预期伴生信号**；它提示"高覆盖"与"低冗余"不可兼得，应在预算足够小、覆盖未饱和时停止采集，而非一味上量。

6.4 拒绝原因分布 (QC 盲检)

表 P4-2 盲检拒绝原因计数

拒绝原因	被动偏态	Coverage-aware
camera_drift	4	7
static_or_empty	4	0
duplicate	8	0
合计拒绝	16	7

被动池因按生成顺序偏态上量，重复摆拍（duplicate=8）与静止片段（static=4）集中出现；主动臂的贪心绕开了这些低边际片段，duplicate/static 拒绝归零，仅余 7 个 camera_drift（盲检抖动代理检出）。这解释了 Yield 的差异：**良率的差距首先来自"选片避开了低质/重复片段"，其次来自"选片覆盖了新状态"。**

6.5 消融归因（RQ2）

同池贪心消融（在偏态被动池上只换选片策略）取得 oracle 覆盖 0.889、良率 0.7917。它显著高于被动（0.695 / 0.6667），说明**选片策略本身有效**；但它又低于均匀池主动臂（0.951 / 0.8542），说明**采集池分布去偏带来额外增益**。换言之，"Coverage-aware"的收益是两层叠加：先把池子从偏态拉向均匀，再用贪心在线选边际最大者。这一归因对工程实践直接有用：在无法改变上游采集分布时，仅靠事后贪心选片也能拿到大部分收益（0.695→0.889）。

注：以上全部为 seed=0 单 seed 试点估计。方差、配对差异的 CI、Wilcoxon 统计量均待 ≥30 seed 补齐，标记 [RESULT NEEDED: 多 seed 配对差异 CI 与 p 值]。

6.6 边际曲线与"何时停止上量"

边际曲线刻画了"再采一片能补多少新单元"。被动臂的 marginal_curve 显示：中段（约第 27–38 片）出现连续多个 0 边际——这意味着该区间内被动臂每采一片合格片段，新状态单元数为零，纯在重复已知状态；直到偶发一片不同任务的片段才跳出平台。主动臂的边际曲线虽也从 26 单元/片单调衰减到末段 1 单元/片，但**几乎不出现连续 0 段**，说明它始终在主动寻找未覆盖单元。

这一观察有直接的工程含义：边际新状态是天然的**停止信号**。当连续多片边际新状态低于某阈值（例如 <1）时，应停止在当前偏态上继续上量，转而诊断盲区（哪些任务/空间状态最稀疏）并定向补采。
CoverageMap.sparsest_tasks() 已提供这一诊断原语：它按分任务已覆盖单元数排序，返回最稀疏任务列表，供采集器决定下一批去哪里补。这正是产业叙事中"Agent 反向诊断数据盲区"的可计算版本。

表 P4-3 覆盖饱和行为对照（来自曲线序列，seed=0）

行为指标	被动偏态	Coverage-aware
首次达到终值的片段序号	约第 44 片后才到 157	全程爬升至 215
中段连续 0 边际段	多处（约第 27–38 片）	几乎无连续 0 段
末段边际新单元	0	约 1
相对 oracle 缺口	226–157=69 单元	226–215=11 单元

缺口对比尤其说明问题：被动臂即便把 48 片预算花完，仍有 69 个状态单元从未触及；主动臂只剩 11 个单元缺口。这 69 个"看不见的状态"，恰恰是模型在部署时最可能翻车的分布外区域——这把"数据覆盖缺口"与"部署鲁棒性"直接连了起来。

7 讨论与威胁有效性

合成世界的外部效度（最大威胁）。 世界是点质量具身环境，"第一人称视频"是末端轨迹代理量，不含真实图像、手部追踪与 SLAM；缺陷是可控注入的，真实 QC 需要视觉大模型判别。因此本文的 0.854 良率**不能解读为"真实视频采集能达到 85% 良品率"**，它只说明：在一个可控、可看真值的试验台上，盲检 + 子模贪心的相对增益方向是稳健的。

oracle 已知既是优势也是边界。 我们能计算覆盖率真值（因为合成世界全量合格片段的并集已知），这是本文区别于产业口号的核心优势；但真实场景没有 oracle，覆盖率只能估计。升级路径是在真实 egocentric 视频子集上人工标注状态单元，报告"合成→真实"的 gap。

单 seed 威胁。 所有差异为点估计，未控制跨 seed 方差；H1-H3 的"显著"二字在补齐多种子前仅为方向断言。

缺陷分布威胁。 25% 注入率、三类缺陷的相对比例是我们设的；真实数据的缺陷长尾（如遮挡、模糊、光照）未建模。

子集选择 ≠ 训练收益。 本文只证明"选片提高了良率/覆盖/密度"，**没有证明"这些更高质量的数据真的降低了下游世界模型/策略的误差"**。把覆盖→下游性能的因果链打通是后续工作。这一步之所以重要，是因为"覆盖广"与"学得好"之间可能存在非平凡关系：也许某个状态单元虽然从未被采到，但它对预测误差的贡献极小，那么花预算去补它就是浪费；反过来，也许某个被覆盖了单元恰好是误差的主要来源。要回答"补哪段经验最能降低下游误差"，需要把选择器从"覆盖最大"升级为"边际误差下降最大"，这是覆盖感知走向误差感知的下一步，也是与 P5（世界模型共形预测可信度）自然衔接的地方。

与产业绝对数字的关系（再强调）。 本文的良率 0.8542 与产业转述的"98%"不可比较，原因有三：其一，分母不同——我们的分母是"被选原始分钟"，而"98%"未公开其分母是否含人工精修、是否排除了明显不可用片段；其二，缺陷模型不同——我们只注入三类合成缺陷，真实视频的缺陷长尾（遮挡、失焦、光照剧变、手部出画）远更复杂；其三，QC 能力不同——我们的盲检是阈值规则，真实流水线可能用视觉大模型做更严的判废。因此本文不主张"我们的良率接近/超过某厂商"，只主张"在同一可控试验台上，盲检+子模贪心的相对增益方向是可复现的"。任何跨来源的良率数字横向比较，都应先对齐分母、缺陷模型与 QC 能力这三件事，否则比较无意义。

为什么"冗余率反升"不是 bug。 一个自然的审稿质疑是：主动臂冗余率 0.692 反而高于被动臂 0.599，是否说明主动臂其实在重复采？我们的解释是：冗余率度量的是"合格片段之间相互覆盖的程度"。当覆盖被推到 215/226 (95%) 时，剩下的可选片段天然只能补到极少数新单元，重叠必然升高。这是覆盖饱和的数学必然，不是策略失败。真正应据此做的工程决策是：把"覆盖接近饱和"作为停止信号，在覆盖达到 ~90% 时就停止上量、转入对未覆盖 11 个单元的定向补采，而不是继续花预算换冗余。

良率定义为何要"盲"。 如果 QC 可以偷看缺陷真值标签，那么只需"丢弃所有注入了 drift/static/duplicate 的片段"，良率会被人为推到接近 1.0——但这在真实场景中做不到，因为真实场景没有真值标签。坚持盲检，是为了让这个良率定义在真实部署时可执行。我们在实验设置里把 QC 严格限定在可观测信号（轨迹长度、抖动代理、量化签名），并在 `quality_control` 源码中确认缺陷真值 `defect` 字段不参与判决。

8 资源闸门与适用边界

当前可达（CPU，本文已完成）：合成飞轮、盲检 QC、子模贪心、三臂对照、覆盖/密度/冗余指标、10 项契约测试。

解锁真实数据所需闸门（当前不可达，不模拟冒充）：

- 真实 egocentric 采集网络与手部追踪/SLAM；
- 视频理解大模型（"MaxVLM 类"，需多 LLM/视觉 API key）做真实 QC；

- 跨本体 Embodiment Gap 的真机验证。

计划中的因子设计（当前仅单格试点，尚未跑全因子）。 one-pager 已规划但本文尚未执行的全因子为：预算 $\{12, 24, 48, 96\}$ 、片段、缺陷率 $\{0.1, 0.25, 0.4\}$ 、池偏态度 $\{\text{低}, \text{中}, \text{高}\}$ 、状态图粒度 $\{\text{粗}, \text{细}\}$ 。当前实测只取了其中一格（预算 48、缺陷率 0.25、偏态被动 vs 均匀主动）。我们预期：(i) 预算越小，主动相对被动的覆盖率优势越大（因为偏态池在小预算下更早撞墙）；(ii) 缺陷率越高，盲检 QC 对良率的影响越大；(iii) 偏态度越高，H3 越成立。这些均为**待验证预期**，在补全因子前不写成结论，标记

[RESULT NEEDED: 全因子网格 $\times$ 预算/缺陷率/偏态/粒度]。

预注册分析计划（ab-experiment-analysis 门禁）：

- 随机化单元：同一世界同一缺陷率下的独立 seed；曝光单元 = 一次完整 run。
- 主指标：oracle 覆盖率；护栏指标：Yield、经验密度、冗余率、末段边际。
- 最小有意义效应（MDE）：覆盖率绝对差 ≥ 0.05 ；显著性 $\alpha=0.05$ 、功效 0.8；样本量按基线方差情景估计 [RESULT NEEDED: 多 seed 基线方差 $\rightarrow$ 样本量]。
- 停止/质量门禁：SRM（三臂池大小一致）、缺陷注入率一致、QC 阈值固定不回看；不调参消除负向结果。
- 决策规则：主动臂主指标显著优于被动且护栏不降，才支持 H1；同池消融显著支持选片归因。

9 结论

本文把“Coverage-aware 第一人称数据采集”从口号做成了一个可复现、可证伪、带 oracle 的 CPU 实验台。在固定预算下，盲检 QC + 子模贪心把良率从 0.6667 提到 0.8542、oracle 覆盖从 0.695 提到 0.951、密度从 7.80 提到 11.38（均为 seed=0 试点点估计）；同池消融证明收益同时来自选片策略与池子去偏。我们不与任何厂商的“98% 良率”互证，而是强调：良率必须盲检、覆盖必须到状态级、增益必须做消融归因。下一步在 ≥ 30 seed 与小规模真实视频标注上，把方向断言升级为带 CI 的验证性结论。

一句话结论：在固定采集预算下，把“选哪段经验去采”从被动上量换成覆盖函数上的子模贪心，并让良率定义保持盲检，是一个在 CPU 上即可复现、且方向一致地提升良率、状态覆盖与经验密度的工程手段；它的真正价值不在某个漂亮的良率数字，而在于把数据采集从“拍脑袋上量”变成“可度量、可停止、可归因”的闭环。我们既不与厂商的绝对良率互证，也不把单 seed 点估计说成统计显著——这套克制本身，就是本文想传递的方法论立场：在数据采集团队里，先把良率、覆盖、密度三件事用同一套可复现口径量清楚，再谈规模扩张，比一上来追绝对数字更能避免“上量不上质”。

参考文献

说明：以下前两条为本次共享《参考文献总库》中  已核验条目（核验日期 2026-09-19，字段照抄总库）；其余为待补检索方向，保留占位，不伪造出处。

已核验 ( 2026-09-19)

1. Paul, M., Ganguli, S., Dziugaite, D. (2021). Deep Learning on a Data Diet: Finding Important Examples Early in Training (GraNd/EL2N). NeurIPS 2021. arXiv:2106.00278.（关联：早期梯度范数评分剪枝约半数数据无损精度，本文数据选点的直接参照。）
2. Krogh, A., Vedelsby, J. (1995). Neural Network Ensembles, Cross Validation, and Active Learning. NIPS 8 (NeurIPS 1995).（关联：bias-variance-ambiguity 分解与 query-by-committee，本文“边际覆盖作为信息量代理”的理论祖先。）

待核验（保留 [CITATION NEEDED]，不伪造）

- 子模覆盖贪心与 $1-1/e$ 近似：submodular maximization coverage function greedy $1-1/e$ （候选：Nemhauser/Wolsey/Fisher 经典结果）。
- 机器人学习轨迹子集/coreset：coreset selection robot learning trajectory subset。
- 第一人称/具身操作数据集：egocentric video dataset manipulation learning from human videos。
- 数据清洗与去重：data deduplication filtering pretraining dataset quality。
- 覆盖感知/主动采集：active dataset acquisition coverage-aware robot data。

附录

附录 A 复现命令与证据台账

```
# 仓库: udos-engine tag v7.5.0 (commit 1a71270)
python scripts7/egodata_flywheel_demo.py      # 生成 reports7/egodata_flywheel_demo.json
pytest tests7/test_v740_flywheel.py -q        # 10 项契约测试
```

证据台账： - 主数据：reports7/egodata_flywheel_demo.json (v7.4.0, cpu-proto)，trace 7a8ca2ca4ce94bf0。 - 源码：udos7/egodata/{episodes,coverage,processing,collection,benchmark}.py。 - 测试：tests7/test_v740_flywheel.py (10 项：确定性、QC 拒绝三类缺陷、state vs task 覆盖、密度、同池 active $\geq$ passive、良率与拒绝计数、基准分层、最稀疏任务引导)。

复现一致性。 tests7/test_v740_flywheel.py 的 test_benchmark_active_covers_more_and_graded 用 pool_size=50, budget=16, seed=11 跑两次基准并断言两次的 state_cells 完全相等 ($== r2["..."]$)，把"同 seed 同配置结果逐位一致"这一确定性属性固定为回归断言。这意味着本文报告的 seed=0 主数字，任何人在同版本代码下重跑都应逐位复现，不存在随机性带来的数字漂移。trace 记录 (trace_id=7a8ca2ca4ce94bf0，单次 4889 ms, token_usage=0) 也佐证该基准不调用任何外部 LLM，纯本地 CPU 计算。

1. Yield 0.8542 $\leftarrow$ JSON coverage_aware_collection.yield。
2. oracle 覆盖 0.951 $\leftarrow$ JSON coverage_aware_collection.oracle_fraction (215/226 $\approx$ 0.9513)。
3. 被动密度 7.80 $\leftarrow$ JSON passive_collection.mean_density。
4. 消融覆盖 0.889 $\leftarrow$ JSON ablation_greedy_on_skewed_pool.oracle_fraction (201/226 $\approx$ 0.8894)。
5. duplicate 拒绝 8 $\leftarrow$ JSON passive_collection.reject_reasons.duplicate。

附录 C 作者拟用声明

- **目标出口**：CoRL / RSS workshop、NeurIPS Datasets & Benchmarks、ICRA；期刊 IJRR / IEEE RA-L / T-PAMI（若含真实数据）。分区/影响因子/截稿日一律 [待核]，投稿前联网核验并标注核验日期。
- **预注册计划**：按第 8 节主指标/护栏/MDE/停止规则，在收集 ≥ 30 seed 数据前冻结方案并登记。
- **数据与代码可用性**：Apache-2.0；代码 tag v7.5.0 (commit 1a71270)；报告 reports7/egodata_flywheel_demo.json。
- **AI 使用声明**：本文撰写借助 AI 辅助生成初稿与配图脚本，全部数字经作者从 reports7 与源码逐一回源核对；外部数字保持 unverified 标注，未填充未经核验的 p 值/CI/DOI/分区。

附录 D 内审记录（五维审稿自评，只看不改）

按 doubao-academic-evaluator 五维自评 (1-5)：

1. **新颖性**：3/5。子模选择与盲检均成熟，新意在"把 egocentric Yield/覆盖做成带 oracle 的可复现基准"。

2. **证据强度**: 2/5 (当前稿)。全部单 seed 点估计, 无 CI/p 值; 这是当前最大硬伤, 已如实标注 [RESULT NEEDED]。
3. **可复现性**: 5/5。固定 seed、CPU、复现命令、测试索引、证据台账齐全。
4. **外部效度**: 2/5。纯合成代理世界, 已显式声明不能等同真实视频良率。
5. **写作与诚实性**: 4/5。区分 verified/cpu-proto/unverified, 负向结果 (冗余率反升、子集 $\neq$ 训练收益) 如实呈现。

总体判断: 当前为**可投稿的方法/基准稿骨架, 但证据强度未达标**。投稿前必须完成 ≥ 30 seed 配对统计与至少小规模真实视频标注试点, 否则建议定位为 benchmark/workshop 短文而非主会长文。