



P13

The Wall of Scaling Is a Paradigm Wall, Not a Physical Limit: Four Bottlenecks, Five Breakout Paths, and a Three-Section Phase Transition

The Wall of Scaling Is a Paradigm Wall, Not a Physical Limit

The Wall of Scaling Is a Paradigm Wall, Not a Physical Limit: Four Bottlenecks, Five Breakout Paths, and a Three-Section Phase Transition

Abstract — A direct extension of P0b, this paper argues that the widely discussed scaling wall is a paradigm wall rather than a hard physical limit. It catalogs four bottlenecks (communication, coordination, data, energy) and five breakout paths, and frames progress as a three-section phase transition. When a structure saturates, changing the paradigm, layered topology, or routing lets the curve bend rather than terminate. The cortex folds to beat the wiring wall just as layered agent topologies beat the communication wall.

Keywords: scaling wall; paradigm; bottleneck; phase transition; breakout path; topology

孪生地球

Scaling 的"墙"是范式墙，不是物理极限：四面墙、五条破墙路径与三段式相变

Working Title (EN): The Wall of Scaling Is a Paradigm Wall, Not a Physical Limit: Four Bottlenecks, Five Breakout Paths, and a Three-Section Phase Transition

专题篇 P13 · 旗舰篇 P0b 《结构 + 规模，本身就是智能》的直接延伸 · UDOS 推演引擎 v7.5.0 · 2026-09-20

一句话先说清：当前被反复讨论的"Scaling 撞墙"，撞的不是智能的物理极限，而是**固定范式（Transformer + 稠密计算 + 互联网文本）的承载极限**。破墙不是把墙推倒，而是换一条增长曲线——**更换结构，而非停止堆叠**。

证据口径（全文只声明这一次）：UDOS 引擎自己跑出的数字全部来自 reports7/*.json，普通 CPU、固定随机种子、可重复运行，分三级标注：verified（有自动化测试守门）、cpu-proto（CPU 原型趋势，常数未经多种子校准）、unverified（外部报道/论文一方主张，只作动机）。单种子结果一律写"试点"，投稿前需 ≥30 个种子与 95% 置信区间。**外部文献与产业数字逐条联网核验于 2026-09-20；**凡只在新闻稿或论文自述中出现、未经独立复现的数字，均明确标注"论文报告/公司披露，未独立复核"。

摘要

"Scaling Law 撞墙了吗？"已成为 2026 年大模型领域最分裂的问题。本文不直接选边，而是先把"墙"拆成四个**可以分别测量**的维度：数据墙（高质量语料有限、合成数据熵饱和）、算力/能源墙（稠密矩阵乘法逼近热力学与电网约束）、架构墙（注意力与残差等沿用近十年的结构成为瓶颈）、收益墙（同一架构内规模每升一个数量级，边际能力增益递减）。我们论证：这四面墙有一个共同前提——**结构被冻结**。它们量到的都是"在固定范式内沿一条曲线走到头"的现象，因此是**范式墙**，不是智能的物理极限。

在姊妹篇 P0b 的三段式框架下，墙恰好对应曲线的第二段——结构相变拐点：第一段结构对、规模小，能力沿幂律增长；第二段旧结构撑不住，必须换组织方式；第三段在新曲线上继续增长直到撞上一堵墙。破墙因此是"换曲线"而不是"在旧曲线上跑得更快"。我们把 2025–2026 年的破墙尝试归并为五条路径并给出可证伪假设：(P0) 数据效率，用采集结构而非采集预算提高有效经验，UDOS 受控试点中 Coverage-aware 主动采集在同等预算下把良率从 0.667 提到 0.854、经验密度从 7.80 提到 11.38 (+46%，verified 试点)；(P0) 架构重构，包括深度维度注意力（Attention Residuals，论文报告约 $1.25\times$ 计算效率，arXiv:2603.15031，未独立复核）、非线性注意力扩展（Nexusformer，arXiv:2604.19147）、线性-softmax 混合（InclusionAI Ling

2.5) ; (P1) 训练范式, 从预训练 Scaling 转向思维链/测试时 Scaling 与回放式自改进 (Dream-RL, arXiv: 2609.14858, 论文报告最多省 162× Agent 调用) ; (P1) 系统级 Scaling 与 Agent 治理 (UDOS P1/P2/P9/P10/P11) ; (P2) 硬件范式, 以华为"韬(τ)定律"为代表的时间缩微路线 (何庭波等, ChinaXiv, 2026-05) 。

我们同时做了一项必要的事实核查: 流传甚广的"GPT-4 到 GPT-5 算力增加约 10 倍"缺乏公开证据; 第三方 Epoch AI 口径的估计约为 2-3 倍 (GPT-5 总训练算力约 5e25 FLOP 对 GPT-4 约 2e25 FLOP, unverified) , 且"舰队 GPU 总数"与"单次训练算力"常被混为一谈。本文不采用 10 倍这一数字。最后给出五条可杀死本文结论的预测与四条反方意见。

关键词: scaling law; 数据墙; 架构墙; 相变; 注意力残差; test-time scaling; RSI; 证据分级; 可证伪预测

结构化摘要 (背景问题 → 方法 → 证据结果 → 贡献)

- **背景问题:** 同架构下边际收益递减被解读为"Scaling 已死", 但该结论把"固定范式的极限"误当成"智能的极限"。
- **方法:** 把墙操作化为四个可测维度; 用 P0b 的三段式曲线 (幂律→相变→饱和/负收益) 统一解释; 把破墙尝试归并为五条路径, 每条路径预注册一个可证伪假设; 对外部数字做逐条核验。
- **证据结果:** UDOS 自有证据为受控 CPU 试点 (良率 0.667→0.854、密度 +46%、错结构下 8 Agent 吞吐仅 0.695×、等权差专家误差差约 23 倍) ; 外部证据按"已核验存在/论文报告未复核/查无实据"三档分列。
- **贡献:** (1) 范式墙的四维操作定义; (2) 五路径优先级与判据; (3) "墙=相变点"的可检验表述; (4) 对 10× 算力说法的公开更正。

1 引言: 墙这个比喻, 需要先被测量

2020 年 Kaplan 等人的 Scaling Laws 给出了一个极其好用的工程信念: 只要同时放大参数 N 、数据 D 与算力 C , 损失就沿可预测的幂律下降 [CITATION NEEDED: Kaplan 2020, arXiv:2001.08361, 版本卷参考文献总库]。Chinchilla 随后补上了"数据与参数要等比"的约束 [CITATION NEEDED: Hoffmann et al. 2022, arXiv:2203.15556]。到 2024-2026 年, 三个现象让"撞墙"成为流行叙事: 高质量互联网文本趋近采空、前沿模型训练的电力与集群规模逼近现实约束、同代架构之间代际差距收窄。

比喻不能替代测量。"墙"这个词如果要进入工程讨论, 必须回答三件事: 墙在哪个变量上、墙的高度怎么量、墙的另一边是什么。本文的立场是:

四面墙量到的都是同一件事——在结构被冻结时, 沿单一规模轴的边际收益递减。它们是范式墙 (paradigm wall) , 不是物理极限墙 (physical wall) 。

这一立场直接继承 P0b 的中心公式:

$$S \approx F(S; N, D, C), \quad S = (T, G, M)$$

其中 S 是结构三元组 (连接拓扑 T 、几何/空间组织 G 、模块边界 M) , N, D, C 分别是节点/参数、数据/经验、算力/能量。固定 S 只放大 N, D, C , 系统沿一条既定曲线移动; 改变 S , 则换到另一条曲线。本文讨论的所有"破墙路径", 本质上都是在回答"换哪一个结构变量"。

1.1 本文不主张什么

为避免被读成又一篇"Scaling 万岁"的辩护词，先划三条边界：

1. 本文**不否认墙的真实性**。数据、能源、架构、收益四类约束都有可观测证据，否认它们等于否认工程现实。
2. 本文**不预测墙后是无限增长**。换结构只把墙推后，新结构会撞上下一堵墙；三段式曲线是开放的、可反复出现的，不是通向奇点的单行道。
3. 本文**不把外部厂商的效率倍数当作已证实事实**。凡未经独立复现的 $1.25\times$ 、 $162\times$ 、 $3.2\times$ 等，一律标"论文报告/公司披露"。

2 相关工作与脉络

Scaling 与数据约束。Kaplan 式幂律与 Chinchilla 的计算最优配比构成"旧约" [CITATION NEEDED]。此后两条线索与本文直接相关：一是数据侧，重复数据、合成数据的"模型崩塌 (model collapse)"研究指出自噬式数据存在熵饱和 [CITATION NEEDED: Shumailov et al., Nature 2024]；二是架构侧，稀疏化 (Switch Transformer, arXiv:2101.03961) 证明"总参数大、激活参数小"可行 [CITATION NEEDED]。

结构先验即性能。BPE (arXiv:1508.07909) 与 SentencePiece (arXiv:1808.06226) 是输入结构先验；注意力 (arXiv:1706.03762) 是序列结构先验；MoE 路由是容量结构先验。2026 年的一批工作开始直接重写这些先验：Attention Residuals 重写深度维度的残差聚合 (arXiv:2603.15031, 已核验存在)；Nexusformer 用非线性 Nexus-Rank 替换线性 Q/K/V 投影 (arXiv:2604.19147, 已核验存在)；JTok 提出 token-indexed parameters 作为与 FLOPs 解耦的正交 Scaling 轴 (arXiv:2602.00800, 已核验存在)；SCONE 给出嵌入层/n-gram 扩展策略 (arXiv:2502.01637, 已核验存在)。

测试时与自改进 Scaling。Chain-of-Thought (arXiv:2201.11903) 开启推理链激发 [CITATION NEEDED]；2026 年的 Dream-RSI 把"发现树回放"当作零成本模拟器来改进探索策略 (arXiv:2609.14858, 已核验存在，准确标题为 Recursive Self-Improvement through Evolving Worlds)。RSI 谱系与七大厂商路线是姊妹篇 P14 的主题，本文只在路径三中引用其结论。

硬件时间缩微。华为 2026-05-25 在 IEEE ISCAS 提出"韬(τ)定律"，何庭波署名论文《A Time Scaling Theory for Multi-Layer Electronic Systems》提交 ChinaXiv，主张以系统级时间常数 τ 的缩微替代几何缩微，披露 2020-05 至 2026-05 设计量产 381 款芯片，预测 2031 年高端芯片晶体管密度 ($155 \rightarrow 400+$ MT/mm²) 达到 1.4nm 制程同等水平 (公司/会议披露，已核验多源报道，具体预测值属 unverified)。

3 四面墙：把比喻拆成四个可测量

图1 Scaling 的四面墙

图1 四面墙不是四堵独立的墙，而是同一面"范式墙"的四个投影。以下逐一测量口径。

3.1 数据墙：有效 token 不是总 token

数据墙的严格表述不是"互联网文本有限"，而是**去重、去污染、去低质后的有效 token 流**
 $\$D_{\mathrm{eff}}(t)\$ 的增长率有限：$

$$\$D_{\mathrm{eff}} = \sum_i \mathbb{1}[\text{novel}_i] \cdot q_i, \quad q_i \in [0,1] \tag{2}$$

其中 novel_i 表示第 i 份数据相对既有数据池是否带来新的状态覆盖， q_i 是质量分。当新增数据主要是旧场景的复刻时， $\text{novel}_i \rightarrow 0$ ，总小时数上涨而 $\$D_{\mathrm{eff}}\$ 不涨。合成数据在此之上叠加熵饱和和风险：用模型输出再训练模型，分布方差逐代收缩。数据墙因此首先是一个**采集结构**问题，而不是采集预算问题——这正是路径一的切入口。$

3.2 算力/能源墙：线性降损失需要指数级能量

在幂律损失 $L(C) \approx L_{\infty} + (C/C_0)^{-\alpha}$ 下，把损失再压低一个固定量 ΔL 所需算力按 $1/\Delta L^{1/\alpha}$ 量级增长；而数据中心的供电、散热与电网接入是线性资源。墙的高度可用“单位能力增量的边际焦耳数” $dE/d(\text{capability})$ 测量。这堵墙是真实的物理约束，但它约束的是稠密全激活计算这一特定结构；稀疏激活、测试时按需计算、专用硬件都在改变 $dE/d(\text{capability})$ 曲线本身。

3.3 架构墙：十年标准成为增长语法的瓶颈

架构墙指：被默认为“中性底座”的连接方式——软max 自注意力的二次复杂度、残差连接对各层的无差别累加、稠密 FFN——在深度/序列长度增大时引入结构性折扣。Attention Residuals 一文把后者表述为“PreNorm 稀释”：隐状态量级随深度线性增长，第 5 层的有用表示到第 50 层被其余 45 层稀释（arXiv:2603.15031 摘要与二手解读，已核验论文存在；机制描述据其摘要）。架构墙最容易被忽视，因为它伪装成“算力不够”。

3.4 收益墙：同架构边际增益递减

收益墙是前三面墙在能力轴上的汇总表现：固定 $\$$ 时， $\partial \text{capability} / \partial \log N$ 随 $\log N$ 单调下降。P0b 在 CPU 原型上给过一个尖锐的微型例证：CPU 密集任务上并发 Agent 从 1→2 吞吐 $1.594\times$ ，2→8 不升反降到 $0.695\times$ （reports7，单 seed 试点）；而 I/O 密集任务同区间近似线性 $7.99\times$ 。规模轴完全相同，收益符号由结构匹配与否决定——收益墙是结构墙的影子。

4 五条破墙路径：动作、证据与可证伪假设

图2 三段式曲线与换曲线

图2 墙对应三段式曲线的相变拐点。破墙=让系统跳到新曲线，而非在旧曲线上继续右移。

4.1 路径一（P0）：数据效率——改采集结构，而不是加采集预算

动作：把数据采集从被动记录升级为 Coverage-aware 的主动扫描——先对既有数据池做分布诊断，锁定状态覆盖盲区（长尾物体、柔性操作、复杂受力），再定向调度补采；同时用自动质检剔除无效片段。

UDOS 受控证据（verified 试点，reports7，48 episode / 144 分钟，oracle 226 单元）：

图3 主动采集良率与密度

图3 同等采集预算下，被动采集良率 0.667、经验密度 7.80 单元/小时；主动盲区扫描良率 0.854、密度 11.38（+46%）；同偏态池贪心消融对照为 0.7917/0.889，说明增益来自“盲区定向”而非“更努力采集”。单 seed 试点，投稿前需 ≥ 30 seed。

外部同方向工作（unverified，论文报告）：JTok 的 token-indexed parameters 声称在不扩展主干 FLOPs 的前提下增加容量（arXiv:2602.00800，已核验论文存在；“节省约 1/3 算力”的具体数字未在本次核验中从原文证实，标 [RESULT NEEDED]）；SCONE 的 n-gram 嵌入扩展提供了另一条嵌入层 Scaling 轴（arXiv:2502.01637）。

可证伪假设 H1：固定采集预算，主动扫描相对被动采集的良率提升 $\Delta Y > 0$ 在 ≥ 30 个独立场景种子、95% 置信下显著；若多场景复现中 ΔY 的置信区间跨 0，路径一的核心主张被推翻。

4.2 路径二（P0）：架构重构——更换增长的语法

动作与证据（均为外部论文报告，未独立复核）：

方向	工作	报告的核心突破	核验状态 (2026-09-20)
深度维度注意力	Attention Residuals (Kimi/Moonshot)	用对历史层输出的 softmax 注意力替换固定残差累加; Block AttnRes 把复杂度从 $\mathcal{O}(Ld)$ 降到 $\mathcal{O}(Nd)$; 论文报告 1.4T token 预训练约 $1.25\times$ 计算效率、推理延迟增加 $<2\%$ (48B 总参/3B 激活的 Kimi Linear)	arXiv:2603.15031 已核验存在; 倍数为论文报告
非线性注意力扩展	Nexusformer	Nexus-Rank 三阶段非线性映射; 零初始化块支持无损结构化增长; 报告以最多约 41% (参数量/算力口径) 匹配 Tokenformer 困惑度	arXiv:2604.19147 已核验存在; 具体百分比为论文报告
线性-softmax 混合	InclusionAI Ling 2.5 (1T, 2026-02)	Lightning Attention 循环线性通路 + DeepSeek 式 MLA, 降长程 KV 缓存	二手综述 (Raschka 等) 多源一致, 未读原文报告
线性注意力 ("SeedFold")	材料中称字节 SeedFold, 立方 $\rightarrow$ 二次复杂度	—	本次检索未找到对应论文/产品, 标查无实据 [CITATION NEEDED], 本文不采信

UDOS 侧的同构证据是 P0b 的 "23 倍 vs 0.5%": 把一个不合格专家等权集成, MSE 从校准加权的 0.0092 涨到 0.2131 (约 23 倍恶化), 而单纯增加合格成员数量误差几乎不动 (reports7, $\$k\leq 2\$$ verified)。改连接/加权结构的杠杆, 远大于加节点数量。

可证伪假设 H2: 在同一数据、同一训练算力预算下, 新结构相对旧结构的单位算力困惑度/任务收益优势, 应能被第三方在 $\geq 1B$ 参数规模独立复现; 若只有原作者团队能复现, 或优势在换一个数据域后消失, 则"换结构换曲线"在该方向上不成立。

4.3 路径三 (P1) : 训练范式——从预训练 Scaling 到思维链/测试时 Scaling

预训练 Scaling 是"见过更多", 测试时与回放式 Scaling 是"推演更深": 1 条真实经验经世界模型回放生成 1000 次虚拟模拟、上万条内部思维轨迹。Dream-RSI (Google/DeepMind 等, arXiv:2609.14858, 2026-09-14 提交) 的关键机制是把已完成的发现树当作"已实现搜索空间上的回放模拟器", 在树上离线评估并改进探索策略, 底层编码 Agent 保持不变; 论文报告相对 SimpleTES 最多省 $162\times$ Agent 调用、相对固定探索基线约 $1.7\times$, 并观察到人类引导反而更差 (以上倍数均为论文报告, 未独立复核; 且作者与第三方都强调它不是模型自改权重的完整 RSI)。

可证伪假设 H3: 回放式策略改进的收益应随发现树规模单调不减, 且迁移到新任务族时不出现显著负迁移; 若"做梦"只在原任务上有效, 它属于任务内缓存, 不是新 Scaling 轴。

4.4 路径四 (P1) : 系统级 Scaling 与 Agent 治理——从单模型到组织

当单点模型的曲线趋平, 把多个 Agent 组织成系统会打开一条新的规模轴, 但这条轴同样服从"结构决定形状"。UDOS 六篇专题的受控结果 (数字均回 reports7, 属性/契约/单元测试守门为 verified, 外推为 cpu-proto) :

- **拓扑 (P1) :** 百万节点下星型中心需处理约 2097 万条消息、关键路径约 839 万轮; 分层混合拓扑中心负载恒为 9、轮次仅 14——增长指数从 1 变成 0。
- **停止决策 (P2) :** BFT-lite 委员会 $\$n\geq 3f+1\$$ 、法定人数 $\$2f+1\$$, $\$n=7,f=2\$$ 下对 24 个工单 24/24 验收正确; 10 项属性测试 verified。
- **质量饱和 (P9) :** $\$mse(k)=a+b/k\$$, 同质化扩招越过真实独立源数后红利归零 ($\$k\leq 2\$$ verified, $\$k>2\$$ cpu-proto)。
- **交接契约 (P10) :** TransferBundle 六字段 (Goal/Context/Done/ToDo/Trace/Owner) 机械校验, 26 项契约测试 verified; 失败率字段为 [RESULT NEEDED]。

- **结算守恒 (P11)** : $\frac{\text{balance_sum}}{\text{paid}}$ 由代码结构保证，混合任务预算 24/已付 16/罚没 1 守恒为真，10 项单元测试 verified。

可证伪假设 H4: 治理机制（唯一 Owner、Trace、显式停止条件、守恒不变量）带来的收口率提升，应在 Agent 数 10^{11} 的压测中保持；若越过某个规模阈值后 Trace 断裂率失控上升，则系统级 Scaling 同样存在自己的墙，且本文给出的机制不够用。

4.5 路径五 (P2)：硬件与能源范式——绕过几何缩微墙

华为"韬(τ)定律"主张不再把性能增长全部押在晶体管几何尺寸上，而以器件-电路-芯片-软件全栈协同压缩信号传播的时间常数 τ （逻辑折叠、关键路径缩短、寄生 RC 下降）；其论文与发布会披露 6 年 381 款芯片、2031 年密度等效 1.4nm (155→400+ MT/mm²)。这是典型的"换结构换曲线"思路，但所有 2031 年数字都是**预测目标而非实测**，本文列为 unverified。架构层面与之配套的是异构混合：Transformer 负责逻辑推理、线性注意力/Mamba 类负责长时序、世界模型负责物理状态推演。

可证伪假设 H5: 时间缩微路线应在不依赖最先进光刻节点的前提下，在公开基准（如每瓦 token 吞吐）上持续兑现代际提升；若 2027–2028 的量产芯片无法复现预测曲线，τ 路线被证伪为工程叙事。

4.6 五条路径的优先级

优先级	路径	核心动作	证据成熟度
P0	架构重构	更换底层连接方式	外部论文报告活跃，UDOS 侧有结构杠杆微型验证
P0	数据效率	改采集结构	UDOS 有受控试点（单 seed），外部有同方向论文
P1	训练范式	测试时/回放 Scaling	外部论文报告，机制清晰、倍数待复核
P1	Agent 治理	拓扑+委员会+契约+守恒	UDOS 多项 verified 测试，规模外推待做
P2	硬件范式	时间缩微+异构混合	厂商路线图与预测，兑现周期最长

优先级的排序原则是**杠杆/证据成熟度之比**，不是技术酷炫程度。

5 一项必要的事实核查："GPT-4→GPT-5 算力 10 倍"不成立

图4 算力倍数核查

图4 公开估计与传言的对比。第三方 Epoch AI 口径（经 TensorFeed 2026-05 汇编）估计 GPT-5 总训练算力约 5e25 FLOP、GPT-4 约 2e25 FLOP，约 2.5 倍；且 GPT-4.5 据同一口径可能高于 GPT-5。以上均为 unverified 第三方估计。

"算力约增 10 倍但性能不成比例"是四面墙叙事中被引用最多的数字之一。本次核验（2026-09-20）未找到支持 10 倍的公开口径，反而发现三类常见口径混淆：

1. **舰队规模 ≠ 单次训练算力**。"OpenAI 约 20 万张 GPU""单次 10 万卡训练任务"是基础设施容量或编排规模，不能直接当作某一代模型预训练算力。
2. **预训练算力 ≠ 总训练算力**。RL/后训练占比在不同估计中从 10% 到 200% 不等，口径不同倍数可差一倍以上。
3. **投入算力 ≠ 有效算力**。利用率（MFU）、浮点精度、MoE 激活率都会改变"同样 FLOP 买到的能力"。

因此本文在所有图表中**不使用 10 倍**，改用"约 2–3 倍（第三方估计，unverified）"并显式标注口径。这一更正本身也是方法立场：讨论"墙"之前，先保证量墙的尺子是准的。

6 讨论：墙是相变点，破墙是换曲线

P0b 的三段式曲线给了四面墙一个统一位置：它们都发生在第二段。大脑用皮层褶皱应对布线墙、芯片用多核应对功耗墙、模型用 MoE 路由应对参数墙、Agent 系统用分层拓扑应对中心扇入墙——历史反复呈现同一个模式：**饱和不是终点信号，而是"该换结构了"的信号。**

这也限定了"Scaling 没有死"这类乐观说法的成立条件。Anthropic 方面关于"2026 年仍将激进加速"的判断（二手报道，[CITATION NEEDED]）只有在"加速发生在新曲线上"时才成立；如果加速指的是在旧曲线上投更多电，它恰好会被收益墙否定。**Scaling Laws 没有死，它换了个活法：从在一条曲线上跑得更远，变成不断换到更好的曲线。**

7 可杀死本文的预测与反方意见

五条硬预测（预注册）：

- F1（对应 H1）： ≥ 30 场景种子复盘，主动采集良率增益的 95% CI 不跨 0；跨 0 则路径一被否。
- F2（对应 H2）：Attention Residuals/Nexusformer 类结构优势在第三方 $\geq 1B$ 复现中成立；两年内无独立复现则"架构墙可由换结构突破"的强主张降级为个案。
- F3（对应 H3）：回放式 RSI 在新任务族出现负迁移或收益随树规模转平，则它不是新 Scaling 轴。
- F4（对应 H4）：Agent 治理机制在 $\$10^4$ 量级压测中收口率跌破对照组，则系统级 Scaling 的治理红利存在未被识别的墙。
- F5（总纲）：若存在一类能力，其提升在**所有已知结构变换**下都严格受同一条幂律支配、且无任何换曲线空间，则"范式墙"框架错误，那才是真正的物理极限墙。

四条反方意见：

1. "墙就是物理极限，换结构只是把常数变好、指数逃不掉。" 部分同意—— τ 、能源、土地最终是物理约束；但本文主张的是反复相变会把极限持续推后，可观测的未来墙仍是范式墙，F5 是裁决实验。
2. "效率倍数全是厂商自报，不可信。" 同意大半，因此本文全部外部倍数标论文报告/unverified，结论不依赖任何单一倍数成立。
3. "主动采集的增益只是挑了容易的任务。" 这正是设同偏态池贪心消融（0.7917/0.889）的原因；但单 seed 不足以下结论，F1 已要求多种子。
4. "五路径是并列清单，不是理论。" 接受——本文的理论主张只有一条（墙=固定结构的相变点），五路径是该主张在 2026 年技术地图上的投影，会过时，主张不必过时。

8 效度威胁与适用边界

- 本文 UDOS 数字来自 CPU 原型、固定单种子，属试点估计；绝对常数不能外推到真实 LLM 集群，投稿前需 ≥ 30 seed 与 95% CI（约 64/65 处 [RESULT NEEDED]）。
- 外部论文多为 2026 年预印本，未经同行评审；arXiv 编号已核验存在，但报告倍数未独立复现。
- "SeedFold"在本次核验中查无实据，已明确剔除；材料中若还有同类未核验名称，应同此处理。
- 华为 τ 定律与各厂商 2028/2031 目标是预测，不是事实。
- 本文不讨论意识、不主张任何系统已具备自我；RSI 的定性与安全边界见姊妹篇 P14。

9 结论

Scaling 的墙真实存在，但它量的的是一个被冻结的范式的承载力，不是智能的物理极限。把墙拆成数据、算力/能源、架构、收益四个可测维度后可以看到：前三者的共同解法是更换结构（采集结构、连接结构、计算的时间结构），第四者（收益墙）则是前三类结构错配的汇总症状。P0b 的三段式曲线给了墙一个精确位置——相变拐点；2025–2026 年的五条路径给出了绕墙开门的工程地图。优先级最高的不是更贵的算力，而是数据采集结构与模型连接结构的重构。**破墙的本质不是把墙推倒，而是在墙旁边开一扇新门；而开门的图纸，是结构，不是规模。**

参考文献（核验状态随条标注）

1. Kaplan J. et al. Scaling Laws for Neural Language Models. arXiv:2001.08361, 2020（用户附件原件，写作范本）。
 2. Hoffmann J. et al. Training Compute-Optimal LLMs (Chinchilla). arXiv:2203.15556, 2022 [CITATION NEEDED: 卷内统一著录]。
 3. Fedus W. et al. Switch Transformers. arXiv:2101.03961 [CITATION NEEDED]。
 4. Sennrich R. et al. BPE. arXiv:1508.07909 [CITATION NEEDED]; Kudo & Richardson SentencePiece arXiv:1808.06226 [CITATION NEEDED]。
 5. Vaswani A. et al. Attention Is All You Need. arXiv:1706.03762 [CITATION NEEDED]。
 6. Kimi Team. Attention Residuals. arXiv:2603.15031, 2026-03（**已核验存在**； $1.25 \times / 1.4T/48B-3B / < 2\%$ 为论文报告，未独立复核）。
 7. Nexusformer: Nonlinear Attention Expansion for Stable and Inheritable Transformer Scaling. arXiv: 2604.19147, 2026（**已核验存在**；41% 等数字为论文报告）。
 8. JTok: On Token Embedding as Another Axis of Scaling Law via Joint Token Self-modulation. arXiv: 2602.00800, 2026（**已核验存在**；"省 1/3 算力"未从原文证实，[RESULT NEEDED]；作者机构归属未核验）。
 9. Scaling Embedding Layers in Language Models (SCONE). arXiv:2502.01637, 2025（**已核验存在**）。
 10. Zheng T. et al. Dream-RSI: Recursive Self-Improvement through Evolving Worlds. arXiv:2609.14858, 2026-09-14（**已核验存在**； $162 \times / 1.7 \times /$ "人类引导更差"为论文报告）。
 11. InclusionAI. Ling 2.5 / Ring 2.5 技术材料，2026-02（MLA+Lightning Attention；据 Raschka 综述与 InfoQ 二手材料，未读原文 [CITATION NEEDED]）。
 12. 何庭波等. A Time Scaling Theory for Multi-Layer Electronic Systems（ τ/τ 定律）. ChinaXiv, 2026-05；IEEE ISCAS 2026 发布；381 款芯片/ $155 \rightarrow 400+ \text{ MT/mm}^2/2031$ 等效 1.4nm 为公司披露与预测（多源报道已核验事件，预测值 unverified）。
 13. Epoch AI / TensorFeed 汇编. Has frontier AI training-compute growth actually slowed? 2026-05（ $\text{GPT-5} \approx 5e25$ 、 $\text{GPT-4} \approx 2e25$ FLOP 估计，**第三方估计，unverified**）。
 14. "SeedFold": 本次（2026-09-20）公开检索未找到对应论文或产品，**查无实据，不予采信** [CITATION NEEDED]。
 15. UDOS 姊妹篇：P0b《结构+规模，本身就是智能》、P1/P2/P9/P10/P11/P12（本卷），数字回 reports7/*.json。
-

附录 A 复现命令与测试索引

- 数据飞轮试点: `reports7/coverage_flywheel*.json` (48 episode/144 分钟, oracle=226) ; 对照键 `passive/active/greedy_samepool`。
- 拓扑外推: `reports7/topology_scale*.json` (六档目标 $10 \rightarrow 1e6$) ; BFT: `reports7/bft_lite*.json` ($\$n=7, f=2$, 24 工单)。
- 质量饱和: `reports7/expert_mixture*.json` ($\$mse(k)=a+b/k$, $\$a=0.009252, b=-4.233 \times 10^{-5}$)。
- 测试守门: P2 10 项属性测试、P10 26 项契约测试、P11 10 项单元测试 (命令与版本见 P12 附录)。

附录 B 证据台账 (三档)

- **verified (测试守门)** : BFT 24/24、守恒 240/16/1、契约字段校验、拓扑计数公式。
- **cpu-proto (CPU 原型趋势, 单 seed)** : 良率 $0.667 \rightarrow 0.854$ 、密度 $7.80 \rightarrow 11.38$ 、吞吐驼峰 $244.172/106.485$ 、专家混合 0.0092 vs 0.2131 。
- **unverified (外部一方主张)** : $1.25 \times$ 、 $162 \times$ 、 $1.7 \times$ 、 $3.2 \times$ 、+10.9 分、26%、3 万并发、381 款芯片、2031 等效 1.4nm、算力 2-3 倍估计; "SeedFold"查无实据。

附录 C 内审记录 (投稿前五维自评, 只看不改)

- 新颖性: 中高 (范式墙四维操作化 + 五路径可证伪假设 + 算力倍数公开更正)。
- 证据强度: 内部弱 (单 seed)、外部中 (事件多源核验、倍数未复核)。
- 可复现性: 内部高 (JSON 可复跑)、外部不适用。
- 主要缺口: ≥ 30 seed 复算; 外部论文的独立复现实验; 算力口径的一手数据。
- 结论: **当前为可讨论的工作论文 (working paper), 不具备投稿状态**; 补齐 F1-F4 后可投 TMLR / NeurIPS Datasets & Benchmarks / ICML workshops 类 venue [CITATION NEEDED: 选刊需另查截稿与分区]。

作者拟用声明

房文新 (拟用)。UDOS 推演引擎 v7.5.0 论文卷 · 专题篇 P13。本文不含任何受版权限制的第三方图片; 外部数字均标注来源与核验状态。外部机构名称与商标归各自所有者, 引用仅用于学术评述。