



P16

Typed Finality: Upgrading the Binary BFT-lite Stop Decision into Three Levels of Semantic Commit for LM-Agent Committees

Typed Finality: Upgrading the Binary BFT-lite Stop Decision into
strong_stop / weak_stop / abort Three Levels of Semantic
Commit

Typed Finality: Upgrading the Binary BFT-lite Stop Decision into Three Levels of Semantic Commit for LLM-Agent Committees

Abstract — A semantic upgrade to P2, this paper replaces the binary stop decision with three levels of semantic commitment, `strong_stop`, `weak_stop`, and `abort`, for LLM-agent committees. Strong stop commits fully, weak stop commits conditionally pending further evidence, and abort rolls back. Together with weighted BFT (P26) and rules-before-learning (P32), typed finality lets committees express graded confidence as graded commitment rather than a single yes/no threshold.

Keywords: typed finality; semantic commit; BFT; stop decision; LLM agents; rollback

孪生地球

类型化最终性：把二元停止决策升级为 `strong_stop` / `weak_stop` / `abort` 三级语义提交

Working Title (EN): Typed Finality: Upgrading the Binary BFT-lite Stop Decision into Three Levels of Semantic Commit for LLM-Agent Committees

共识治理篇 P16 · v7.5.0 P2 《多智能体停止决策的 BFT-lite》的语义升级 · 与 P26（加权 BFT）、P32（规则优先于学习）互为姊妹篇 · UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

一句话先说清：LLM 委员会每轮产出的是随机自然语言，不可能像经典 BFT 那样对“完全相同的字节”达成一致；v7.5.0 P2 的二元 STOP/CONTINUE 把“语义到底多一致”压成了一个开关，太粗。本文把它升级为三级**类型化最终性 (typed finality)**——`strong_stop` ($\geq 2f+1$ 名成员对语义核心一致)、`weak_stop` (仅对 `verdict` 标签一致)、`abort` (不一致，转 `view change`)，并把 H-CSC v2 的自我撤回负结果作为“哪些东西不要做”的红线。三级升级是**设计提案·待实施**，无新实验数字。

证据口径（全文只声明这一次）：本文外部对话对象为 H-CSC (arXiv:2606.07316，**注意 v2 已改题**为 *Certifiable Semantic Agreement Among LLM Agents: What the Admissibility Instrument Decides*)，其存在性与“类型化提交对象 / $2f+1$ 证书信封”已核验；其负结果数字（聚合距离、诚实保留率、词法谓词与学习编码器 AUROC）为**论文报告、未独立复核**，且为 v2 主动撤回口径。UDOS 侧数字全部回 v7.5.0 P2 (`udos7/topology/consensus.py`，证据等级 `cpu-proto / verified`)。本文不新造任何 UDOS 实测数；三级最终性的收益一律标 `[RESULT NEEDED]`。核验日 2026-09-21。

摘要

v7.5.0 P2 把“一个工单算做完了还是要返工”这一末端决策，降级为一个最小拜占庭容错委员会：委员会规模 $\geq 3f+1$ 、法定人数 $2f+1$ 、同轮 equivocation 整轮作废、超 f 沉默返回 `NO_QUORUM` 并触发 `view change`。它在 $n=7, f=2$ 下用 10 项属性测试 (verified) 守住了“诚实超多数停止、拜占庭无法迫停、沉默转视图”三条安全活性性质。但它有一个未言明的粗糙处：**决策空间是二元的**——STOP 与 CONTINUE 之间没有中间态，“大家结论大体对、但措辞发散”这种真实存在的语义共识梯度，被硬压成“停或不停”两个比特。

H-CSC (arXiv:2606.07316, v2) 恰恰处理了这个粗糙处。它指出：经典 BFT 要求所有诚实节点对**完全相同的字节序列**达成一致，而 LLM Agent 的输出是随机自然语言，字节级一致在原理上不可能；于是它让每轮产出三种**类型化结果**之一——`semantic_commit` (对语义核心的量化聚合摘要签名，细粒度、高信息量、风险更高)、

`verdict_commit`（仅对通过/不通过标签签名，粗粒度、低信息量、更安全）、`typed_abort`（明确拒绝提交），三者共享同一个 $2f+1$ 不同签名者证书信封。更重要的是，H-CSC v2 做了一件在系统论文里罕见的事：用更严格的“钢铁人（steelman）”基线重检后，**主动撤回**了 v1“我们的过滤聚合保留了更多诚实内容”的主张。

本文据此提出三级类型化最终性设计提案：把 P2 的二元 STOP/CONTINUE 重写为 `strong_stop`（语义核心级一致，对应 `semantic_commit`）、`weak_stop`（仅 `verdict` 标签一致，对应 `verdict_commit`）、`abort`（不一致，对应 `typed_abort` 并触发 view change）。本文同时把 H-CSC v2 的负结果转化为一条红线：**不要用学习编码器替代规则校验**——在其对抗实验中，确定性词法一致性谓词的 AUROC（0.865–0.982）显著优于学习语义编码器（0.621–0.744）。三级升级尚未实施，其安全活性性质、成本与失败模式均为 `[RESULT NEEDED]`，需在 P2 现有属性测试套件上扩展后才能声称收益。

关键词：类型化最终性；语义 BFT；停止决策；法定人数；equivocation；钢铁人基线；负结果；规则谓词

结构化摘要（背景问题 → 论点 → 证据 → 贡献）

- **背景问题：**LLM 委员会的输出是随机自然语言，不可能对字节一致达成共识；而 v7.5.0 P2 的二元 STOP/CONTINUE 又把“语义共识到底有多强”压成一个开关，丢失了“语义核心已一致、仅措辞发散”这一中间态的安全信息。
- **核心论点：**停止决策应当按**语义一致程度分级**，而非二元化。同一枚 $2f+1$ 证书信封可绑定不同提交粒度：语义核心一致给强停止、仅标签一致给弱停止、不一致给 `abort` 并转视图；分级让系统对“错停风险”与“返工成本”做梯度匹配，而不是一刀切。
- **证据线索：**(1) H-CSC v2 的类型化提交对象设计（论文报告）；(2) H-CSC v2 用钢铁人基线主动撤回“诚实保留优势”——过滤聚合反而更远离诚实中心（ $5.32^\circ/5.48^\circ$ vs $4.27^\circ/4.32^\circ$ ），对钢铁人 M3 的诚实保留率 0.6475 vs 0.7325，作者明文 “we withdraw it”（论文报告）；(3) 确定性词法谓词 AUROC 0.865–0.982 胜学习编码器 0.621–0.744（论文报告）；(4) UDOS v7.5.0 P2 的 10 项属性测试与 24 工单端到端（cpu-proto / verified）。
- **贡献：**(i) 把 P2 二元停止决策升级为三级类型化最终性的形式化设计；(ii) 把 H-CSC v2 的自我撤回负结果转化为 UDOS 的设计红线（规则为底、学习为补）；(iii) 给出三级决策的可证伪性质清单与待实施 `[RESULT NEEDED]` 项；(iv) 明确本提案的失效边界。

1 问题：二元停止决策丢掉了什么

1.1 P2 做对了什么

v7.5.0 P2 的贡献是把经典 BFT 的“安全/活性”从自然语言证明**降级**为仓库里可 CI、可回归的属性测试套件。它不追求通用状态机复制，只服务一个具体决策点——验收委员会对“工单是否做完”投票。其骨架为：

- 委员会 $V=\{v_1, \dots, v_n\}$ ，最多 f 个成员拜占庭， $n \geq 3f+1$ ；
- 每轮成员对二元决策投票，法定人数 $q=2f+1$ ；
- 同轮 equivocation（摇摆投票）成员整轮作废；
- 超 f 沉默返回 `NO_QUORUM` 并触发 view change，而非挂起。

在 $n=7, f=2$ （ $q=5$ ）下，10 项确定性属性测试（verified）覆盖非法 n 拒绝、诚实超多数停止、拜占庭无法迫停、equivocation 检出整轮作废、冲突法定人数不可达、沉默触发 view change、未知投票人拒绝；端到端集成（cpu-proto，单 seed）中，7 人 QA 委员会在 2 名拜占庭反投票成员下对 24 工单全部验收正确。P2 还诚实声明了三条边界：SHA-256 哈希占位签名非密码学安全、未建模网络分区与自适应攻击者、**语义共因故障会击穿多数票**。

1.2 它丢的那一环：决策空间太粗

P2 把决策空间限定为二元（STOP/CONTINUE），理由写得很清楚：二元法定人数的安全性分析最清晰，且贴合"一个工单要么验收通过、要么返工"的真实末端。这个简化在**字节级**世界里是对的——经典 BFT 的复制状态机本来就是确定字节流投票。

但 LLM 世界里它不对。一个 QA 委员会对同一份工单给出的五份结论，可能是：

- 1. **语义核心一致、措辞发散**：五人都判定"通过"，理由各写各的，甚至引用的关键数字略有出入；
- 2. **标签一致、理由冲突**：五人都勾了"通过"，但三人认为是"勉强通过"、两人认为"完全通过"，验收置信度参差；
- 3. **彻底不一致**：通过与不通过各半。

二元开关只能区分"有没有人凑够 q 票 STOP"，**无法区分上面这三种情况的风险等级**。情况 1 其实已经很安全（语义核心一致），却和情况 3 共用同一个"停"；情况 2 是最危险的——标签被多数裹挟、理由却分裂，P2 的属性测试恰恰指出这是"语义共因故障击穿多数票"的温床，但二元决策没有给它单独的出口。

这就是 H-CSC 切入的位置：**与其对字节投票，不如先决定"对什么粒度的语义产物投票"**。

2 H-CSC 的解法：先分类，再提交

2.1 为什么不能对字节一致

经典 BFT 的前提是状态机复制：所有副本执行**完全相同**的状态转换，因此只要对同一个字节序列投票即可。LLM Agent 不满足这个前提——同一提示、同一温度下，两次采样产出两份不同的自然语言。要求委员会对"逐字相同"的文本达成 $2f+1$ 一致，在原理上就失败（概率随长度指数衰减）。

H-CSC v2 (改题后 Certifiable Semantic Agreement Among LLM Agents: What the Admissibility Instrument Decides) 的核心主张是：**最终性 (finality) 应当是类型化的**——协议必须先决定"这一轮到底承诺什么"，再签名。它给出三种提交对象（论文报告）：

- `semantic_commit`：对**语义核心**的量化聚合摘要签名。细粒度、高信息量，但要把发散的天然语言聚合成一个可签名的核心，聚合过程本身可能引入偏差（风险更高）；
- `verdict_commit`：仅对**标签**（通过/不通过）签名。粗粒度、低信息量，但标签是离散、可机械比对的，最安全；
- `typed_abort`：明确**拒绝提交**，表示这一轮不产生任何承诺。

三者共享同一枚 $2f+1$ 不同签名者证书信封——也就是说，"多少人背书"的安全骨架没变，变的是**这枚证书到底承诺了什么**。这一设计对 UDOS 极友好：它不需要推翻 P2 的 $n \geq 3f+1$ 、 $2f+1$ 、equivocation 整轮作废，只需要在"凑齐法定人数之后"加一步"这法定人数承诺的是哪一级"。

2.2 本文的三级映射

把 H-CSC 的三类提交对象，直接映射到 P2 的停止决策（设计提案）：

三级最终性	对应 H-CSC 对象	触发条件（设计）	工程含义
strong_stop	<code>semantic_commit</code>	$\geq 2f+1$ 名成员对 语义核心 （验收要点的聚合摘要）一致	工单高置信收口，进入结算/归档
weak_stop	<code>verdict_commit</code>	$\geq q$ 名成员仅对 通过标签 一致，但语义核心未达一致	低置信收口，留痕"勉强通过"，下一轮抽样复核
abort	<code>typed_abort</code>	语义核心与标签均未达一致，或检测到语义共因故障迹象	转 view change / 加轮，而非硬停或硬返工

图1 二元停止决策到三级类型化最终性

图1 v7.5.0 P2 的二元 STOP/CONTINUE 把语义共识梯度压成开关；P16 升级为 strong_stop / weak_stop / abort 三级，同一枚 $2f+1$ 证书信封绑定不同提交粒度。概念示意，非实测数据。

这个映射的关键收益是给第 1.2 节的三种情况各自一个出口：情况 1 落 strong_stop，情况 2 落 weak_stop（并触发下一轮复核，而不是悄悄高置信归档），情况 3 落 abort（转视图）。二元 P2 把情况 2 误读为安全的“停”，三级设计让它显形为“弱停+复核”。

3 H-CSC v2 的自我撤回：本文最重要的负结果

3.1 钢铁人基线与“we withdraw it”

任何借鉴 H-CSC 的设计，都必须先消化它 v2 的自我修正——这正是本文把它列为对话对象而非模板的原因。

H-CSC v1 曾主张：其“过滤聚合”机制在保留诚实内容方面优于简单多数。v2 用更严格的钢铁人基线（即给对比方一个更强、更公平的对手，而不是故意找个弱基线衬托自己）重检后发现（论文报告数字，未独立复核）：

- H3：核心聚合距诚实中心的角度，H-CSC 为 $5.32^\circ / 5.48^\circ$ ，而钢铁人基线为 $4.27^\circ / 4.32^\circ$ ——H-CSC 反而离诚实中心更远；
- H4：诚实保留率，v1 口径下 H-CSC 0.6475 对比弱基线 0.4950（看似占优）；但在钢铁人 M3 基线下为 0.6475 vs 0.7325——H-CSC 反而更低。作者明文写出 “we withdraw it”（撤回该主张）。

这一撤回在系统论文里极为罕见，它的方法论价值大于其任何正面结论：一个看似精巧的“学习型过滤聚合”，在公平基线下不仅没带来收益，反而更糟。它提醒 UDOS：不要因为一个模块“听起来聪明”就引入它；每引入一个处理环节，都必须问“它的钢铁人对手是谁、它真的赢了吗”。这与 P2 主动披露“与单点 QA、朴素多数票的全因子对照尚未做”的克制姿态完全一致。

3.2 另一个负结果：学习编码器被词法谓词击败

H-CSC v2 的第二个硬结果同样是负的，但方向明确（论文报告，未独立复核）：在对抗场景下，决定“两份自然语言是否语义一致”的工具里，确定性词法一致性谓词（按约定的关键词/短语集合做机械比对）的 AUROC 为 0.865–0.982，而学习型 CRSE 语义编码器（用神经网络把文本编码到向量空间再算相似度）的 AUROC 仅 0.621–0.744。

也就是说，在“识别语义是否一致”这件事上，那个看起来更高级的神经网络工具，被一个朴素的规则谓词显著击败。这直接引向 P32（规则优先于学习），也直接约束了本文的设计：三级最终性里“判定语义核心是否一致”那一步，必须先用规则谓词打底，学习模型只能作为补充，且必须通过钢铁人对照才能进入安全关键路径。

图2 H-CSC v2 的两个负结果

图2 左：对抗场景下确定性词法谓词 AUROC（0.865–0.982）显著优于学习 CRSE 编码器（0.621–0.744）；右：钢铁人基线下诚实保留率不升反降，v2 明文撤回。数字为论文报告、未独立复核。

4 三级类型化最终性的形式化设计（提案）

4.1 决策函数

在 P2 的 `decide(round_id)` 上扩展。设每轮成员除投 STOP/CONTINUE 外，还产出两个可签名产物： $\$L_i\$$ （verdict 标签，离散）与 $\$C_i\$$ （语义核心聚合摘要的可比对指纹）。在凑齐 $\$q=2f+1\$$ 张 STOP 票之后，再做一次分级判定：

$\text{\text{level}} = \begin{cases} \text{strong_stop}, & \text{若 } q \text{ 张票的 } C_i \text{ 经规则谓词判定一致} \\ \text{weak_stop}, & \text{若 } q \text{ 张票的 } L_i \text{ 一致但 } C_i \text{ 不一致} \\ \text{abort}, & \text{若 } L_i \text{ 未达一致或检出语义共因迹象} \end{cases}$

（此为设计伪码，`cases` 的具体实现以安全命令重写：`strong_stop / weak_stop / abort` 三支由规则谓词的布尔组合给出。）安全骨架不变：`equivocation` 整轮作废、超 $\$f$ 沉默返回 `NO_QUORUM`、`abort` 触发 `view change`。

4.2 与 P2 三条性质的关系

三级设计继承 P2 已验证的三条性质（verified）：

- **安全性**：`strong_stop` 与 `abort` 不可能同时凑齐，因为二者对 $\$C_i$ 的判定互斥；
- **活性**：`weak_stop` 不挂起，而是给"勉强通过 + 下轮复核"；`abort` 转视图而非永久等待；
- **非法配置拒绝**： $\$n < 3f + 1$ 仍由构造器层拒绝，与分级无关。

但新增了一条 P2 没有的性质，它尚未被验证（[RESULT NEEDED]）：

- **H4-new（分级单调性）**：若一轮中语义核心的一致程度越高，`strong_stop` 占比不应反常下降；在钢铁人基线下，三级决策的"错停率"必须不高于 P2 二元决策。这条直接来自 H-CSC v2 的教训——任何分级模块都必须证明它在公平基线下不是"更糟的过滤器"。

4.3 待实施清单

下列均为设计提案，无实验支撑：

1. 在 `udos7/topology/consensus.py` 增加 $\$C_i$ 语义核心指纹与规则谓词判定；[RESULT NEEDED]
2. 把 10 项属性测试扩展为覆盖三级决策的回归套件；[RESULT NEEDED]
3. 设计钢铁人对照（朴素 verdict 多数 vs 三级），测量错停率/返工率；[RESULT NEEDED]
4. 验证 `weak_stop` 的"下轮复核"不会引入无界循环（活性）；[RESULT NEEDED]

5 糟粕 / 失效边界 / 可证伪条件

糟粕（哪些不要做）：

1. **不要照搬 H-CSC 的学习型聚合作为安全关键**。其钢铁人对照证明它更糟（ 5.32° vs 4.27° ；诚实保留 0.6475 vs 0.7325），本文只取其"类型化提交"的思想，不取其学习聚合实现。
2. **不要把 `strong_stop` 当成"绝对安全"**。 $\$2f + 1$ 证书只保证"无 $\$>f$ 拜占庭"，不保证语义共因故障不击穿——P2 已声明此边界，三级设计不消除它。
3. **不要把"三级"误读为"三级都可结算"**。`weak_stop` 是"留痕+复核"，不是高置信归档；若工程上把 `weak_stop` 也直接结算，就退化成了带标签的二元决策。

失效边界：

- 当 $\$C_i$ 的规则谓词设计得过于宽松（把措辞发散误判为语义一致），`strong_stop` 会虚高，错停率上升；
- 当语义共因故障发生（所有 QA 被同一处误导），`strong_stop` 的"语义核心一致"本身可能是**共谋的一致**，证书无法区分"诚实的一致"与"被诱导的一致"；
- 三级判定引入额外一轮指纹聚合，成本高于二元决策，在超大规模下需评估扇入（与 P1 拓扑复杂度耦合）。

可证伪条件：

- 若在钢铁人基线下，三级决策的错停率**不低于** P2 二元决策，则 H4-new 被推翻，本提案应回退；
- 若规则谓词在新攻击族上 AUROC 跌破学习编码器（当前 0.865–0.982 vs 0.621–0.744 的优势反转），则“规则为底”的红线需重估；
- 若 weak_stop 的复核在实测中引入显著无界循环，则三级设计的活性假设失败。

6 结论

v7.5.0 P2 把停止决策做成了一个可证伪、可 CI 的二元委员会；H-CSC v2 则揭示了二元化丢失的语义共识梯度，并以一次罕见的自我撤回警告了“学习型精巧模块可能在公平基线下更糟”。本文的立场克制：**只取类型化提交的思想，把 P2 的 STOP/CONTINUE 升级为 strong_stop / weak_stop / abort 三级；判定语义一致那一步用规则谓词打底、学习模型补位，并强制钢铁人对照。** 三级最终性是设计提案，其收益与失败模式全部 [RESULT NEEDED] ——在 P2 的属性测试套件扩展、并跑通钢铁人对照之前，本文不声称任何实际改善。

把“对字节投票”换成“先决定对什么粒度的语义承诺投票”，是 LLM 时代 BFT 必须跨过的一步；但跨这一步时，要用 H-CSC v2 自己撤回结论的那种诚实，去检验每一个新引入的环节。

参考文献

经典文献

1. Castro, M., & Liskov, B. (1999). Practical Byzantine Fault Tolerance. OSDI 1999. ($n \geq 3f+1$ 、 $2f+1$ 法定人数、view change 的经典骨架)
2. Yin, M., Malkhi, D., Reiter, M. K., et al. (2019). HotStuff: BFT Consensus in the Lens of Blockchain. PODC 2019. arXiv:1803.05069. (线性通信复杂度 BFT、链式视图更换)
3. Wu, Q., Bansal, G., Zhang, Y., et al. (2023). AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. arXiv:2308.08155. (可对话多智能体框架，其“对话无终止条件易死循环”是本文动机之一)

2026 前沿材料（存在性已核验；数字为论文报告、未独立复核）

1. H-CSC 作者团队 (2026). Certifiable Semantic Agreement Among LLM Agents: What the Admissibility Instrument Decides (v2, v1 原题 Hierarchical Certified Semantic Commitment...) . arXiv: 2606.07316v2. (类型化提交对象 semantic_commit / verdict_commit / typed_abort、 $2f+1$ 证书信封；钢铁人基线下主动撤回“诚实保留优势”——聚合距离 $5.32^\circ/5.48^\circ$ vs $4.27^\circ/4.32^\circ$ ，诚实保留 0.6475 vs 0.7325；词法谓词 AUROC 0.865–0.982 胜学习编码器 0.621–0.744)

UDOS 论文卷（证据等级随文标注）

1. UDOS v7.5.0 P2 《多智能体停止决策的 BFT-lite： $n \geq 3f+1$ 委员会、equivocation 整轮作废与 view change 的安全性验证》（`udos7/topology/consensus.py`，10 项属性测试 verified； $n=7, f=2$ 、24 工单端到端 cpu-proto）。
2. UDOS v7.6.0 P26 《加权 BFT 与声誉：等权 $2f+1$ 的权重方向》、P32 《规则优先于学习：对抗场景下的谓词鲁棒性边界》（姊妹篇）。

证据纪律与复现说明

- 本文为设计提案论文，无新实验；H-CSC 的全部数字（聚合距离、诚实保留率、AUROC 区间）均为**论文报告、未独立复核**，且其 v2 已主动撤回 v1 的"诚实保留优势"主张，本文严格采用 v2 口径，不沿用 v1 正面结论。
- UDOS 侧数字全部回 v7.5.0 P2：10 项属性测试为 verified， $\$n=7,f=2\$$ 下 24 工单端到端为 cpu-proto 单 seed 试点估计；P2 的 SHA-256 哈希占位签名非密码学安全、未建模网络分区与自适应攻击者、语义共因故障击穿多数票这三条边界对本文三级设计**依然成立**。
- 三级类型化最终性的所有收益、H4-new 单调性、weak_stop 无界循环风险均标 [RESULT NEEDED]，需在现有 consensus.py 上扩展并跑通钢铁人对照后方可声称；投稿前需 ≥ 30 seed 复现。