



P29

Test-Time Scaling of Multi-Agent Collaboration: The Diversity Axis and the Decomposition Axis

Test-Time Scaling of Multi-Agent Collaboration: The Diversity Axis and the Decomposition Axis, with TUMIX and MAKER

TwinsEarth · 智能体宇宙论文系列

Test-Time Scaling of Multi-Agent Collaboration: The Diversity Axis and the Decomposition Axis

Abstract — This engineering paper splits test-time scaling into two orthogonal axes, diversity and decomposition, and connects them to the P9 quality saturation law. If a model is not retrained and simply runs more at inference, why does it get stronger? The paper examines how diverse independent sources and extreme task decomposition with voting raise performance, and identifies where each axis saturates so that extra inference spend stops paying off.

Keywords: test-time scaling; diversity; decomposition; voting; inference; multi-agent

孪生地球

测试时规模化协同：工具集成与极端分解投票

Working Title (EN): Test-Time Scaling of Multi-Agent Collaboration: The Diversity Axis and the Decomposition Axis, with TUMIX and MAKER

卷中工程篇 P29 · 把"测试时扩展"拆成**多样性**与**分解**两个正交轴 · 对接 P9 质量饱和律 · UDOS 推演引擎 v7.6.0
· 房文新 · 2026-09-21

一句话先说清：模型不训练、只在推理时多跑几遍，为什么能变强？2025–2026 的三个工作把答案拆成两件事——TUMIX (arXiv:2510.01279) 证明**多样性**（并行用不同工具策略）有效；MAKER (arXiv:2511.09030) 证明**极端分解 + 逐步投票**（把百万步任务切到 microagent、每步多数投票纠错）能做到零错误。本文主张：这是两个**正交**的扩展轴，不是同一件事的两种说法；而 UDOS P9 的"独立信息"条件是这两条轴共同的隐藏前提。

证据口径（全文只声明这一次）：本文是方法综合论文，**不含新的 UDOS 实测数字**。外部三篇论文存在性已于 2026-09-21 联网核验；TUMIX 的"+3.55%"、MAKER 的"约 1,048,575 步零错误"、Thinking vs Doing 的"Gemma 3 12B 在 WebVoyager/WebArena 达开源 SOTA"均为**论文报告**，未独立复核；本文用它们说明"哪条轴在起作用"，不把数字当作 UDOS 预期收益。UDOS P9 质量饱和律回指 v7.5.0。

摘要

测试时扩展（test-time scaling）是 2025–2026 年大模型能力提升的第三条轴——不改权重、不堆参数，只在推理时花更多计算。本文主张：多 Agent 测试时扩展其实有两条**正交**的轴。第一条是**多样性轴**：并行跑多个 Agent、各自采用不同工具/策略，再集成。TUMIX (arXiv:2510.01279) 沿这条轴工作——并行多 Agent 用不同工具策略、迭代共享精炼，在 Gemini-2.5-Pro 上平均准确率最高 +3.55%，且近等推理成本（论文报告）。第二条是**分解轴**：把一个长任务极端分解到聚焦的 microagent，每步用多数投票纠错。MAKER (arXiv:2511.09030) 沿这条轴工作——极端分解 + k=3 多数投票，首次以零错误完成约 1,048,575 步（百万级）LLM 任务（论文报告）。Thinking vs Doing (arXiv:2506.07976, NeurIPS 2025) 则提示第三条、与前两条不同的轴——**交互长度轴**：通过课程式在线 RL 自适应调整 Agent 与环境的交互轮数，用仅 12B 的 Gemma 3 在 WebVoyager/WebArena 达开源 SOTA（论文报告）。本文的核心论点是：多样性轴受 P9 质量饱和律约束——多个并行 Agent 若工具策略同构、不携带独立信息，则集成收益迅速饱和；分解轴受"投票能否纠错"约束——k=3 多数投票只在单步错误率独立且低于阈值时有效，共因故障下投票失效。两条轴因此不是"越多 Agent 越好"，而是"多样性 × 分解深度"的联合设计。本文给出 UDOS 把两轴工程化的规格，效果待 [RESULT NEEDED]。

结构化摘要（背景问题 → 方法/论点 → 证据 → 贡献）

- **背景问题**：测试时扩展为什么能变强？业界常把"多跑几个 Agent"当成单一杠杆，但这掩盖了两个正交机制。
 - **核心论点**：多 Agent 测试时扩展 = 多样性轴（异质工具策略集成）× 分解轴（极端分解+逐步投票纠错），外加交互长度轴；P9 的"独立信息"是前两轴共同的隐藏前提。
 - **证据线索**：(1) TUMIX 工具混合 +3.55% (arXiv:2510.01279, 论文报告)；(2) MAKER 百万步零错误极端分解 (arXiv:2511.09030, 论文报告)；(3) Thinking vs Doing 交互长度扩展 (arXiv:2506.07976, 论文报告)；(4) P9 质量饱和律 $mse(k)=a+b/k$ (cpu-proto)。
 - **贡献**：把测试时多 Agent 扩展拆成正交双轴；指出每轴各自的失效条件；把两轴对接 P9 的独立信息要求。
-

1 问题：测试时扩展不是单一杠杆

1.1 第三条扩展轴

训练时扩展（堆参数、堆数据、堆算力）之外，2025–2026 年出现了第三条轴：**测试时扩展**——冻结权重，只在推理时花更多计算。这条轴对多 Agent 系统尤其关键，因为它直接问"并行跑多个 Agent 为什么有用"。

1.2 常被混淆的两种"多 Agent"

直觉上"多跑几个 Agent 投票"和"把任务切成很多小步"像是同一件事的两种说法。本文主张它们不是：

- **多样性轴**：同一任务、并行多解、再集成。变量是"并行 Agent 的策略是否异质"。
- **分解轴**：单一任务、串行切步、逐步纠错。变量是"任务被切得多细、每步如何纠错"。

一个是横向铺，一个是纵向切。它们正交，可以叠加，也各自有失效条件。

图1 测试时扩展的多样性轴与分解轴

图1 横轴多样性（并行异质 Agent）、纵轴分解深度（任务切分粒度+逐步投票）；三个代表工作各占位置。概念示意，非实测数据。

2 多样性轴：TUMIX 与独立信息条件

2.1 TUMIX 做了什么

TUMIX (arXiv:2510.01279, TUMIX: Multi-Agent Test-Time Scaling with Tool-Use Mixture) 并行运行多个 Agent，各自采用**不同的工具策略**，再迭代共享精炼。论文报告在 Gemini-2.5-Pro/Flash 上平均准确率较最佳基线最高 **+3.55%**，且近等推理成本（论文报告，未独立复核）。

它的关键不是"多跑"，而是"**各用不同工具**"。如果并行 Agent 用完全相同的工具与提示，它们会给出高度相关的答案——这正是 P9 警告的同质化副本。

2.2 P9 条件：多样性必须携带独立信息

P9 的质量饱和律 ($mse(k)=a+b/k$, cpu-proto) 把多样性轴的代价写死了。设集成 k 个成员的均方误差：

$$mse(k)=a+\frac{b}{k}$$

其中 a 是不可约误差, b 由成员间的**独立度**决定。TUMIX 的 +3.55% 之所以成立, 正是因为"不同工具策略"抬高了 b (成员独立性); 如果把工具策略换成同质的, b 塌缩, 加再多并行 Agent 也只是把同一个错答案投 k 遍。

白话: 多样性轴的收益上限, 取决于你的并行 Agent 到底有多不一样, 而不是有多少个。

3 分解轴: MAKER 与逐步投票纠错

3.1 MAKER 做了什么

MAKER (arXiv:2511.09030, Solving a Million-Step LLM Task with Zero Errors) 把一个超长任务**极端分解** (MAD, Massive Decomposition) 到聚焦的 microagent, 每一步用多 Agent **多数投票**纠错, 并丢弃带红旗的相关错误。论文报告这是首个以**零错误**完成超过百万 LLM 步任务的系统 (约 1,048,575 步, $k=3$ 多数投票; 论文报告, 未独立复核)。

它的关键不是"切得细", 而是"**每一步都有独立纠错**"——单点 LLM 的持续错误率会随步数累积爆炸; 逐步多数投票把长程错误率压回可控。

3.2 投票何时有效、何时失效

多数投票的有效性有一个经典前提: 各步错误**近似独立**。若单步错误率为 p , $k=3$ 多数投票把错误率降到约 $3p^2(1-p)+p^3$, 当 $p<0.5$ 时显著下降。但——

- **共因故障下投票失效**: 若所有 microagent 被同一个误导性输入带偏 (P2 识别的语义共因故障), $k=3$ 会一致地错, 多数投票变成"一致地错得更自信"。这是分解轴的硬边界。
- **分解引入切分错误**: 切得太粗, microagent 仍面对长程依赖; 切得太细, microagent 之间的交接误差累积。最优分解粒度是设计参数。

白话: 分解轴把"单点错误率"变成"逐步错误率", 但它救不了所有 Agent 一起被骗的情况。

4 第三条轴: 交互长度 (Thinking vs Doing)

Thinking vs. Doing (arXiv:2506.07976, NeurIPS 2025 SEA Workshop) 沿第三条轴工作——**测试时交互长度**: 用课程式在线 RL 自适应调整 Agent 与环境的交互轮数 (探索、回溯、动态重规划), 论文报告仅用 12B 的 Gemma 3 在 WebVoyager/WebArena 达开源/公开数据 SOTA (较非微调 Agent 分别约 +9%/+8%, 论文报告)。

这条轴既不是"并行几个" (多样性), 也不是"切几步" (分解), 而是"**同一个 Agent 与环境来回交互多久**"。它提醒我们: 测试时扩展至少有三个可调维度——宽度 (并行)、深度 (分解)、时长 (交互)。

表 1 测试时多 Agent 扩展的三轴对照

轴	变量	代表工作	失效条件	受谁约束
多样性 (宽度)	并行 Agent 策略异质度	TUMIX (+3.55%)	工具策略同质 $\rightarrow$ 独立度 b 塌缩	P9 质量饱和律
分解 (深度)	任务切分粒度 + 逐步投票	MAKER (百万步零错误)	共因故障 $\rightarrow$ 投票一致地错	P2 语义共因故障
交互 (时长)	与环境交互轮数	Thinking vs Doing (Gemma3 12B)	交互长度无自适应 $\rightarrow$ 浪费或欠探索	课程调度设计

5 糟粕 / 失效边界 / 可证伪条件

5.1 糟粕（把测试时扩展神化的三个误读）

1. **+3.55% 不是普适提升。** TUMIX 的增益依赖任务类型与基线选择，换任务可能更小甚至消失；不要把单基准增量当成“多 Agent 万能”。
2. **百万步零错误 $\neq$ 长任务通用。** MAKER 的零错误建立在“每步可被 microagent 独立判定对错”的高度结构化任务上；语义验收型工单（含隐藏真值）没有这样的逐步 oracle，逐步投票无从落地。
3. **便宜小模型 SOTA $\neq$ 小模型够强。** Thinking vs Doing 用 12B 达开源 SOTA，靠的是测试时交互调度，不是模型本身变小了；把这读成“不用大模型”是误读。

5.2 失效边界

- 多样性轴与 P9 同质副本是同一枚硬币：**没有独立信息，宽度扩展无效。**
- 分解轴在**无逐步 oracle**的任务上无法纠错——UDOS 的语义验收工单恰恰缺逐步 oracle，这是分解轴在 UDOS 上落地的最大障碍。

5.3 可证伪条件

- **F29-a:** 若在 UDOS 工单上，把并行 Agent 的工具策略从“异质”改成“同质”，集成质量的下降幅度与 P9 的 $\$b\$$ 塌缩预测一致，则本文“多样性=独立信息”的论点成立；若无关，则需修正。
- **F29-b:** 若在引入共因故障注入后，分解轴的多数投票纠错优势消失，则“投票受共因故障击穿”的边界成立。
- 以上为设计提案下的可事后记分判据，UDOS 实际数字待 [RESULT NEEDED]。

6 结论

测试时扩展不是“多跑几个 Agent”这一个旋钮。它至少有三个轴：宽度（多样性）、深度（分解）、时长（交互）。TUMIX 证明宽度轴靠“工具异质”换收益，MAKER 证明深度轴靠“极端分解+逐步投票”压错误，Thinking vs Doing 证明时长轴靠“自适应交互轮数”提表现。而 UDOS 的贡献是给这三条轴各自配上失效条件：宽度受 P9 独立信息约束，深度受 P2 共因故障约束。

测试时扩展不是“堆更多 Agent”，而是在多样性 $\times$ 分解 $\times$ 交互三个方向上，各自确认“这些 Agent 真的携带独立信息、真的能逐步被纠错”。堆人不解决问题，堆得有区分度才解决。

参考文献

集成与测试时计算

1. Hansen, J. N., et al. (2024). Let's Verify Step by Step. OpenAI. (逐步推理/过程奖励的经典工作)
2. Brown, T. B., et al. (2020). Language Models are Few-Shot Learners (test-time prompting 的背景)。

2026 前沿材料（存在性已于 2026-09-21 联网核验；数字为论文报告，未独立复核）

1. TUMIX (2025). TUMIX: Multi-Agent Test-Time Scaling with Tool-Use Mixture. arXiv:2510.01279. (异构工具策略并行，Gemini-2.5-Pro 最高 +3.55%)
2. MAKER (2025). Solving a Million-Step LLM Task with Zero Errors. arXiv:2511.09030. (极端分解 + k=3 多数投票，约 1,048,575 步零错误)
3. Thinking vs. Doing (2025). Agents that Reason by Scaling Test-Time Interaction. arXiv:2506.07976, NeurIPS 2025 SEA Workshop. (Gemma 3 12B 在 WebVoyager/WebArena 达开源 SOTA)

UDOS 论文卷（本系列，证据等级随文标注）

1. UDOS v7.5.0 论文卷：P2 《BFT-lite 停止决策》（语义共因故障识别）、P9 《质量饱和律与同质化扩招失效边界》（ $mse(k)=a+b/k$, cpu-proto）。
 2. UDOS v7.6.0 论文卷：P20 《异构性红利与同质性饱和》、P33 《v7.6.0 架构总纲》。
-

证据纪律与复现说明

- 本文为**方法综合论文**，无新增实验；三轴划分、失效条件、F29-a/b 判据为分析框架，UDOS 上的实际增益为 [RESULT NEEDED]，禁止写成实测。
- TUMIX +3.55%、MAKER 百万步零错误、Thinking vs Doing 的 Gemma3 12B SOTA 均为论文报告，未独立复核，仅用于说明"哪条轴在起作用"。
- $mse(k)=a+b/k$ 回指 P9（cpu-proto）；共因故障边界回指 P2。
- 本文不主张测试时扩展可替代训练扩展；三轴是并列杠杆，不是替代关系。