



P34

The v7.6.0 Evidence Ledger and Prediction Update: Three-State Literature Audit, Downgraded Claims, and Falsifiable Forecasts F6-F10

The v7.6.0 Evidence Ledger and Prediction Update: Three-State
Audit, Downgraded Claims, and F6–F10

The v7.6.0 Evidence Ledger and Prediction Update: Three-State Literature Audit, Downgraded Claims, and Falsifiable Forecasts F6-F10

Abstract — The closing paper upgrades the prior evidence ledger into a formal record. It performs a three-state literature audit, downgrades claims that did not survive verification, and updates the hard forecasts of P15 and P33 into falsifiable predictions F6 through F10 with explicit conditions and deadlines. The ledger makes clear which claims are supported, which are partial, and which would falsify the engine forecasts.

Keywords: evidence ledger; literature audit; downgraded claims; falsifiable forecast; prediction; verification

孪生地球

v7.6.0 文献证据台账与预测更新：三级核验、降级清单与 F6–F10

Working Title (EN): The v7.6.0 Evidence Ledger and Prediction Update: Three-State Literature Audit, Downgraded Claims, and Falsifiable Forecasts F6–F10

全卷收口篇 P34 · 把前置核验分片的 EVIDENCE_LEDGER_v76.md 升级为正式论文版证据台账 · 更新 P15/P33 的硬预测 · UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

一句话先说清：v7.6.0 全卷引用的外部文献，没有一条是“听来的”——每一条都经过联网核验，并被钉在三态之一：已核验已核验、部分核验部分核验（给出实际值）、查无实据查无实据（标 [CITATION NEEDED]）。本文把这份台账公开，并公开**哪些流传很广的数字必须降级或删除**（MAPF 百万成功率、结算中立性五属性、Hybrid 96.1% 等），最后把 P15 的 F1–F5 保留、新增 F6–F10 五条可在 2027 年记分的硬预测。

证据口径（全文只声明这一次）：本文是**证据台账与预测登记论文**，不含新实验、不含新的 UDOS 实测数。三态核验于 **2026-09-21** 完成（Asia/Shanghai），方法为对每条线索用 arXiv abs/html、ACL Anthology、IEEE Xplore、OpenReview、Zenodo、官方新闻稿独立复核；用户粘贴的 arXiv 编号、数字、机构归属一律视为“线索”而非事实。标 已核验 者仅代表“文献真实存在、标题/年份/出处一致”，其论文内数字仍标“论文报告·未独立复核”；标 部分核验 者以本文给出的**实际值**为准；标 查无实据 者一律写 [CITATION NEEDED]，禁止写成事实。

摘要

v7.6.0 论文卷（P16–P34）共引用约 50 条外部线索。本文不做综述堆砌，而是把全部线索过一遍**三级核验**：已核验 已核验（存在且题录一致）、部分核验 部分核验（存在但某数字/记录号与线索不符，给出实际值）、查无实据 查无实据（标 [CITATION NEEDED]）。核验结论是乐观但克制的：核心新论文（H-CSC、EPOB、ClawArena-Team、Warp-Cortex、RSIAgent、Ouroboros、OASIS）**绝大多数真实存在且核心命题成立**；真正需要降级的是四类——(a) MAPF 的“百万级 99.9%/163μs”仅见于俄文媒体转述；(b) “结算中立性五属性”未定位到任何原始出处；(c) Hybrid LangGraph-CrewAI 的 96.1%/–76.2% token 未核到原文；(d) ISONOMIA/RSIAIO/Adaptive Bitmask 的记录号与仿真数字需更正。本文同时登记一份“被剔除/降级清单”，并在保留 P15 F1–F5 的基础上新增 F6–F10 五条可证伪预测（三级最终性、scope、BRS+DRS、审核门禁、规则谓词 vs 学习谓词），统一标“待 2027 年记分”。

关键词：证据台账；三级核验；引用审计；降级清单；可证伪预测；文献可信度

结构化摘要（背景问题 → 方法/论点 → 证据 → 贡献）

- **背景问题**：AI 论文卷最容易翻车的地方不是论证，而是**引用**——一个流传甚广的 arXiv 编号或"百万级"数字，若不核验就写进正文，会把整条论证建立在沙子上。
 - **核心论点**：一份诚实的论文卷，必须把它引用的每一条外部材料钉在三态之一，并公开"哪些我信了、哪些我打了折、哪些我没找到"。
 - **证据线索**：约 50 条线索逐条联网核验；核心新论文 已核验 占多数，部分核验 集中在记录号与媒体转述数字，查无实据 集中在无出处的"框架五属性"类。
 - **贡献**：正式论文版三级核验台账；一份被剔除/降级清单；P15 F1–F5 保留 + F6–F10 新增的预测更新；以及 v7.6.0 全卷 19 篇索引。
-

1 为什么需要一份公开台账

AI 写作的默认失败模式是：模型把训练时见过的"印象"当成"事实"，把二手转述的数字当成论文原文，把一个查不到的框架当成"已有共识"。v7.6.0 既然自称"测量与治理"，它对自己的**引用**也必须执行同样的治理。因此本文把前置核验分片的工作台账升级为正式论文，公开三态结果与降级清单——这既是对读者负责，也是 P12 证据分级方法论在文献层的延伸。

三态定义全文只声明这一次：

- **已核验 已核验**：文献真实存在，标题/作者/年份/出处一致；论文内数字仍标"论文报告·未独立复核"。
- **部分核验 部分核验**：文献存在，但某数字/记录号/标题与线索不符，本文写**实际值**。
- **查无实据 查无实据**：搜不到或与所给编号严重不符，写作时标 [CITATION NEEDED]。

图2 全卷外部文献三态分布

图2 v7.6.0 全卷外部线索按三态归类的分布（概念示意；计数以本文台账为准）。概念示意，非实测数据。

2 核心新论文台账（A 组，v7.6 主对话对象）

表 1 A 组：与 v7.6.0 直接对话的八篇核心论文

编号	文献	状态	核验到的实际信息	安全引用口径
A1	H-CSC (语义提交 BFT)	已核验 (v2 改题)	v2 改题 Certifiable Semantic Agreement Among LLM Agents: What the Admissibility Instrument Decides (arXiv:2606.07316v2) ; 类型化提交对象与 2f+1 证书信封属实。负结果逐字命中: 聚合距离 5.32°/5.48° vs 钢铁人 4.27°/4.32°; 诚实保留作者明文 "we withdraw it"; 词法谓词 AUROC 0.865–0.982 胜学习编码器 0.621–0.744。	用 v2 口径: 撤回 + 词法谓词胜学习; 数字为论文报告 · 未独立复核。
A2	EPOB (项目编排基准)	已核验	正式记录为 OpenReview NtPIgzPt0U (2026-05) + epob.us 榜单; 五维 Plan/Assignment/Coordination/Deliverable/Efficiency 属实。	五维名称属实; 失败 taxonomy 为论文报告口径。
A3	ClawArena-Team	已核验	Benchmarking Subagent Orchestration... (arXiv: 2606.31174) ; 41 场景/258 轮/纯执行式评分无 LLM 评判属实。	方向属实; "无 LLM 超 50% 权限精度""成本百倍/总分四倍""SMS 三项乘积"未逐字命中, 写"论文报告 · 未独立复核", 不写死百分数。
A4	Warp-Cortex	已核验	单例权重共享 + 拓扑突触, 内存复杂度 $O(N \cdot L) \rightarrow O(1) + O(N \cdot k)$ 属实。	"100 Agent/2.2GB"为论文报告; "百万"为论文自述理论外推, 实测仅约百级。
A5	RSIAgent	已核验	curricula/actor/verifier 三角色、广后深策略属实 (arXiv: 2609.15364) 。	"开源 Kimi-K3/GLM-5.3 超 GPT-6 级闭源"为论文/媒体报道; 标题 "New Environments"指在新环境中学习、非跨环境迁移。
A6	Ouroboros	已核验	reviewed commits 成为运行时属实 (arXiv:2608.08311, v3) 。	Terminal-Bench 2.1 原始 86.97%/剔除 reward-hack 后 86.74% 为自报告 SOTA, 未独立复核。
A7	OASIS	已核验	百万用户社交模拟、复现信息传播/极化/羊群效应属实 (arXiv:2411.11581, NeurIPS 2024) 。	证据性质是 现象复现, 非因果识别 。
A8	MAPF-GPT-DDG	部分核验	真实标题 Advancing Learnable MAPF Solvers with Active Fine-Tuning (arXiv:2506.23793, IROS 2025) , DDG 主动微调属实。	"2048×2048 / 524k 100% / 1M 99.9% / 163μs"仅见于俄文媒体转述, 不采信为论文事实 ; 前身仅小地图、16–32 Agent。

3 RSI 谱系台账 (B 组) 与市场治理台账 (C 组)

表 2 B 组: 用于 P24 层级定位的 RSI 系统

编号	文献	状态	实际信息
B1	The Last AI Built by Humans	已核验	arXiv:2609.11873; HCI + 七项 RSI 判别标准，作 P24 标尺。
B2	Dream-RSI	已核验	准确标题 Recursive Self-Improvement through Evolving Worlds (arXiv: 2609.14858) ; "317 次调用 $\approx$ 51200 代"为论文/官方报告。
B3	Gödel Agent	已核验	ACL 2025, 2025.acl-long.1354 (arXiv:2410.04444) ; 自指代码修改式自改进，二手资料标 L4，不称 L5。
B4	HyperAgents	已核验	arXiv:2603.19461 (Meta FAIR) ; 元层修改过程本身可编辑，最接近"递归元改进"但未达 L5。
B5	RSIAI0	部分核验	正确记录为 Zenodo 15644670 (非用户所给 15646184) ; VM 受控执行 + Darwinian Mode。

表 3 C 组：市场与治理

编号	文献	状态	实际信息
C1	AgentLance	已核验	arXiv:2608.23867; 私有成本投标 + 自维护策略笔记 + VCG 风格支付。
C2	Agent Exchange	已核验	arXiv:2507.03904; 多属性拍卖 + 广义第二价格，流动性不足降级贪心/随机。
C3	ISONOMIA	部分核验	正确记录 Zenodo 21338480 (非 21287289) ; 互信记账单位 ergs + 两院制治理属实; "45000 次仿真/300 参数点"未核到，标 [RESULT NEEDED] 。
C4	When Agent Markets Arrive	已核验	arXiv:2604.06688; 第一价格密封投标拍卖。
C5	结算中立性五属性	查无实据	未定位到任何原始论文/Zenodo 记录; 禁止 作为已有框架引用，改写为 UDOS P11/P25 自拟设计目标或标 [CITATION NEEDED] 。

4 通信规模、评估框架与经典/产业台账 (D/E/F/G 组摘要)

表 4 D 组通信与规模

编号	文献	状态	实际信息
D1	RocketMQ-A2A	已核验	ACM FSE 2026 Industry (阿里云) ; 会话级可重放事件流、LiteTopic 会话隔离、断点续跑。
D2	Adaptive Bitmask	部分核验	npm 产品真实、子 10ms 方向可信; "85 $\times$ 压缩/8.2ms p99/N=5000"未独立复核，标作者主张。
D3	AI Agent Protocols 综述	已核验	arXiv:2504.16736; $CNS = (N_{\text{success}} / N_{\text{attempts}}) / T_{\text{avg}}$ 逐字命中。

表 5 E 组评估与框架

编号	文献	状态	实际信息
E1	TUMIX	已核验	arXiv:2510.01279; Gemini-2.5-Pro 上最高 +3.55% 逐字命中。
E2	MAKER	已核验	arXiv:2511.09030; 极端分解 + k=3 多数投票, 首个零错误完成超百万步任务。
E3	Thinking vs Doing	已核验	arXiv:2506.07976, NeurIPS 2025 WS; Gemma 3 12B 在 WebVoyager/ WebArena 达开源 SOTA。
E4	Hybrid LangGraph-CrewAI	部分核验	混合方向真实存在, 但 IEEE Access 11481053、"96.1%/-76.2% token/14.5× 延迟"未定位到原文, 标待核。
E5	MultiAgentBench	已核验	ACL 2025, 2025.acl-long.421; 系统比较星/链/树/图拓扑; "图最佳"精确排名未逐字命中, 写"拓扑与任务强相关"。
E6	AgentSociety	已核验	arXiv:2502.08691; 1 万+ Agent、约 500 万交互逐字命中。
E7	MegaAgent	已核验	ACL 2025 Findings, 2025.findings-acl.259; 无预定义 SOP, 国家级政策模拟扩至 590 Agent。

F 组经典背景 (F1–F10, 均已核验 编号正确) : Kaplan 2020 (2001.08361)、Chinchilla 2022 (2203.15556)、Attention 2017 (1706.03762)、AutoGen 2023 (2308.08155)、Practical BFT 1999、HotStuff 2019 (1803.05069)、Switch Transformers 2021 (2101.03961)、Krogh & Vedelsby 1995、Emergence Mirage 2023 (2304.15004)、Conformal Prediction 2021 (2107.07511)。

G 组产业传闻 (重点逐条核, 均已核验, 个别数字 部分核验) : Kimi K2.6 Agent Swarm (官方称至多 300 子 Agent 并行)、Kimi K3 (arXiv:2607.24653, 2.8T 参数开源 MoE)、蚂蚁 Agentar 2.0 (WAIC 2026, 近 200 岗位模板)、浪潮单柜 384 颗 OCM CPU 支撑 4 万+ Agent、华为 openJiuwen (双维度 RSI, arXiv: 2608.27969)、华为韬(τ)定律 (ISCAS 2026-05-25, 六年量产 381 款芯片、2031 等效 1.4nm)、Anthropic 研发自动化 (约 26% 研发由 AI 主导、约 3 万并发 Agent; "10 亿次决策"部分核验未核到, 弃用)、OpenAI 自动化研究实习生→2028-03 研究员 (约 3.1 Agent 工作日/人日)、Pillar 3 Fail-Safe & Recovery (Swarm 法定中止/漂移回滚/级联遏制)。

5 被剔除 / 降级清单 (写作者务必遵守)

以下九条是本次核验**主动放弃或降级**的流传说法。它们不是"错得离谱", 而是"写进正文会误导":

- C5 结算中立性五属性 (查无实据)** : 无任何原始出处。只能改写为 UDOS P11/P25 自拟设计目标, 或标 [CITATION NEEDED]。
- A8 MAPF 百万数字 (部分核验 降级)** : DDG 主动微调属实; "524k 100% / 1M 99.9% / 163μs"仅俄文媒体转述, P21 只能说方向、百万数字标媒体主张。
- B5 RSIAIO 记录号 (部分核验)** : 正确为 Zenodo **15644670**, 非 15646184。
- C3 ISONOMIA 记录号与仿真数字 (部分核验)** : 正确为 Zenodo **21338480**; "45000 次仿真/300-300 通过"未核到, 标 [RESULT NEEDED]。
- D2 Adaptive Bitmask (部分核验)** : 子 10ms 方向可信, "85× 压缩/8.2ms p99"标作者主张。
- E4 Hybrid LangGraph-CrewAI (部分核验)** : "96.1%/-76.2%/14.5×"未定位到原文, 降级为待核。
- A3 ClawArena 精确阈值 (部分核验)** : 方向属实, "50% 权限精度/百倍成本/SMS 公式"未逐字命中, 标 论文报告 · 未独立复核。
- G6 Anthropic"10 亿次决策" (部分核验)** : 26%/3 万并发已核; "10 亿次"未核到, 弃用。

9. **A1 H-CSC 版本（部分核验）**：必须用 v2 口径——已撤回"诚实保留优势"，词法谓词胜学习编码器；不得沿用 v1 正面结论。

6 预测更新：保留 F1–F5，新增 F6–F10

P15 提出的 F1–F5（结构变更占比、换结构即换曲线、架构搜索边界、校准类增益、跨基质 master curve 塌缩）**全部保留**，继续作为 2026–2031 的记分对象。本节新增 F6–F10，专门记分 v7.6.0 八项设计提案的成败——它们都写成**可证伪条件**，不是已成立结论。

图3 新增预测 F6–F10 的记分时间轴

图3 F6–F10 五条设计预测的提出时点（2026-09）与预期记分窗口（2027）。概念示意，非实测数据。

- **F6（三级最终性 vs 二元停止）**：在同一故障注入套件下，三级类型化最终性相对 v7.5.0 二元 STOP/CONTINUE，收口率应显著更高、误停率不应上升；若二者无可测差异，则①回滚二元。**判据**：≥30 seed、95% CI 不跨零。待 2027 年记分。
- **F7（scope 收紧的越界拒绝）**：TransferBundle 加 scope 后，结构越界调用的拒绝率应显著上升，而正常工单可用性损失低于预设阈值；若可用性损失超过越界收益，则②改为按需授权。待记分。
- **F8（BRS+DRS 对盲区的覆盖）**：两阶段飞轮相对单阶段 coverage-aware，对 P6 识别的可辨识性盲区（加速度标量类）覆盖率应可测提升；若无提升则③回退单阶段。待记分。
- **F9（审核门禁拦截静默失败）**：[structural] 门禁对"版本号事故类"静默失败的拦截率应显著高于无门禁基线，且对合入速度的代价可接受；若空转则④降级为提示。待记分。
- **F10（规则谓词 vs 学习谓词 AUROC 差）**：在同一对抗攻击族下，确定性规则谓词的安全判别 AUROC 应不低于学习谓词（延续 H-CSC v2 方向）；若学习谓词稳定大幅占优，则⑧"规则为底"需弱化为按攻击族分流。待记分。

7 v7.6.0 全卷 19 篇索引

表 6 P16–P34 篇目速查

篇号	标题	一句话主题	外部对话对象
P16	类型化最终性	二元停止→三级语义提交	H-CSC v2
P17	最小权限编排	TransferBundle 增 scope	ClawArena-Team
P18	广度—深度两阶段飞轮	BRS+DRS 子模采集	RSIAgent
P19	结构变更审核门禁	MatrixConfig 提交必伴断言	Ouroboros
P20	异构性红利与同质性饱和	独立信息源数 ≠ 人头数	OASIS/TUMIX/P9
P21	百万级协调端到端证据	MAPF 成功不可外推语义任务	MAPF-GPT-DDG
P22	内存墙不等于协调墙	容量 ≠ 质量 ≠ 协调	Warp-Cortex
P23	项目级五维评估	工单→项目失败 taxonomy	EPOB
P24	RSI 谱系实测定位	六系统落 L1–L5，无一 L5	Theseus/Dream-RSI/Gödel/HyperAgents
P25	Agent 任务市场	VCG 私有信息与结算	AgentLance/Exchange/ISONOMIA
P26	加权 BFT 与声誉	等权 2f+1 的权重方向	WBFT/COALITION-VAST/BlockAgents
P27	大规模社会仿真因果效度	现象复现 ≠ 机制验证	OASIS/AgentSociety/MegaAgent
P28	百万级通信协议	可重放事件流/亚 10ms	RocketMQ-A2A/Bitmask
P29	测试时规模化协同	工具集成与极端分解投票	TUMIX/MAKER/TTI
P30	混合编排与框架-任务匹配	拓扑选型决策树校准	MultiAgentBench/AutoGen
P31	故障安全与恢复	法定中止/漂移回滚/级联遏制	Pillar 3
P32	规则优先于学习	对抗场景谓词鲁棒性边界	H-CSC v2 教训一般化
P33	v7.6.0 架构总纲	八项结构变更统一规格	全卷收束
P34	文献证据台账与预测更新	三级核验 + F6–F10	本文

8 糟粕、失效边界与可证伪条件

8.1 本台账自身的边界

- **三级核验是"存在性核验"，不是"正确性核验"。**标 已核验 只代表"这篇论文真的存在、题录对得上"，不代表它的结论是对的；论文内数字一律"论文报告·未独立复核"。
- **核验在摘要级完成。**A3 的 SMS 公式、E4 的 96.1% 等"未逐字命中"，只意味着本次核验没在摘要层读到，不等于论文里一定没有——它们应在投稿前逐篇打开正文复核，而非一棍打死。
- **产业传闻时效短。**G 组（Kimi/蚂蚁/浪潮/华为/OpenAI/Anthropic）来自官方页与主流媒体，2026-09-21 之后仍可能变动，引用时须带日期。

8.2 可证伪条件

- **C-ledger-1:** 若读者打开任一 已核验 文献的原文，发现标题/编号/核心机制与本文台账不符，则该条应立即改标 部分核验/查无实据 并更正安全引用句。
- **C-ledger-2:** 若 F6–F10 在 2027 记分窗口被证伪，则对应的设计提案（P16–P19、P32）应按 P33 的 C1–C5 回滚，而非换话术坚持。

9 结论

一份论文卷的可信度，最终不取决于它引用了多少论文，而取决于它**敢不敢公开承认哪些没核到、哪些打了折**。v7.6.0 的诚实立场是：核心新论文绝大多数真实、核心命题成立；但凡是流传很广却站不住的数字（MAPF 百万成功率、结算中立性五属性、Hybrid 96.1%、Anthropic 10 亿次），本文一律降级或剔除，并写明理由。F6-F10 把八项设计提案从"自我感觉良好"变成"等着被打脸的无证伪命题"。

台账不是装饰品，它是本卷的免责书和记分板——写进去的都要负责，核不到的绝不当成事实。

参考文献

UDOS 论文卷（证据等级随文标注）

1. UDOS v7.5.0: P9《质量饱和律》、P12《证据分级驱动的可复现系统工程》、P14《RSI 的收敛》、P15《生命起源于结构组织》（F1-F5）。
2. UDOS v7.6.0: P16-P33 全部专篇（篇目见表 6）。

外部文献（存在性已于 2026-09-21 按 EVIDENCE_LEDGER_v76.md 核验；数字为论文报告/公司披露，未独立复核）

1. H-CSC v2 (arXiv:2606.07316) ; EPOB (OpenReview NtPlgzPtOU, 2026) ; ClawArena-Team (arXiv:2606.31174) ; Warp-Cortex (arXiv:2601.01298) ; RSIAgent (arXiv:2609.15364) ; Ouroboros (arXiv:2608.08311) ; OASIS (arXiv:2411.11581, NeurIPS 2024) ; MAPF-GPT-DDG (arXiv:2506.23793, IROS 2025) 。
2. Theseus Labs (arXiv:2609.11873) ; Dream-RSI (arXiv:2609.14858) ; Gödel Agent (ACL 2025, long.1354) ; HyperAgents (arXiv:2603.19461) ; RSIAI0 (Zenodo 15644670) 。
3. AgentLance (arXiv:2608.23867) ; Agent Exchange (arXiv:2507.03904) ; ISONOMIA (Zenodo 21338480) ; When Agent Markets Arrive (arXiv:2604.06688) 。
4. RocketMQ-A2A (ACM FSE 2026 Industry) ; A Survey of AI Agent Protocols (arXiv:2504.16736) 。
5. TUMIX (arXiv:2510.01279) ; MAKER (arXiv:2511.09030) ; Thinking vs Doing (arXiv:2506.07976) ; MultiAgentBench (ACL 2025, long.421) ; AgentSociety (arXiv:2502.08691) ; MegaAgent (ACL 2025 Findings, 259) 。
6. 经典背景: Kaplan 2020 (2001.08361) ; Chinchilla 2022 (2203.15556) ; Attention 2017 (1706.03762) ; AutoGen 2023 (2308.08155) ; Castro & Liskov 1999; HotStuff (1803.05069) ; Switch Transformers (2101.03961) ; Krogh & Vedelsby 1995; Emergence Mirage (2304.15004) ; Conformal Prediction (2107.07511) 。
7. 产业披露 (G 组) : Kimi K2.6/K3 (arXiv:2607.24653) ; 蚂蚁 Agentar 2.0 (WAIC 2026) ; 浪潮整机柜 (2026-07) ; 华为 openJiuwen (arXiv:2608.27969) 与 韬(τ)定律 (ISCAS 2026-05-25) ; Anthropic 研发自动化数据 (2026-09) ; OpenAI 自动化研究实习生 (2026-09-06) ; Cyber Strategy Institute AI SAFE² Pillar 3 (2026-05) 。

证据纪律与复现说明

- 本文为**证据台账与预测登记**论文，无新增实验；三态核验于 2026-09-21 完成，方法为对每条线索独立联网复核。
- 已核验 仅代表文献存在性与题录一致，论文内数字仍"未独立复核"；部分核验 一律以本文实际值为准；查无实据 一律 [CITATION NEEDED] 。
- 被剔除/降级九条（第 5 节）是本卷的硬纪律，任何专篇引用相关数字时不得回退到用户原始线索值。

- F6-F10 为设计提案的可证伪记分条件，标"待 2027 年记分"；投稿前应对 部分核验 条目逐篇打开正文二次复核。