




P38

China's AI Classification: Institutional and Technical Design, a Multi-Dimensional AI Classification Governance Platform for Education

China's AI Classification: Institutional & Technical Design — A Multi-Dimensional AI Classification Governance Platform for Education

China's AI Classification: Institutional and Technical Design, a Multi-Dimensional AI Classification Governance Platform for Education

Abstract — AI classification is not about labeling a model good or bad; it is about specifying who, in what scenario, may use which tier of AI capability. This supplement designs a multi-dimensional AI classification governance platform oriented toward education, covering both institutional rules and technical enforcement. It maps capability tiers to user roles and scenarios and defines how classifications are assigned, audited, and updated.

Keywords: AI classification; governance; education; institutional design; technical design; capability tiers

孪生地球

中国的AI分级：制度&技术设计——面向教育场景的多维AI分级治理平台

Working Title (EN): China's AI Classification: Institutional & Technical Design — A Multi-Dimensional AI Classification Governance Platform for Education

P38 · 增补卷 v7.7.7 · 孪生地球 Twin Earth · 房文新 · 2026-09-21

一句话先说清：AI 分级不是给模型贴"好/坏"标签，而是给"谁在什么场景下、用什么能力的 AI、做什么任务、受谁监督、用多少额度、在什么时段"做动态授权。本文把中国自上而下的法规谱系（个保法→未保条例→生成式AI办法→标识办法+GB 45438→教育部"分类分级"政策）与国际对照（EU AI Act 四级风险、COPPA、GDPR-K）转译为一套可落地的十维分级编码、PDP/PEP 决策函数、十层系统架构、数据模型与 API、学段策略矩阵，并给出技术选型的精华与糟粕、失效边界与可证伪预测。**全文不含新实验；所有设计提案标"设计提案·待实施"，额度/时长数字标"策略示例·可配置"，外部法规与工具均附官方来源与三态标注。**

证据口径（全文只声明这一次）：中国法规核至 gov.cn / npc.gov.cn / cac.gov.cn / moe.gov.cn / std/openstd.samr.gov.cn 官方原文，访问日期 2026-09-21；国际制度核至欧盟委员会、FTC/Federal Register、ICO、NIST、OASIS 官方页面；技术组件核至 CNCF、NVIDIA、Meta HF、Microsoft、BerriAI 官方文档与 arXiv。三态：☒已核验（官方原文可访问）／☐部分核验（存在性确认但个别字段为指导性文件或二手转述）／☐查无实据（标 [CITATION NEEDED]）。UDOS 自有实测数字本篇几乎不引用；凡引用均带 verified/cpu-proto/unverified 三级标注。

摘要

生成式 AI 进入教育场景后，"一刀切禁用"与"无边界放开"都不可持续：前者剥夺学生学习 AI 素养的机会，后者把未成年人暴露在内容安全、数据隐私、过度依赖与学术诚信的多重风险中。中国法规体系已给出"分类分级"的制度方向——《生成式人工智能服务管理暂行办法》（七部门令第15号，2023-08-15 施行）第3条明文"分类分级监管"，2026-04 教育部等五单位《"人工智能+教育"行动计划》正式提出"分类分级确定安全防护标准"，2025 年教指委《中小生成式人工智能使用指南》明确"小学阶段禁止学生独自使用开放式内容生成功能"。但制度方向不等于可执行的技术方案。

本文的核心贡献是把制度方向转译为工程设计：①构建**十维分级编码**（安全 S0-S4、年龄 A0-A5、内容主题 C0-C4、认知准备度 L0-L5、智能化 I0-I5、内容来源 G0-G4、版本 V0-V3、权限 P0-P5、额度 Q0-Q5、时间

T0-T4)，其中用户原始清单中第3/6项重名"内容分级"，本文裁定拆分为"内容主题/风险分级"与"内容来源/原创性分级"；②定义**决策函数** $Decision=f(\text{身份,年龄,角色,学段,认知准备度,场景,任务,内容,请求I级,版本,权限,额度,时间,监护人同意,教师监督})$ ，输出九种枚举，拒绝须给教育性替代；③设计**十层系统架构**（接入→身份组织→分级策略中心→内容安全→模型网关→教育编排→记忆学情→额度时间→审计合规→管理后台），采用 PDP/PEP 分离与 Policy as Code；④给出**数据模型、关键 API、学段策略矩阵与教育编排机制**（前置任务门、苏格拉底提示、过程证据、AI 使用声明、教师终评、考试禁用）；⑤与 UDOS 治理体系（L0-L5 自主性、证据工程规则优先、TransferBundle 最小权限、BFT-lite 多人复核、质量饱和律）建立映射；⑥对 OPA/Casbin、Llama Guard/NeMo Guardrails/Presidio/LiteLLM、AI 检测工具、年龄保证技术做**精华与糟粕**批判；⑦给出**失效边界、可证伪条件与预测**。

关键词：AI 分级；教育治理；生成式人工智能；Policy as Code；PDP/PEP；未成年人保护；内容标识；渐进开放；人类在环；可审计

结构化摘要（背景问题 → 方法/论点 → 证据 → 贡献）

- **背景问题：**生成式 AI 进入教育场景后，"一刀切禁用"与"无边界放开"均不可持续；中国法规已提出"分类分级"方向（生成式 AI 办法第3条、教育部2026行动计划），但缺少从制度到可执行技术方案的转译。
- **方法/论点：**把"分级"从单一年龄开关重构为十维正交的动态授权体系，用 PDP/PEP 分离 + Policy as Code 实现策略与模型解耦，用教育编排层保证"先自己想、AI 做提示教练、教师保留最终判断"。
- **证据线索：**(1) 中国14项法规/政策核至官方原文（含生成式 AI 办法七部门令第15号、未保条例国务院令 766号、个保法第31条、标识办法国信办通字〔2025〕2号+GB 45438-2025、教育部2026"AI+教育"行动计划）；(2) 国际对照核至 EU AI Act（Annex III 教育高风险、情绪识别 Art.5(1)(f) 禁止）、COPPA 2025 修订、GDPR Art.8；(3) 技术组件核至 OPA/CNCF、NIST SP 800-162、Llama Guard 3、NeMo Guardrails、Presidio、LiteLLM、共形预测 arXiv:2107.07511；(4) AI检测工具偏见有同行评审硬证据 Liang et al. 2023, Patterns 4(7) 100779。
- **贡献：**十维分级编码体系、决策函数与输出枚举、十层系统架构、数据模型与 API、学段策略矩阵、与 UDOS 治理映射、技术选型精华糟粕批判、失效边界与可证伪预测。

1 问题与定位：分级不是给 AI 贴标签，是给"人—场景—能力"授权

一句话结论：教育场景的 AI 治理失败，本质是把"AI 能不能用"当成了一个布尔开关，而真正需要治理的是"谁、在什么场景、用什么能力、做什么任务、受谁监督"这一组多维约束。

1.1 两种极端都不可持续

当前教育领域对生成式 AI 的态度呈现两极：

- **"一刀切禁用"：**部分学校/地区禁止学生在校使用任何生成式 AI。其代价是剥夺学生学习 AI 素养的机会——而 2024-12 教育部办公厅《关于加强中小学人工智能教育的通知》已明确要求按学段推进 AI 教育（小学低年级感知体验、小学高年级和初中理解与使用、高中项目创作与高阶技术应用），禁用与政策方向相悖。
- **"无边界放开"：**部分平台直接向未成年人开放全功能生成式 AI，不做年龄判定、内容适配、时长限制或过程留痕。这直接违反《未成年人网络保护条例》（国务院令 766 号，2024-01-01 施行）要求的"时间管理、权限管理、消费管理"，也违反《生成式人工智能服务管理暂行办法》第10条"防范未成年人过度依赖沉迷"。

两极之间的可行路径是**分级治理**——但"分级"常被简化为"按年龄一刀切"，这同样不够。

1.2 为什么单一年龄分级不够

单一年龄分级至少有四个盲区：

- 1. **同一年龄，认知准备度差异大**：同样12岁，有的学生可以批判性使用 AI，有的仍需教师全程代理。年龄是门槛，不是能力证明。
- 2. **同一年龄，场景差异大**：课堂作业中用 AI 做苏格拉底提示是学习，考试中用 AI 生成答案是作弊。场景必须独立于年龄做分级。
- 3. **同一年龄，任务认知复杂度差异大**：用 AI 解释一个概念（L1 理解）和用 AI 写一篇研究论文（L5 创造）需要完全不同的权限与监督。
- 4. **同一年龄，AI 自主性差异大**：用 AI 做检索问答（I1）和让 AI 作为多智能体自主执行任务（I5）的风险等级完全不同。

因此，本文把"分级"重构为**十维正交的动态授权体系**。

1.3 本文定位与边界

本文是一篇**制度+技术设计论文**，不是实证研究论文。它回答的问题是：在中国现行法规框架下，面向教育场景的 AI 分级治理平台应该如何设计？它不声称已经实现或验证了该平台——所有架构、接口、策略矩阵均为**设计提案·待实施**，标注 [RESULT NEEDED]。

本文不讨论：通用 AI 安全对齐的技术细节（RLHF、红队训练等）、具体模型的能力评测、教育心理学的学习效果实证。这些是相邻但独立的议题。

本章小结：AI 分级的治理对象不是 AI 本身，而是"人—场景—能力—任务—监督"的多维组合；单一年龄开关有四个盲区，需要十维正交体系。

2 制度依据：中国法规谱系与国际对照

一句话结论：中国已形成"法律（个保法）→行政法规（未保条例）→部门规章（生成式AI办法/算法/深度合成/标识/儿童规定）→国家标准（GB 45438）→教育行业政策（教育部分类分级）"的自上而下法规谱系，"分类分级"已从网信领域的监管原则上升为教育行业的正式政策表述；国际对照中 EU AI Act 把教育招生/评分/考试监控明确列为高风险、情绪识别直接禁止，为中国方案提供了风险分级的参照系。

2.1 中国法规谱系（按法律效力层级）

表 1 中国 AI 分级治理相关法规政策谱系（14项，全部核至官方来源，访问日期 2026-09-21）

层级	法规/政策名称	发布机构	文号/标准号	施行日期	对AI分级的核心含义	核验状态
法律	个人信息保护法	全国人大常委会	主席令第91号	2021-11-01	第31条：不满14周岁须监护人同意+专门规则；第28条敏感个人信息	✓
行政法规	未成年人网络保护条例	国务院	国务院令766号	2024-01-01	要求时间管理/权限管理/消费管理；防沉迷/防欺凌专章；覆盖未满18岁全段	✓
部门规章	生成式人工智能服务管理暂行办法	七部门	七部门令第15号	2023-08-15	第3条"分类分级监管" ；第10条防沉迷；第12条内容标识；第17条算法备案	✓
部门规章	互联网信息服务算法推荐管理规定	四部门	四部门令第9号	2022-03-01	第24条算法备案；未成年人不沉迷模式；关闭算法推荐选项	✓
部门规章	互联网信息服务深度合成管理规定	三部门	三部门令第12号	2023-01-10	深度合成内容显著标识；分类分级备案	✓
部门规章	儿童个人信息网络保护规定	国家网信办	网信办令第4号	2019-10-01	"儿童"=不满14周岁；监护人同意；专人负责；保存记录	✓
部门规章	人工智能生成合成内容标识办法	四部门	国信办通字〔2025〕2号	2025-09-01	显式标识+隐式标识（元数据/水印）为强制要求 ；对话式生成须提示标识	✓
国家标准	网络安全技术 人工智能生成合成内容标识方法	市场监管总局+国标委	GB 45438-2025	2025-09-01	规定显式/隐式标识技术方法；不符合标准不得对境内公众提供	✓
规范性文件	教育信息化2.0行动计划	教育部	教技〔2018〕6号	2018-04	信息素养测评、网络学习空间（政策源流）	✓
规范性文件	关于加强中小学人工智能教育的通知	教育部办公厅	[CITATION NEEDED] （文号未逐字核对）	2024-12	按学段分层：小学低感知体验→初中理解使用→高中项目创作	●
规范性文件	关于加快推进教育数字化的意见	教育部等九部门	[CITATION NEEDED]	2025-04	落实算法与大模型备案机制；规范AI进校园	●
规范性文件	"人工智能+教育"行动计划	教育部等五单位	[CITATION NEEDED]	2026-04	第（十六）条"分类分级确定安全防护标准" ；教育大模型安全审核	●
指导性文件	中小生成式人工智能使用指南（2025年版）	教育部基础教育指导委员会	无令号	2025-05	"小学阶段禁止学生独自使用开放式内容生成功能" ；初中适度探索；高中应用	●
类比参考	关于进一步严格管理 切实防止未成年人沉迷网络游戏的通知	国家新闻出版署	国新出发〔2021〕14号	2021-09-01	仅借"年龄+时长+实名"制度逻辑； 类比非直接适用于AI教育	✓

表1注：七部门=网信办、发改委、教育部、科技部、工信部、公安部、广电总局；四部门（算法推荐）=网信办、工信部、公安部、市场监管总局；三部门（深度合成）=网信办、工信部、公安部；四部门（标识办法）=网信办、工信部、公安部、广电总局。事实纠正：算法推荐规定为四部门而非七部门。

2.2 法规谱系的三条制度主线

从表1可以提炼出三条贯穿全谱系的制度主线，它们直接对应本文的技术设计维度：

- 主线一：分类分级监管**——生成式AI办法第3条确立"包容审慎和分类分级监管"原则，教育部2026行动计划把它落到教育场景（"分类分级确定安全防护标准"）。这是本文"十维分级编码"的直接法源。
- 主线二：未成年人分层保护**——一个保法第31条+儿童规定把"不满14周岁"设为监护人同意的硬门槛；未保条例把保护范围扩展到未满18周岁全段，要求时间/权限/消费管理。这意味着年龄分级不能只切14岁一刀，而应覆盖 A0-A5 全段并差异化设计（<14岁强监护人同意，14-18岁未成年人模式+学校/家长知情）。
- 主线三：内容标识与可追溯**——深度合成规定（2023）→标识办法+GB 45438（2025-09-01）形成"显式标识+隐式标识（元数据/数字水印）"的强制技术要求。这是本文"内容来源/原创性分级 G0-G4"和"过程证据"机制的技术法源。

2.3 国际对照：EU AI Act 四级风险与教育定位

表 2 EU AI Act 四级风险与教育场景对照（核至欧盟委员会官方页面，访问日期 2026-09-21）

风险等级	定义要点	教育场景示例	义务要求
不可接受风险 (Art.5)	对基本权利构成明显威胁，直接禁止	教育机构/工作场所中的情绪识别AI (Art.5(1)(f) 明文禁止)；社会评分；推断受保护属性的生物特征分类	禁止投放市场/投入使用
高风险 (Art. 6+Annex III)	可能对健康安全或基本权利产生显著不利影响	Annex III 第3类"教育与职业培训"：招生/入学筛选、学习结果评估、教育水平评定、考试过程行为监控	全生命周期合规：风险管理、数据治理、技术文档、记录留存、透明度与人工监督、稳健性与网络安全、合格评定、CE标志、登记
有限风险 (Art.50透明度)	不构成禁止或高风险，但须履行透明度义务	通用教育聊天机器人、AI辅导对话（非用于评分/录取）；AI生成教育材料	告知用户正在与AI交互；披露AI生成/操纵内容
最小风险	绝大多数AI应用，无特定义务	课堂作业辅助建议、个性化练习推荐	无强制义务；鼓励自律与AI素养

表2注：EU AI Act（Regulation (EU) 2024/1689）2024-08-01 生效；禁止条款与AI素养义务 2025-02-02 起适用；GPAI 模型义务 2025-08-02 起适用；绝大多数高风险义务 2026-08-02 起适用。

EU AI Act 对本文的三个关键启示：

- 教育不是单一风险等级**：用于招生/评分/考试监控的AI是高风险，用于课堂辅导的聊天机器人是有限风险——这印证了本文"场景独立分级"的设计。
- 情绪识别在教育场景被直接禁止**：Art.5(1)(f) 明文禁止在教育机构和场所使用情绪识别AI。本文的"认知准备度 L0-L5"必须严格限定为"任务认知复杂度适配标签"，**不得走向情绪识别或心理状态推断**。
- 高风险义务的核心是"人工监督+记录留存"**：这与本文"人类在环、可解释可审计"的设计原则完全对齐。

2.4 其他国际制度要点

- COPPA（美国）**：13岁以下儿童个人信息须取得可验证家长同意（VPC）；2025-01-16 FTC 通过最终修订规则，新增知识认证（KBA）与人脸识别（须人工复核）作为 VPC 方式。与中国个保法第31条（<14岁）的年龄线不同，但制度逻辑一致——低龄段强监护人同意。

- **GDPR Art.8（欧盟）**：数字服务同意年龄默认16岁，成员国可在13-16岁区间下调（英国13、德国16、法国15、奥意西14，后三项为二手学术mapping [CITATION NEEDED]）。跨国部署需按最严或逐国适配。
- **Age Assurance（英国 ICO）**：按风险分级的年龄确信度——低风险可自声明，高风险须 hard identifiers（政府ID）/年龄估计等多因子。**自声明年龄可被轻易绕过**，面部年龄估计对未成年人、不同肤色存在偏见与隐私争议。教育场景应优先采用政府数字身份或家长账户验证，AI 年龄估计仅作辅助信号。
- **FERPA（美国）**：保护学生教育记录隐私；AI 厂商在自有服务器上生成且未回传学校的推断性分析是否构成 FERPA"教育记录"，截至2025年初 DOE 尚无最终明确解释 🟡。

本章小结：中国已形成自上而下的"分类分级"法规谱系，三条主线（分类分级监管、未成年人分层保护、内容标识可追溯）直接对应技术设计维度；EU AI Act 证明教育场景需按用途分级（高风险/有限风险），情绪识别被直接禁止，高风险义务核心是人工监督+记录留存。

3 十维分级编码

一句话结论：十维分级编码把"分级"从模糊的政策口号变为可计算、可版本化、可审计的工程对象；其中用户原始清单中第3/6项重名"内容分级"，本文裁定拆分为"内容主题/风险分级（C0-C4）"与"内容来源/原创性分级（G0-G4）"，避免策略引擎冲突。

图1 十维分级总览

图1 十维分级总览：Decision=f(身份,年龄,角色,场景,内容,任务,模型,版本,权限,额度,时间,同意,监督)。十维正交：安全是红线、年龄是门槛、认知是适配、自主性是路由、权限/额度/时间是约束、版本是可回滚。（概念示意）

3.1 十维编码定义大表

表 3 十维分级编码定义与教育映射

#	维度	编码	等级定义	教育映射	技术实现
1	安全分级	S0-S4	S0正常/S1提醒/S2拦截/S3高危转人工/S4危机干预	自伤·暴力·色情·违法·心理危机·隐私；S4不继续生成、转监护人/学校心理老师	多模态审核、分类器、危机干预工单
2	年龄分级	A0-A5	A0学前(0-5)/A1小学低(6-8)/A2小学高(9-11)/A3初中(12-14)/A4高中(15-18)/A5大学成人(18+)	低龄默认无自由生成、教师/家长代理；高中逐步开放	IAM、学籍、监护人同意、年龄断言
3	内容主题/风险分级	C0-C4	C0通识/C1学科儿童适宜/C2争议/C3敏感高风险/C4成人专业	标签含适龄性、事实性、争议性、来源可信度；暴力/色情/自伤/隐私按等级拦截或引导	内容标签、分类器、知识库、RAG
4	认知准备度	L0-L5	L0记忆/L1理解/L2应用/L3分析/L4评价/L5创造（布鲁姆分类）	用户明确"智力分级"改名认知准备度 ；仅内部适配标签，禁止贴标签/排名/分流/预测未来，可申诉可重置	任务模板、学段评估、动态更新
5	智能化/自主性分级	I0-I5	I0无AI/I1检索/I2模板单轮/I3多轮对话/I4工具代理/I5多智能体自主	低龄限I0-I2，高中受控I3-I4试点，教师I4-I5；与UDOS L0-L5、SAE J3016呼应	模型网关、能力注册卡、工具白名单
6	内容来源/原创性分级	G0-G4	G0人工原创/G1 AI辅助/G2 AI生成已审/G3 AI直生/G4 AI代写未声明	水印+原创性检测+过程记录；支撑学术诚信与教学评价	数字水印、原创性检测、过程证据库
7	版本分级	V0-V3	V0实验/V1试点/V2稳定默认/V3强制	策略·模型·标签·SDK版本；灰度/回滚/审计；教育默认稳定版禁止自动升级	版本管理、灰度发布、回滚机制
8	权限分级	P0-P5	P0无/P1只读/P2受限对话/P3生成/P4 API/工具/P5管理	角色：学生/家长/教师/教研/管理员/监管； final_assessment 评价权仅教师	RBAC+ABAC、OPA/Casbin
9	额度分级	Q0-Q5	token/次数/时长/并发/成本/字符/图片	按年龄·学段·任务·信用动态；低龄低额度，教师较高	配额中心、限流、计量
10	时间分级	T0-T4	T0禁用/T1课堂监督/T2家庭时段/T3自由时段/T4考试禁用	时段/连续时长/日累计/冷却/夜间锁/课堂模式；考试模式全局禁用	时钟策略、场景模式、屏幕时间

3.2 关于第3/6项重名的裁定说明

用户原始设计素材中第3项和第6项均命名为"内容分级"，这会导致策略引擎中两个同名字段冲突。本文裁定如下：

- **第3项 = 内容主题/风险分级（C0-C4）**：回答"这段内容在讲什么、风险多高、是否适龄"。它是内容安全与适龄适配的维度。
- **第6项 = 内容来源/原创性分级（G0-G4）**：回答"这段内容是谁写的、AI 参与了多少、是否声明"。它是学术诚信与过程追溯的维度，直接对应《标识办法》+GB 45438 的显式/隐式标识要求。

另一套草稿中提出的"内容呈现分级 P0-P4（纯文本/图文/多模态/交互/沉浸）"可作为**备选第十一维**，但本文不纳入核心十维——因为呈现方式更多是交互设计选择，而非治理决策维度。如需纳入，建议命名为"呈现模态分级 M0-M4"以避免与 C/G 混淆。

3.3 三个关键区分

区分一：安全分级（S）vs 内容主题分级（C）。S 是红线——S3/S4 直接拦截或转人工，不讨论"是否适龄"；C 是适配——C2 争议内容在高中可以引导讨论，在小学则拦截。S 优先于 C：任何内容先过 S 级红线，再做 C 级适配。

区分二：认知准备度（L）vs 智能化分级（I）。L 是任务本身需要多少认知能力（布鲁姆分类），决定 AI 的交互方式（L0-L1 可直接反馈，L2-L3 给提示，L4-L5 辩论/反方）；I 是 AI 被允许有多强自主性，决定模型路由和工具权限。二者正交：一个 L5（创造）任务可以用 I2（模板单轮）AI 来做提示，一个 L1（理解）任务也不应该用 I5（多智能体自主）AI 来执行。

区分三：年龄（A）vs 认知准备度（L）。年龄是法律与制度门槛（<14岁须监护人同意），认知准备度是内部适配标签。年龄不可跳过（法律硬约束），认知准备度可动态调整、可申诉、可重置。**严禁**用认知准备度标签对学生进行排名、分流或预测未来——这是伦理红线，也呼应 EU AI Act 对教育场景高风险系统的严格约束。

本章小结：十维编码把分级变为可计算的工程对象；第3/6重名裁定拆分为内容主题（C）与内容来源（G）；三个关键区分（S vs C、L vs I、A vs L）保证维度正交、策略无冲突。

4 决策函数与 PDP/PEP 架构

一句话结论：分级决策的核心是一个纯函数 $\text{Decision} = f(\text{输入属性}) \rightarrow \text{输出枚举} + \text{约束}$ ，采用 PDP（策略决策点）与 PEP（策略执行点）分离的架构，策略与模型解耦，每次决策可解释、可版本化、可审计。

4.1 决策函数定义

$$\text{Decision} = f(\text{身份}, \text{年龄}, \text{角色}, \text{学段}, \text{认知准备度}, \text{场景}, \text{任务认知级}, \text{内容安全/主题/来源}, \text{请求I级}, \text{版本}, \text{权限}, \text{额度}, \text{时间}, \text{监护人同意}, \text{教师监督})$$

输入分为四类：

- **主体属性：**身份(userId)、年龄(A)、角色、学段、认知准备度(L)、监护人同意状态、教师监督状态。
- **场景属性：**场景模式（课堂/作业/考试/家庭/项目）、设备、位置、网络环境。
- **资源属性：**任务类型、任务认知级(L)、内容安全级(S)、内容主题级(C)、内容来源级(G)、请求的智能化级(I)。
- **环境属性：**版本(V)、权限(P)、额度剩余(Q)、时间窗口(T)、当前时钟。

4.2 输出枚举

表 4 决策输出枚举与含义

枚举	含义	典型触发条件
ALLOW	允许，按默认模式执行	所有约束满足
DENY	拒绝，返回教育性替代	安全 S3/S4、考试 T4、低龄无权限、额度耗尽
ALLOW_WITH_GUARDRAILS	允许但加护栏（强制引用/过程记录/不直接给答案）	初中生成作文、高中项目
REQUIRE_SUPERVISION	需教师/家长监督后执行	低龄请求高 I 级、敏感内容 C2/C3
REQUIRE_VERIFICATION	需引用/验证/事实核查后输出	争议内容、高中研究任务
TEACHER_ONLY	仅教师可用，学生端路由到教师代理	学前/低小 A0-A1 生成式请求
DOWNGRADE_CAPABILITY	降级到更低 I 级或更保守模型	请求 I4 但策略只允许 I2
PROXY_TEACHER	教师/家长代理执行，学生不直接交互	低龄特殊需求

关键设计：拒绝不是冷冰冰的"禁止"。当决策为 DENY 时，系统必须返回**教育性替代**，例如："这个阶段先自己写10分钟提纲，然后我可以帮你检查逻辑和用词。"这是教育场景与通用内容审核的本质区别——审核的目的不是阻止学习，而是引导学习。

4.3 决策输入输出示例

输入（JSON）：

```
{
  "subject": {
    "user_id": "u123", "role": "student", "age": 10, "grade": "小学四年级",
    "guardian_consent": true,
    "readiness": {"knowledge": 0.4, "self_control": 0.5, "risk_understanding": 0.3}
  },
  "scene": {"mode": "homework", "teacher_supervised": false, "exam_mode": false},
  "task": {"type": "writing", "subject": "语文", "cognitive_level": "L2"},
  "content": {"safety_level": "S0", "topic_level": "C1", "source_level": "G2"},
  "model": {"requested_level": "I3"},
  "quota": {"daily_remaining": 8},
  "time": {"current_window": "T2", "used_minutes": 12}
}
```

输出（JSON）：

```
{
  "decision_id": "d_001",
  "allow": true,
  "mode": "SOCRATIC_HINT",
  "model_level": "I2",
  "permissions": ["chat.limited", "rag.textbook"],
  "constraints": [
    "不直接给作文全文",
    "先提交自己的提纲",
    "必须给引用",
    "记录修改过程"
  ],
  "quota": {"max_tokens": 1200, "remaining_calls": 8},
  "time": {"max_minutes": 15, "cooldown_minutes": 30},
  "human_in_loop": "parent_notify_if_sensitive",
  "policy_version": "v2.3.1",
  "model_version": "edu-llm-v1.8-stable",
  "reasons": ["age_A2_default_I2", "writing_task_require_outline_first", "quota_sufficient"]
}
```

注意输出中包含 `policy_version`、`model_version`、`reasons` ——这是可解释性与可审计性的基础。每次决策都可以追溯到“哪条策略、哪个模型版本、为什么这样决定”。

4.4 PDP/PEP 分离架构

图2 决策流与十层架构

图2 决策流（PEP→PDP→输出枚举）与十层系统架构。PEP 部署在网关/客户端/LMS入口，负责拦截请求与执行决策；PDP 独立部署，负责策略求值，与业务代码解耦。（概念示意）

图5 核心决策时序八步

图5 核心决策时序八步：客户端请求→身份认证与年龄断言→PDP策略求值→模型网关路由与能力匹配→内容安全输入审核→教育编排（苏格拉底/前置任务门）→输出审核与审计计量→返回决策与教育性替代。旁路：记忆与学情在请求前后异步更新，不阻塞主决策链路。（概念示意）

- **PEP（Policy Enforcement Point，策略执行点）**：部署在 API 网关、客户端 SDK、LMS 插件入口。职责：拦截所有 AI 请求 → 收集上下文属性 → 调用 PDP → 执行决策（放行/拒绝/降级/加约束） → 记录审计。PEP 不做策略判断，只做执行。
- **PDP（Policy Decision Point，策略决策点）**：独立部署的策略引擎。职责：接收属性 → 加载策略版本 → 求值 → 返回决策。PDP 无状态，可水平扩展。
- **PAP（Policy Administration Point，策略管理点）**：管理后台，负责策略的编写、版本化、灰度发布、回滚。
- **PIP（Policy Information Point，策略信息点）**：提供属性数据源（身份服务、额度服务、时间服务、学情服务）。

这一架构参考 XACML（OASIS 标准）的 PDP/PEP/PAP/PIP 四组件分离，在云原生场景下用 OPA/Rego 或 Casbin 实现。**策略与模型解耦**是核心原则——换模型不改教育规则，换教育规则不改模型。

4.5 Policy as Code：策略即代码

分级策略用声明式语言编写（Rego 或 Casbin 策略文件），纳入版本控制，支持代码评审、测试、灰度发布、回滚。示例（Rego 伪代码）：

```

# 小学低段(A1)学生端默认关闭自由生成
deny[msg] {
    input.subject.age <= 8
    input.subject.role == "student"
    input.model.requested_level >= "I3"
    msg := "小学低段学生端不开放自由生成，请由教师/家长代理使用"
}

# 考试模式全局禁用
deny[msg] {
    input.scene.exam_mode == true
    msg := "考试模式下禁用生成式AI"
}

# 写作任务必须先提交提纲
constraint[c] {
    input.task.type == "writing"
    input.subject.age <= 14
    c := "require_outline_first"
}

```

策略文件本身有版本号（V0-V3），每次决策关联策略版本，支持回滚到任意历史版本。这呼应 UDOS 证据工程的"版本可追溯"原则。

本章小结：决策函数是纯函数，输入四类属性、输出九种枚举+约束；PDP/PEP 分离保证策略与业务/模型解耦；Policy as Code 让策略可版本化、可测试、可回滚；拒绝必须给教育性替代。

5 十层系统架构

一句话结论：十层架构从接入到管理后台逐层递进，核心是"分级策略中心"作为决策大脑、"模型网关"作为能力路由、"教育编排"作为学习过程守护、"审计合规"作为全链路可追溯；每层职责单一、接口明确、可独立替换。

5.1 十层架构总览

表 5 十层系统架构定义

层	名称	核心职责	关键组件
①	接入层	多端接入、协议转换、流量入口	Web/App、学校SSO、API、浏览器插件、教育软件SDK
②	身份与组织层	身份认证、组织管理、年龄断言、监护人关系	IAM(OIDC/SAML/Keycloak)、组织/班级/角色、监护人、年龄断言服务
③	分级策略中心	策略决策、规则引擎、版本管理	PDP/PEP、Policy as Code(OPA/Rego/Casbin)、决策表、灰度/回滚
④	内容安全与分级	输入输出审核、多模态分类、危机干预	多模态审核、分类器(Llama Guard等)、知识库、危机干预工单
⑤	模型网关	模型路由、提示模板、RAG、工具调用、能力注册	LiteLLM路由、提示词模板、RAG白名单知识库、工具白名单、能力注册卡
⑥	教育编排层	任务模板、苏格拉底引导、先答后问、过程记录	任务模板、SOCRATIC_HINT模式、前置任务门、过程证据采集
⑦	记忆与学情层	学习档案、知识图谱、掌握度、认知负荷、原创性检测	学习档案、知识图谱、掌握度模型、认知负荷评估、原创性检测
⑧	额度与时间层	计量、配额、限流、时钟、课堂模式	计量服务、配额中心、限流、时钟策略、课堂模式/考试模式
⑨	审计与合规层	日志、可解释、报告、申诉、数据留存	审计日志、决策可解释、家长/教师报告、申诉通道、数据留存/删除
⑩	管理后台	学校/家长/教师/监管多视角管理	学校管理端、家长控制端、教师工作台、监管报表端

5.2 核心数据流

客户端请求

→ ①接入层(PEP拦截)

→ ②身份与组织(认证+年龄断言+监护人同意)

→ ③分级策略中心(PDP求值 → 决策+约束)

→ ⑤模型网关(路由到对应I级模型 + 提示模板 + RAG + 工具)

→ ④内容安全(输入审核 → 生成 → 输出审核)

→ ⑥教育编排(苏格拉底模式/前置任务门/过程记录)

→ ⑧额度与时间(扣减配额/更新时长)

→ ⑨审计合规(记录决策+输入+输出+版本 → 生成报告)

→ 返回客户端(带decision_id + constraints + citations + audit)

旁路：⑦记忆与学情在请求前后异步更新（掌握度、认知负荷、原创性），不阻塞主决策链路。

5.3 三层关键设计说明

设计一：模型网关的能力注册卡。每个模型/工具/Agent 都有一张"能力注册卡"，记录：智能化级(I)、支持的内容级(C)、适用年龄下限(A)、版本(V)、是否可记忆、是否可联网、是否可生成代码/图片/文件、成本/Token 速率、已知局限。模型网关根据 PDP 决策选择满足约束的模型——例如决策要求 I2+C1+A2，则网关只路由到满足这三个条件的模型，不允许"请求什么模型就用什么模型"。这是**能力路由**而非简单的 API 代理。

设计二：教育编排层的"前置任务门"。这是整个平台最核心的教育差异点。学生调用 AI 前，必须先提交自己的思路、提纲、草稿或答案——系统校验"学生已尝试"后，才允许 AI 介入。AI 默认进入 SOCRATIC_HINT（苏格拉底提示）模式，只给问题、线索、检查点，不直接给答案。高中阶段可开放"反方观点模式"，但必须标注

证据和来源。这一设计直接呼应 2025 教指委指南"小学禁止独自使用开放式生成"的政策红线，也体现"AI 是提示教练，不是代写工具"的教育哲学。

设计三：审计合规层的"决策可解释"。每次决策记录：谁(userId)、何时、什么场景、用了哪个模型版本、哪个策略版本、输入属性快照、输出决策、理由(reasons)、是否被教师覆盖、覆盖理由。家长/教师/监管可按 decision_id 查询完整决策链。这呼应 EU AI Act 高风险系统的"记录留存"义务，也呼应 UDOS 证据工程的"三层一致"原则。

5.4 技术选型

表 6 技术选型建议（均核至官方文档，访问日期 2026-09-21）

层级	推荐组件	备选	选择理由	局限/注意
策略引擎	OPA/Rego	Casbin、Drools	CNCF毕业项目(2021-01-29)、PDP/PEP原生支持、Rego表达力强	Rego学习曲线陡峭；策略正确性需测试
身份	Keycloak(OIDC/SAML)	Auth0、学校SSO对接	开源、支持联邦身份、教育场景常见	需与教育学籍系统对接
网关	Kong/APISIX/Envoy	—	PEP部署点、限流、认证	网关本身成为关注点
模型网关	LiteLLM	自研路由	统一100+提供商(厂商口径)、成本跟踪、fallback	企业级SSO为付费版；不同提供商工具调用支持不一致
内容安全	Llama Guard 3 + NeMo Guardrails + Presidio	Guardrails AI、自研分类器	Llama Guard S1-S13分类、NeMo编排、Presidio PII脱敏	中文教育敏感词需自微调；不能替代人工审核
知识库/向量	pgvector/Milvus	—	RAG白名单教材库	需定期更新教材版本
事件/工作流	Kafka/Temporal	—	异步审计、额度扣减、重试	增加系统复杂度
数据存储	Postgres/Redis/ClickHouse	—	结构化数据/缓存/审计日志分析	未成年人数据需加密+区域驻留
可观测性	OpenTelemetry/ELK	—	全链路追踪、日志聚合	—
部署	K8s	私有化/混合云	区域数据驻留、弹性伸缩	教育私有化部署需考虑运维能力

本章小结：十层架构职责单一、接口明确；三个关键设计（能力注册卡、前置任务门、决策可解释）是教育场景的核心差异；技术选型优先成熟开源组件，但中文教育敏感词需自微调、AI检测工具不可作为唯一判定依据。

6 数据模型与关键 API

一句话结论：数据模型围绕"决策可追溯"设计，核心实体是 User、Policy、Decision、AuditLog、ProcessEvidence；API 以 /v1/ai/query 为核心入口，所有请求带 context、所有返回带 decision_id，保证端到端可审计。

6.1 核心数据模型

表 7 核心数据实体与关键字段

实体	关键字段	说明
User	user_id, role, age, grade, org_id, class_id, status	角色：student/parent/teacher/researcher/admin/regulator
AgeProfile	user_id, age_band(A0-A5), birth_date, age_assertion_method, guardian_verified	年龄断言方法：学籍/家长账户/政府ID/自声明(仅低风险)
GuardianConsent	consent_id, student_id, guardian_id, scope, granted_at, revoked_at, status	可撤销；scope限定数据用途
Role/Permission	role_id, permissions[], data_scope, final_assessment(bool)	final_assessment仅教师为true
Org/Class	org_id, org_type(school/district), class_id, grade	组织层级
Policy	policy_id, name, description, version(V0-V3), status, code(Rego), created_by	策略即代码
PolicyVersion	version_id, policy_id, version_str, changelog, 灰度范围, created_at	支持灰度/回滚
Resource/Content	content_id, content_type, safety_level(S), topic_level(C), source_level(G), labels[], creator	内容标签
ContentLabel	label_id, content_id, label_type, value, confidence, label_version	标签版本化
Model	model_id, name, provider, version, capability_level(I), cost_per_token, status	模型注册
ModelCapability	model_id, capability_card(json), min_age(A), max_content(C), tools[], limitations	能力注册卡
Session	session_id, user_id, scene, started_at, ended_at, duration, mode	会话
Request	request_id, session_id, prompt_hash, attachments_hash, task_type, cognitive_level(L), timestamp	请求（内容哈希，不存原文以保护隐私）
Decision	decision_id, request_id, policy_version, model_version, input_snapshot, output(json), reasons[], created_at	核心可追溯实体
Quota	user_id, period, quota_type(token/calls/time/cost), limit, used, remaining	额度
TimeWindow	user_id, date, window_type(T0-T4), allowed_hours, used_minutes, cooldown_until	时间
AuditLog	log_id, decision_id, actor, action, timestamp, metadata	审计
Consent	consent_id, user_id, type, scope, granted_at, revoked_at	同意管理
Guardian	guardian_id, student_ids[], relationship, contact_verified	监护人
ClassroomMode	class_id, mode(active/exam/locked), teacher_id, started_at, ended_at	课堂/考试模式
Assessment	assessment_id, student_id, task_id, teacher_id, ai_assisted(bool), process_evidence_ids[], final_score, teacher_notes	教师终评，AI不做最终评价
ProcessEvidence	evidence_id, session_id, type(draft/outline/prompt/modification/citation), content_hash, timestamp, ai_usage_declaration	过程证据：草稿史/提示/修改轨迹/引用

实体	关键字段	说明
TeacherOverride	override_id, decision_id, teacher_id, original_decision, new_decision, reason, timestamp	教师可覆盖但留痕

6.2 关键 API

表 8 关键 API 定义

方法	路径	说明	关键输入	关键输出
POST	/v1/ai/query	核心AI查询入口	context(userId,role,age,scene,task,prompt,attachments,requested_l_level)	decision_id, allowed, mode, model, constraints, content, citations, hints, audit
POST	/v1/policy/evaluate	策略求值（调试/审计用）	input_attributes	decision, reasons, policy_version
POST	/v1/content/classify	内容分类	content_text/hash	safety_level(S), topic_level(C), source_level(G), labels
POST	/v1/quota/check	额度检查	userId, quota_type	remaining, limit
POST	/v1/quota/consume	额度扣减	userId, quota_type, amount	new_remaining
POST	/v1/time/check	时间窗口检查	userId, scene	allowed, current_window(T), remaining_minutes
POST	/v1/audit/log	审计日志写入	decision_id, actor, action, metadata	log_id
POST	/v1/guardian/consent	监护人同意授予/撤销	student_id, guardian_id, scope, action	consent_id, status
POST	/v1/teacher/override	教师覆盖决策	decision_id, new_decision, reason	override_id
GET	/v1/report/guardian/{student_id}	家长报告	student_id, period	usage_summary, decisions, alerts, quota
GET	/v1/audit/decision/{decision_id}	决策详情查询	decision_id	full decision chain

6.3 /v1/ai/query 的契约

请求必须携带：用户身份、年龄、角色、班级、场景（课堂/作业/考试/家庭/项目）、任务类型、是否教师监督、是否家长同意、请求的模型能力级别、内容附件哈希、隐私标记。

返回必须包含：决策ID、是否允许、教育模式（直接回答/SOCRATIC_HINT/只给线索/拒绝并替代）、引用来源、额度与时间约束、审计ID。

设计提案·待实施 [RESULT NEEDED]: 以上 API 为设计提案, 尚未实现。实际实现时需补充: 认证中间件、速率限制、错误码规范、WebSocket 流式响应支持、版本化 API 迁移策略。

本章小结: 数据模型围绕 Decision 核心可追溯实体设计, ProcessEvidence 和 TeacherOverride 是教育场景特有的实体; API 以 /v1/ai/query 为核心, 所有请求带 context、所有返回带 decision_id; 均为设计提案·待实施。

7 学段策略矩阵与教育编排

一句话结论: 学段策略矩阵把十维编码落到每个年龄段的具体权限与约束, 数字均为策略示例·可配置; 教育编排层通过"前置任务门、苏格拉底提示、过程证据、AI使用声明、教师终评、考试禁用"六大机制保证"AI 是提示教练, 不是代写工具"。

7.1 学段策略矩阵

图3 学段×维度策略矩阵

图3 学段×维度策略矩阵 (策略示例·可配置, 非实测; 颜色越绿开放度越高)。学前/低小锁定, 高小受控问答, 初中生成+引用+过程, 高中开放+批判+项目, 教师全功能但不做最终评价。

图4 分级门渐进开放

图4 分级门渐进开放六扇门: 年龄轴 A0→A5, 权限从"安全红线/教师代理"逐级打开到"全功能/审计"。每扇门对应一组默认策略, 可被教师/家长/监管在授权范围内调整, 但不可越级跳过安全红线。"分级不是开关, 是门: 该慢则慢、该放则放。" (策略示例·可配置)

表 9 学段策略矩阵 (所有额度/时长数字为策略示例·可配置, 非实测)

学段	年龄	默认权限	智能级 (I)	典型模式	额度/时间(示例)	监督
学前 A0	0-5	学生端无自由生成	I0-I1	教师/家长代理、白名单内容、故事/识字	Q0, T0/T1	强
低小 A1	6-8	学生端无自由生成	I0-I1	教师/家长代理、白名单问答	Q0, T0/T1	强
高小 A2	9-11	受限问答+教材RAG	I1-I2	苏格拉底提示、先答后问、提示卡	10-20次/日, 15-20min	家长同意
初中 A3	12-14	可生成但强制引用+过程记录	I2-I3	辩论、实验、逻辑分析、反代写检测	30-50次/日, 30min	教师监督
高中 A4	15-18	开放+批判+项目+API教师监督试点	I3-I4	AI素养、反方观点、验证、项目创作	80-200次/日, 60min	教师试点, 考试禁用
教师 A5	18+	全功能但不做最终评价	I4-I5	备课、出题、批改辅助、学情分析	按组织配额	审计
考试场景	任意	全局禁用生成式AI	I0	仅白名单离线工具(计算器/词典)	Q0, T4	监考

表9注: 额度/时长数字为策略示例·可配置, 实际部署时应由学校/区域根据学情、设备、网络条件调整, 并经过试点验证。低龄段的"无自由生成"直接对应 2025 教指委指南"小学阶段禁止学生独自使用开放式内容生成功能"。

7.2 教育编排六大机制

机制一：前置任务门（Pre-task Gate）。学生调用 AI 前，必须先提交自己的思路、提纲、草稿或答案。系统校验"学生已尝试"（通过文本输入、手写拍照识别、或教师确认）后，才允许 AI 介入。这是"先自己想"的技术实现——AI 不能替代思考过程，只能在思考之后提供反馈。

机制二：SOCRATIC_HINT（苏格拉底提示模式）。低龄段默认模式，AI 不直接给答案，只给问题、线索、检查点。例如学生问"这道数学题怎么做"，AI 回复："你先想想这道题涉及什么运算？已知条件有哪些？第一步可以做什么？"高中阶段可切换为"反方观点模式"，AI 给出对立论证，但必须标注证据和来源。

机制三：过程证据（Process Evidence）。系统保存草稿历史、提示记录、修改轨迹、AI 对话摘要、引用来源。每条过程证据带 content_hash（不存原文以保护隐私）和时间戳。教师可查看学生的完整学习过程——这比"最终作业是否AI生成"更有教育价值，也比 AI 检测分数更可靠。

机制四：AI 使用声明（AI Usage Declaration）。作业中自动附带元数据：用了什么模型、哪个段落用了 AI、提示是什么、AI 参与程度（G0-G4）。这对应《标识办法》+GB 45438 的显式/隐式标识要求，也培养学生的学术诚信意识。

机制五：教师终评（Teacher Final Assessment）。AI 可以辅助批改、给出反馈、分析学情，但 final_assessment 权限仅教师——AI 不能直接决定学生评价。教师可覆盖 AI 决策（TeacherOverride），但必须留痕（覆盖理由、时间）。这是"人类在环"的核心体现。

机制六：考试禁用（Exam Mode Lock）。考试场景下全局 T4/Q0/I0，禁用生成式 AI，仅允许白名单离线工具（计算器、词典）。课堂模式由教师一键切换，考试模式由学校管理员配置时间窗口。这是评价公平的技术保障。

7.3 拒绝的教育性替代示例

场景	系统决策	教育性替代回复
8岁学生请求"帮我写作文"	DENY + TEACHER_ONLY	"这个阶段先自己写10分钟提纲，然后可以让老师或爸爸妈妈帮你看看。"
10岁学生请求"直接给我答案"	ALLOW_WITH_GUARDRAILS + SOCRATIC_HINT	"先说说你是怎么想的？你觉得第一步应该做什么？我可以帮你检查思路。"
14岁学生写作文不提交提纲	DENY + 前置任务门	"请先提交你的作文提纲（至少3个要点），提交后我可以帮你完善逻辑和用词。"
考试期间任何AI请求	DENY + T4	"考试模式下禁用AI，请独立完成。"
高中学生请求"帮我写完整论文"	ALLOW_WITH_GUARDRAILS + 强制引用 +过程记录	"我可以帮你列大纲、找文献、检查论证，但论文需要你 自己写。每段AI辅助内容会自动标注。"

本章小结：学段策略矩阵把十维编码落到具体年龄段，数字均为策略示例·可配置；教育编排六大机制（前置任务门、苏格拉底提示、过程证据、AI使用声明、教师终评、考试禁用）是"AI 是提示教练不是代写工具"的技术实现；拒绝必须给教育性替代。

8 与 UDOS 治理体系的映射

一句话结论：本平台的十维分级与 UDOS 治理体系在五个维度上深度同构——I0-I5 对齐 UDOS L0-L5 自主性等级，Policy as Code 对齐证据工程"规则优先于学习"，TransferBundle 最小权限对齐权限分级，BFT-lite 多人复核对齐教师委员会/人审闸门，质量饱和律解释"生成可扩展、教师审查不扩展"的治理天花板。

8.1 五重映射

表 10 本平台与 UDOS 治理体系的五重映射

维度	本平台设计	UDOS 对应	映射含义
自主性分级	智能化 I0-I5（无AI→检索→模板→对话→工具代理→多智能体自主）	UDOS L0-L5 自主性等级；产业篇 SOP 闸门	教育场景限制高自主性（低龄 I0-I2），与 UDOS "自主性越高、治理成本越高"的判断一致
规则优先	内容安全/准入用确定性规则为底、学习分类器为补	证据工程 H-CSC v2：确定性词法谓词 AUROC 0.865-0.982 击败学习编码器 0.621-0.744	教育场景的安全红线（自伤/暴力/违法）必须用确定性规则拦截，不能依赖学习分类器的概率输出
最小权限	权限分级 P0-P5、RBAC+ABAC、final_assessment仅教师	TransferBundle 的 scope 最小权限字段	每次 AI 交互只授予完成任务所需的最小权限，与 UDOS "交接即契约"的最小权限原则同构
多人复核	教师可覆盖决策、教师委员会审查高风险决策、S4危机转人工	BFT-lite 三级类型化最终性；审核门禁（5人审+1红队+1版本）	高风险/高 stakes 决策需要多人复核，单一 AI 决策或单一教师决策都不够
治理天花板	生成可扩展、教师审查不扩展；AI 处理标准化，教师专注个体差异	质量饱和律（验证能力天花板：生成可扩展、审查不扩展，Little's Law/WIP=1）	平台的目標是用 AI 扩展"生成/反馈/分析"的产能，把教师从标准化工作中解放出来专注个体判断——但教师审查本身不可扩展，这是治理的硬天花板

8.2 规则优先于学习：H-CSC 证据对本平台的启示

UDOS 第06篇 H-CSC v2 的核心证据是：**确定性词法谓词 AUROC 0.865-0.982 击败学习语义编码器 0.621-0.744**（作者主动撤回 v1"诚实保留优势"主张后的正确口径）。这对本平台的内容安全设计有直接启示：

- **安全红线（S3/S4）用确定性规则：**自伤、暴力、违法、未成年人隐私等红线内容，必须用确定性规则（关键词、正则、模式匹配）拦截，不能依赖学习分类器的概率输出。确定性规则的优势是可解释、可审计、零幻觉——这正是教育场景最需要的。
- **学习分类器作为补充：**内容主题分级（C0-C4）、适龄性判断、争议内容识别等"灰度"决策，可以用学习分类器辅助，但必须给置信度，低置信度转人工。
- **学习编码器的失效边界：**学习分类器在分布外输入、对抗性提示、多语言混合场景下性能显著下降（H-CSC 证据显示学习编码器 AUROC 仅 0.621-0.744）。教育场景中学生会用各种方式尝试绕过（谐音、拆字、多语言），确定性规则的鲁棒性更高。

8.3 质量饱和律：为什么教师终评不可省略

UDOS 第07篇质量饱和律的核心判断是：**生成能力可扩展（加更多模型/更多算力），但验证/审查能力不可扩展（教师时间是硬约束）**，用 Little's Law 表达为 WIP=1 时审查吞吐有上限。

这对本平台的含义是：

- **AI 可以扩展"反馈产能"：**自动批改选择题、生成练习题、分析学情数据——这些是标准化工作，AI 可以规模化。
- **教师不可扩展"判断产能"：**学生的最终评价、个性化反馈、心理关怀、伦理判断——这些需要人类教师，AI 不能替代。
- **平台的目标不是"用 AI 替代教师"，而是"用 AI 把教师从标准化工作中解放出来"，**让教师有更多时间做 AI 做不了的事。这就是"AI 提供信息和效率，人保留判断和责任"的经济学基础。

本章小结：本平台与 UDOS 治理体系五重同构（自主性分级、规则优先、最小权限、多人复核、治理天花板）；H-CSC 证据证明安全红线用确定性规则、学习分类器为补；质量饱和律解释教师终评不可省略的经济学原因。

9 精华与糟粕：技术选型批判

一句话结论：不是所有"AI 安全工具"都适合教育场景——LiteLLM/OPA/Presidio 可直接采用，Llama Guard/NeMo Guardrails 需中文教育场景自微调，AI 生成内容检测工具（GPTZero/Turnitin/ZeroGPT）有同行评审证据证明对非英语写作者系统性误判、绝不可作为学术处分唯一依据，年龄估计 AI 有偏见与隐私争议、仅作辅助信号。

9.1 精华：适合直接采用的组件

1. LiteLLM 作为 LLM 网关层。把"用哪家模型、走哪个 key、花多少钱、挂了怎么 fallback"从业务代码剥离。教育平台可在不上传学生数据到厂商遥测的前提下自托管；成本跟踪与预算限流对学校/区域采购极有价值。局限：企业级 SSO/SCIM 为付费版；不同提供商对工具调用/流式/JSON Schema 的支持不一致（厂商口径"140+提供商/1800+模型"，引用时标注厂商口径）。

2. Presidio 做学生数据出域前的 PII 脱敏。在学生聊天/作业送外部大模型前，先识别姓名、学号、家长手机、学校名等并替换为占位符。这是 FERPA/COPPA/GDPR/个保法合规链路中性价比最高的一层。局限：对中文人名、低资源语言需自训练；脱敏不等于匿名化（链接攻击风险）；治理过渡说法（2026年向 data-privacy-stack 过渡）来自第三方，需 Microsoft 官方公告确认 [CITATION NEEDED]。

3. OPA/Rego 或 Casbin 做策略层。把"小学年级禁用开放聊天、中学生仅限白名单模型、考试期间禁止生成式AI"这类分级策略写成代码，PDP 独立部署，与 EU AI Act 高风险义务所需的"人工监督、记录留存"结构天然对齐。OPA 为 CNCF 毕业项目（2021-01-29），Casbin 支持多语言。局限：Rego 学习曲线陡峭；Casbin 的 ABAC 表达能力弱于 OPA/Rego。

4. XACML/NIST RBAC/ABAC 作为架构术语与对标。不必落地整套 XACML（XML 笨重，云原生场景多被 OPA 替代），但引用 ANSI/INCITS 359-2012（RBAC）与 NIST SP 800-162（ABAC）可把"分级访问控制"从工程口号提升到标准语言。

9.2 需要定制或二次训练的组件

5. Llama Guard 3 / NeMo Guardrails / Guardrails AI 作为内容安全护栏。Llama Guard 3 覆盖 S1-S13 共 13类安全风险（暴力犯罪、非暴力犯罪、性犯罪、儿童性剥削、诽谤、专业建议、隐私、知识产权、indiscriminate weapons、仇恨、自杀自残、性内容、选举），但分类体系是为**英语成人安全场景**设计的。中文教育敏感词（校园暴力、未成年人诱导、考试泄题、超纲内容、价值观引导）需要自微调或自写 validator。建议用 NeMo Guardrails 做编排层，把 Llama Guard 3 作为其中一个内置 risk signal，而非唯一裁判。局限：规则可被多轮对话绕过；幻觉/事实核查依赖外部打分模型。

6. 共形预测做"低置信度自动降级"。技术原理可靠（分布无关的不确定性量化，split conformal 用校准集分位数给出预测集，提供有限样本覆盖保证，参考 Angelopoulos & Bates 2021, arXiv:2107.07511），但 LLM 开放式输出没有唯一正确标签。建议先在选择题、知识点诊断、作文评分这类有明确答案集的子任务上试点，用 split conformal 给出"该 AI 回答置信度不足→转人工/转更贵模型"的兜底，而非全场景直接套。局限：依赖可交换性（exchangeability）假设，数据漂移下覆盖失效。

9.3 糟粕：有已知失效模式、不可作为唯一判定依据

7. AI 生成内容检测（GPTZero / Turnitin / ZeroGPT）——有同行评审硬证据的系统性偏见。

Liang, W., Yuksekgonul, M., Mao, Y., Wu, E., & Zou, J. (2023). "GPT detectors are biased against non-native English writers." *Patterns*, 4(7), 100779. PMID: 37521038.

实验：7款主流 GPT 检测器 × 91篇中国论坛来源的非母语 TOEFL 作文 + 88篇 Hewlett Foundation ASAP 数据集美国八年级作文。

结论：检测器对非母语的英语写作**系统性误判为 AI 生成**；对美国八年级作文准确率接近完美；简单 prompt 策略既缓解偏见也可绕过检测器。

对教育场景的含义：**AI 检测分数不得单独作为学术不端处分依据**。中文写作上的可信度更低（检测器主要训练英语）。本平台最多把检测分数作为"建议教师复核"的弱信号，且必须配合**人工判分、写作过程留痕**

(ProcessEvidence)、学生自述三重证据。第三方报道称 Turnitin 自报非母语误判率约6-9%、母语者1-4%（该数字来自 Turnitin 自身研究的二手转述，正式引用前建议核 Turnitin 官方报告 [CITATION NEEDED]）；Vanderbilt 大学 2023-08、Curtin 大学 2026-01 先后停用 Turnitin AI 检测功能（机构决定，可作治理案例引用）。

8. 面部年龄估计 / 自声明年龄门——绕过与偏见。自声明年龄可被轻易绕过（学生随便填一个成年年龄）；面部年龄估计对未成年人、不同肤色、眼镜/口罩场景存在偏见与隐私争议（ICO 2025-2026 进展文件已要求平台"超越自声明"）。教育场景若需区分 13/14/16 岁，应优先采用**政府数字身份或家长账户验证**，把 AI 年龄估计仅作为辅助信号，且不得作为唯一准入依据。

9. "开源=安全/合规"的直觉——开源不等于合规。开源组件（Presidio、NeMo Guardrails、Llama Guard）本身不等于合规；模型训练数据许可、学生数据是否进入微调、跨境传输、日志留存周期仍需在 Policy as Code 层显式声明。Llama Guard 的社区许可需遵守 Meta Llama 社区许可条款。

本章小结：技术选型分三档——直接采用（LiteLLM/OPA/Presidio）、需定制（Llama Guard中文微调/共形预测试点）、不可作为唯一依据（AI检测工具/年龄估计AI）；AI检测工具的系统性偏见有 Liang et al. 2023 同行评审硬证据，绝不可作为学术处分唯一依据。

10 失效边界、可证伪条件与预测

一句话结论：任何分级治理平台都有失效边界——私人设备绕过、第三方教育软件SDK接入、标签无绝对标准、教师负担、误判/标签偏差、家长资源差距、策略碎片化、过度封锁损害学习、认知准备度标签的伦理风险、形式合规绕过；本章给出可证伪条件和具体预测，投稿前需≥30 seed+95%CI 验证。

10.1 失效边界清单

表 11 失效边界与影响等级

#	失效模式	影响等级	说明	缓解措施
1	私人设备绕过	高	学生用个人手机/家用电脑访问未接入策略中心的 AI 产品，平台完全无法管控	学校网络层管控+家长端联动+AI素养教育（教学生"什么场景该用什么"）
2	第三方教育软件SDK接入	高	学校采购的教育软件内嵌 AI，若不接入策略中心则成为治理盲区	SDK/API 强制接入策略中心作为采购准入条件；教育大模型安全审核机制
3	标签无绝对标准	中	内容分级（C0-C4）、认知准备度（L0-L5）的标签边界是模糊的，不同标注者可能不一致	标签版本化+多人标注+一致性监控+低置信度转人工
4	教师负担增加	中	教师需要复核 AI 决策、查看过程证据、处理申诉，可能增加工作负担	AI 优先处理标准化工作（批改选择题、生成练习），教师只复核高风险/高 stakes 决策；质量饱和律
5	误判/标签偏差	中	内容分类器、认知准备度评估可能对特定群体（非母语、特殊教育需求学生）产生偏差	定期公平性审计+申诉机制+教师复核+不得用标签做排名/分流
6	家长资源差距（数字鸿沟）	中	高学历/高收入家长更能理解和使用平台的家长控制功能，低资源家庭可能无法有效监督	家长端简化设计+学校提供统一默认策略+不得把家长参与度作为学生评价依据
7	策略碎片化	中	不同学校/区域/教师制定不同策略，导致学生跨校体验不一致	区域级基准策略+学校可在基准上微调+策略版本管理+最佳实践共享
8	过度封锁损害学习	中	策略过于保守（如全学段禁用生成式AI）会剥夺学生学习AI素养的机会，与教育部政策相悖	渐进开放原则+定期效果评估+学生/教师反馈渠道
9	认知准备度标签的伦理风险	高	L0-L5 标签若被用于排名、分流、预测未来，会造成标签污名和自我实现预言	仅内部适配标签，禁止对外展示/排名/分流/预测未来 ；可申诉可重置；EU AI Act 高风险约束
10	形式合规绕过	中	学生/教师可能通过"先提交垃圾提纲再过前置任务门"等方式形式化满足流程，实质仍依赖AI	过程证据质量评估+教师抽查+AI使用声明+学术诚信教育

10.2 可证伪条件

本平台的核心设计主张可以通过以下条件证伪：

1. **"前置任务门提升学习效果"可证伪**：如果 A/B 测试显示，使用前置任务门的学生组在学习成果测试中**不优于**（或劣于）直接使用 AI 的对照组，则该机制的教育价值被证伪。[RESULT NEEDED]
2. **"十维分级优于单一年龄分级"可证伪**：如果对比实验显示，十维分级在用户满意度、学习效果、安全事件率上**不显著优于**简单的年龄分级，则十维的复杂度成本不值得。[RESULT NEEDED]
3. **"确定性规则优于学习分类器用于安全红线"可证伪**：如果在教育场景的真实数据上，学习分类器的 AUROC **显著高于**确定性规则（与 H-CSC 证据相反），则规则优先的设计需要修正。[RESULT NEEDED]
4. **"教师终评不可省略"可证伪**：如果 AI 自动评价在特定任务（如选择题批改）上与教师评价的一致性**超过**教师间一致性，则该任务可以由 AI 独立完成，不需要教师终评。[RESULT NEEDED]
5. **"渐进开放优于全开放/全禁用"可证伪**：如果长期跟踪显示，渐进开放组的 AI 素养和学业表现**不优于**全开放组，且安全事件率**不低于**全开放组，则渐进开放的收益不成立。[RESULT NEEDED]

10.3 预测

表 12 可验证预测与记分時点

#	预测	记分时点	验证方法	当前状态
P1	教育场景 AI 分级平台将在2027年前成为中国中小学信息化采购的标配（类似当前的防火墙/上网行为管理）	2027-06	教育部/省级采购目录统计	预测・待验证
P2	"小学禁止独自使用开放式生成"的政策红线将在2026-2027年被更多地区细化为可执行的技术标准	2027-06	地方教育部门文件检索	预测・待验证
P3	AI 生成内容检测工具将在2027年前被更多高校停用（继 Vanderbilt/Curtin 之后），原因是系统性偏见证据积累	2027-12	高校公告/媒体报道统计	预测・待验证
P4	中国将在2027年前出台教育领域 AI 分级的专门技术标准或行业规范（在 GB 45438 基础上延伸到教育场景）	2027-12	国家标准委/教育部标准发布	预测・待验证
P5	认知准备度标签的伦理争议将在2027年前成为公共讨论话题，推动"禁止用AI标签对学生分流"的政策出台	2028-06	媒体/政策文件检索	预测・待验证
P6	本平台的前置任务门在 A/B 测试中将显示学习效果提升（效应量 $d>0.2$ ）	试点后6个月	随机对照实验， ≥ 30 seed+95%CI	[RESULT NEEDED]

表12注：P1–P5为趋势预测，P6为实验预测。所有预测均为设计提案的推论，尚未验证。投稿前需 ≥ 30 seed+95%CI 验证实验类预测。

本章小结：十类失效边界中，私人设备绕过和第三方SDK接入是最高影响；五个可证伪条件明确了设计主张何时需要修正；六个预测（含记分时点）为后续验证提供了路线图。所有实验类预测标 [RESULT NEEDED]。

11 合规清单与落地路线

一句话结论：合规清单把法规要求转译为平台必须实现的技术动作，落地路线分五阶段（标准标签→MVP→试点学校→模型网关+教育编排→规模评估），每阶段有明确的交付物和验证标准，均为设计提案・待实施。

11.1 合规清单

表 13 法规要求→平台技术动作映射

法规要求	来源	平台技术动作	实现层
分类分级监管	生成式AI办法第3条	十维分级编码+PDP决策	③策略中心
防范未成年人过度依赖沉迷	生成式AI办法第10条	时间分级T0-T4+额度分级Q0-Q5+冷却机制	⑧额度时间
生成内容标识	生成式AI办法第12条+标识办法+GB 45438	显式标识(AI使用声明)+隐式标识(元数据/水印)+内容来源分级G0-G4	④内容安全+⑥教育编排
算法备案	生成式AI办法第17条+算法推荐规定第24条	算法备案材料准备+策略版本管理	③策略中心+⑨审计
不满14周岁监护人同意	个保法第31条+儿童规定	年龄断言+监护人同意流程+可撤销+专门规则	②身份组织
时间/权限/消费管理	未保条例	时间分级+权限分级+额度分级+课堂/考试模式	⑧+⑨
个人信息最小必要	个保法+生成式AI办法第11条	数据最小化采集+PII脱敏(Presidio)+内容哈希不存原文	②+④+⑦
投诉举报机制	生成式AI办法第15条	申诉通道+教师/家长复核+决策可查询	⑨审计合规
小学禁止独自使用开放式生成	2025教指委指南	A0-A1学生端无自由生成+TEACHER_ONLY路由	③策略中心
分类分级确定安全防护标准	2026教育部"AI+教育"行动计划	十维分级+安全分级S0-S4+教育大模型安全审核	全平台

11.2 落地路线

表 14 五阶段落地路线（设计提案·待实施）

阶段	名称	核心交付物	验证标准	预计周期
Phase 0	标准与标签	十维编码规范、内容标签体系、模型能力注册卡模板、策略DSL规范	标签一致性≥85%（多人标注）；策略文件通过语法检查	1-2月
Phase 1	MVP	身份组织+策略中心(PDP/PEP)+安全审核+额度时间+审计日志	决策延迟<200ms(p95)；安全红线拦截率100%（确定性规则）；审计日志完整率100%	2-3月
Phase 2	试点学校	1-2所试点学校（高小+初中），教师/家长控制台，学段策略矩阵落地	教师满意度≥7/10；安全事件率<1/1000请求；学生AI素养前后测提升	3-6月
Phase 3	模型网关+教育编排	LiteLLM路由+RAG教材库+苏格拉底模式+前置任务门+过程证据+AI使用声明	前置任务门完成率≥80%；过程证据完整率≥90%；教师终评覆盖率100%	3-6月
Phase 4	规模评估与监管报表	多校/区域推广；公平性审计；效果评估；家长报告；监管报表；可证伪预测验证	公平性审计无显著群体偏差；可证伪条件验证完成；监管报表按时生成	6-12月

表14注：所有周期和验证标准为设计提案·待实施 [RESULT NEEDED]。实际周期取决于学校配合度、设备条件、教师培训进度。

11.3 最小可行验证路径

如果资源有限，建议优先验证以下三个最小实验：

- 1. 前置任务门效果实验：在一所初中的两个平行班（随机分配），一个班用前置任务门+苏格拉底提示，一个班直接用AI。6周后比较写作成绩、AI依赖度、学生满意度。≥30 seed+95%CI。[RESULT NEEDED]

2. **确定性规则vs学习分类器安全红线对比**：在教育场景真实数据（含学生尝试绕过的案例）上，比较确定性规则和学习分类器的 AUROC、误报率、漏报率。验证 H-CSC 证据是否在教育场景成立。[RESULT NEEDED]
3. **学段策略矩阵的教师接受度调查**：向试点学校教师发放问卷，评估各学段策略的合理性、可操作性、负担程度。收集教师修改建议，迭代策略矩阵。[RESULT NEEDED]

本章小结：合规清单把10项法规要求映射到具体技术动作和实现层；落地路线分五阶段，每阶段有交付物和验证标准；最小可行验证路径优先验证前置任务门效果、规则vs学习分类器、教师接受度三个实验。均为设计提案·待实施。

参考文献

中国法规与政策（核至官方来源，访问日期 2026-09-21）

1. 全国人民代表大会常务委员会. 中华人民共和国个人信息保护法[Z]. 主席令第九十一号, 2021-08-20通过, 2021-11-01施行. http://www.npc.gov.cn/npc/c2/c30834/202108/t20210820_313088.html
2. 国务院. 未成年人网络保护条例[Z]. 国务院令第七六六号, 2023-10公布, 2024-01-01施行. https://www.gov.cn/zhengce/zhengceku/202310/content_6911289.htm
3. 国家网信办等七部门. 生成式人工智能服务管理暂行办法[Z]. 七部门令第十五号, 2023-07-13公布, 2023-08-15施行. https://www.cac.gov.cn/2023-07/13/c_1690898327029107.htm
4. 国家网信办等四部门. 互联网信息服务算法推荐管理规定[Z]. 四部门令第九号, 2021-12-31发布, 2022-03-01施行. https://www.gov.cn/zhengce/zhengceku/2022-01/04/content_5666429.htm
5. 国家网信办等三部门. 互联网信息服务深度合成管理规定[Z]. 三部门令第十二号, 2022-12-11发布, 2023-01-10施行. https://www.gov.cn/gongbao/content/2023/content_5741257.htm
6. 国家互联网信息办公室. 儿童个人信息网络保护规定[Z]. 网信办令第四号, 2019-08-22公布, 2019-10-01施行. https://www.gov.cn/zhengce/zhengceku/2019-08/22/content_5458118.htm
7. 国家网信办等四部门. 人工智能生成合成内容标识办法[Z]. 国信办通字〔2025〕2号, 2025-03-14发布, 2025-09-01施行. https://www.cac.gov.cn/2025-03/14/c_1743654684782215.htm
8. 国家市场监督管理总局, 国家标准化管理委员会. 网络安全技术 人工智能生成合成内容标识方法[S]. GB 45438-2025, 2025-02-28发布, 2025-09-01实施. <https://openstd.samr.gov.cn/bzgk/std/newGblInfo?hcno=F32EA2A561F1886CD8D606513512D547>
9. 教育部. 教育信息化2.0行动计划[Z]. 教技〔2018〕6号, 2018-04-13. http://www.moe.gov.cn/srcsite/A16/s3342/201804/t20180425_334188.html
10. 教育部办公厅. 关于加强中小学人工智能教育的通知[Z]. 2024-12. http://www.moe.gov.cn/jyb_xwfb/gzdt_gzdt/s5987/202412/t20241202_1165500.html（文号 [CITATION NEEDED]）
11. 教育部等九部门. 关于加快推进教育数字化的意见[Z]. 2025-04. http://www.moe.gov.cn/srcsite/A01/s7048/202504/t20250416_1187476.html
12. 教育部等五单位. "人工智能+教育"行动计划[Z]. 2026-04. <http://www.moe.gov.cn/fbh/live/2026/77927/wj/>（五单位全称与文号 [CITATION NEEDED]）
13. 教育部基础教育教学指导委员会. 中小生成式人工智能使用指南（2025年版）[Z]. 2025-05.（指导性文件，无令号）
14. 国家新闻出版署. 关于进一步严格管理 切实防止未成年人沉迷网络游戏的通知[Z]. 国新出发〔2021〕14号, 2021-08-30.（类比参考，非直接适用于AI教育）

国际制度与技术（核至官方/权威来源，访问日期 2026-09-21）

1. European Union. Regulation (EU) 2024/1689 (AI Act)[Z]. 2024-07-12 OJ发布, 2024-08-01生效. <https://digital-strategy.ec.europa.eu/en/policies/regulatory-framework-ai>
2. Federal Trade Commission. FTC Finalizes Changes to Children's Privacy Rule[EB/OL]. 2025-01-16. <https://www.ftc.gov/news-events/news/press-releases/2025/01/ftc-finalizes-changes-childrens-privacy-rule-limiting-companies-ability-monetize-kids-data>
3. ICO. Age Assurance for the Children's Code[EB/OL]. <https://ico.org.uk/about-the-ico/what-we-do/information-commissioners-opinions/age-assurance-for-the-children-s-code/>
4. UK Parliament. Online Safety Act 2023[Z]. c.50, 2023. <https://www.legislation.gov.uk/ukpga/2023/50/enacted>
5. NIST. Guide to Attribute Based Access Control (ABAC)[S]. NIST SP 800-162, 2014（2019-02-25更新）. <https://nvlpubs.nist.gov/nistpubs/specialpublications/NIST.SP.800-162.pdf>
6. INCITS. Role Based Access Control[S]. ANSI/INCITS 359-2012. <https://csrc.nist.gov/Projects/Role-Based-Access-Control>
7. OASIS. eXtensible Access Control Markup Language (XACML)[S]. <https://docs.oasis-open.org/xacml/3.0/xacml-3.0-core-spec-os-en.html>
8. CNCF. Open Policy Agent (OPA)[EB/OL]. <https://www.openpolicyagent.org>（CNCF毕业 2021-01-29）
9. Meta. Llama Guard 3[EB/OL]. <https://huggingface.co/meta-llama>（S1-S13分类）
10. NVIDIA. NeMo Guardrails[EB/OL]. <https://docs.nvidia.com/nemo/guardrails/>
11. Microsoft. Presidio[EB/OL]. <https://microsoft.github.io/presidio/>
12. BerriAI. LiteLLM[EB/OL]. <https://docs.litellm.ai>
13. Angelopoulos, A. N., & Bates, S. A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification[J]. arXiv:2107.07511, 2021.
14. Liang, W., Yuksekgonul, M., Mao, Y., Wu, E., & Zou, J. GPT detectors are biased against non-native English writers[J]. Patterns, 4(7), 100779, 2023. PMID: 37521038.

UDOS 内部引用（同卷）

1. UDOS v7.7.2 第06篇. 共识与停止：BFT-lite三级类型化最终性与规则优先（H-CSC v2 撤回口径：确定性词法谓词 AUROC 0.865–0.982 击败学习编码器 0.621–0.744）.
2. UDOS v7.7.2 第07篇. 质量多样性与仿真效度：质量饱和律（生成可扩展、审查不扩展，Little's Law/WIP=1）.
3. UDOS v7.7.2 第09篇. 交接即契约：TransferBundle 最小权限与 MCP/A2A 互操作.
4. UDOS v7.7.2 第12篇. 产业级工程架构：五层栈、SOP 闸门、EPOB.
5. UDOS v7.7.2 第13篇. 证据工程与研究方法：三级证据分级、三态台账、修订追溯.

证据台账（EVIDENCE LEDGER v777 摘要）

完整证据台账见同目录 EVIDENCE_LEDGER_v777.md。本摘要列出三态分布与关键事实纠正。

三态分布：中国法规14项——已核验10项、部分核验4项（2024中小学AI教育通知文号、2026"AI+教育"行动计划五单位全称与文号、2025九部门数字化意见文号、2025教指委指南无令号属指导性文件）、查无实据0项。国际制度7项——已核验5项、部分核验1项（FERPA DOE官方指南）、查无实据1项（澳

大利亚OSA一手条文 [CITATION NEEDED])。技术组件11项——已核验8项、部分核验3项 (Guardrails AI GitHub链接、Presidio治理过渡、star数/版本号未实时抓取)。

关键事实纠正： 1. 《互联网信息服务算法推荐管理规定》为**四部门**令第9号（网信办、工信部、公安部、市场监管总局），非七部门。 2. 《人工智能生成合成内容标识办法》为**四部门**发布（含广电总局），文号国信办通字〔2025〕2号，非单纯网信办。 3. GB 45438-2025 与《标识办法》同日（2025-09-01）生效，过渡期6个月。 4. EU AI Act 教育场景情绪识别被 Art.5(1)(f) **直接禁止**，非高风险。 5. AI检测工具对非英语写作者的系统性偏见有 Liang et al. 2023 Patterns 同行评审硬证据，非传闻。

查无实据披露： - 澳大利亚 Online Safety Act 2021 一手条文本次未检索 [CITATION NEEDED]。 - OPA/Casbin/Presidio/LiteLLM 的 GitHub star 数与最新 release 版本号本次未实时抓取，正式稿需补 [CITATION NEEDED]。 - DOE《Designing for Education with AI》(2024-07) 官方原文 PDF 链接本次未直接取得 [CITATION NEEDED]。 - Turnitin 自报误判率（非母语6–9% vs 母语1–4%）为二手转述，需核官方报告 [CITATION NEEDED]。 - GDPR Art.8 各成员国同意年龄现行值（FRA 2017 mapping 较旧），正式发表前需对照各国 DPA 官网 [CITATION NEEDED]。

本文为 UDOS 增补卷 v7.7.7 P38，独立增补卷，不并入 v7.7.2 的13篇总卷。全文不含新实验；所有设计提案标"设计提案·待实施"，额度/时长数字标"策略示例·可配置"，外部法规与工具均附官方来源与三态标注。投稿前需≥30 seed+95%CI 验证实验类预测。