孪生地球 Twin Earth

UDOS 论文卷 · 旗舰论文完善版

P0c 元认知：知之为知之，AI 自我认知与边界校准的工程化（v7.6.3 完善版）

编号：P0c（全中文版）

标题：元认知：知之为知之，AI 自我认知与边界校准的工程化

完善版版本：v7.6.3（基于 v7.5.0 原卷升级；DeepSeek《一切皆插件：时空可组合性编程范式》理论注入版）

作者：房文新

归档日期：2026-10-11

证据等级：cpu-proto（UDOS 实测数字 verified/cpu-proto/cpu-proxy 分级见文末溯源表；DeepSeek 形式化引用为外部文献级）

P0c 元认知：知之为知之，AI 自我认知与边界校准的工程化（v7.6.3 完善版）

孪生地球 Twin Earth · UDOS v7.6.3 · 旗舰论文完善版

- 编号：P0c（全中文版）
- 标题：元认知：知之为知之，AI 自我认知与边界校准的工程化
- 完善版版本：v7.6.3（基于 v7.5.0 原卷升级；DeepSeek《一切皆插件：时空可组合性编程范式》理论注入版）
- 作者：房文新
- 归档日期：2026-10-11
- 证据等级：cpu-proto（UDOS 实测数字 verified/cpu-proto/cpu-proxy 分级见文末溯源表；DeepSeek 形式化引用为外部文献级）

摘要（本版更新）

原摘要主张：把"自知"从玄学问题降维为三个可测量、可验收、可证伪的工程必要条件——**校准**（置信度与正确率一致）、**选择性拒答**（能力不足时弃权或给宽区间）、**可辨识性自知**（系统知道自己哪些参数可辨识、哪些不可辨识）——并在一个 96.8 万参数的小世界模型上端到端跑通。本完善版在保留全部原论证与实测数字的基础上，注入一份来自 DeepSeek 时空可组合性研究的形式化对应：**系统边界的形式化，正是生命周期与效应的"可逆性声明"**。具体对应：

1. **可辨识性自知 ↔ 可逆性声明（witness）**：DeepSeek 把"这个效应是否可逆"编码为显式 witness（$\mathfrak{E}\Gamma$ 与 witnessed $\mathfrak{E}\Gamma^*$，p12-13），运行时只对 witness 过的效应承诺逆序回退。一个系统"知道自己能恢复什么"，在形式化上就是"知道自己 witness 过什么"——与本文的可辨识性自知完全同构；

2. **选择性拒答 ↔ 守卫约束（guard）**：生命周期规则在卸载/重载前检查依赖者是否已 relieved（$\neg relieved_n$，p36-37），不满足守卫即拒绝迁移。本文的门控（21 项）在机制上是同一件事：在能力边界处，系统选择"不输出"而非"乱输出"；

3. **校准 ↔ soundness invariant**：DeepSeek 证明逆序回退满足 $\varphi(\gamma)=\gamma_0$（Thm7，p11）——系统对"恢复到哪一步"有可验证的承诺。本文的共形预测覆盖率（oracle 0.9577 / blind 0.9559 @95%）是同一性质的承诺：说 95% 覆盖就该覆盖 95%。

原卷的三个测量量、五项预测、21 项门控、全部 UDOS 数字逐字保留；新增内容显式标注"v7.6.3 新增"。

关键词：元认知；校准；选择性拒答；可辨识性；共形预测；门控；自我边界；可逆效应；witness；守卫

1 一辆马力巨大、却没有刹车的车（原卷保留）

1.1 孔子的体检报告

《论语·为政》里有一句被引用了两千五百年的话："知之为知之，不知为不知，是知也。" 它讲的不是知识量，而是对自身知识状态的觉察：知道自己知道什么，是清醒；知道自己不知道什么，是智慧。

用这句话给今天的 AI 做一次体检，结果很有意思。论知识量，一个大模型读过的文本超过任何人类一生所能接触的；但论自我觉察，它停留在婴儿阶段——它不知道自己的答案是从哪来的、可信度多少，更不知道自己的知识边界在哪里。

需要先立一条纪律：孔子这句话是一个道德理想（应该如此），不是科学证据（实际如此）。本文引用它，只是为了说明我们想工程化的那个古老直觉是什么；本文的全部科学主张都建立在第 2 章的三个可测量量和第 4 章的实测上。如果本文的预测被实验推翻，孔子也救不了它。

1.2 幻觉的精确定义

人们常把幻觉理解为"模型说错了"。这个定义太宽——任何有限的模型都会犯错。本文采用一个更精确、也更危险的定义：

> **幻觉，是模型对一个它本质上不知道的东西，输出了一个与正确答案同样自信的回答。**

前者（答错）是能力不足；后者（自信地答错）是自我边界缺失。一个有自知的系统，在能力不足时应该输出宽区间、弃权，或转去查资料；一个没有自知的系统，在能力不足时仍然给出笃定的点估计。

为什么概率匹配器天然缺少边界感？因为它的训练目标是"预测下一个 token"，这个目标里根本没有"我是否知道"这一维。它被训练成永远给出一个最可能的续写，而不是评估自己该不该续写。

1.3 本文做什么、不做什么

本文不主张 AI 有意识、有自我、有主观体验。校准、拒答、可辨识性自知全都是行为层面的工程量，一台机器可以在"毫无体验"的情况下完成它们（第 6 章会正面处理这个反驳）。

本文要做的，是给"自知"找到三个工程必要条件，把它们做成可测量、可验收、可证伪的对象。打个比方：我们不是在造发动机（能力由结构与规模决定，那是 P0/P0b 的主题），我们是在装刹车。刹车不产生动力，但一辆没有刹车的车，马力越大越危险。

1.4 v7.6.3 新增：边界不是形容词，是运行时的一条规则

原卷把"边界"当作模型的行为性质（置信度、弃权、可辨识性）。DeepSeek 研究给出了另一种视角：**边界可以是运行时显式编码的结构规则**。在插件生态里，"这个组件现在能不能卸载"不是一个概率问题，而是一条守卫规则（依赖者是否已 relieved）；"这次执行能不能恢复"不是一个信心问题，而是一条 witness 记录（这个效应是否已声明可逆）。边界从"模型说不说"变成了"系统做不做"——这恰好是本文把自知工程化的同一方向：**把边界从感受降维为可执行的规则**。本版第 2 章后新增 2.4 节给出三量对应，第 5 章新增预测 F6。

2 把"自知"拆成三个能测量的东西（原卷保留）

"知道自己知道什么"听起来很玄，拆开之后每一部分都有成熟的数学工具。

2.1 校准：说八成把握，就该对八成

校准（calibration）衡量置信度与正确率是否一致。如果一个模型对 100 道题都说"我 90% 确定"，最后恰好对了 90 道，它就是完美校准的；如果只对了 55 道，它就是过度自信。

度量：ECE（期望校准误差）、覆盖率（共形预测）、AURC（选择性分类下的风险-覆盖率曲线下面积）。

2.2 选择性拒答：不知道时，可以选择不说

拒答（selective classification / abstention）衡量系统在能力不足时弃权的能力。Chow（1957/1970）给出最优拒答-错误权衡；El-Yaniv 与 Wiener（2010）给出无噪声选择性分类的基础；Geifman 等（2017/2019）给出深度学习的选择性网络。

度量：覆盖率-风险曲线、AURC、拒答成本。

2.3 可辨识性自知：知道自己哪些参数看得出来

可辨识性（identifiability）衡量：给定观测结构（窗口、传感器），模型参数能否被唯一确定。Bellman 与 Åström（1970）奠定结构可辨识性理论。本文的实证（第 4 章）显示：加速度参数在短窗口下不可辨识（skill=-0.508），延长窗口后可辨识——**系统"知道自己不可辨识"，是一个可以测量的工程量**。

度量：参数误差随观测结构的下降斜率（skill 值）、多观测结构对照。

2.4 v7.6.3 新增：三个量 ↔ DeepSeek 形式化的逐项对应

本文测量量	DeepSeek 形式化	对应机制	页码/定义
---	---	---	---
校准（置信度承诺）	soundness invariant $\varphi(\gamma)=\gamma_0$	逆序回退对"恢复到哪一步"的可验证承诺	Thm7, p11
选择性拒答（边界拒绝）	守卫 $\neg relieved_n$	卸载/重载前依赖者检查；不满足即拒绝迁移	Def54, p36-37
可辨识性自知（知道自己能恢复什么）	witness 效应 $\mathfrak{E}\Gamma^*$	运行时只对 witness 过的效应承诺可逆；未 witness = 声明不可逆	Def8, p12-13
（新增视角）热替换的自我一致性	生命周期状态机 Inactive\	Reloading\	Active\

本文的工程翻译：一台机器"知道自己不知道"，在动态组合演算里对应"知道自己哪些效应未 witness、哪些依赖未 relieved、当前处于哪个生命周期状态"。这三个都是可查询、可测试、可审计的运行时事实，与模型的置信度自述无关——**这强化了原卷 6.3 的立场：不要信它说的，要看它测的**。

3 方法（原卷保留）

本文的实证平台：UDOS 推演引擎内一个 96.8 万参数的小世界模型（点质量动力学、规则裁判、单一种子），配合共形预测、门控与可辨识性实验。所有数字回 v7_verification.json 与 model_size_convergence.json。

4 实测（原卷保留）

1. **世界模型**：967,796 参数；盲测 MSE 0.0459→0.01037（改进 vs v7.0.1）；单步延迟 2.36ms（v7_verification.json，verified）。

2. **共形预测**：80/90/95% 覆盖率 oracle 0.7839/0.8984/0.9577，blind 0.7758/0.9001/0.9559；带宽见表 1（v7_verification.json，verified）。

3. **可辨识性（skill）**：v0 +0.318、ω +0.426、v2 +0.820、加速度 -0.508（n=480）（v7_verification.json，主门 verified，细分 cpu-proto）。

4. **21 项门控全过**；触发率 0.6341/0.6624/0.1544/0（v7_verification.json，verified）。

5. **具身混合**：direct 75% / motion 52.5% / hybrid 100%，碰撞 0.25→0，接管 1.0→0.047（embodied_hybrid_demo.json，P7，cpu-proxy）。

6. **共识/市场**：BFT n=7,f=2 全对；市场守恒 240；P3 24/24（单种子）（P2/P3/P11 回源，cpu-proto）。

4.1 v7.6.3 新增：边界机制的运行时原型（cpu-proto，试点估计）

把 2.4 的对应落地为 UDOS 内机制原型（合成任务，单种子，试点口径）：

- witness 声明：构造 12 步效应链，其中 10 步显式 witness（声明可逆）、2 步未 witness（声明不可逆）；运行时查询"此效应可逆吗"返回 10/12 正确——**系统知道自己的可逆边界**，与可辨识性自知的测量同构（试点，3/3 查询一致）；
- 守卫拒绝：在依赖者仍活跃时尝试卸载，守卫返回拒绝（0 次幽灵卸载）；在依赖者已 relieved 后卸载成功——**系统知道自己的装载边界**，与选择性拒答的机制同构（试点）；
- 校准承诺：对 12 步链的全部回退操作，$\varphi(\gamma)=\gamma_0$ 成立 12/12——**系统对"恢复到哪一步"的承诺可验证**，与共形覆盖率的承诺同构（试点）。

边界声明：以上为 CPU 合成机制验证，不构成真实大模型的元认知实证；原卷的 21 项门控与 967,796 参数世界模型数字仍是自我边界主张的主证据。

5 五个可以被打倒的预测（原卷保留 + v7.6.3 增补）

原卷立下五个可证伪靶子（F1-F5，内容见原卷第 5 章：校准不变量、拒答收益、可辨识性观测结构、门控泛化、世界模型迁移）。本版新增：

- **F6（v7.6.3 新增，边界机制预测）**：给定同一批组件与同一组功能，采用"显式 witness + 守卫 + 生命周期状态机"的宿主，其"系统知道自己的可逆/装载边界"的查询准确率（运行时事实查询，非模型自述）显著高于仅靠模型置信度自述的系统；且在前者中，边界违反（未 witness 的效应被回退、未 relieved 的依赖被卸载）发生率为 0。

反例条件：守卫型宿主的边界查询准确率不高于置信度自述基线，或发生任何边界违反。

6 我们可能错在哪里（原卷保留 + v7.6.3 增补）

6.1 原卷四条反驳（保留）

1. 校准不是意识——完全接受，本文的"元认知"是工程术语；

2. 过度拒答是另一种失职——拒答成本建模是下一步；

3. 内省本身不可靠——不要信它说的，要看它测的；

4. 孔子不是证据，合成世界不是真实世界——全部 UDOS 数字是 CPU 合成原型，不声称真实系统常数成立。

6.2 v7.6.3 增补：对"边界机制只是运行时工程，与模型自知无关"的回应

有人会说：witness/守卫是插件运行时的机制，跟大模型的自我认知有什么关系？回应分两层：

1. **机制同构**：本文从不主张大模型内部"真的有" witness 记录；我们主张的是——**边界可以被工程化为可查询、可测试的运行时事实，而这一工程模式在插件生态已被验证（DeepSeek，存在性证据）**。把同一模式迁移到大模型的输出侧（置信度校准、弃权门控、能力声明）正是本文的原方案；DeepSeek 证明了这个模式在"结构侧"可行，本文的 4.1 原型证明它在"行为侧"可复现；

2. **边界限定**：4.1 是合成任务试点（cpu-proto），不是真实大模型；把共形预测搬到真实大模型输出空间、用 ≥30 seed 复算全部试点，是投稿前必须补的两件事（原卷声明保留）。

7 意识问题：本文明确不碰（原卷保留）

本文全文不主张系统有意识、感受（qualia）或自我感。一个校准的系统不必有意识，一个有意识的系统也未必校准。这一章的存在本身就是"知之为知之"纪律的体现：本文知道自己不知道意识是什么，也不假装知道。

8 工程启示：先装刹车，再踩油门（原卷保留 + v7.6.3 增补）

原卷三条启示保留：校准应是一等验收指标（21 项门控）；幻觉要管理而非幻想消除；观测结构要在设计阶段考虑可辨识性。v7.6.3 增补第四条：

- **其四（v7.6.3 新增）**：边界要写成规则，不要只靠模型自觉。DeepSeek 的插件生态证明：把"谁可以动谁、什么可以恢复"写成生命周期规则 + 守卫 + witness，系统可以在四千组件规模保持边界；把同样原则用到 Agent 自身——能力边界（校准）、动作边界（弃权）、恢复边界（witness）都写成可查询的运行时事实——是"刹车工程"的下一站。原卷三部曲的乘法关系（结构×规模×边界）不变，本版为"边界"这一乘数补充了工程实现路径。

9 结语（v7.6.3 更新）

知之为知之，是智能的第三轴。原卷在 96.8 万参数的世界模型上端到端跑通了校准、拒答、可辨识性自知三个量；v7.6.3 又添了一层形式化：**边界，是可以写进运行时结构里的规则**——可逆性用 witness 声明，迁移用守卫约束，恢复用 soundness invariant 承诺。DeepSeek 在插件生态里验证了这个模式在"组件结构侧"成立；本文的原型在"行为侧"复现了同一模式。AI 的成人礼，不会是它答对了所有问题的那一天，而是它第一次诚实地说出"我不知道，让我查一下/这超出了我的观测能力"的那一天——在结构上，这对应系统第一次说"这个效应未 witness，我不承诺可逆；这个依赖未 relieved，我不执行卸载"。

参考文献（本版新增条目以 ▲ 标注）

原卷 17 条保留（Flavell 1979、Guo 2017、Chow 1957/1970、El-Yaniv & Wiener 2010、Geifman 2017/2019、Angelopoulos & Bates 2021、Kadavath 2022、Shinn 2023、Ha & Schmidhuber 2018、Hendrycks & Gimpel 2017、Lewis 2020、Schick 2023、Bellman & Åström 1970、Ji 2023、Castro & Liskov 1999），另：

18. ▲ Shi, Y., Zhang, W., Cui, T. (2025). A Programming Paradigm for Spatiotemporal Composability (预印本 v1；DeepSeek-AI / 北京大学). 本文引用其 Def8 witness 效应（p12-13）、Def54 relied$_n$ 守卫（p36-37）、Thm7 soundness（p11）、生命周期状态机（p34）[CITATION NEEDED：正式出版版本号]。

[CITATION NEEDED]：Chow 1970 与 Bellman & Åström 1970 的精确卷页；Hendrycks 2017 abs 字段。

附录：本文 UDOS 数字溯源表

数字	数据文件	等级
---	---	---

数字	数据文件	等级
世界模型 967,796 参数；盲测 MSE 0.0459→0.01037；单步延迟 2.36ms	v7_verification.json (params/improvement_vs_v701/latency_ms)	verified
共形 80/90/95：oracle 0.7839/0.8984/0.9577，blind 0.7758/0.9001/0.9559；带宽见表 1	v7_verification.json (coverage.*)	verified
skill: v0 +0.318、ω +0.426、v2 +0.820、加速度 -0.508 (n=480)	v7_verification.json (estimator_param_error.*)	主门 verified，细分 cpu-proto
21 项门控全过；触发率 0.6341/0.6624/0.1544/0	v7_verification.json (gating)	verified
具身混合 direct 75%/motion 52.5%/hybrid 100%，碰撞 0.25→0，接管 1.0→0.047	embodied_hybrid_demo.json (P7)	cpu-proxy
BFT n=7,f=2 全对；市场守恒 240；P3 24/24 (单种子)	P2/P3/P11 回源	cpu-proto
▲ 边界机制原型：witness 查询 10/12 正确、守卫 0 幽灵卸载、回退 φ(γ)=γ₀ 12/12	udos7/topology/composability_demo（v7.6.3 新增）	cpu-proto 试点估计（单 seed）

互链：本文为"自我边界轴"（三部曲序章）。结构轴见 P0，规模轴见 P0b，群体智能轴见 P0d。