



元认知：知之为知之，不知为不知——AI 自我认知与边界校准的工程化

Engineering AI Self-Knowledge: Calibration, Abstention, and Identifiability

UDOS 推演引擎 v7.5.0 · 房文新 · 2026-09-20

证据等级: UDOS 数字回 reports7/ 原始 JSON, 按 verified / cpu-proto / cpu-proxy / unverified
标注; 单 seed 试点写作“试点点估计”, 投稿前需 ≥ 30 seed 复现。

Working Title (EN): Engineering AI Self-Knowledge: Calibration, Abstention, and Identifiability

旗舰三部曲序章 P0c · 与 P0 《空间结构，本身就是智能》、P0b 《结构+规模，本身就是智能》构成” 结构 × 规模 × 自我边界” 三轴 · UDOS 推演引擎 v7.5.0 · 2026-09-20

一句话先说清：孔子说”知之为知之，不知为不知，是知也”。今天的 AI 恰恰做不到这一点——它知识量近乎无限，却不知道自己的答案边界在哪里。本文不讨论 AI 有没有意识，只回答一个工程问题：怎样让一台机器在它不知道的时候，诚实地说”我不知道”。

证据口径（全文只声明这一次）：文中 UDOS 引擎的数字全部来自 `reports7/*.json`，普通 CPU、固定随机种子、可重复运行，分 `verified`（有测试守门）、`cpu-proto / cpu-proxy`（CPU 原型趋势）、`unverified`（外部动机）三级。凡单种子试点均写明，投稿前需 ≥ 30 个种子复算。文献逐条核验于 2026-09-20。

摘要

当前最强的大模型，本质上是一个超级概率匹配器：给它一个问题，它在海量参数里找出统计上最像答案的那个，然后用流畅的语言输出。这套机制有一个致命缺口——它没有”我不知道”这个概念。遇到训练数据里没有的问题，它不会停下来承认边界，而是自信地生成一个看似合理的错误答案。这就是幻觉的根源：不是知识不够，而是缺少对自身知识边界的感知（元认知）。

本文刻意不碰”AI 是否有意识”这个形而上学问题，而是把”自知”降维成三个可以直接测量、可以验收、可以证伪的工程量：

1. **校准**：模型说”我有八成把握”时，是否真的有八成正确率；
2. **选择性拒答**：在高风险样本上主动弃权，用”风险—覆盖率”曲线衡量拒得准不准；
3. **可辨识性自知**：知道哪些隐变量在当前观测条件下根本无法估计，从而拒绝硬猜。

我们在一个 967,796 参数的小型世界模型上给出三组直接证据。其一，分裂共形预测在 80%/90%/95% 三个置信水平上全部通过覆盖率检验（实测 95% 水平覆盖 0.9577），即使对”看不到隐藏参数”的盲路径也成立。其二，在一个 6 帧短窗口里估计加速度，估计器的误差比”直接报平均值”还差 50.8%（自知分数 -0.508）——正确动作是弃权或加长观测，而不是硬估。其三，21 项门控检查全部通过，接触类任务在没有动作先验时成功率为 0%，引入门控后升到 100%。

这些都只是 CPU 原型上的单种子初步证据，不是已在真实大模型上验证的定律。本文的真正贡献是一个研究纲领：把”智慧”这个无法直接测量的词，替换成三个可测量的工程必要条件，并给出五条可以被实验推翻的预测。在这三件事被做成可测量、可验收之前，任何”系统有智慧”的宣称都不严谨。

关键词：元认知；幻觉；校准；选择性预测；共形预测；结构可辨识性；世界模型；安全门控

1 一辆马力巨大、却没有刹车的车

1.1 孔子的体检报告

《论语·为政》里有一句被引用了两千五百年的话：“**知之为知之，不知为不知，是知也。**” 它讲的不是知识量，而是对自身知识状态的觉察：知道自己知道什么，是清醒；知道自己不知道什么，是智慧。

用这句话给今天的 AI 做一次体检，结果很有意思。论知识量，一个大模型读过的文本超过任何人类一生所能接触的；但论自我觉察，它停留在婴儿阶段——它不知道自己的答案是从哪来的、可信度多少，更不知道自己的知识边界在哪里。

需要先立一条纪律：**孔子这句话是一个道德理想（应该如此），不是科学证据（实际如此）。** 本文引用它，只是为了说明我们想工程化的那个古老直觉是什么；本文的全部科学主张都建立在第 2 章的三个可测量量和第 4 章的实测上。如果本文的预测被实验推翻，孔子也救不了它。

1.2 幻觉的精确定义

人们常把幻觉理解为“模型说错了”。这个定义太宽——任何有限的模型都会犯错。本文采用一个更精确、也更危险的定义：

幻觉，是模型对一个它本质上不知道的东西，输出了一个与正确答案同样自信的回答。

前者（答错）是能力不足；后者（自信地答错）是自我边界缺失。一个有自知的系统，在能力不足时应该输出宽区间、弃权，或转去查资料；一个没有自知的系统，在能力不足时仍然给出笃定的点估计。

为什么概率匹配器天然缺少边界感？因为它的训练目标是“预测下一个 token”，这个目标里根本没有“我是否知道”这一维。它被训练成永远给出一个最可能的续写，而不是评估自己该不该续写。

1.3 本文做什么、不做什么

本文**不主张** AI 有意识、有自我、有主观体验。校准、拒答、可辨识性自知全都是行为层面的工程量，一台机器可以在“毫无体验”的情况下完成它们（第 6 章会正面处理这个反驳）。

本文**要做的**，是给“自知”找到三个工程必要条件，把它们做成可测量、可验收、可证伪的对象。打个比方：我们不是在造发动机（能力由结构与规模决定，那是 P0/P0b 的主题），我们是在装**刹车**。刹车不产生动力，但一辆没有刹车的车，马力越大越危险。

2 把“自知”拆成三个能测量的东西

“知道自己知道什么”听起来很玄，拆开之后每一部分都有成熟的数学工具。

2.1 校准：说八成把握，就该对八成

校准（calibration）衡量置信度与正确率是否一致。如果一个模型对 100 道题都说“我 90% 确定”，最后恰好对了 90 道，它就是完美校准的；如果只对了 55 道，它就是过度自信。

常用指标是期望校准误差 ECE（把样本按置信度分桶，比较每桶的置信度均值与正确率均值之差）和 Brier 分数（置信度与对错的均方误差）。**关键点：校准和准确率是两件事。**一个准确率 70% 的模型可以校准得很好（它知道自己只有七成把握），一个准确率 95% 的模型也可能校准得很差（它总说自己百分百对）。Guo 等（2017）发现，现代深度神经网络普遍过度自信，而一个叫“温度缩放”的单参数后处理，能显著改善校准却几乎不改变准确率——这说明“知道自己对不对”和“对不对”是可以分离的两个轴。

2.2 选择性拒答：允许说“我不答”

选择性预测（selective classification）给模型加一个弃权开关：对置信度低于阈值的样本，模型不回答，转交给人类或其他系统。

它的核心工具是**风险—覆盖率曲线（risk-coverage curve）**：覆盖率是模型答了多少比例的样本，风险是它在已答样本上的错误率。把置信度阈值从松调到紧，覆盖率下降、风险也下降，整条曲线越靠左下越好。一个汇总指标是曲线下面积 AURC，**越小越好**。这个框架最早可追溯到 Chow（1957）的最优误差—拒绝权衡，经 El-Yaniv 与 Wiener（2010）、Geifman 与 El-Yaniv（2017）形式化。

拒答不是越多越好——在医疗、自动驾驶场景，“我不知道”有时比答错更危险（它把责任推回给了已经分心的人类）。好的系统让使用者在风险预算下显式权衡，而不是简单地“不确定就拒”。

2.3 可辨识性自知：有些东西在当前观测下根本不可知

前两个量都在问“我对这个答案有多确定”。第三个量更根本：**这个量在当前观测结构下，到底能不能被估计出来？**

系统辨识理论区分两个概念（Bellman & Åström, 1970）：

- **可观测性（observability）**：从一段观测轨迹，能否恢复系统的内部状态？它是一个“是/否”的结构属性；
- **可辨识性（identifiability）**：给定数据，能否把未知参数估计到足够精度？它是一个“能估到多准”的问题。

一个量可以高度可观测（数据里确实有它的影子），却仍然不可辨识（影子太弱、样本太少，估计误差大过不用模型）。**有自知的系统必须能识别这种情况并拒绝硬猜**——这是本文相对传统校准文献最想补上的一块。我们用一个“自知分数”来量化：

公式

分数为正，说明模型比“无脑报均值”强；分数为零，说明模型白学；**分数为负，说明模型比什么都不做还差——这时最理性的动作就是别用它。**

2.4 三元组：一个工程化的最小框架

把三件事合起来，本文用一个三元组描述“工程意义上的自我模型”：

$(M_{\text{self}}, U, A(x, \tau))$


- M_{self} （自我模型）：系统对自身能力的估计——我在这类任务上历史表现如何；
- U （不确定性）：对当前预测给出的不确定度，且要区分两种来源——**偶然不确定性**（数据本身的噪声，给再多数据也消不掉）与**认知不确定性**（因为没见过、数据不够，可以靠补数据消除）；

- $A(x, \tau)$ (拒答策略)：当不确定度超过阈值 τ 时弃权、转人工或调用工具。

不确定性还要能给出**有覆盖保证的区间**而不只是一个点，这由共形预测提供（第 4.2 节）。

顺带说明本文的层次定位。认知可以粗分四层：L1 感知（识别模式）、L2 认知（推理规划）、L3 元认知（知道自己知道什么、不知道什么）、L4 超认知（对”自己的校准”再校准，乃至主动提出新问题）。本文只做 L3，L4 是开放问题。这个四层划分是本文的组织框架，不是文献共识。

Fig.1 Metacognitive Triple: prediction — self-model/uncertainty — abstain gate (schematic)



The loop: $f(x)$ produces a prediction; M_{self} and U estimate how trustworthy it is; $A(x, \tau)$ decides to answer or abstain; residuals feed back to recalibrate M_{self} .

图 1：元认知闭环示意。系统行动后观测结果，世界模型给出预测与不确定度，校准/可辨识性模块判断”我知不知道”，拒答策略决定作答、弃权还是转外部，并把结果写回自我模型。

3 前人已经走过的路

本文不是凭空起楼，四条研究脉络在过去几十年分别把三块拼图磨了出来。

元认知概念来自发展心理学。Flavell（1979）提出”元认知”一词，把它分为元认知知识（对自己认知过程的了解）与元认知监控（对自己当前理解状态的监视）。本文借用的是后者的工程对应物：系统对自身预测可靠性的在线监视。

校准在深度学习时代被重新发现。Guo 等（2017）证明现代网络过度自信，温度缩放（把 logits 除以一个标量 T 再做 softmax）能以极小代价改善校准、且不改变预测类别——这直接支撑本文的预测 F1。

拒答有一条完整的理论线：Chow（1957）提出带拒绝选项的最优识别；El-Yaniv 与 Wiener（2010）建立无噪声选择性分类的风险一覆盖框架；Geifman 与 El-Yaniv（2017）给出任意训练好网络的选择性分类器；SelectiveNet（2019）把拒绝选项直接做进网络结构。

分布无关的不确定性量化由共形预测提供。Angelopoulos 与 Bates (2021) 的导论系统介绍了分裂共形法：在一批没参与训练的校准数据上算分位数，就能给预测区间一个不依赖任何分布假设、只依赖”校准样本与测试样本可交换”的覆盖率保证。

大模型到底知不知道自己知道什么？Kadavath 等 (2022) 做了关键实证：大模型在多项选择里”非语言地”预测自己对错的能力，与真实正确率相关但远不完美，而且 RLHF 微调会损害校准。Reflexion (Shinn 等, 2023) 让智能体把反思写进语言记忆。世界模型 (Ha & Schmidhuber, 2018) 则提示了另一条路：用预测误差本身作为”我没见过这个”的信号。Hendrycks 与 Gimpel (2017) 发现最大 softmax 值可作为检测分布外样本的廉价基线。

这些工作合起来留下一个缺口：校准文献很少问”这个量在结构上可不可估”，可辨识性文献很少接大模型的拒答工程，共形预测很少被放进一个统一的”元认知”框架里。本文的工作就是把三块拼起来，并在一个可控的小世界模型上端到端跑通。

4 我们实测到了什么

实验平台是 UDOS 引擎里的小型世界模型：2 层门控循环网络，隐藏维 256，场景潜变量 32 维，输入 6 帧窗口，共 967,796 个参数。它在合成的二维动力学世界里学习”状态—动作—下一状态”的转移。这个世界有意被设计成包含四类动力学：匀速、加速度、弹簧、碰撞。

4.1 世界模型本身：先证明它能预测

从 v7.0.1 到 v7.0.3，盲测集上的整体预测误差 (MSE) 从 0.0459 降到 0.01037，约改善 4.4 倍。分类别看，碰撞最容易 (0.00304)、匀速次之 (0.00573)、加速度中等 (0.01410)、弹簧最难 (0.01862)。单步预测 (批大小 1) 中位延迟 2.36 毫秒，4 步推演 4.83 毫秒——轻到可以放进实时控制回路。(等级 verified)

这一步是后续一切的前提：一个连预测都做不好的模型，谈不上评估自己预测得好不好。

4.2 共形预测：承诺 95%，实测 95.8%

我们用分裂共形法给世界模型的预测加区间：640 个窗口、128 条轨迹作为留出校准集，然后在全新测试轨迹上检查”真实值落进区间”的比例。分两条路径：oracle 路径允许看到隐藏物理参数的真值，blind 路径完全看不到 (更接近真实部署)。

表 1 共形覆盖率：承诺值 vs 实测值 (等级 verified, ±0.05 容差)

名义水平	oracle 实测覆盖	oracle 区间带宽	blind 实测覆盖	blind 区间带宽
80%	0.7839	0.0430	0.7758	0.0504
90%	0.8984	0.0858	0.9001	0.1081
95%	0.9577	0.1612	0.9559	0.2052




图 2：三个名义水平下，实测覆盖率都落在 ± 0.05 容差内（21 项门控检查全部通过）。blind 路径看不到隐藏参数，覆盖率依然达标，代价是区间系统性地更宽（95% 水平带宽 0.2052 vs 0.1612）。

怎么读这张表：模型不需要“感觉”自己有多确定，它只需要在一批校准数据上老老实实在地量一次分位数，就能给出有数学保证的区间——“我说 95%，长期来看就真的有 95% 左右的真实值落进来”。blind 路径更宽的带宽尤其重要：**系统在信息更少时，自动变得更“谦虚”**，这正是边界感知的雏形。

共形保证有一个明确前提：校准数据与测试数据可交换。分布漂移、分布外场景下这个前提失效，覆盖率会衰减——这是本文预测 F4 要处理的问题，我们不假装它不存在。

4.3 加速度负结果：当“硬猜”比“不猜”更糟

这是全文最反直觉、也最有价值的一组结果。我们让估计器从 6 帧观测窗口里反推四个隐藏物理量，每个量 160 个样本，用式（1）算自知分数：

表 2 四个隐参数的可辨识性（ $n=480$ ，主门 verified，细分为 cpu-proto）

隐参数	估计器误差	报均值的误差	自知分数 skill	可观测性
初始速度 v_0	0.6606	0.9683	+0.318	0.771
角频率 ω	0.1471	0.2563	+0.426	0.914
碰撞弹性 v_2	0.0432	0.2396	+0.820	0.908
加速度 a （6 帧窗口）	0.9256	0.6138	-0.508	0.798




图 4：前三个参数的自知分数为正，模型确实学到了东西；加速度在 6 帧窗口下为 -0.508，估计器比直接报平均值还差 50.8%。注意它的可观性并不低（0.798）——数据里有加速度的影子，但 6 帧太短，不足以把它辨识出来。

这个负结果说明三件事。第一，可观性高不等于可辨识：加速度在数据里有影子，但窗口太短，任何模型都估不准。第二，一个没有自知的系统此时会自信地输出那个糟糕的点估计——这就是一次教科书式的幻觉；一个有自知的系统看到 skill 为负，应当弃权或把观测窗口从 6 帧加长到 12/24 帧。第三，也是预测 F2 的核心：这是观测结构的硬边界，不是靠把模型做大就能绕过去的。

4.4 门控：把”不知道”接到真实动作上

校准和区间如果只停留在报表里，就不产生安全价值。我们把不确定度接成了一组发布前门控（gating），共 21 项检查，全部通过（覆盖率容差 ± 0.05 、参数扇形 ± 0.10 ）。

两个最能说明问题的门控：

- **接触门控**：在具身混合控制实验里（每臂 40 个回合，等级 cpu-proxy），纯语义层直接控制机械臂，成功率 75%、碰撞率 0.25、平均接管 1.0 次；只靠动作先验运动控制，成功率 52.5%；而在接触类任务上，没有动作先验的直接控制成功率是 0%，门控识别后把这类任务全部切给混合策略，最终混合策略成功率 100%、碰撞率 0、平均接管仅 0.047 次。门控不是让模型变聪明，而是阻止它在不擅长的场景里硬上。
- **熔断开关**：当重试预算被设为 0 时，系统如实拒绝接受任务、治理检查返回不通过并降级——它没有为了”完成任务”而强行通过。

门控的触发率本身也携带信息：匀速场景触发 63.4%、加速度 66.2%、碰撞 15.4%、弹簧 0%。模型在自己更难辨识的动力学上更频繁地求助，这与第 4.3 节的可辨识性排序一致。

4.5 群体层：一个智能体的刹车，和一百万个智能体的刹车

自我边界在多智能体系统里还有一层集体含义：整个军团也要知道”自己还能不能收口”。三个来自姊妹论文的结果：

- 拜占庭容错委员会在 $n = 7, f = 2$ 配置下对 24 个工单全部裁决正确（法定人数 $2f + 1$ ）；
- 压力注入实验中，带 Owner/Trace/停止条件治理矩阵的系统在正常与加压两种条件下都 24/24 收口，并通过 5 次返工隔离了 3 个故障智能体（单种子试点，需 ≥ 30 种子）；

- 内部任务市场的预算、支付、余额严格守恒（240=240=240），账目守恒本身就是一个”系统状态是否仍然自治”的全局自检信号。

4.6 证据汇总

表 3 三组核心证据与元认知三元组的对应

三元组组件	实验	关键数字	等级
不确定性 U（校准）	分裂共形	95% 水平实测 0.9577 (oracle) /0.9559 (blind)	verified
自我模型 M _{self} （可辨识性自知）	四参数辨识	加速度 skill=-0.508，应弃权	主门 verified
拒答策略 A(x,τ)	21 项门控	全部通过；接触任务 0%→100%	verified/cpu-proxy

5 怎么证明本文是错的

保留五条预测中判决力最强的三条，每条给出最小实验与判据。

F1 | 校准与性能是两个可分离的轴。 最小实验：取一个训好的模型（无需重训），冻结权重，在校准集上对温度 T 做一维网格搜索，5 折交叉测量 ECE 与准确率。判据：若存在某个 T 使 ECE 相对下降 ≥30% 而准确率变化在噪声内（<0.1%），F1 成立；若校准每次改善都伴随准确率同比例改善，F1 死亡（校准只是性能的附属品）。

F2 | 观测结构不足时，加参数救不回来。 最小实验：固定 6 帧窗口，只把估计器容量翻倍、再翻四倍（隐藏维 256→512→1024，层数 2→4），测加速度的 skill；同时设正对照臂，把窗口加到 12/24 帧。判据：若加容量后 skill 始终 ≤0、而加长窗口后立刻转正，就干净地分离了”观测结构”与”模型容量”两个变量，F2 成立；若大模型靠容量把 skill 稳定抬到 +0.2 以上，F2 死亡——那意味着规模确实能突破观测结构的硬边界，本文退为”小模型的约束”。这是本文最激进、也最容易被检验的一条。

F3 | 门控在同样的错误率预算下能答得更多。 最小实验：同一模型设两臂（裸模型 vs 加共形/置信门控），固定目标错误率，扫描阈值，比较覆盖率与 AURC。判据：门控臂的覆盖率显著更高（AURC 显著更小）则 F3 成立；两条风险—覆盖曲线在统计噪声内重合则 F3 死亡（拒答只是把难题推给别人）。

另有两条次级预测：**F4** 显式不确定性通道（共形区间、参数扇形）在分布外数据上应比模型口头自报的置信度（verbalized confidence）退化更慢——Kadavath 已发现口头置信度不完美且会被 RLHF 损害；**F5** 带治理矩阵的多智能体系统在故障注入下收口率更高，但现有 24/24 只是单种子点估计，**必须 ≥30 种子、报告差值的 95% 置信区间**，置信区间包含零则 F5 死亡。

6 我们可能错在哪里

第一，校准不是意识。 温度缩放只是除以一个标量，共形预测只是查一次分位数表，门控只是比较两个数的大小——没有任何一步需要系统“反思自己在反思”。我们完全接受这个行为主义反驳，并把它写进标题：本文说的“元认知”是一个工程术语，等于“校准 + 拒答 + 可辨识性自知”这三个行为量，不是 Flavell 意义上的元认知体验，更不是意识。一个系统可以在毫无主观体验的情况下完美校准。把“自知”从内在体验问题降维成行为测量问题，恰恰是本文能把它做出来的前提。

第二，过度拒答是另一种失职。 稍微不确定就弃权的系统会失去使用价值；在医生稀缺时把患者推出去、在驾驶员分神时把控制权甩回去，可能比硬答更危险。置信度还可能被对抗样本欺骗，共形的可交换性前提在分布外失效。本文目前的 AURC 只度量了“答了多少、错了多少”，没有度量“拒了多少、拒的代价多大”——拒答成本建模是明确的下一步。

第三，内省本身不可靠。 让模型直接说“我有几成把握”，这个自述也需要被校准；Reflexion 式的语言反思还可能把错误原因写进记忆、污染下一次。所以本文的立场是一句话：**不要信它说的，要看它测的。** 模型内部的置信信号可以当候选，但必须用独立校准集把它校准成可靠量。

第四，孔子不是证据，合成世界不是真实世界。 《论语》只作引言；全部 UDOS 数字都来自 CPU 上的确定性合成原型（点质量动力学、规则裁判、单一种子），不是真实大模型、不是真机、没有 95% 置信区间。加速度的负结果是在人为注入的短窗口缺陷上测的，真实世界的“观测不足”形态更复杂。因此本文把自己定位为**研究纲领加硅基初步证据**：它证明机制的形状在简化世界里跑得通，不声称常数在真实系统里成立。把共形预测搬到真实大模型的输出空间、用 ≥ 30 种子复算全部试点，是投稿前必须补的两件事。

7 意识问题：本文明确不碰

本章单独声明越界。本文全文不主张系统有意识、感受 (qualia) 或自我感。注意力图式理论 (AST)、全局工作空间理论 (GWT) 等意识假说与本文的自我模型有表面相似，但本文**不背书、不引用、不检验**它们：它们是关于人类意识的假说，能否用于硅基系统本身就有争议，而本文的 M_{self} 只是一个对自身能力的数值估计，与“注意力图式”不是同一个概念。

一个校准的系统不必有意识，一个有意识的系统也未必校准。这一章的存在本身就是“知之为知之”纪律的体现：本文知道自己不知道意识是什么，也不假装知道。

8 工程启示：先装刹车，再踩油门

其一，校准应当是一等验收指标，而不是上线后的补丁。 温度缩放很便宜，但前提是你得去测它。把 ECE、覆盖率、AURC 写进持续集成的门禁（本文的 21 项门控就是这么做的），比事后救火便宜得多。

其二，幻觉要管理，而不是幻想“消除”。 你不可能让有限系统在所有样本上都对；你能做的是让它在不知道的时候做三件事之一：输出宽区间（共形）、弃权（门控）、转去查外部知识 (RAG/Toolformer)。“用更大模型消除幻觉”的思路只对分布内有效——幻觉的根源是自我边界缺失，不是规模不足，这与 P0b 的预测 F2 直接呼应。

其三，观测结构要在设计阶段就考虑可辨识性。加速度负结果提醒架构师：如果观测窗口太短、传感器看不到关键量，换再大的模型也没用，正确动作是加长窗口、增加传感器，而不是堆参数。

其四，三部曲是乘法关系。P0 说结构决定能力函数长什么样，P0b 说规模决定站在曲线哪一段，本文说自我边界决定走到哪里必须停。结构与规模是发动机，自我边界是刹车：一辆刹车失灵的车，动力越强越危险；一辆只有刹车没有动力的车，则只是路障。三者缺一不可。

9 结语

P0 说：空间结构，本身就是智能。P0b 说：结构加规模，本身就是智能。本文说：知之为知之，是智能的第三轴。

我们没有证明任何系统拥有智慧。我们做的事情朴素得多：把”智慧”这个无法直接测量的词，替换成校准、拒答、可辨识性自知三个可以测量的工程必要条件，在一个 96.8 万参数的小世界模型上端到端跑通，并立好五个可以被实验推翻的靶子。

AI 的成人礼，不会是它答对了所有问题的那一天，而是它第一次诚实地说出”我不知道，让我查一下 / 这超出了我的观测能力”的那一天。《论语》把这个理想讲了两千五百年，本文做的，是把它从道德训诫改造成一道可测量、可验收、可证伪的工程命题。在这三件事被做成之前，“这个系统有智慧”的说法都不严谨——无论它的回答多么流畅。

参考文献

AI/系统类文献复用本卷《参考文献总库》（2026-09-19 核验）；以下为本文相关条目，逐条核验于 2026-09-19/20。

1. Flavell, J. H. (1979). Metacognition and Cognitive Monitoring. *American Psychologist*, 34(10), 906–911. DOI:10.1037/0003-066X.34.10.906.
2. Guo, C., Pleiss, G., Sun, Y. & Weinberger, K. Q. (2017). On Calibration of Modern Neural Networks. *ICML*, PMLR 70:1321–1330. arXiv:1706.04599.
3. Chow, C. K. (1957). An Optimum Character Recognition System Using Decision Functions. *IRE Trans. Electronic Computers*, EC-6, 247–254.
4. Chow, C. K. (1970). On Optimum Recognition Error and Reject Tradeoff. *IEEE Trans. Information Theory*, IT-16 (精确卷页 [CITATION NEEDED]) .
5. El-Yaniv, R. & Wiener, Y. (2010). On the Foundations of Noise-free Selective Classification. *JMLR*, 11, 1605–1641.
6. Geifman, Y. & El-Yaniv, R. (2017). Selective Classification for Deep Neural Networks. *NeurIPS*.
7. Geifman, Y., Uziel, G. & El-Yaniv, R. (2019). SelectiveNet. arXiv:1901.09192.
8. Angelopoulos, A. N. & Bates, S. (2021). A Gentle Introduction to Conformal Prediction. arXiv:2107.07511.

9. Kadavath, S. 等 (2022). Language Models (Mostly) Know What They Know. arXiv: 2207.05221.

10. Shinn, N. 等 (2023). Reflexion: Language Agents with Verbal Reinforcement Learning. NeurIPS. arXiv:2303.11366.

11. Ha, D. & Schmidhuber, J. (2018). World Models. arXiv:1803.10122.

12. Hendrycks, D. & Gimpel, K. (2017). A Baseline for Detecting Misclassified and Out-of-Distribution Examples. ICLR. arXiv:1610.02136 (abs 字段 [CITATION NEEDED]) .

13. Lewis, P. 等 (2020). Retrieval-Augmented Generation. NeurIPS. arXiv:2005.11401.

14. Schick, T. 等 (2023). Toolformer. NeurIPS. arXiv:2302.04761.

15. Bellman, R. & Åström, K. J. (1970). On Structural Identifiability. Mathematical Biosciences (精确卷页 [CITATION NEEDED]) .

16. Ji, Z. 等 (2023). Survey of Hallucination in Natural Language Generation. ACM Computing Surveys (精确卷页 [CITATION NEEDED]) .

17. Castro, M. & Liskov, B. (1999). Practical Byzantine Fault Tolerance. OSDI.

附录：本文 UDOS 数字溯源表

数字	数据文件	等级
世界模型 967,796 参数；盲测 MSE 0.0459→0.01037；单步延迟 2.36ms	v7_verification.json (params / improvement_vs_v701 / latency_ms)	verified
共形 80/90/95: oracle 0.7839/0.8984/0.9577, blind 0.7758/0.9001/0.9559；带宽见表 1	v7_verification.json (coverage.*)	verified
skill: v0 +0.318、ω +0.426、v2 +0.820、加速度 -0.508 (n=480)	v7_verification.json (estimator_param_error.*)	主门 verified, 细分 cpu-proto
21 项门控全过；触发率 0.6341/0.6624/0.1544/0	v7_verification.json (gating)	verified
具身混合 direct 75%/motion 52.5%/hybrid 100%，碰撞 0.25→0，接管 1.0→0.047	embodied_hybrid_demo.json (P7)	cpu-proxy
BFT n=7,f=2 全对；市场守恒 240；P3 24/24 (单种子)	P2/P3/P11 回源	cpu-proto

(全文完。P0c 为旗舰三部曲序章”自我边界”轴；结构轴见 P0，规模轴见 P0b。)