



隐藏动力学参数的可观测性与可辨识性实证：估计器何时胜过均值基线

UDOS 推演引擎 v7.5.0 · 房文新 · 2026-09-20

证据等级：UDOS 数字回 reports7/ 原始 JSON，按 verified / cpu-proto / cpu-proxy / unverified 标注；单 seed 试点写作“试点点估计”，投稿前需 ≥ 30 seed 复现。

An Empirical Study of Observability and Identifiability of Hidden Kinematic Parameters: When Does an Estimator Beat the Mean Baseline

中文摘要

“从一段短运动轨迹反推隐藏物理参数”不是一个统一可解的问题：每个参数有自己的可观测性与可辨识性。本文在一个 96.8 万参数的小型世界模型（UDOS v7.0.3, 单 CPU、固定 seed）上，用**可辨识性技能**（ $\text{identifiability skill} = 1 - \text{MAE_est} / \text{MAE_mean}$ ，相对均值预测器的归一化误差削减）逐参数给出能力边界。在固定历史窗 $W=6$ 、 $dt=0.5$ 下，四个隐藏参数的技能分化为：碰撞对速度 v_2 为 **0.820**（高度可辨识）、弹簧角频率 ω 为 **0.426**、初速度 v_0 为 0.318；而**加速度标量 a 为 -0.508 ——估计器 MAE 0.926 反而劣于均值基线 0.614，是一个诚实的负结果**。我们进一步定位根因：三维加速度向量本身可从速度对时间的最小二乘斜率精确反演（技能=1.0），弱可辨识的只是”沿未知随机三维方向的带符号标量 a ”——方向翻转与符号反号给出同一轨迹，标量天然弱可辨识。该负结果在 $\text{hidden}=64/128/256$ 三档模型尺寸上稳定（ $-0.523/-0.514/-0.508$ ），不是模型容量伪影。本文主张：把控制论的可辨识性概念操作化为学习系统上的逐参数经验基准，并按参数诚实分级，而非笼统宣称”隐藏参数都能估计”。

关键词：可辨识性；可观测性；系统辨识；世界模型；负结果；参数估计

Abstract

“Recovering hidden physical parameters from a short motion trajectory” is not uniformly solvable: each parameter has its own observability and identifiability. On a 0.97M-parameter small world model (UDOS v7.0.3, single CPU, fixed seeds), we score each hidden parameter by an **identifiability skill** ($1 - \text{MAE_est} / \text{MAE_mean}$, the normalized error reduction over a mean predictor). With a fixed window $W=6$ and $dt=0.5$, the four hidden parameters split sharply: the collision counterpart velocity v_2 is **0.820** (highly identifiable), the spring angular frequency ω is **0.426**, the initial velocity v_0 is 0.318; whereas the **signed acceleration scalar a is -0.508 —the estimator MAE 0.926 is actually worse than the mean baseline 0.614, an honest negative result**. We localize the root cause: the 3D acceleration vector is exactly recoverable from the least-squares slope of velocity versus time (skill=1.0); what is weakly identifiable is only the signed scalar a along an unknown random 3D direction—flipping the direction and flipping (v_0, a) together yield the same trajectory, so the scalar is intrinsically weakly identifiable. The negative result is stable across model widths (hidden 64/128/256: $-0.523/-0.514/-0.508$), ruling out a capacity artifact. We argue for operationalizing control-theoretic identifiability as a per-parameter empirical benchmark on learned systems, graded honestly per parameter rather than claiming “all hidden parameters are estimable.”

Keywords: identifiability; observability; system identification; world models; negative results; parameter estimation

结构化摘要（背景/问题 → 方法 → 证据/结果 → 贡献）

- **背景与问题：**“从一段短运动轨迹反推隐藏物理参数”不是一个统一可解的问题——平均误差会掩盖”有的参数从短窗根本不可辨识、硬估只会比训练集均值更差”这一事实；在具身/推演系统中，隐藏参数估计误差会沿时间积分放大。
- **方法：**在 0.97M 参数小世界模型（UDOS v7.0.3，单 CPU、固定 seed、 $W = 6$ 、 $dt = 0.5$ ）上，用归一化指标 $\text{identifiability skill} = 1 - \text{MAE}_{\text{est}}/\text{MAE}_{\text{mean}}$ （相对均值预测器的误差削减）逐参数打分，并以三档模型尺寸（hidden 64/128/256）检验负结果是否为容量伪影；再以”三维向量可反演 vs 带符号标量”对照做根因定位。
- **证据与结果：**四参数分化为——碰撞对速度 v_2 skill **0.820**、弹簧 ω **0.426**、初速度 v_0 **0.318**；反直觉负结果：带符号加速度标量 a skill = **-0.508**（估计器 MAE 0.926 反劣于均值基线 0.614）。该负结果在三档尺寸上稳定（-0.523/-0.514/-0.508），且三维加速度向量反演 skill=1.0，根因是方向-符号不可分离，而非模型没学出来。
- **贡献：**把控制论可辨识性概念操作化为学习系统上的逐参数经验基准，并按参数诚实分级；把”负结果”作为主角卖点（而非一笔带过）。全部数字为 CPU 固定 seed 单试点点估计，未做 ≥ 30 seed，不报告 p 值/CI；外部产业数字标 unverified。

1 引言

学习型世界模型在做预测时，往往隐式地”猜”了一些它并未显式观测到的物理量：这个物体是在匀速、加速、被弹簧牵引，还是刚被撞了一下？这些隐藏参数一旦猜错，长程预测就会系统性跑偏。工程上常见的做法是训一个网络，让它从窗口里”端到端”地把这些参数估出来，然后报告一个平均误差。但平均误差会掩盖一个关键事实：**有的参数从短窗里根本不可辨识，硬估只会比”直接用训练集均值”更差。**

为什么这是个重要问题？因为在具身与推演系统里，隐藏参数估计的误差会沿时间积分放大：一个偏差 0.5 的加速度估计，在 4 步 rollout 里被二次项 $\frac{1}{2}at^2$ 放大成显著的位置漂移。如果这个估计本身是负 skill（比均值还差），那把它喂给世界模型只会比不喂更糟。因此，“哪些参数该学、哪些参数该用解析、哪些参数干脆别碰”，不是一个学术洁癖问题，而是一个直接影响下游预测误差的工程决策。

本文要回答的问题很具体：在固定的观测窗 $W=6$ 、采样间隔 $dt=0.5$ 下，四个隐藏参数——初速度幅值 v_0 、加速度幅值 a 、弹簧角频率 ω 、碰撞对速度 v_2 ——各自的可辨识性如何？估计器在什么条件下真的比”什么都不估、直接用均值”更好？我们用一个归一化指标 $\text{identifiability skill}$ 来回答：

$$\text{skill} = 1 - \frac{\text{MAE}_{\text{est}}}{\text{MAE}_{\text{mean}}},$$

其中 MAE_{mean} 是”永远预测训练集均值”的基线。skill>0 表示估计器优于均值，skill<0 表示估计器不如均值（负结果），skill=1 表示完美估计。

这个指标的好处是把”参数尺度”归一化掉： v_2 与 a 的物理量纲不同、取值范围不同，直接比 MAE 不公平；除以均值基线后，skill 变成一个可跨参数比较的”相对增益”。它也天然鼓励诚实：如果估计器没学到东西，skill 会接近 0；如果学错了，skill 会变负——而负结果正是本文的差异化贡献。

选择均值基线而非更强的基线（如最近邻、线性回归），是一个有意的保守设计。均值基线是”什么都不做”的下界参照：如果一个学习估计器连均值都打不过，它在工程上就是负资产，应该被关掉或换成解析方法。更强的基线（如对加速度做最小二乘）会把 skill 整体压低，但那是”估计器对解析方法”的比较，回答的是另一个问题。本文先回答”要不要这个学习估计器”，用均值基线最直接。

需要交代外部动机的证据等级。近年具身智能与世界模型文献大量讨论”从视觉/轨迹反推物理参数”“系统辨识可微化”，但相关外部数字多为厂商或报道口径，**未在本研究中独立核验**（标 `unverified`，仅作动机）。我们刻意把研究范围收敛到**真值已知的合成动力学**：匀速、匀加速、简谐、一维弹性碰撞四类，状态 6 维。真值已知使我们能把”估计误差”算到每个参数、每个样本，而不是只能报一个端到端预测误差。

本文的具体贡献：

1. **逐参数可辨识性基准**：在统一协议下对四个隐藏参数给出 skill、MAE、可观测性代理，包括一个**负结果**（加速度标量 a skill=-0.508）。
2. **根因定位**：区分”三维加速度向量可精确反演（skill=1.0）“与”带符号标量 a 沿未知方向弱可辨识”，把负结果归因到**方向-符号不可分离**的结构性问题，而非模型容量不足。
3. **负结果稳健性**：证明 a 的负 skill 在 hidden=64/128/256 三档模型尺寸上稳定（-0.523/-0.514/-0.508），排除”模型太小没学出来”的解释。

边界声明：全部数字来自 `CPU` 固定 `seed` 单次验证（`reports7/v7_verification.json`，`evidence_grade=verified`），为**试点点估计**；未做 ≥ 30 `seed` 重复，不报告 `p` 值/CI，相关位置保留 `[RESULT NEEDED]`。

2 相关工作

可观测性（observability）与可辨识性（identifiability）是控制论与系统辨识的经典概念 [CITATION NEEDED: identifiability system identification Ljung; observability Kalman; structural identifiability Bellman Aström]。可观测性问”从观测能否推断状态”，可辨识性问”从数据能否唯一确定参数”。经典理论多针对已知结构的线性/非线性模型，给出解析或代数判据；而学习型世界模型把这一问题推向”参数在网络隐式表征里、结构未知”的新场景 [CITATION NEEDED: identifiability deep learning; identifiable neural networks; latent parameter estimation world models]。

与本文最相关的是三条线。其一，**可微系统辨识/物理信息神经网络** [CITATION NEEDED: physics-informed neural networks; universal differential equations]，它们把物理残差写进损失，常能反演参数；但在短窗、噪声、方向未知时，参数是否唯一可辨仍需逐案分析。其二，**世界模型中的隐变量估计** [CITATION NEEDED: latent dynamics estimation; world model latent parameter inference]，多用 VAE/状态空间模型把参数压进隐变量，再报告重建误差。其三，**负结果/可复现性运动** [CITATION NEEDED: negative results machine learning; reproducibility crisis]，强调诚实报告失败案例。

我们的定位是**实证基准 + 负结果**，不主张新的辨识算法。新颖性在于：把”可辨识性”从一个理论概念，操作化为学习系统上可直接测量的 skill 指标，并诚实地保留一个负结果。这与 P5（共形可信度）互补：P5 关心”预测区间多宽”，P6 关心”区间为什么宽——哪些参数根本估不准”。

还需要区分两个常被混用的概念。**可观测性**（observability）关心的是”从一段无噪声、无限长的理想观测里，理论上能否算出这个量”——在本文里，加速度向量的可观测性是 1（状态含速度，斜率可算），而带符号标量 a 的可观测性受方向-符号歧义限制。**可辨识性**（identifiability）关心的是”在有限窗、有限采样率、有噪声的实际条件下，估计误差相对基线到底降了多少”——这正是 skill 度量的东西。本文的一个核心

观察是：高可观测性不等于高可辨识性（a 的向量形式可观测，但标量形式 skill 为负），高自评置信也不等于高可辨识性（a 自评 0.798 但 skill -0.508）。这三者之间存在一个我们要填补的空白：学习系统文献很少逐参数报告负结果，更很少把负结果归因到结构性不可辨识而非训练失败。大多数工作报告“我们的方法在 X% 参数上成功反演”，但对失败的参数一笔带过。本文反其道而行：把失败的那个参数（a）作为主角，用三档模型尺寸证明它不是训练失败，再用向量/标量对照给出结构性解释。这种“把失败当结果”的写法，在工程社区比在理论社区更需要——因为部署时踩坑的，往往正是这些被一笔带过的参数。

3 问题定义与假设

3.1 记号

状态 $s_t = [p_x, p_y, p_z, v_x, v_y, v_z] \in \mathbb{R}^6$ 。观测窗 $X = (s_{t-W+1}, \dots, s_t)$, $W = 6$, $dt = 0.5$ 。隐藏参数 $P \in \mathbb{R}^4$ ，槽序 `(v0, accel_a, spring_omega, other_v2)`：v0 初速度幅值、accel_a 加速度幅值、spring_omega 弹簧角频率、other_v2 碰撞第二质点速度。估计器 $P = f(X)$ 由 `SceneEstimator` (`scene.py`) 从窗口输出；均值基线 P 为训练集该槽位均值。

四个参数的物理来源不同，可辨识性机制也不同。v0 是匀速/加速轨迹的初速度，在匀速窗里直接等于观测速度；accel_a 是恒定加速度幅值，理论上由速度斜率给出但带方向-符号歧义；spring_omega 是简谐振动物角频率，由位置振荡的频域特性决定；other_v2 是碰撞中被撞质点的速度，从速度阶跃跳变推断。这种“参数来源不同→可观测信号不同→可辨识性不同”的对应，是本文逐参数报告的物理基础。

3.2 可证伪假设

- H1 (v2 高度可辨识)：碰撞对速度 v2 的 skill 显著为正（实测 0.820）。可证伪：skill 置信区间上界 ≤ 0 。
- H2 (ω 可辨识)：弹簧角频率 ω 的 skill 为正（实测 0.426）。可证伪：skill ≤ 0 。
- H3 (a 负结果)：加速度标量 a 在 $W=6$ 窗下 skill 为负（实测 -0.508），即估计器劣于均值。可证伪：若加长窗/提高采样率后 skill 转正，则 H3 被“窗口不足”解释而非“不可辨识”。
- H4 (向量 vs 标量)：三维加速度向量可精确反演 (skill=1.0)，弱可辨识的只是带符号标量。可证伪：若向量反演 skill 不接近 1，则根因定位错误。

4 方法与系统设计

4.1 估计器族

`udos7/scene.py` 的 `SceneEstimator` 是一个两层 MLP：把窗口展平 $[B, W \cdot 6] \rightarrow 128 \rightarrow 128$ ，输出 4 维参数 P 与 4 维可观测置信 (sigmoid)。它与 `WorldModelCore` 联合训练，参数辨识损失只在 `ACTIVE_SLOTS` 有效槽上计算 (`dynamics.py`)。

但本文的关键不是这个学习估计器，而是 `udos7/kinematics.py` 的确定性、无需训练、零未来泄漏运动学反演。它只吃观测窗 W 帧，做三件事：

1. 窗心速度 `v_c[3]`：速度均值。匀速窗下这就是速度本身；加速窗下是时间窗心处的速度。

2. **加速度向量 $a_{lin}[3]$** : 速度对时间的最小二乘斜率。因为状态本身含三维速度，恒定加速度就是速度对时间的斜率，三维向量可直接、精确反演——这是 H4 的核心。具体地，记中心化时间 $t_c = t - \bar{t}$ ，则 $a_{lin} = \Sigma t_c(v - \bar{v}) / \Sigma t_c^2$ ，这是一个闭式最小二乘，无需迭代、无需训练。
3. **弹簧 ω + 有效性**: 位置沿 PCA 主轴投影成标量 q ，对内点做带截距最小二乘 $\ddot{q} = b_1 q + b_0$ ($b_1 = -\omega^2$)，以“弹簧残差 < 常加速度残差 + ω^2 下限 + 残差门限”做模型选择，避免短窗二次轨迹被误判为简谐。模型选择的三个门限（`_OMEGA_MIN=0.45`、`_SPRING_REL_RESID=0.25`、以及弹簧残差严格小于常加速度残差）在 seed 42/1337/314/2026 上探针得到“弹簧召回 1.0、其余误报 0”。
4. **碰撞跳变 $jump$ + 有效性**: x 轴帧间速度跳变的稳健检测（中位尺度 `_JUMP_MED_K=3.0`、`_JUMP_BIAS=0.35`）。用中位绝对偏差而非均值，是为了让单个离群跳变不被自身拉高三尺度。

这套反演的纪律是“无效特征置 0 且有效性标志置 0，不编造”：非弹簧窗的 ω 置 0，非碰撞窗的 $jump$ 置 0。所有量只来自观测窗，rollout 每步用当前滑窗重测一次，无未来泄漏。

4.2 为什么标量 a 弱可辨识：方向-符号不可分离

`kinematics.py` 的文档记录了 v7.0.1 的诚实负结果：盲路径 `accel` 缺口最大，且标量 `accel_a` 的 `skill` 为负。根因不是“加速度不可辨识”，而是**表征口径错误**。

状态向量本身含三维速度，恒定加速度是速度对时间的最小二乘斜率，**三维加速度向量可从观测窗直接、精确反演**。但旧估计器被迫输出“沿未知随机三维方向 d 的带符号标量 a ”。问题在于：方向 d 是随机三维单位向量，其符号与 a 的符号不可分离——把 d 翻成 $-d$ 、同时把 (v_0, a) 反号，给出的是**同一条轨迹**。也就是说，从轨迹上看， a 与 $-a$ 不可区分（因为运动方向也反了）。这个**标量天然弱可辨识**，无论模型多大。这正是 H3 负结果的结构性根因，也是 H4“向量可辨、标量不可辨”的由来。

把这件事写清楚：匀速/加速轨迹为 $p(t) = x_0 + (v_0 \cdot d)t + \frac{1}{2}at^2$ 。若我们不知道方向 d ，只观测 $p(t)$ ，则 d 与 a 以乘积形式出现： $p(t) - x_0 = d \cdot (v_0 t + \frac{1}{2}at^2)$ 。观测本身只能确定 $d \cdot (v_0 t + \frac{1}{2}at^2)$ 这个向量；要把它拆成标量 (v_0, a) 乘方向 d ，就需要约定 d 的符号。但 $d \mapsto -d$, $(v_0, a) \mapsto (-v_0, -a)$ 是同一个观测。因此标量 a 的符号在结构上不可辨，只有 $|a|$ （结合方向后）才有物理意义。当估计器被迫输出一个带符号的 $a \in [-1.5, 1.5]$ ，它本质上在猜一个符号歧义，而均方误差惩罚会让它倾向于向 0 收缩——但这又和“用训练集均值”的基线冲突，于是 `skill` 为负。这不是模型没学好，而是问题本身的对称性。

工程上的正确解法不是“把模型做大硬猜符号”，而是**改变表征**：要么输出三维向量 $a_{lin}[3]$ （无符号歧义，`skill=1.0`），要么显式估计方向并约定符号。P5 的解析积分门控正是前者——它用 `kinematic_features` 给出的 $a_{lin}[3]$ ，从不使用标量 `accel_a`。

4.3 可观测性代理与 `skill` 计算

`SceneEstimator` 同时输出每槽位可观测置信 $\in [0, 1]$ (`observ_head`, sigmoid)。 `udos7/metrics.py` 的 `estimator_param_error` 对每个参数计算：

```
text(MAE)_(text(est))=frac(1nsum|hat P-P_(text{true})|; text(MAE)_(text(mean))=frac(1nsum|bar P-P_(text{true})|; text(skill)=1-frac(text(MAE)_(text(est)))text(MAE)_(text(mean))
```

并报告 `mean_observability`（该参数上估计器输出的平均可观测置信）。 `kinematic_recovery` 则在合成恢复测试上检验确定性反演：加速度向量对真值 MSE、弹簧 ω 召回、碰撞跳变检出率与误报率。

4.4 数据

与 P5 同一套合成动力学（`dynamics.py`），四类运动、轨迹级独立 seed 四分。测试集 640 窗/128 轨迹；`estimator_param_error` 中 v0 槽 n=480（跨所有含 v0 的类），`accel_a/spring_omega/other_v2` 各 n=160（各自类内）。硬件指纹：PyTorch 2.14.0+cpu、2 线程、Python 3.12.11。

需要说明，本文所有”估计器”指 `SceneEstimator` 的学习估计输出，而非 `kinematics.py` 的确定性反演。表 1 的 skill 是学习估计器相对均值基线的对比；表 2 的运动学恢复是确定性反演对真值的对比。两者在 `metrics.py` 里分开计算、分开报告，不混为一谈。读者若把表 1 的 a skill=-0.508 误读成”加速度完全不能反演”，请回到表 2：向量形式反演是完美的。

5 实验设置

主结果来自 `scripts7/verify_v7.py` 对 checkpoint `checkpoints7/worldmodel_v7.0.3.pt` 的重算，输出 `reports7/v7_verification.json`。为检验负结果是否为模型容量伪影，我们额外读取 `reports7/model_size_convergence.json` 中三档 hidden (64/128/256) 的 `estimator_param_error`，比较 a 的 skill 是否随容量改善。单 seed 试点点估计；[RESULT NEEDED: 每参数 skill 对 0 的单样本检验 CI、多重比较校正、窗口长度 {3,6,12,24} 扫描] 待补。

样本量需要诚实说明：v0 槽 n=480 是因为它在 uniform/accel/collision 三类里都有定义（初速度），而 `accel_a` 只在 `accel` 类、`spring_omega` 只在 `spring` 类、`other_v2` 只在 `collision` 类，各 n=160。因此 v0 的估计最稳，而三个类专属参数的样本量小了约三分之二。skill=-0.508 是在 n=160 上的点估计，其抽样波动可能不小；这正是必须补多种子与 CI 的原因。我们不把”-0.508”写成”显著为负”，只写”点估计为负、三档模型尺寸一致”。

6 结果

本章展开顺序（v2 规范）：第 5 章给出实验设置。本章按”对照 → 消融/敏感性”组织。对照：6.1 以”学习估计器 vs 训练集均值基线”为逐参数对照（skill 即该对照的归一化），6.2 以”三维向量反演 vs 带符号标量”为表征口径对照；消融：表 1 是 AlexNet 式逐组件消融表（四个隐藏参数各占一行，移除”这个参数该不该由学习估计器估”的代价即 skill 增减），6.4 以三档模型尺寸做容量敏感性消融。全部数字来自 `reports7/v7_verification.json` 与 `model_size_convergence.json`（verified，单 seed 试点）。效度威胁单独成第 8 章。

6.1 逐参数 skill：四参数分化

表 1 给出四个隐藏参数的 MAE、skill 与可观测性。图 1 为 skill 条形图，图 2 为估计器 vs 均值基线 MAE，图 3 为可观测性 vs skill 散点。

表 1 隐藏参数可辨识性（verified，v7.0.3，W=6；AlexNet 式逐参数消融表——每个参数一行，skill 即”用学习估计器替换均值基线”的误差增减，加粗为正/负两端极值）

参数	MAE(估计器)	MAE(均值)	skill	可观测性	n
v0 初速度	0.6606	0.9683	0.318	0.771	480
a 加速度标量	0.9256	0.6138	-0.508	0.798	160
ω 弹簧角频率	0.1471	0.2563	0.426	0.914	160
v2 碰撞对速度	0.0432	0.2396	0.820	0.908	160

表 1 读法（对照 AlexNet Table 1/2 的双列对照表）：skill>0 表示学习估计器优于”什么都不估、直接用均值”，skill<0 表示该参数由本估计器、在本窗口、以本表征去估是**负资产**。-0.508 是本表唯一被加粗的负向极值，与 0.820 的正向极值并列，构成”哪些参数该学、哪些该换表征/别碰”的工程判据；n 列标明 v0=480、其余三参数各 n=160（单 seed 试点，抽样波动未量化）。




图 1 四隐藏参数的可辨识性 skill（横轴 v0/a/ ω /v2，纵轴 skill=1-MAE_est/MAE_mean，零线为虚线）。柱高从 -0.508 (a) 到 0.820 (v2) 剧烈分化，负值柱向下突出——这是本文主角负结果的可视化。数据来源 `v7_verification.json: estimator_param_error.*.identifiability_skill`, verified, 单 seed, n 见表 1。

H1 成立：v2 skill=0.820，估计器 MAE 0.043 远低于均值 0.240，是四个参数中最可辨识的。直觉上这合理：碰撞在轨迹上表现为速度的阶跃跳变，跳变前后的速度差在等质量弹性碰撞下直接揭示对方速度，是窗内最锐利的信号。值得补充的是，碰撞跳变的**检出率只有 0.7437**（表 2），但**非碰撞误报为 0**——这是一个高特异度、中等敏感度的检测器：它宁可不报，也不乱报。这解释了为什么 v2 的 skill 高达 0.82：一旦跳变被检出，v2 几乎估得准（MAE 0.043）；未检出的那 25.6% 窗，估计器只能回退到先验。误报为 0 意味着这个检测器可以被安全地用作”是否发生碰撞”的闸门，而不必担心把匀速段误判成碰撞。

H2 成立： ω skill=0.426，频域最小二乘把振荡频率反得相当准（MAE 0.147 vs 均值 0.256）。弹簧 ω 的召回为 1.0、非弹簧误报为 0（表 2），说明模型选择门限有效：它不会把一段二次（加速）轨迹误判成简谐。 ω MAE 0.147 相对采样域 [0.6,1.6] 约为 15% 的相对误差，在 W=6、dt=0.5（窗长约 2.5–3.0 秒，而 $\omega \in [0.6,1.6]$ 对应周期约 3.9–10.5 秒，即窗内不足一个完整周期、约 0.24–0.76 个周期）的极短窗下已属合

理——在不足一个周期的窗内仍把 ω 反到 0.147 的 MAE，反而说明频域最小二乘在该合成干净数据上是有效的。

H3 成立（负结果）： a skill=-0.508。估计器 MAE 0.926 比均值基线 0.614 还差 50%。也就是说，在 W=6 窗下，试图从窗口反推带符号加速度标量的网络，比”干脆不猜、用训练集均值”更糟。这不是噪声导致的随机失败，而是系统性地把方向-符号混淆学错了方向。

至于 v0（初速度），skill=0.318，介于”明显可辨”与”不可辨”之间。v0 在匀速窗里就是速度本身（窗心速度 v_c 直接给出），在加速窗里则是初始速度、需要从速度斜率外推到窗前。它的可观测性代理 0.771 是四者最低，与”部分类可直接观测、部分类需外推”的混合性质一致。v0 的结果提醒我们：同一个槽位在不同运动类里的可辨识性不同，逐类报告比逐参数单一数字更精确。




图 2 学习估计器 MAE（深）与训练集均值基线 MAE（浅）逐参数并列对照（横轴 v0/a/ω/v2，纵轴 MAE）。a 柱上深柱高于浅柱（0.926>0.614）即 skill 为负；其余三参数深柱低于浅柱即 skill 为正。数据来源 `v7_verification.json: estimator_param_error.*.mae / mae_mean_predictor`，verified，单 seed。

6.2 根因：向量可辨、标量不可辨

H4 成立。表 2 给出确定性运动学恢复（不依赖训练）。加速度向量对真值 MSE=0.0（相对均值预测器 0.2182，skill=1.0）——三维加速度向量被完美反演。这与表 1 中标量 a 的 skill=-0.508 形成尖锐对照：同一个”加速度”，向量形式精确可辨，标量形式反而不可辨。

表 2 确定性运动学恢复（verified）

量	结果	对照
加速度向量 MSE vs 真值	0.0	均值预测器 0.2182, skill=1.0
弹簧 ω 召回	1.0	非弹簧误报 0.0
弹簧 ω MAE（有效窗）	0.0231	—

量	结果	对照
碰撞跳变检出率	0.7437	非碰撞误报 0.0
匀速误报	0.0 (归一化)	—

这组对照把负结果的性质讲清楚了：**问题不在”加速度信息不足”，而在”把三维向量压成带符号标量时引入了不可分离的方向-符号歧义”**。一旦下游需要的是三维加速度向量（P5 的解析积分门控正是用 `a_lin[3]` 而非标量 `a`），负结果就消失了。

还需要澄清一个可能的误解：`skill=1.0` 的加速度向量恢复，是在**合成恢复测试**上、且轨迹确实是恒定加速度的条件下测的；它不是说”任何轨迹的加速度向量都能被精确恢复”。如果轨迹是弹簧或碰撞，`ca_conf` 门会把它标记为非恒定加速度，此时 `a_lin` 就不应被解释为恒定加速度。`kinematic_recovery` 里的”匀速误报=0”正是测这一点：模型不会把匀速/弹簧/碰撞窗误报成恒定加速度。这种”什么时候能用 `a_lin`”的门控，和 `a_lin` 本身准不准，是两个独立的问题。




图 3 估计器自报可观测性代理（纵轴，0–1）vs 实际可辨识性 skill（横轴）散点。理想对齐应沿单调上升；a 点落在”自评高（0.798）、skill 负（-0.508）”的离群区，警示”置信高≠可辨识”。`v2/ω` 自评高且 skill 高、`v0` 居中。数据来源 `v7_verification.json: estimator_param_error.*.mean_observability / identifiability_skill, verified, 单 seed`。

6.3 可观测性代理 ≠ 实际 skill

图 3 揭示了一个值得警惕的失配：可观测性代理（估计器自评的置信）与实际 skill 并不单调对齐。a 的可观测性代理 0.798 不低（甚至高于 `v0` 的 0.771），但它的实际 skill 是 -0.508。也就是说，**估计器对自己最不可辨识的参数，自评置信却不低**。这是一个危险信号：如果下游盲目相信可观测性代理来决定”要不要信任参数估计”，它会在 a 上过度自信。`v2` 与 `ω` 则自评高（0.908/0.914）且实际 skill 高，自评与现实一致；a 是唯一”自评高、实际差”的离群点。[RESULT NEEDED: 可观测性代理与解析 Fisher 信息的对照验证]。

这个失配的工程后果是直接的。假设下游控制器设计了一条规则：“当可观测性代理 >0.75 时，相信参数估计并据此规划；否则回退到保守策略。”在 `v2`、`ω`、`v0` 上这条规则工作良好（它们的 skill 都为正），但在

a 上，代理 $0.798 > 0.75$ 会让控制器自信地采用一个比均值还差的加速度估计，进而在长程预测上系统性跑偏。更安全的规则是**双向门槛**：代理高且历史 skill 为正才放行；代理高但历史 skill 为负时，宁可忽略该参数、用向量形式或均值。本文的逐参数 skill 表，正是这种”历史 skill 护栏”所需的先验数据。

6.4 负结果稳健性：不是模型容量问题

表 3 显示 a 的负 skill 在三档模型尺寸上稳定。

表 3 加速度标量 skill 随模型尺寸 (verified)

hidden	参数量	a MAE(est)	a MAE(mean)	a skill
64	95,348	0.9346	0.6138	-0.523
128	271,476	0.9292	0.6138	-0.514
256	967,796	0.9256	0.6138	-0.508

随着 hidden 从 64 增到 256，a 的 skill 仅从 -0.523 缓慢改善到 -0.508，**始终为负、且改善微乎其微**。这排除了”模型太小没学出来、加大容量就能转正”的解释：如果是容量问题，skill 应随参数量明显上升；实际几乎平动。这支持 H3 的结构解释——负结果源于方向-符号不可分离，而非学习不充分。同理，v2 的 skill 在三档上为 0.809/0.813/0.820， ω 为 0.428/0.425/0.426，都稳定。

这一稳健性观察在方法学上很重要。它说明 skill 是一个**对模型容量稳健**的指标：好的参数 (v2) 在不同容量下都好，坏的参数 (a) 在不同容量下都坏。这反过来支持把 skill 当作”参数本身的性质”而非”这次训练的偶然结果”来报告。如果一个参数的 skill 随训练随机性大幅波动，那它就是”不可靠可辨”；如果它随容量三档稳定，那它就是”结构性可辨/不可辨”。本文的三档比较，正是为了把这两种情形区分开。

7 讨论

负结果为什么有价值。 如果只报告平均误差，a 的失败会被 v2 的成功稀释。逐参数 skill 把它暴露出来：在 $W=6, dt=0.5$ 下，带符号加速度标量不可辨识，这是一个可复用的工程教训——**不要在方向未知的短窗里硬估带符号标量参数，要么用向量形式，要么加长窗口/提高采样率**。H4 的”窗口加长后 skill 能否转正”是下一个关键实验 ([RESULT NEEDED: 窗口长度 {3,6,12,24} × 采样率扫描])；我们假设加长窗能让 a 的 skill 转正，因为更长的时间基线会让加速度斜率信噪比提高、且方向可从位置轨迹主轴定出。

需要强调，“skill 为负”不是”估计器坏了”。它在工程上的正确含义是：**这个参数不应该由这个估计器、在这个窗口下、以这个表征去估**。三个杠杆中的任何一个改变（换表征为向量、加长窗口、换估计器族为频域/解析）都可能让它转正。本文只断言”在当前配置下为负”，不断言”加速度永远不可辨识”。这种精确的边界陈述，比”我们成功估计了物理参数”这种笼统说法更可执行。

可观测性代理的失真。 a 的自评 0.798 与实际 skill -0.508 的背离提醒我们：学习出来的可观测性置信本身可能不可靠，尤其是在”结构上不可辨识但统计上看起来有信号”的参数上。把它当一等指标使用前，需要与解析 Fisher 信息或似然面对照 ([RESULT NEEDED])。一个实用的护栏是：**可观测性代理只能用于”筛掉明显不可观的参数”，不能用于”放行置信高的参数”**——前者保守安全，后者会在 a 这类参数上栽跟头。

8 效度威胁与局限

本章为独立的效度威胁与局限章（v2 规范第 4/6 条）。外推纪律按 Kaplan 2020 的 C 节 Caveats 写法：本仓 skill 数字只在已观测量程内成立—— $W=6$ 、 $dt=0.5$ 、无噪声合成动力学、单 seed；“加长窗后 a 的 skill 能否转正”（H3 可证伪分支）尚未执行，因此本文只断言“ $W=6$ 下为负”，不断言“加速度标量在一切窗口下不可辨”；窗口长度 {3,6,12,24} 与采样率扫描是未做的激进外推检验。

威胁有效性。(i) 内部威胁：单 seed, $n=160$ /参数, skill 的抽样波动未量化；skill=-0.508 的 CI 是否整体 <0 需多种子确认。(ii) 构造威胁：合成动力学、无噪声（当前合成数据干净）；真实传感器噪声会进一步恶化短窗辨识，负结果可能更严重而非消失。(iii) 外部威胁： $W=6$ 、 $dt=0.5$ 是特定窗口，结论只在该窗下成立。(iv) 测量威胁：可观测性代理是网络自报，非解析量，存在乐观偏差。

还有一个容易被忽略的威胁：**基线的选择本身会影响 skill 的符号**。我们用训练集均值做基线，如果训练集本身的 a 分布很窄（ $a \in [-1.5, 1.5]$ 但实际采样偏 0），均值基线会意外地强，把 skill 压低；反之如果分布很宽，均值基线弱，skill 会虚高。本文报告的 $MAE_mean=0.6138$ 是 a 槽的实测基线，它反映了训练分布的实际宽度，因此 skill=-0.508 是在这个真实基线下算的，而非人为挑选一个弱基线来让估计器好看。这一点在跨数据集比较时需要特别注意：换一个 a 分布更宽的数据集，a 的 skill 可能从负转正——这不是估计器变好了，而是基线变弱了。

9 资源闸门与适用边界

- 本文结论停在 verified（CPU 固定 seed）。窗口长度扫描、采样率扫描、噪声注入、Fisher 信息对照均待补。
- 真实视频/传感器的参数反演需真实数据（资源闸门，当前不可达）。
- 适用边界：本文方法适用于“合成/受控动力学、真值已知、需要逐参数诚实分级”的辨识任务；不用于真实医疗/金融参数估计。
- 与 P5 的关系：P5 的 blind 带宽之所以在 spring 类偏宽，正源于 ω 估计虽可辨但不完美（skill 0.426）；把可辨识性先验注入 blind 校准，是两篇合读的工程落点。

具体而言，资源闸门对 P6 结论的限制体现在三处。其一，**真实噪声**：当前合成数据无传感器噪声，加速度斜率的信噪比被高估；真实 IMU 噪声会让 a 的负 skill 更负，还是让 ω 的 skill 下降，需要噪声注入实验才能回答。其二，**窗口扫描**：H4 的可证伪完全依赖“加长窗后 a 转正”这一尚未执行的实验；在它做完之前，本文只能声称“ $W=6$ 下为负”，不能声称“加速度标量在一切窗口下不可辨”。其三，**解析对照**：可观测性代理是网络自报，与 Fisher 信息的对照能判断它是否系统性高估，这是把代理指标用于生产前的必要验证。

10 结论

在固定 $W=6$ 、 $dt=0.5$ 下，四个隐藏参数的可辨识性并不一致：碰撞对速度 v_2 （skill 0.820）与弹簧 ω （0.426）可辨识，初速度 v_0 （0.318）弱可辨，而带符号加速度标量 a（-0.508）不可辨识——估计器反劣于均值基线。我们把这一负结果根因定位到“三维加速度向量可精确反演、带符号标量沿未知方向因方向-符号不可分离而弱可辨”，并证明它在三档模型尺寸上稳定，排除了容量伪影。本文的方法论主张是：把可辨识性逐参数操作化、对负结果不遮掩，比笼统宣称“隐藏参数都能估计”更有工程价值。

后续工作有三条。第一，执行窗口长度 $\{3,6,12,24\} \times$ 采样率扫描，验证 H4（加长窗能否让 a 的 skill 转正），给出“最小可辨识窗口”曲线——这对传感器采样率设计有直接指导意义。第二，把可观测性代理与解析 Fisher 信息对照，判断自报置信何时可信、何时需要历史 skill 护栏。第三，把逐参数 skill 表作为先验，注入 P5 的 blind 校准：对 skill 为负的参数，校准器应自动加宽区间或回退均值，而非硬估。三篇合读（P5 可信度 + P6 可辨识性 + P11 结算）共同指向一个工程哲学：**诚实的系统不是什么都做，而是知道自己什么不能做**。在学习型世界模型走向具身部署的过程中，“逐参数知道自己的盲区”比“平均误差低一个点”更有长期价值——因为前者决定了系统在遇到训练分布外的参数时，是安全地回退，还是自信地犯错。

参考文献

说明：截至本次（2026-09-19），全卷《参考文献总库》尚未收录系统辨识/可观测性/Fisher 信息方向的已核验经典（总库待补检索式 `Fisher information system identifiability classic` 明示“本卷暂未列入核验”）。故本稿第 2 节相关方向一律保留 `[CITATION NEEDED]`，不凭记忆补入 Ljung、Bellman–Aström、Kalman、Raissi 等作者名/年份。以下为待核验检索式，投稿前逐条核验元数据与 DOI。

待核验文献检索式与候选方向

- 系统辨识/可辨识性： `system identification Ljung; structural identifiability Bellman Aström; observability Kalman`。
- 可辨识深度学习： `identifiable deep learning; identifiable neural networks; latent identifiability`。
- 物理信息/可微辨识： `physics-informed neural networks Raissi; universal differential equations`。
- 世界模型隐变量： `world model latent parameter estimation; latent dynamics identification`。
- 负结果： `negative results machine learning; reproducibility check failed`。

在系统辨识传统里，结构可辨识性（structural identifiability）通常用微分代数或 Fisher 信息矩阵的秩来判断 `[CITATION NEEDED: structural identifiability differential algebra; Fisher information identifiability]`。这类理论工具给出的是“无穷数据、无噪声”下的判别，与工程上“有限窗、有噪声、学习估计器”的可辨识性之间还有一段距离。本文的 skill 指标是这座距离上的一座小桥：它不替代理论判据，而是把理论上“是否可辨”翻译成“在我们的具体窗口和估计器下，实际比均值好了多少”。理想的后续工作是把 skill 与 Fisher 信息秩对照——理论上不可辨的参数，skill 应该落在 0 附近或为负；理论上可辨的，skill 应随信噪比单调上升。本文在 a 上观察到的“理论上方向-符号不可辨、skill 为负”，与这一预期一致，但严格的对照实验仍待补。

附录 A 复现命令与测试索引

```
cd release-v5.4.4/udos-engine # main, tag v7.5.0, commit 1a71270
python3 scripts7/verify_v7.py # 重算 estimator_param_error / kinematic_recovery
pytest tests7/test_v702_kinematics.py tests7/test_v703_kin_gate.py tests7/test_m3_uncertainty.py -q
```

关键源码：`udos7/kinematics.py`（确定性反演与方向-符号讨论）、`udos7/scene.py`（`SceneEstimator`）、`udos7/metrics.py`（`estimator_param_error / kinematic_recovery`）、`udos7/dynamics.py`（`ACTIVE_SLOTS`）。

附录 B 证据台账

数字	来源	等级
v2 skill 0.820	<code>estimator_param_error.other_v2.identifiability_skill</code>	verified
ω skill 0.426	<code>estimator_param_error.spring_omega</code>	verified
a skill -0.508	<code>estimator_param_error.accel_a</code>	verified (负结果保留)
加速度向量 skill 1.0	<code>kinematic_recovery.accel_vector.skill</code>	verified
a skill 三档 -0.523/-0.514/-0.508	<code>model_size_convergence.runs[*].estimator_param_error.accel_a</code>	verified
外部产业数字	—	unverified

最后提醒：本文所有结论的适用范围严格限定在”合成动力学、W=6、dt=0.5、无噪声、单 seed”这一具体实验配置内。超出这一配置的任何外推，都需要新的实验与新的证据，本文不替读者做这种外推。

补充说明：表中”三档模型尺寸”数字来自 `model_size_convergence.json` 的 `runs[*].estimator_param_error`，是同一训练协议在 `hidden=64/128/256` 上的复跑结果，故标 verified。负结果 a=-0.508 在此稿中未做任何美化或舍弃：它既在主结果表（表 1）保留，也在稳健性表（表 3）中与正参数并列展示。任何把”-0.508”改写为”约等于 0”或”待改进”的做法都会破坏本文的诚实声明。

[RESULT NEEDED]：skill 对 0 的单样本检验与 CI、多重比较校正、窗口/采样率扫描、Fisher 信息对照。

[CITATION NEEDED]：第 2 节五处候选方向。

附录 C 内审记录（投稿前五维自评，只看不改）

- 按 `doubao-academic-evaluator` 五维打分（0-10，单 seed 试点口径）：
- 1. 问题重要性：6。负结果 + 逐参数基准有差异化价值，方向-符号不可分离的根因定位是真正的贡献点。
 - 2. 技术正确性：7。向量/标量区分与源码一致；主要扣分在单 seed、无 CI、窗口扫描未做。
 - 3. 实验严谨度：5。三档模型尺寸稳健性是硬贡献；但 n=160/参数、无多种子、无显著性检验。

4. 新颖性：6。负结果诚实 + 统一 skill 指标，新颖性中等偏上。

5. 可复现性：9。脚本、checkpoint、seed、报告 JSON 齐全，CPU 可复跑。

致命缺陷检查：负结果 $a=-0.508$ 完整保留且未美化；无伪造 p 值/CI/DOI；可观测性代理失真已如实报告。

结论：负结果是本文最大卖点，投稿前必须补窗口长度扫描以验证 H4（加长窗 skill 转正），否则负结果只能停在“W=6 下”这一窄结论。

作者拟用声明

- **目标期刊/会议：**候选 L4DC / IFAC SysID / CDC workshop；期刊 Mechanical Systems and Signal Processing、IEEE T-RO。分区/IF [待核]。
- **预注册计划：**主结论” a 在 W=6 的 skill 置信区间上界是否仍 <0 ” 预注册；窗口扫描的因子设计与停止规则投稿前登记。
- **数据与代码可用性：**Apache-2.0；tag v7.5.0、commit 1a71270；报告 reports7/v7_verification.json、reports7/model_size_convergence.json。
- **AI 使用声明：**作者主导实验与结论，AI 协助结构化写作、图表与语言润色；数字经作者对照源码与报告回源，AI 未产生实验数据。