




Scaling 的"墙"是范式墙，不是物理极限：四面墙、五条破墙路径与三段式相变

The Wall of Scaling Is a Paradigm Wall, Not a Physical Limit: Four Bottlenecks, Five Breakout Paths, and a Three-Section Phase Transition

UDOS 推演引擎 v7.5.0 · 房文新 · 2026-09-20

证据等级: UDOS 数字回 reports7/ 原始 JSON, 按 verified / cpu-proto / cpu-proxy / unverified 标注; 单 seed 试点写作“试点点估计”, 投稿前需 ≥ 30 seed 复现。

Working Title (EN): The Wall of Scaling Is a Paradigm Wall, Not a Physical Limit: Four Bottlenecks, Five Breakout Paths, and a Three-Section Phase Transition

专题篇 P13 · 旗舰篇 P0b 《结构 + 规模，本身就是智能》的直接延伸 · UDOS 推演引擎 v7.5.0 · 2026-09-20

一句话先说清：当前被反复讨论的” Scaling 撞墙”，撞的不是智能的物理极限，而是**固定范式（Transformer + 稠密计算 + 互联网文本）的承载极限**。破墙不是把墙推倒，而是换一条增长曲线——**更换结构，而非停止堆叠**。

证据口径（全文只声明这一次）：UDOS 引擎自己跑出的数字全部来自 `reports7/*.json`，普通 CPU、固定随机种子、可重复运行，分三级标注：`verified`（有自动化测试守门）、`cpu-proto`（CPU 原型趋势，常数未经多种子校准）、`unverified`（外部报道/论文一方主张，只作动机）。单种子结果一律写”试点”，投稿前需 ≥ 30 个种子与 95% 置信区间。**外部文献与产业数字逐条联网核验于 2026-09-20**；凡只在新闻稿或论文自述中出现、未经独立复现的数字，均明确标注”论文报告/公司披露，未独立复核”。

摘要

“Scaling Law 撞墙了吗？”已成为 2026 年大模型领域最分裂的问题。本文不直接选边，而是先把”墙”拆成四个**可以分别测量**的维度：数据墙（高质量语料有限、合成数据熵饱和）、算力/能源墙（稠密矩阵乘法逼近热力学与电网约束）、架构墙（注意力与残差等沿用近十年的结构成为瓶颈）、收益墙（同一架构内规模每升一个数量级，边际能力增益递减）。我们论证：这四面墙有一个共同前提——**结构被冻结**。它们量到的都是”在固定范式内沿一条曲线走到头”的现象，因此是**范式墙**，不是智能的物理极限。

在姊妹篇 P0b 的三段式框架下，墙恰好对应曲线的第二段——结构相变拐点：第一段结构对、规模小，能力沿幂律增长；第二段旧结构撑不住，必须换组织方式；第三段在新曲线上继续增长直到撞上下一堵墙。破墙因此是”换曲线”而不是”在旧曲线上跑得更快”。我们把 2025–2026 年的破墙尝试归并为五条路径并给出可证伪假设：(P0) 数据效率，用采集结构而非采集预算提高有效经验，UDOS 受控试点中 Coverage-aware 主动采集在同等预算下把良率从 0.667 提到 0.854、经验密度从 7.80 提到 11.38 (+46%, `verified` 试点)；(P0) 架构重构，包括深度维度注意力 (Attention Residuals, 论文报告约 $1.25\times$ 计算效率, arXiv:2603.15031, 未独立复核)、非线性注意力扩展 (Nexusformer, arXiv:2604.19147)、线性-softmax 混合 (InclusionAI Ling 2.5)；(P1) 训练范式，从预训练 Scaling 转向思维链/测试时 Scaling 与回放式自改进 (Dream-RSI, arXiv:2609.14858, 论文报告最多省 $162\times$ Agent 调用)；(P1) 系统级 Scaling 与 Agent 治理 (UDOS P1/P2/P9/P10/P11)；(P2) 硬件范式，以华为” τ 定律”为代表的时间缩微路线 (何庭波等, ChinaXiv, 2026-05)。

我们同时做了一项必要的事实核查：流传甚广的”GPT-4 到 GPT-5 算力增加约 10 倍”缺乏公开证据；第三方 Epoch AI 口径的估计约为 2–3 倍 (GPT-5 总训练算力约 $5e25$ FLOP 对 GPT-4 约 $2e25$ FLOP, `unverified`)，且”舰队 GPU 总数”与”单次训练算力”常被混为一谈。本文不采用 10 倍这一数字。最后给出五条可杀死本文结论的预测与四条反方意见。

关键词：scaling law；数据墙；架构墙；相变；注意力残差；test-time scaling；RSI；证据分级；可证伪预测

结构化摘要（背景问题 → 方法 → 证据结果 → 贡献）

- **背景问题：**同架构下边际收益递减被解读为”Scaling 已死”，但该结论把”固定范式的极限”误当成”智能的极限”。
- **方法：**把墙操作化为四个可测维度；用 P0b 的三段式曲线（幂律→相变→饱和/负收益）统一解释；把破墙尝试归并为五条路径，每条路径预注册一个可证伪假设；对外部数字做逐条核验。
- **证据结果：**UDOS 自有证据为受控 CPU 试点（良率 0.667→0.854、密度 +46%、错结构下 8 Agent 吞吐仅 0.695×、等权差专家误差差约 23 倍）；外部证据按”已核验存在/论文报告未复核/查无实据”三档分列。
- **贡献：**(1) 范式墙的四维操作定义；(2) 五路径优先级与判据；(3) “墙=相变点”的可检验表述；(4) 对 10× 算力说法的公开更正。

1 引言：墙这个比喻，需要先被测量

2020 年 Kaplan 等人的 Scaling Laws 给出了一个极其好用的工程信念：只要同时放大参数 N 、数据 D 与算力 C ，损失就沿可预测的幂律下降 [CITATION NEEDED: Kaplan 2020, arXiv:2001.08361, 版本卷参考文献总库]。Chinchilla 随后补上了”数据与参数要等比”的约束 [CITATION NEEDED: Hoffmann et al. 2022, arXiv:2203.15556]。到 2024–2026 年，三个现象让”撞墙”成为流行叙事：高质量互联网文本趋近采空、前沿模型训练的电力与集群规模逼近现实约束、同代架构之间代际差距收窄。

比喻不能替代测量。”墙”这个词如果要进入工程讨论，必须回答三件事：墙在哪个变量上、墙的高度怎么量、墙的另一边是什么。本文的立场是：

四面墙量到的都是同一件事——在结构被冻结时，沿单一规模轴的边际收益递减。它们是范式墙（paradigm wall），不是物理极限墙（physical wall）。

这一立场直接继承 P0b 的中心公式：

$$\text{能力} \approx F(S; N, D, C), \quad S = (T, G, M)$$

其中 S 是结构三元组（连接拓扑 T 、几何/空间组织 G 、模块边界 M ）， N, D, C 分别是节点/参数、数据/经验、算力/能量。固定 S 只放大 N, D, C ，系统沿一条既定曲线移动；改变 S ，则换到另一条曲线。本文讨论的所有”破墙路径”，本质上都是在回答”换哪一个结构变量”。

1.1 本文不主张什么

为避免被读成又一篇”Scaling 万岁”的辩护词，先划三条边界：

1. 本文不否认墙的真实性。数据、能源、架构、收益四类约束都有可观测证据，否认它们等于否认工程现实。
2. 本文不预测墙后是无限增长。换结构只把墙推后，新结构会撞上下一堵墙；三段式曲线是开放的、可反复出现的，不是通向奇点的单行道。

3. 本文不把外部厂商的效率倍数当作已证实事实。凡未经独立复现的 $1.25\times$ 、 $162\times$ 、 $3.2\times$ 等，一律标” 论文报告/公司披露”。

2 相关工作与脉络

Scaling 与数据约束。 Kaplan 式幂律与 Chinchilla 的计算最优配比构成”旧约” [CITATION NEEDED]。此后两条线索与本文直接相关：一是数据侧，重复数据、合成数据的”模型崩塌 (model collapse)” “研究指出自噬式数据存在熵饱和 [CITATION NEEDED: Shumailov et al., Nature 2024]；二是架构侧，稀疏化 (Switch Transformer, arXiv:2101.03961) 证明”总参数大、激活参数小”可行 [CITATION NEEDED]。

结构先验即性能。 BPE (arXiv:1508.07909) 与 SentencePiece (arXiv:1808.06226) 是输入结构先验；注意力 (arXiv:1706.03762) 是序列结构先验；MoE 路由是容量结构先验。2026 年的一批工作开始直接重写这些先验：Attention Residuals 重写深度维度的残差聚合 (arXiv:2603.15031, 已核验存在)；Nexusformer 用非线性 Nexus-Rank 替换线性 Q/K/V 投影 (arXiv:2604.19147, 已核验存在)；JTok 提出 token-indexed parameters 作为与 FLOPs 解耦的正交 Scaling 轴 (arXiv:2602.00800, 已核验存在)；SCONE 给出嵌入层/n-gram 扩展策略 (arXiv:2502.01637, 已核验存在)。

测试时与自改进 Scaling。 Chain-of-Thought (arXiv:2201.11903) 开启推理链激发 [CITATION NEEDED]；2026 年的 Dream-RSI 把”发现树回放”当作零成本模拟器来改进探索策略 (arXiv:2609.14858, 已核验存在, 准确标题为 Recursive Self-Improvement through Evolving Worlds)。RSI 谱系与七大厂商路线是姊妹篇 P14 的主题，本文只在路径三中引用其结论。

硬件时间缩微。 华为 2026-05-25 在 IEEE ISCAS 提出” τ 定律”，何庭波署名论文《A Time Scaling Theory for Multi-Layer Electronic Systems》提交 ChinaXiv，主张以系统级时间常数 τ 的缩微替代几何缩微，披露 2020-05 至 2026-05 设计量产 381 款芯片，预测 2031 年高端芯片晶体管密度 ($155\rightarrow 400+$ MT/mm²) 达到 1.4nm 制程同等水平 (公司/会议披露, 已核验多源报道, 具体预测值属 unverified)。

3 四面墙：把比喻拆成四个可测量

图1 Scaling 的四面墙：四个可分别测量的约束维度（概念示意，非实测）




图1 四面墙不是四堵独立的墙，而是同一面”范式墙”的四个投影。以下逐一测量口径。

3.1 数据墙：有效 token 不是总 token

数据墙的严格表述不是”互联网文本有限”，而是去重、去污染、去低质后的有效 token 流 $D_{\text{eff}}(t)$ 的增长率有限：

$$D_{\text{eff}} = \sum_i \mathbb{1}[\text{novel}_i] \cdot q_i, \quad q_i \in [0,1]$$

其中 novel_i 表示第 i 份数据相对既有数据池是否带来新的状态覆盖， q_i 是质量分。当新增数据主要是旧场景的复刻时， $\text{novel}_i \rightarrow 0$ ，总小时数上涨而 D_{eff} 不涨。合成数据在此之上叠加熵饱和和风险：用模型输出再训练模型，分布方差逐代收缩。数据墙因此首先是一个采集结构问题，而不是采集预算问题——这正是路径一的切入口。

3.2 算力/能源墙：线性降损失需要指数级能量

在幂律损失 $L(C) \approx L_{\infty} + (C/C_0)^{-\alpha}$ 下，把损失再压低一个固定量 ΔL 所需算力按 $1/\Delta L^{1/\alpha}$ 量级增长；而数据中心的供电、散热与电网接入是线性资源。墙的高度可用”单位能力增量的边际焦耳数” $dE/d(\text{capability})$ 测量。这堵墙是真实的物理约束，但它约束的是稠密全激活计算这一特定结构；稀疏激活、测试时按需计算、专用硬件都在改变 $dE/d(\text{capability})$ 曲线本身。

3.3 架构墙：十年标准成为增长语法的瓶颈

架构墙指：被默认为”中性底座”的连接方式——软max 自注意力的二次复杂度、残差连接对各层的无差别累加、稠密 FFN——在深度/序列长度增大时引入结构性折扣。Attention Residuals 一文把后者表述为”PreNorm 稀释”：隐状态量级随深度线性增长，第 5 层的有用表示到第 50 层被其余 45 层稀释 (arXiv: 2603.15031 摘要与二手解读，已核验论文存在；机制描述据其摘要)。架构墙最容易被忽视，因为它伪装成”算力不够”。

3.4 收益墙：同架构边际增益递减

收益墙是前三面墙在能力轴上的汇总表现：固定 S 时， $\partial \text{capability} / \partial \log N$ 随 $\log N$ 单调下降。P0b 在 CPU 原型上给过一个尖锐的微型例证：CPU 密集任务上并发 Agent 从 $1 \rightarrow 2$ 吞吐 $1.594\times$ ， $2 \rightarrow 8$ 不升反降到 $0.695\times$ （reports7，单 seed 试点）；而 I/O 密集任务同区间近似线性 $7.99\times$ 。规模轴完全相同，收益符号由结构匹配与否决定——收益墙是结构墙的影子。

4 五条破墙路径：动作、证据与可证伪假设




图2 墙对应三段式曲线的相变拐点。破墙=让系统跳到新曲线，而非在旧曲线上继续右移。

4.1 路径一（P0）：数据效率——改采集结构，而不是加采集预算

动作：把数据采集从被动记录升级为 Coverage-aware 的主动扫描——先对既有数据池做分布诊断，锁定状态覆盖盲区（长尾物体、柔性操作、复杂受力），再定向调度补采；同时用自动质检剔除无效片段。

UDOS 受控证据（verified 试点，reports7，48 episode / 144 分钟，oracle 226 单元）：




图3 同等采集预算下，被动采集良率 0.667、经验密度 7.80 单元/小时；主动盲区扫描良率 0.854、密度 11.38 (+46%)；同偏态池贪心消融对照为 0.7917/0.889，说明增益来自”盲区定向”而非”更努力采集”。单 seed 试点，投稿前需 ≥ 30 seed。

外部同方向工作 (unverified, 论文报告)：JTok 的 token-indexed parameters 声称在不扩展主干 FLOPs 的前提下增加容量 (arXiv:2602.00800, 已核验论文存在；“节省约 1/3 算力”的具体数字未在本次核验中从原文证实，标 [RESULT NEEDED])；SCONE 的 n-gram 嵌入扩展提供了另一条嵌入层 Scaling 轴 (arXiv:2502.01637)。

可证伪假设 H1：固定采集预算，主动扫描相对被动采集的良率提升 $\Delta Y > 0$ 在 ≥ 30 个独立场景种子、95% 置信下显著；若多场景复现中 ΔY 的置信区间跨 0，路径一的核心主张被推翻。

4.2 路径二 (P0)：架构重构——更换增长的语法

动作与证据 (均为外部论文报告，未独立复核)：

方向	工作	报告的核心突破	核验状态 (2026-09-20)
深度维度注意力	Attention Residuals (Kimi/Moonshot)	用对历史层输出的 softmax 注意力替换固定残差累加；Block AttnRes 把复杂度从 $O(Ld)$ 降到 $O(Nd)$ ；论文报告 1.4T token 预训练约 $1.25\times$ 计算效率、推理延迟增加 $<2\%$ (48B 总参/3B 激活的 Kimi Linear)	arXiv:2603.15031 已核验存在；倍数为论文报告
非线性注意力扩展	Nexusformer	Nexus-Rank 三阶段非线性映射；零初始化块支持无损结构化增长；报告以最多约 41% (参数量/算力口径) 匹配 Tokenformer 困惑度	arXiv:2604.19147 已核验存在；具体百分比为论文报告
线性-softmax 混合	InclusionAI Ling 2.5 (1T, 2026-02)	Lightning Attention 循环线性通路 + DeepSeek 式 MLA，降长程 KV 缓存	二手综述 (Raschka 等) 多源一致，未读原文报告
线性注意力 (“SeedFold”)	材料中称字节 SeedFold, 立方 $\rightarrow$ 二次复杂度	—	本次检索未找到对应论文/产品，标查无实据 [CITATION NEEDED], 本文不采信

UDOS 侧的同构证据是 P0b 的”23 倍 vs 0.5% “：把一个不合格专家等权集成，MSE 从校准加权的 0.0092 涨到 0.2131 (约 23 倍恶化)，而单纯增加合格成员数量误差几乎不动 (reports7, $k \leq 2$ verified)。改连接/加权结构的杠杆，远大于加节点数量。

可证伪假设 H2：在同一数据、同一训练算力预算下，新结构相对旧结构的单位算力困惑度/任务收益优势，应能被第三方在 $\geq 1B$ 参数规模独立复现；若只有原作者团队能复现，或优势在换一个数据域后消失，则”换结构换曲线”在该方向上不成立。

4.3 路径三（P1）：训练范式——从预训练 Scaling 到思维链/测试时 Scaling

预训练 Scaling 是”见过更多”，测试时与回放式 Scaling 是”推演更深”：1 条真实经验经世界模型回放生成 1000 次虚拟模拟、上万条内部思维轨迹。Dream-RSI（Google/DeepMind 等，arXiv:2609.14858，2026-09-14 提交）的关键机制是把已完成的发现树当作”已实现搜索空间上的回放模拟器”，在树上离线评估并改进探索策略，底层编码 Agent 保持不变；论文报告相对 SimpleTES 最多省 $162 \times$ Agent 调用、相对固定探索基线约 $1.7 \times$ ，并观察到人类引导反而更差（以上倍数均为论文报告，未独立复核；且作者与第三方都强调它不是模型自改权重的完整 RSI）。

可证伪假设 H3：回放式策略改进的收益应随发现树规模单调不减，且迁移到新任务族时不出现显著负迁移；若”做梦”只在原任务上有效，它属于任务内缓存，不是新 Scaling 轴。

4.4 路径四（P1）：系统级 Scaling 与 Agent 治理——从单模型到组织

当单点模型的曲线趋平，把多个 Agent 组织成系统会打开一条新的规模轴，但这条轴同样服从”结构决定形状”。UDOS 六篇专题的受控结果（数字均回 reports7，属性/契约/单元测试守门为 verified，外推为 cpu-proto）：

- **拓扑（P1）**：百万节点下星型中心需处理约 2097 万条消息、关键路径约 839 万轮；分层混合拓扑中心负载恒为 9、轮次仅 14——增长指数从 1 变成 0。
- **停止决策（P2）**：BFT-lite 委员会 $n \geq 3f + 1$ 、法定人数 $2f + 1$ ， $n = 7, f = 2$ 下对 24 个工单 24/24 验收正确；10 项属性测试 verified。
- **质量饱和（P9）**： $mse(k) = a + b/k$ ，同质化扩招越过真实独立源数后红利归零（ $k \leq 2$ verified， $k > 2$ cpu-proto）。
- **交接契约（P10）**：TransferBundle 六字段（Goal/Context/Done/ToDo/Trace/Owner）机械校验，26 项契约测试 verified；失败率字段为 [RESULT NEEDED]。
- **结算守恒（P11）**： $balance_sum = paid - slashed$ 由代码结构保证，混合任务预算 24/已付 16/罚没 1 守恒为真，10 项单元测试 verified。

可证伪假设 H4：治理机制（唯一 Owner、Trace、显式停止条件、守恒不变量）带来的收口率提升，应在 Agent 数 $10^1 \rightarrow 10^4$ 的压测中保持；若越过某个规模阈值后 Trace 断裂率失控上升，则系统级 Scaling 同样存在自己的墙，且本文给出的机制不够用。

4.5 路径五（P2）：硬件与能源范式——绕过几何缩微墙

华为” τ 定律”主张不再把性能增长全部押在晶体管几何尺寸上，而以器件-电路-芯片-软件全栈协同压缩信号传播的时间常数 τ （逻辑折叠、关键路径缩短、寄生 RC 下降）；其论文与发布会披露 6 年 381 款芯片、2031 年密度等效 1.4nm（ $155 \rightarrow 400+ \text{ MT/mm}^2$ ）。这是典型的”换结构换曲线”思路，但所有 2031 年数字都是预测目标而非实测，本文列为 unverified。架构层面与之配套的是异构混合：Transformer 负责逻辑推理、线性注意力/Mamba 类负责长时序、世界模型负责物理状态推演。

可证伪假设 H5：时间缩微路线应在不依赖最先进光刻节点的前提下，在公开基准（如每瓦 token 吞吐）上持续兑现代际提升；若 2027–2028 的量产芯片无法复现预测曲线， τ 路线被证伪为工程叙事。

4.6 五条路径的优先级

优先级	路径	核心动作	证据成熟度
P0	架构重构	更换底层连接方式	外部论文报告活跃，UDOS 侧有结构杠杆微型验证
P0	数据效率	改采集结构	UDOS 有受控试点（单 seed），外部有同方向论文
P1	训练范式	测试时/回放 Scaling	外部论文报告，机制清晰、倍数待复核
P1	Agent 治理	拓扑+委员会+契约+守恒	UDOS 多项 verified 测试，规模外推待做
P2	硬件范式	时间缩微+异构混合	厂商路线图与预测，兑现周期最长

优先级的排序原则是杠杆/证据成熟度之比，不是技术酷炫程度。

5 一项必要的事实核查：“GPT-4→GPT-5 算力 10 倍”不成立




图4 公开估计与传言的对比。第三方 Epoch AI 口径（经 TensorFeed 2026-05 汇编）估计 GPT-5 总训练算力约 5e25 FLOP、GPT-4 约 2e25 FLOP，约 2.5 倍；且 GPT-4.5 据同一口径可能高于 GPT-5。以上均为 unverified 第三方估计。

“算力约增 10 倍但性能不成比例”是四面墙叙事中被引用最多的数字之一。本次核验（2026-09-20）未找到支持 10 倍的公开口径，反而发现三类常见口径混淆：

1. 舰队规模 ≠ 单次训练算力。“OpenAI 约 20 万张 GPU”“单次 10 万卡训练任务”是基础设施容量或编排规模，不能直接当作某一代模型预训练算力。
2. 预训练算力 ≠ 总训练算力。RL/后训练占比在不同估计中从 10% 到 200% 不等，口径不同倍数可差一倍以上。

3. 投入算力 $\neq$ 有效算力。利用率（MFU）、浮点精度、MoE 激活率都会改变” 同样 FLOP 买到的能力”。

因此本文在所有图表中不使用 10 倍，改用” 约 2-3 倍（第三方估计，unverified）“并显式标注口径。这一更正本身也是方法立场：讨论” 墙” 之前，先保证量墙的尺子是准的。

6 讨论：墙是相变点，破墙是换曲线

P0b 的三段式曲线给了四面墙一个统一位置：它们都发生在第二段。大脑用皮层褶皱应对布线墙、芯片用多核应对功耗墙、模型用 MoE 路由应对参数墙、Agent 系统用分层拓扑应对中心扇入墙——历史反复呈现同一个模式：饱和不是终点信号，而是” 该换结构了” 的信号。

这也限定了” Scaling 没有死” 这类乐观说法的成立条件。Anthropic 方面关于” 2026 年仍将激进加速” 的判断（二手报道，[CITATION NEEDED]）只有在” 加速发生在新曲线上” 时才成立；如果加速指的是在旧曲线上投更多电，它恰好会被收益墙否定。Scaling Laws 没有死，它换了个活法：从在一条曲线上跑得更远，变成不断换到更好的曲线。

7 可杀死本文的预测与反方意见

五条硬预测（预注册）：

- F1（对应 H1）： ≥ 30 场景种子复盘，主动采集良率增益的 95% CI 不跨 0；跨 0 则路径一被否。
- F2（对应 H2）：Attention Residuals/Nexusformer 类结构优势在第三方 $\geq 1B$ 复现中成立；两年内无独立复现则” 架构墙可由换结构突破” 的强主张降级为个案。
- F3（对应 H3）：回放式 RSI 在新任务族出现负迁移或收益随树规模转平，则它不是新 Scaling 轴。
- F4（对应 H4）：Agent 治理机制在 10^4 量级压测中收口率跌破对照组，则系统级 Scaling 的治理红利存在未被识别的墙。
- F5（总纲）：若存在一类能力，其提升在所有已知结构变换下都严格受同一条幂律支配、且无任何换曲线空间，则” 范式墙” 框架错误，那才是真正的物理极限墙。

四条反方意见：

1. “墙就是物理极限，换结构只是把常数变好、指数逃不掉。” 部分同意—— τ 、能源、土地最终是物理约束；但本文主张的是反复相变会把极限持续推后，可观测的未来墙仍是范式墙，F5 是裁决实验。
2. “效率倍数全是厂商自报，不可信。” 同意大半，因此本文全部外部倍数标论文报告/unverified，结论不依赖任何单一倍数成立。
3. “主动采集的增益只是挑了容易的任务。” 这正是设同偏态池贪心消融（0.7917/0.889）的原因；但单 seed 不足以结论，F1 已要求多种子。

4. “五路径是并列清单，不是理论。” 接受——本文的理论主张只有一条（墙=固定结构的相变点），五路径是该主张在 2026 年技术地图上的投影，会过时，主张不必过时。

8 效度威胁与适用边界

- 本文 UDOS 数字来自 CPU 原型、固定单种子，属试点点估计；绝对常数不能外推到真实 LLM 集群，投稿前需 ≥ 30 seed 与 95% CI（约 64/65 处 [RESULT NEEDED]）。
- 外部论文多为 2026 年预印本，未经同行评审；arXiv 编号已核验存在，但报告倍数未独立复现。
- “SeedFold” 在本次核验中查无实据，已明确剔除；材料中若还有同类未核验名称，应同此处理。
- 华为 τ 定律与各厂商 2028/2031 目标是预测，不是事实。
- 本文不讨论意识、不主张任何系统已具备自我；RSI 的定性与安全边界见姊妹篇 P14。

9 结论

Scaling 的墙真实存在，但它量的是一个被冻结的范式的承载力，不是智能的物理极限。把墙拆成数据、算力/能源、架构、收益四个可测维度后可以看到：前三者的共同解法是更换结构（采集结构、连接结构、计算的时间结构），第四者（收益墙）则是前三类结构错配的汇总症状。P0b 的三段式曲线给了墙一个精确位置——相变拐点；2025–2026 年的五条路径给出了绕墙开门的工程地图。优先级最高的不是更贵的算力，而是数据采集结构与模型连接结构的重构。**破墙的本质不是把墙推倒，而是在墙旁边开一扇新门；而开门的图纸，是结构，不是规模。**

参考文献（核验状态随条标注）

1. Kaplan J. et al. Scaling Laws for Neural Language Models. arXiv:2001.08361, 2020（用户附件原件，写作范本）。
2. Hoffmann J. et al. Training Compute-Optimal LLMs (Chinchilla). arXiv:2203.15556, 2022 [CITATION NEEDED: 卷内统一著录]。
3. Fedus W. et al. Switch Transformers. arXiv:2101.03961 [CITATION NEEDED]。
4. Sennrich R. et al. BPE. arXiv:1508.07909 [CITATION NEEDED]; Kudo & Richardson SentencePiece arXiv:1808.06226 [CITATION NEEDED]。
5. Vaswani A. et al. Attention Is All You Need. arXiv:1706.03762 [CITATION NEEDED]。
6. Kimi Team. Attention Residuals. arXiv:2603.15031, 2026-03（**已核验存在**； $1.25\times/1.4T/48B-3B/<2\%$ 为论文报告，未独立复核）。
7. Nexusformer: Nonlinear Attention Expansion for Stable and Inheritable Transformer Scaling. arXiv:2604.19147, 2026（**已核验存在**；41% 等数字为论文报告）。
8. JTok: On Token Embedding as Another Axis of Scaling Law via Joint Token Self-modulation. arXiv:2602.00800, 2026（**已核验存在**；“省 1/3 算力”未从原文证实，[RESULT NEEDED]；作者机构归属未核验）。

9. Scaling Embedding Layers in Language Models (SCONE). arXiv:2502.01637, 2025 (已核验存在)。
10. Zheng T. et al. Dream-RSI: Recursive Self-Improvement through Evolving Worlds. arXiv: 2609.14858, 2026-09-14 (已核验存在; $162\times/1.7\times/$ “人类引导更差” 为论文报告)。
11. InclusionAI. Ling 2.5 / Ring 2.5 技术材料, 2026-02 (MLA+Lightning Attention; 据 Raschka 综述与 InfoQ 二手材料, 未读原文 [CITATION NEEDED])。
12. 何庭波等. A Time Scaling Theory for Multi-Layer Electronic Systems (韬/τ 定律) . ChinaXiv, 2026-05; IEEE ISCAS 2026 发布; 381 款芯片/155→400+ MT/mm²/2031 等效 1.4nm 为公司披露与预测 (多源报道已核验事件, 预测值 unverified)。
13. Epoch AI / TensorFeed 汇编. Has frontier AI training-compute growth actually slowed? 2026-05 (GPT-5≈5e25、GPT-4≈2e25 FLOP 估计, 第三方估计, unverified)。
14. “SeedFold” : 本次 (2026-09-20) 公开检索未找到对应论文或产品, 查无实据, 不予采信 [CITATION NEEDED]。
15. UDOS 姊妹篇: P0b 《结构+规模, 本身就是智能》、P1/P2/P9/P10/P11/P12 (本卷), 数字回 `reports7/*.json`。

附录 A 复现命令与测试索引

- 数据飞轮试点: `reports7/coverage_flywheel*.json` (48 episode/144 分钟, oracle=226) ; 对照键 `passive / active / greedy_samepool`。
- 拓扑外推: `reports7/topology_scale*.json` (六档目标 10→1e6) ; BFT: `reports7/bft_lite*.json` ($n = 7, f = 2, 24$ 工单)。
- 质量饱和: `reports7/expert_mixture*.json` ($mse(k) = a + b/k, a = 0.009252, b = -4.233 \times 10^{-5}$)。
- 测试守门: P2 10 项属性测试、P10 26 项契约测试、P11 10 项单元测试 (命令与版本见 P12 附录)。

附录 B 证据台账 (三档)

- **verified** (测试守门) : BFT 24/24、守恒 240/16/1、契约字段校验、拓扑计数公式。
- **cpu-proto** (CPU 原型趋势, 单 seed) : 良率 0.667→0.854、密度 7.80→11.38、吞吐驼峰 244.172/106.485、专家混合 0.0092 vs 0.2131。
- **unverified** (外部一方主张) : $1.25\times$ 、 $162\times$ 、 $1.7\times$ 、 $3.2\times$ 、+10.9 分、26%、3 万并发、381 款芯片、2031 等效 1.4nm、算力 2-3 倍估计; “SeedFold” 查无实据。

附录 C 内审记录 (投稿前五维自评, 只看不改)

- 新颖性: 中高 (范式墙四维操作化 + 五路径可证伪假设 + 算力倍数公开更正)。
- 证据强度: 内部弱 (单 seed)、外部中 (事件多源核验、倍数未复核)。

- 可复现性：内部高（JSON 可复跑）、外部不适用。
- 主要缺口：≥30 seed 复算；外部论文的独立复现实验；算力口径的一手数据。
- 结论：当前为可讨论的工作论文（working paper），不具备投稿状态；补齐 F1-F4 后可投 TMLR / NeurIPS Datasets & Benchmarks / ICML workshops 类 venue [CITATION NEEDED：选刊需另查截稿与分区]。

作者拟用声明

房文新（拟用）。UDOS 推演引擎 v7.5.0 论文卷·专题篇 P13。本文不含任何受版权限制的第三方图片；外部数字均标注来源与核验状态。外部机构名称与商标归各自所有者，引用仅用于学术评述。