




异构性红利与同质性饱和：Agent 多样性的信息论条件

The Diversity Dividend and Homogeneous Saturation: An Information-Theoretic Account of Why Independent Information Sources, Not Headcount, Are the Quality Variable in Multi-Agent Systems

UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

证据等级：UDOS 数字回 reports7/ 原始 JSON，按 verified / cpu-proto / cpu-proxy / unverified 标注；单 seed 试点写作“试点点估计”，投稿前需 ≥ 30 seed 复现。

Working Title (EN): The Diversity Dividend and Homogeneous Saturation: An Information-Theoretic Account of Why Independent Information Sources, Not Headcount, Are the Quality Variable in Multi-Agent Systems

卷 P20 · P9 《Agent 军团的质量饱和律与同质化扩招失效边界》的外部对话篇 · 与 P22 《内存墙不等于协调墙》互为姊妹篇 · UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

一句话先说清：把一万个同一个模型、同一套提示、同一份上下文的”克隆 Agent”堆在一起，质量不会变——因为它们看到的是同一份世界；真正决定多 Agent 系统上限的，不是 Agent 的数量 N ，而是独立信息源的数量 D 。OASIS 用百万级异质社交个体观察到”越大越多样”，UDOS P9 用 cpu-proto 实验测出”同质化副本加多少都饱和”，TUMIX 用异构工具策略证明多样性带来可测提升——三条独立证据指向同一个信息论结论。

证据口径（全文只声明这一次）：本文是理论/综合论文，不含新的 UDOS 实测数字；引用的 UDOS 结论均回 v7.5.0 各篇及其 `reports7/*.json` 三级标注 (verified / cpu-proto / cpu-proxy / unverified)。外部文献 (OASIS、TUMIX、Krogh & Vedelsby、Kaplan、Chinchilla、NSA 等) 存在性已于 2026-09-21 按 EVIDENCE_LEDGER_v76.md 核验；其中 OASIS 的”更大组→更多样”与 TUMIX 的”+3.55%”均为论文报告口径、未独立复核。本文不把任何外部数字写成本文论证的独立证据，只作”行业现象与 UDOS 推论一致”的旁证。

摘要

多 Agent 系统的流行叙事是”堆人即变强”：只要并行的子 Agent 数量 N 上去，正确率、鲁棒性、覆盖度就会随之上升。本文论证这一叙事混淆了两个不同的量——**规模** (headcount N) 与**独立信息源数** (diversity D)。论证分四步。第一，集成学习的经典饱和律 $mse(k) = a + b/k$ 表明：集成误差的下降幅度 b/k 由成员误差的独立性决定，当成员同质化 (误差相关 $\rho \approx 1$)， $b \rightarrow 0$ ，再加成员质量钉死在不可约底 a 上；UDOS P9 的 cpu-proto 实测复现了这一形状 ($a = 0.009252$ ， $b = -4.23 \times 10^{-5}$ ， $k > 2$ 后走平)。第二，OASIS (arXiv:2411.11581, NeurIPS 2024) 在百万级社交模拟中观察到”更大的 Agent 组带来更强群体动态与更多样意见”，但该系统的 Agent 是**异质个体** (不同用户画像、不同行为规则)，这与 P9 的**同质副本** (同一模型、同一提示、 $corr \approx 0.9999$) 恰成对照——两条证据放在一起才说明问题：规模本身不决定多样性，个体间的信息独立性才决定。第三，TUMIX (arXiv:2510.01279) 在 Gemini-2.5-Pro 上用”并行多 Agent、各用不同工具策略”的异构集成平均提升至 +3.55%，证明异构化是可操作的质量杠杆。第四，由此得到工程推论：扩招前先问”新来的 Agent 是否携带了现有 Agent 没看到的信息”，而不是”能不能再开一个实例”；Warp-Cortex 类单例权重共享架构 (P22) 天然不携带独立信息，其价值在内存而非质量。本文给出三条可证伪条件与两条硬预测。

关键词：多 Agent 系统；集成饱和律；多样性红利；独立信息源；同质化扩招；偏差-方差-歧义分解；可证伪性

结构化摘要（背景问题 → 论点 → 证据 → 贡献）

- **背景问题**：多 Agent 工程长期在”加人”这条路上狂奔，但加人到底买来什么？是质量、吞吐，还是只是账单？现有文献要么只报端到端成功率（掩盖了成员是否真的独立），要么只报吞吐曲线（与质量无关）。
- **核心论点**：多 Agent 质量的第一性变量是**独立信息源数 D**，不是 Agent 总数 N；同质化副本把 N 做大却不增加 D，质量曲线按 $1/k$ 压平；异构个体把 D 做大，质量才有余量继续下降。
- **证据线索**：(1) UDOS P9 cpu-proto：同质副本 $mse(k) = a + b/k$ 、 $k > 2$ 走平、等权差源拖差约 23 倍；(2) OASIS 百万级异质社交模拟的”越大越多样”观察（论文报告）；(3) TUMIX 异构工具策略集成 +3.55%（论文报告）；(4) 理论祖先 Krogh & Vedelsby 1995 的 bias-variance-ambiguity 分解。
- **贡献**：把”规模 N “与”独立信息源 D “在同一框架下分开操作化；用 OASIS（异质→多样）与 P9（同质→饱和）的对照说明规模叙事的混淆；给出”扩招先问信息独立性”的工程判据；两条硬预测。

1 引言：把”加人”翻译成”加什么”

“我们已经并行跑了几百个子 Agent”——这句话在 2026 年的多 Agent 工程语境里几乎等于”我们很强”。但它到底测量了什么？是更多的独立判断，还是更多的同一判断的重复投票？

这不是咬文嚼字。分布式决策有一条被反复验证的饱和律：多个独立错误的平均能把方差压下去，多个**相关**错误的平均不能。前者是集成学习之所以有效的全部理由，后者是”加人加不出效果”的全部原因。问题在于，LLM Agent 军团的工程实践里，“新加一个 Agent”往往是**再开一次同模型调用、再喂同一套上下文**——它和原来的 Agent 几乎看到同一份世界。这样的”加人”增加的是 N（headcount），不是 D（独立信息源数）。

UDOS P9 已经在受控原型里把这条曲线量出来：等权纳入一个差专家可使集成 MSE 从约 0.0092 恶化到 0.2131（约 23 倍），而 $k > 2$ 之后再多 15 个同质化副本，MSE 围绕饱和底 $a = 0.009252$ 走平（cpu-proto，单 seed 试点）。本文要做的是把这条 cpu-proto 曲线放回 2026 年的外部证据版图里：OASIS 的百万级社交模拟、TUMIX 的异构工具集成，从两个相反方向为”独立信息源才是质量变量”提供旁证。

全文刻意区分三类陈述：**UDOS 工程证据**（回 P9，带证据等级）、**外部论文报告**（OASIS/TUMIX，标”论文报告·未独立复核”）、**理论推论**（标注为推论并在第 8 节给证伪条件）。

2 核心论点：两个被混淆的量

2.1 N 与 D 的操作化

- **N（规模 / headcount）**：系统里同时存在的 Agent 实例总数。它决定的是计算开销、通信扇入、内存占用——即”要花多少资源维持这个军团”。
- **D（独立信息源数）**：这些 Agent 所依赖的、彼此不冗余的信息通路数量。它决定的是集成能从多样性里榨出多少误差下降——即”这个军团的质量还能走多远”。

N 与 D 不必同步增长。把同一个模型实例复制成 1000 个容器， $N = 1000$ ，D 可能仍约等于 1（大家看到的是同一份参数、同一份上下文）；把 10 个不同模型、各自用不同工具、喂不同数据源的 Agent 凑在一起， $N = 10$ ，D 可能接近 10。

2.2 为什么 D 才是质量变量

沿用 P9 的推导：k 个成员加权平均预测的方差，在成员误差两两独立、零均值、方差 σ^2 时降为 σ^2/k ；再加上所有成员共享的不可约偏置 a，总 MSE 形如

$$\text{mse}(k) = a + \frac{b}{k}, \quad a \text{ 为不可约底, } \frac{b}{k} \text{ 为靠独立性换来的方差下降.}$$

关键推论藏在 b 里：b 正比于成员误差的独立性。当成员误差相关系数 $\rho \rightarrow 1$ （同质化），方差项不再随 k 下降， $b \rightarrow 0$ ，于是


$$\text{mse}(k) \rightarrow a \quad (\rho \rightarrow 1).$$

也就是说，同质化副本的质量曲线不是”下降变慢”，而是”根本不下降”。Krogh 与 Vedelsby (NeurIPS 1995) 的 bias-variance-ambiguity 分解把这件事写成了经典形式：集成泛化误差 = 平均单模型误差 - 成员间歧义 (ambiguity)；歧义越大、集成越优。b 就是歧义在 $1/k$ 形式下的化身。

2.3 与 Kaplan scaling 的形态区分

必须把这条 $1/k$ 饱和律与 Kaplan 的模型规模幂律 ($L(N) = (N_c/N)^\alpha$) 区分开，否则容易误读。Kaplan 描述的是换更大模型时损失连续、近似单调下降；本文描述的是加同构副本时误差迅速压平到不可约底。两者形态不同：一个是”规模越大越好（只是变慢）”，一个是”过了真独立源数就触底”。P9 的 cpu-proto 实测 $b = -4.23 \times 10^{-5}$ （绝对值极小）正是 $b \approx 0$ 的体现——新增 15 个同质化副本没有把 MSE 从 0.0092 显著拉低。

图1 规模 N 与独立信息源 D 的二分（概念示意）



OASIS (异质个体，越大越多样) ↔ P9 (同质副本，加人即饱和)：差异不在规模，在个体是否独立

图1 左：同质化扩容——N 增大而 D 不变，质量曲线按 $1/k$ 压平到不可约底 a；右：异构扩容——D 增大，不可约底 a 本身被拉低。横轴为 Agent 数 N。概念示意，非实测数据。

3 外部证据一：OASIS 的”越大越多样”是异质个体的结果

3.1 OASIS 测到了什么

OASIS (Yang 等, arXiv:2411.11581, NeurIPS 2024, CAMEL 团队) 是一个基于社交媒体范式的大规模 Agent 社会模拟, 支持最高 100 万用户级别的动态社交网络、多样化行动空间与推荐系统 (论文报告)。它复现了信息传播、群体极化、羊群效应三类社会现象, 并观察到: **更大的 Agent 组规模导致更强的群体动态与更多样的意见** (论文观察, 未独立复核)。

3.2 为什么这与 P9 不矛盾, 反而互补

初看这似乎与 P9 的”同质化扩招饱和”冲突: OASIS 说越大越多样, P9 说加人没用。但把两者的 Agent 构成摆在一起就清楚了——

- OASIS 的 Agent 是**异质个体**: 不同用户画像、不同行为规则、不同初始立场, 它们之间天然携带独立的信息通路 (D 随 N 大致同步增长)。
- P9 的同质化副本是**同一近相关源的复制**: 同一模型、同一提示、 $\text{corr} \approx 0.9999$, N 从 1 加到 17 而 D 始终约等于 2 (最强单专家 + 一个差源)。

差异不在”规模”, 在”个体是否独立”。OASIS 的”越大越多样”之所以成立, 是因为它的”大”是**异质个体的多**; P9 的”加人无效”之所以成立, 是因为它的”多”是**同一判断的重复**。把两条曲线画在同一张图上 (图 1), 结论就一目了然: 规模 N 不是质量变量, 个体间的信息独立性才是。

3.3 必须诚实指出的 OASIS 边界

OASIS 的证据性质是**现象复现**——它能重现极化、羊群等已知社会现象, 但这不等于它证明了”规模导致极化”的因果机制 (P27 将专门讨论社会仿真的因果效度)。本文只借用它的一个观察: 在异质个体前提下, 规模与多样性同步增长; 这与 P9 在同质副本前提下的饱和曲线, 共同圈出了 D 的作用区间。

4 外部证据二：TUMIX 的异构工具策略是可操作的质量杠杆

4.1 TUMIX 做了什么

TUMIX (Chen 等, arXiv:2510.01279) 是一个测试时扩展集成框架: 并行运行多个 Agent, 各自采用**不同的工具策略**, 再迭代共享精炼。论文报告在 Gemini-2.5-Pro/Flash 上, 其平均准确率较最佳基线**最高提升 +3.55%**, 且推理成本近似持平 (论文报告, 未独立复核)。

4.2 为什么这是”异构化”而非”加人”

TUMIX 的关键不在”并行多 Agent”, 而在”各用不同工具策略”。如果它只是把同一个提示并行跑 k 次再投票, 按 P9 的饱和律, 这 +3.55% 里大部分会被 $b \approx 0$ 吃掉。它之所以能测出可提升的增益, 恰恰是因为不同工具策略让不同 Agent 触达了**不同的信息通路**——有的会查知识库, 有的会写代码验证, 有的会检索网页——这些通路彼此独立, D 随策略数增长。

这把第 2 节的理论推论落到了工程可操作的位置: **异构化不是”换个模型名字”, 而是”换信息通路”**。

4.3 与 ClawArena-Team 的旁证

ClawArena-Team (arXiv:2606.31174, 本卷 P17 详论) 报告了一个方向一致的发现: 子 Agent 编排中, API 成本与管理质量近似解耦, 最便宜的配置反而落在 Pareto 前沿上 (论文报告方向, 精确阈值未独立复核)。这从”管理能力”维度侧面印证: 堆更贵的同质模型并不能买到质量, 真正的杠杆是结构与信息源的多样性。

5 工程推论：扩招前的三个问题

把第 2-4 节合起来, UDOS 的 Agent 军团在扩招前应依次回答三个问题, 而不是直接开新实例。

表 1 扩招前的”信息独立性”三问

问题	若回答”否”	工程含义
新 Agent 是否看到现有 Agent 没看到的信息?	D 不增	加它只增加 N 与账单, 质量钉在 a 上
新 Agent 的错误是否与现有 Agent 近相关 ($\rho \approx 1$) ?	$b \rightarrow 0$	不带来方差下降, P9 饱和曲线适用
新 Agent 的质量是否已在独立校准集上验证?	权重无法校准	等权并入会拖差结果 (P9: 0.2131 vs 0.0092, 约 23 倍)

三个问题全部为”是”, 扩招才买到多样性红利; 任一为”否”, 扩招买到的只是规模叙事。这与 P9 的加权机制直接衔接: UDOS 不用”一人一票”, 而用校准加权 $w_i = \exp(-\text{calib_mse}_i/\tau) / \sum_j \exp(-\text{calib_mse}_j/\tau)$ ($\tau = 0.05$), 把话语权按独立校准集上的历史准确率分配。这一机制本身就是对”同质化扩招”的结构性防御——差源在权重上被自动压低, 不会像等权那样把偏差灌进结果。

6 与 Warp-Cortex 的对照：内存扩展 ≠ 信息扩展

6.1 单例权重共享的代价

Warp-Cortex (arXiv:2601.01298, 本卷 P22 详论) 用 Singleton Weight Sharing (所有 Agent 共享同一模型实例的权重) 把内存复杂度从 $O(N \cdot L)$ 压到 $O(1) + O(N \cdot k)$, 单张 RTX 4090 实测约 100 个并发 Agent、2.2 GB 显存 (论文报告)。这是一项漂亮的**内存墙突破**。

但从本文的视角看, Singleton Weight Sharing 是一种**强制同质化**: 所有 Agent 共享同一份权重, 只有 KV-cache 不同。这意味着它们在架构层面就被设计成”看同一套参数”, 天然不携带独立信息。它的价值是把 N 做大的内存成本降下来, 而不是把 D 做大的质量增益做上去。

6.2 内存墙与协调墙是两堵墙

由此得到本文与 P22 的分工：Warp-Cortex 解决”内存能不能装下 1000 个 Agent”，本文回答”装下之后质量会不会涨”。答案是：**内存能扩展 ≠ 能力能扩展 ≠ 协调能扩展**。单例权重共享把第一堵墙（内存）拆了，却把第二堵墙（质量饱和）原样保留——因为它的 Agent 们从一开始就是同质化副本。

这不是批评 Warp-Cortex，而是给它的价值划界：它是规模化基础设施，不是质量提升手段。把”能跑 1000 个 Agent”误读成”1000 个 Agent 更强”，正是本文要纠正的规模叙事混淆。




图2 同质化副本（红线）：N 增大，D 不变，质量沿 1/k 压平到不可约底 a；异构个体（蓝线）：D 增大，a 本身被拉低。两者的纵轴差距不是”加人”买来的，是”加独立信息源”买来的。概念示意，非实测数据。

7 与 UDOS 论文卷的互证

表 2 本文命题 ↔ 论文卷与外部证据对照

本文命题	证据	证据等级
质量曲线按 $a + b/k$ 饱和	P9 实测 $a = 0.009252$ 、 $b = -4.23 \times 10^{-5}$	cpu-proto ($k \leq 2$ verified)
同质化副本 $b \rightarrow 0$ 、质量走平	P9 $k > 2$ 后 MSE 围绕 a 波动	cpu-proto
等权差源拖差约 23 倍	P9: 0.2131 vs 0.0092	verified（两源对照）
异质个体规模与多样性同步	OASIS 观察	论文报告·未独立复核
异构工具策略可买质量	TUMIX +3.55%	论文报告·未独立复核
成本与管理质量解耦	ClawArena-Team	论文报告方向·未复核
偏差-方差-歧义分解为理论祖先	Krogh & Vedelsby 1995	经典文献

8 糟粕、失效边界与可证伪条件

本文的论点有明确的失效边界，特逐条划界，不做综述堆砌。

8.1 糟粕与容易被误读的地方

1. “越大越多样”不是普遍定律。OASIS 的观察只在异质个体前提下成立；若把 OASIS 的 Agent 换成同质化副本（同一画像、同一行为规则），“越大越多样”会立刻退化为 P9 的饱和曲线。把规模与多样性画等号，是本文要反对的核心混淆。
2. TUMIX 的 +3.55% 不是“并行万能”的证据。它的增益来自异构工具策略带来的独立通路，而非并行本身；把它解读为“多跑几次投票就涨点”，会再次落回 $b \approx 0$ 的陷阱。
3. D 不是越大越好。引入独立信息源也引入了协调成本、冲突裁决成本和不一致风险；D 过大可能让聚合本身成为瓶颈（P1 的扇入爆炸）。本文只主张“D 是质量变量”，不主张“D 越大越好”。

8.2 失效边界

- 本文的饱和律 $mse(k) = a + b/k$ 假设成员误差零均值、两两独立。若任务是结构化几何求解（如 MAPF 路径规划，见 P21），Agent 间的“错误”不再是随机噪声而是规划偏差， $1/k$ 形式可能不成立——该任务的协调成功不依赖误差平均，而依赖全局约束满足。
- 本文不讨论因果推断型任务（需要识别效应、控制混淆），那是 P3 RCT 与 P27 社会仿真效度的领域。

8.3 可证伪条件

- C1: 若在受控对照中，同质化副本 ($corr \approx 0.9999$) 的 MSE 仍随 k 显著下降（显著跌破 a 并接近独立成员曲线），则 P9 的“同质化饱和”与本文 $b \rightarrow 0$ 的推论被证伪。
- C2: 若异构工具策略（TUMIX 式）在固定成本下反复测不出超过噪声的增益，而纯同质化投票反而稳定提升，则“独立信息源是质量变量”需降级为“在部分任务上成立”。
- C3: 若未来出现一个大规模系统，其 Agent 全部同质化（同模型、同上下文）却在质量上随 N 持续单调提升，且无法用“更强的最强成员”解释，则本文整个 N/D 二分需重构。

9 硬预测（2026–2031，可事后记分）

- F1: 未来五年公开的多 Agent 系统，凡报告“随 N 持续线性提升”且无法说明成员间信息独立性的，其增益在第三方复现中多数会被收窄到噪声或被归因于最强单成员。（判据：复现研究中同质副本臂的 b 是否仍显著为负。）
- F2: 会出现至少一个被广泛复现的“异构信息源 > 更多同质副本”的对照——即在固定总算力下，3–5 个真正独立的信息源（不同模型/不同工具/不同数据）的集成，稳定优于 20+ 个同质化副本的军团。

10 结论

把三处证据并置：P9 的 cpu-*proto* 曲线说”同质化副本加多少都饱和”，OASIS 的百万级异质模拟说”异质个体越大越多样”，TUMIX 的异构工具集成说”换信息通路能买到可测提升”。三条证据的共同结论是：**多 Agent 质量的第一性变量是独立信息源数 D，不是 Agent 总数 N。**

对工程，这一命题给出冷酷的优先级：在开第 1001 个 Agent 之前，先问它是否看到了前 1000 个 Agent 没看到的世界；如果答案是否，它只是又一份账单。对研究，它给出一个可杀死的研究纲领（C1-C3）：同质化饱和律要么在受控对照中站稳，要么被反例推翻。对整个 v7.6.0 卷，它为 P22（内存墙）和 P30（拓扑选型）划出边界——架构能把 N 做大，但只有信息源的异构化能把质量做高。

规模买来的是账房，多样性买来的是质量。在多 Agent 系统里，把这两件事搞混，是最贵的混淆。

参考文献

经典文献

1. Krogh, A., & Vedelsby, J. (1995). Neural Network Ensembles, Cross Validation, and Active Learning. NIPS (NeurIPS 1995).
2. Kaplan, J., et al. (2020). Scaling Laws for Neural Language Models. arXiv:2001.08361.
3. Hoffmann, J., et al. (2022). Training Compute-Optimal Large Language Models (Chinchilla). arXiv:2203.15556, NeurIPS 2022.
4. Fedus, W., Zoph, B., & Shazeer, N. (2021). Switch Transformers. arXiv:2101.03961.

2026 前沿材料（存在性已于 2026-09-21 按 EVIDENCE_LEDGER_v76.md 核验；数字均为论文报告，未独立复核）

1. Yang, K., et al. (2024). OASIS: Open Agent Social Interaction Simulations with One Million Agents. arXiv:2411.11581, NeurIPS 2024.
2. Chen, et al. (2025). TUMIX: Multi-Agent Test-Time Scaling with Tool-Use Mixture. arXiv:2510.01279.
3. Ruiz Williams, J. L. (2026). Warp-Cortex: An Asynchronous, Memory-Efficient Architecture for Million-Agent Cognitive Scaling on Consumer Hardware. arXiv:2601.01298.
4. Xiong, et al. (2026). ClawArena-Team: Benchmarking Subagent Orchestration and Dynamic Workflows in Language-Model Agents. arXiv:2606.31174.

UDOS 论文卷（本系列，证据等级随文标注）

1. UDOS v7.5.0 论文卷：P9 《Agent 军团的质量饱和律与同质化扩招失效边界》、P1 《分层混合拓扑的协调复杂度百万级外推》、P0b 《结构加规模，万物皆可 Scaling Laws》、P15 《生命起源于结构组织》。

证据纪律与复现说明

- 本文为理论/综合论文，无新增实验；所有 UDOS 数字均回 P9 与 `reports7/agent_scaling.json`，证据等级以 P9 标注为准（ $k \leq 2$ verified、 $k > 2$ cpu-proto、吞吐曲线受本机 2 线程约束），单 seed 结果均为试点点估计，投稿前须补 ≥ 30 seed 与 95% CI。
- 外部文献的存在性、标题与 arXiv 编号已于 2026-09-21 按 EVIDENCE_LEDGER_v76.md 核验；OASIS 的”越大越多样”与 TUMIX 的 +3.55% 一律保持”论文报告，未独立复核”口径，不作为本文论证的独立证据，只作”行业现象与 UDOS 推论一致”的旁证。
- 本文全部预测（F1-F2）与证伪条件（C1-C3）均可在 2026-2031 年间用公开证据事后记分。