



v7.6.0 文献证据台账与预测更新：三级 核验、降级清单与 F6-F10

The v7.6.0 Evidence Ledger and Prediction Update: Three-State Literature Audit, Downgraded Claims, and Falsifiable Forecasts F6-F10

UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

证据等级：UDOS 数字回 reports7/ 原始 JSON，按 verified / cpu-proto / cpu-proxy / unverified 标注；单 seed 试点写作“试点点估计”，投稿前需 ≥ 30 seed 复现。

Working Title (EN): The v7.6.0 Evidence Ledger and Prediction Update: Three-State Literature Audit, Downgraded Claims, and Falsifiable Forecasts F6–F10

全卷收口篇 P34 · 把前置核验分片的 `EVIDENCE_LEDGER_v76.md` 升级为正式论文版证据台账 · 更新 P15/P33 的硬预测 · UDOS 推演引擎 v7.6.0 · 房文新 · 2026-09-21

一句话先说清：v7.6.0 全卷引用的外部文献，没有一条是”听来的”——每一条都经过联网核验，并被钉在三态之一：已核验已核验、部分核验部分核验（给出实际值）、查无实据查无实据（标 [CITATION NEEDED]）。本文把这份台账公开，并公开**哪些流传很广的数字必须降级或剔除**（MAPF 百万成功率、结算中立性五属性、Hybrid 96.1% 等），最后把 P15 的 F1–F5 保留、新增 F6–F10 五条可在 2027 年记分的硬预测。

证据口径（全文只声明这一次）：本文是**证据台账与预测登记论文**，不含新实验、不含新的 UDOS 实测数。三态核验于 2026-09-21 完成（Asia/Shanghai），方法为对每条线索用 arXiv abs/html、ACL Anthology、IEEE Xplore、OpenReview、Zenodo、官方新闻稿独立复核；用户粘贴的 arXiv 编号、数字、机构归属一律视为”线索”而非事实。标 已核验 者仅代表”文献真实存在、标题/年份/出处一致”，其论文内数字仍标”论文报告·未独立复核”；标 部分核验 者以本文给出的**实际值**为准；标 查无实据 者一律写 [CITATION NEEDED]，禁止写成事实。

摘要

v7.6.0 论文卷（P16–P34）共引用约 50 条外部线索。本文不做综述堆砌，而是把全部线索过一遍**三级核验**：已核验 已核验（存在且题录一致）、部分核验 部分核验（存在但某数字/记录号与线索不符，给出实际值）、查无实据 查无实据（标 [CITATION NEEDED]）。核验结论是乐观但克制的：核心新论文（H-CSC、EPOB、ClawArena-Team、Warp-Cortex、RSIAgent、Ouroboros、OASIS）**绝大多数真实存在且核心命题成立**；真正需要降级的是四类——(a) MAPF 的”百万级 99.9%/163 μ s”仅见于俄文媒体转述；(b) “结算中立性五属性”未定位到任何原始出处；(c) Hybrid LangGraph-CrewAI 的 96.1%/–76.2% token 未核到原文；(d) ISONOMIA/RSIAIO/Adaptive Bitmask 的记录号与仿真数字需更正。本文同时登记一份”被剔除/降级清单”，并在保留 P15 F1–F5 的基础上新增 F6–F10 五条可证伪预测（三级最终性、scope、BRS+DRS、审核门禁、规则谓词 vs 学习谓词），统一标”待 2027 年记分”。

关键词：证据台账；三级核验；引用审计；降级清单；可证伪预测；文献可信度

结构化摘要（背景问题 → 方法/论点 → 证据 → 贡献）

- **背景问题：**AI 论文卷最容易翻车的地方不是论证，而是引用——一个流传甚广的 arXiv 编号或”百万级”数字，若不核验就写进正文，会把整条论证建立在沙子上。
- **核心论点：**一份诚实的论文卷，必须把它引用的每一条外部材料钉在三态之一，并公开”哪些我信了、哪些我打了折、哪些我没找到”。
- **证据线索：**约 50 条线索逐条联网核验；核心新论文 已核验 占多数，部分核验 集中在记录号与媒体转述数字，查无实据 集中在无出处的”框架五属性”类。

- 贡献：正式论文版三级核验台账；一份被剔除/降级清单；P15 F1–F5 保留 + F6–F10 新增的预测更新；以及 v7.6.0 全卷 19 篇索引。

1 为什么需要一份公开台账

AI 写作的默认失败模式是：模型把训练时见过的”印象”当成”事实”，把二手转述的数字当成论文原文，把一个查不到的框架当成”已有共识”。v7.6.0 既然自称”测量与治理”，它对自己的引用也必须执行同样的治理。因此本文把前置核验分片的工作台账升级为正式论文，公开三态结果与降级清单——这既是对读者负责，也是 P12 证据分级方法论在文献层的延伸。

三态定义全文只声明这一次：

- 已核验 已核验：文献真实存在，标题/作者/年份/出处一致；论文内数字仍标”论文报告·未独立复核”。
- 部分核验 部分核验：文献存在，但某数字/记录号/标题与线索不符，本文写实际值。
- 查无实据 查无实据：搜不到或与所给编号严重不符，写作时标 [CITATION NEEDED]。




图2 v7.6.0 全卷外部线索按三态归类的分布（概念示意；计数以本文台账为准）。概念示意，非实测数据。

2 核心新论文台账（A 组，v7.6 主对话对象）

表 1 A 组：与 v7.6.0 直接对话的八篇核心论文

编号	文献	状态	核验到的实际信息	安全引用口径
A1	H-CSC（语义提交 BFT）	已核验（v2 改题）	v2 改题 Certifiable Semantic Agreement Among LLM Agents: What the Admissibility Instrument Decides (arXiv:2606.07316v2)；类型化提交对象与 2f+1 证书信封属实。负结果逐字命中：聚合距离 5.32°/5.48° vs	用 v2 口径：撤回 + 词法谓词胜学习；数字为论文报告·未独立复核。

编号	文献	状态	核验到的实际信息	安全引用口径
			钢铁人 4.27°/4.32°；诚实保留作者明文 “we withdraw it” ；词法谓词 AUROC 0.865–0.982 胜学习编码器 0.621–0.744。	
A2	EPOB（项目编排基准）	已核验	正式记录为 OpenReview NtPIgzPt0U （2026-05）+ epob.us 榜单；五维 Plan/Assignment/Coordination/Deliverable/Efficiency 属实。	五维名称属实；失败 taxonomy 为论文报告口径。
A3	ClawArena-Team	已核验	Benchmarking Subagent Orchestration…（arXiv: 2606.31174）；41 场景/258 轮/纯执行式评分无 LLM 评判属实。	方向属实；“无 LLM 超 50% 权限精度” “成本百倍/总分四倍” “SMS 三项乘积” 未逐字命中，写” 论文报告·未独立复核”，不写死百分数。
A4	Warp-Cortex	已核验	单例权重共享 + 拓扑突触，内存复杂度 $O(N \cdot L) \rightarrow O(1) + O(N \cdot k)$ 属实。	“100 Agent/ 2.2GB” 为论文报告；“百万” 为论文自述理论外推，实测仅约百级。
A5	RSIAgent	已核验	curricula/actor/verifier 三角色、广后深策略属实（arXiv:2609.15364）。	“开源 Kimi-K3/ GLM-5.3 超 GPT-6 级闭源” 为论文/媒体报道；标题” New Environments” 指在新环境中学习、非跨环境迁移。
A6	Ouroboros	已核验	reviewed commits 成为运行时属实（arXiv: 2608.08311, v3）。	Terminal-Bench 2.1 原始 86.97%/剔除 reward-hack 后 86.74% 为自报告 SOTA，未独立复核。
A7	OASIS	已核验	百万用户社交模拟、复现信息传播/极化/羊群效应属实（arXiv:2411.11581, NeurIPS 2024）。	证据性质是现象复现，非因果识别。
A8	MAPF-GPT-DDG	部分核验	真实标题 Advancing Learnable MAPF Solvers with Active Fine-Tuning（arXiv:2506.23793, IROS	“2048×2048 / 524k 100% / 1M 99.9% / 163μs” 仅见于俄文媒体转述，不采信为

编号	文献	状态	核验到的实际信息	安全引用口径
			2025)，DDG 主动微调属实。	论文事实；前身仅小地图、16-32 Agent。

3 RSI 谱系台账（B 组）与市场治理台账（C 组）

表 2 B 组：用于 P24 层级定位的 RSI 系统

编号	文献	状态	实际信息
B1	The Last AI Built by Humans	已核验	arXiv:2609.11873；HCI + 七项 RSI 判别标准，作 P24 标尺。
B2	Dream-RSI	已核验	准确标题 Recursive Self-Improvement through Evolving Worlds (arXiv: 2609.14858)；“317 次调用≈51200 代”为论文/官方报告。
B3	Gödel Agent	已核验	ACL 2025, 2025.acl-long. 1354 (arXiv: 2410.04444)；自指代码修改式自改进，二手资料标 L4，不称 L5。
B4	HyperAgents	已核验	arXiv:2603.19461 (Meta FAIR)；元层修改过程本身可编辑，最接近”递归元改进”但未达 L5。
B5	RSIAI0	部分核验	正确记录为 Zenodo 15644670（非用户所给 15646184）；VM 受控执行 + Darwinian Mode。

表 3 C 组：市场与治理

编号	文献	状态	实际信息
C1	AgentLance	已核验	arXiv:2608.23867；私有成本投标 + 自维护策略笔记 + VCG 风格支付。
C2	Agent Exchange	已核验	arXiv:2507.03904；多属性拍卖 + 广义第二价格，流动性不足降级贪心/随机。

编号	文献	状态	实际信息
C3	ISONOMIA	部分核验	正确记录 Zenodo 21338480（非 21287289）；互信记账单位 ergs + 两院制治理属实；“45000 次仿真/300 参数点”未核到，标 [RESULT NEEDED]。
C4	When Agent Markets Arrive	已核验	arXiv:2604.06688；第一价格密封投标拍卖。
C5	结算中立性五属性	查无实据	未定位到任何原始论文/ Zenodo 记录；禁止作为已有框架引用，改写为 UDOS P11/P25 自拟设计目标或标 [CITATION NEEDED]。

4 通信规模、评估框架与经典/产业台账（D/E/F/G 组摘要）

表 4 D 组通信与规模

编号	文献	状态	实际信息
D1	RocketMQ-A2A	已核验	ACM FSE 2026 Industry（阿里云）；会话级可重放事件流、LiteTopic 会话隔离、断点续跑。
D2	Adaptive Bitmask	部分核验	npm 产品真实、子 10ms 方向可信；“85× 压缩/ 8.2ms p99/N=5000”未独立复核，标作者主张。
D3	AI Agent Protocols 综述	已核验	arXiv:2504.16736；CNS=(N_success/ N_attempts)/T_avg 逐字命中。

表 5 E 组评估与框架

编号	文献	状态	实际信息
E1	TUMIX	已核验	arXiv:2510.01279；Gemini-2.5-Pro 上最高 +3.55% 逐字命中。
E2	MAKER	已核验	

编号	文献	状态	实际信息
			arXiv:2511.09030；极端分解 + k=3 多数投票，首个零错误完成超百万步任务。
E3	Thinking vs Doing	已核验	arXiv:2506.07976, NeurIPS 2025 WS; Gemma 3 12B 在 WebVoyager/WebArena 达开源 SOTA。
E4	Hybrid LangGraph-CrewAI	部分核验	混合方向真实存在，但 IEEE Access 11481053、“96.1%/-76.2% token/14.5× 延迟”未定位到原文，标待核。
E5	MultiAgentBench	已核验	ACL 2025, 2025.acl-long. 421；系统比较星/链/树/图拓扑；“图最佳”精确排名未逐字命中，“写”拓扑与任务强相关”。
E6	AgentSociety	已核验	arXiv:2502.08691；1 万+ Agent、约 500 万交互逐字命中。
E7	MegaAgent	已核验	ACL 2025 Findings, 2025.findings-acl.259；无预定义 SOP，国家级政策模拟扩至 590 Agent。

F 组经典背景（F1–F10，均 已核验 编号正确）：Kaplan 2020 (2001.08361)、Chinchilla 2022 (2203.15556)、Attention 2017 (1706.03762)、AutoGen 2023 (2308.08155)、Practical BFT 1999、HotStuff 2019 (1803.05069)、Switch Transformers 2021 (2101.03961)、Krogh & Vedelsby 1995、Emergence Mirage 2023 (2304.15004)、Conformal Prediction 2021 (2107.07511)。

G 组产业传闻（重点逐条核，均 已核验，个别数字 部分核验）：Kimi K2.6 Agent Swarm（官方称至多 300 子 Agent 并行）、Kimi K3 (arXiv:2607.24653, 2.8T 参数开源 MoE)、蚂蚁 Agentar 2.0 (WAIC 2026, 近 200 岗位模板)、浪潮单柜 384 颗 OCM CPU 支撑 4 万+ Agent、华为 openJiuwen（双维度 RSI, arXiv:2608.27969）、华为韬(τ)定律 (ISCAS 2026-05-25, 六年量产 381 款芯片、2031 等效 1.4nm)、Anthropic 研发自动化（约 26% 研发由 AI 主导、约 3 万并发 Agent；“10 亿次决策”部分核验未核到，弃用）、OpenAI 自动化研究实习生→2028-03 研究员（约 3.1 Agent 工作日/人日）、Pillar 3 Fail-Safe & Recovery (Swarm 法定中止/漂移回滚/级联遏制)。

5 被剔除 / 降级清单（写作者务必遵守）

以下九条是本次核验主动放弃或降级的流传说。它们不是“错得离谱”，而是“写进正文会误导”：

1. C5 结算中立性五属性（查无实据）：无任何原始出处。只能改写为 UDOS P11/P25 自拟设计目标，或标 [CITATION NEEDED]。
2. A8 MAPF 百万数字（部分核验 降级）：DDG 主动微调属实；“524k 100% / 1M 99.9% / 163μs”仅俄文媒体转述，P21 只能说方向、百万数字标媒体主张。
3. B5 RSIAIO 记录号（部分核验）：正确为 Zenodo 15644670，非 15646184。
4. C3 ISONOMIA 记录号与仿真数字（部分核验）：正确为 Zenodo 21338480；“45000 次仿真/300-300 通过”未核到，标 [RESULT NEEDED]。
5. D2 Adaptive Bitmask（部分核验）：子 10ms 方向可信，“85× 压缩/8.2ms p99”标作者主张。
6. E4 Hybrid LangGraph-CrewAI（部分核验）：“96.1%/-76.2%/14.5×”未定位到原文，降级为待核。
7. A3 ClawArena 精确阈值（部分核验）：方向属实，“50% 权限精度/百倍成本/SMS 公式”未逐字命中，标论文报告·未独立复核。
8. G6 Anthropic” 10 亿次决策”（部分核验）：26%/3 万并发已核；“10 亿次”未核到，弃用。
9. A1 H-CSC 版本（部分核验）：必须用 v2 口径——已撤回”诚实保留优势”，词法谓词胜学习编码器；不得沿用 v1 正面结论。

6 预测更新：保留 F1–F5，新增 F6–F10

P15 提出的 F1–F5（结构变更占比、换结构即换曲线、架构搜索边界、校准类增益、跨基质 master curve 塌缩）全部保留，继续作为 2026–2031 的记分对象。本节新增 F6–F10，专门记分 v7.6.0 八项设计提案的成败——它们都写成可证伪条件，不是已成立结论。




图3 F6–F10 五条设计预测的提出时点（2026-09）与预期记分窗口（2027）。概念示意，非实测数据。

- F6（三级最终性 vs 二元停止）：在同一故障注入套件下，三级类型化最终性相对 v7.5.0 二元 STOP/CONTINUE，收口率应显著更高、误停率不应上升；若二者无可测差异，则①回滚二元。判据：≥30 seed、95% CI 不跨零。待 2027 年记分。

- **F7（scope 收紧的越界拒绝）**：TransferBundle 加 scope 后，结构越界调用的拒绝率应显著上升，而正常工单可用性损失低于预设阈值；若可用性损失超过越界收益，则② 改为按需授权。待记分。
- **F8（BRS+DRS 对盲区的覆盖）**：两阶段飞轮相对单阶段 coverage-aware，对 P6 识别的可辨识性盲区（加速度标量类）覆盖率应可测提升；若无提升则③ 回退单阶段。待记分。
- **F9（审核门禁拦截静默失败）**：[structural] 门禁对”版本号事故类”静默失败的拦截率应显著高于无门禁基线，且对合入速度的代价可接受；若空转则④ 降级为提示。待记分。
- **F10（规则谓词 vs 学习谓词 AUROC 差）**：在同一对抗攻击族下，确定性规则谓词的安全判别 AUROC 应不低于学习谓词（延续 H-CSC v2 方向）；若学习谓词稳定大幅占优，则⑧”规则为底”需弱化为按攻击族分流。待记分。

7 v7.6.0 全卷 19 篇索引

表 6 P16–P34 篇目速查

篇号	标题	一句话主题	外部对话对象
P16	类型化最终性	二元停止→三级语义提交	H-CSC v2
P17	最小权限编排	TransferBundle 增 scope	ClawArena-Team
P18	广度—深度两阶段飞轮	BRS+DRS 子模采集	RSIAgent
P19	结构变更审核门禁	MatrixConfig 提交必伴断言	Ouroboros
P20	异构性红利与同质性饱和	独立信息源数 ≠ 人头数	OASIS/TUMIX/P9
P21	百万级协调端到端证据	MAPF 成功不可外推语义任务	MAPF-GPT-DDG
P22	内存墙不等于协调墙	容量 ≠ 质量 ≠ 协调	Warp-Cortex
P23	项目级多维评估	工单→项目失败 taxonomy	EPOB
P24	RSI 谱系实测定位	六系统落 L1–L5，无一 L5	Theseus/Dream-RSI/ Gödel/HyperAgents
P25	Agent 任务市场	VCG 私有信息与结算	AgentLance/Exchange/ ISONOMIA
P26	加权 BFT 与声誉	等权 2f+1 的权重方向	WBFT/COALITION-VAST/ BlockAgents
P27	大规模社会仿真因果效度	现象复现 ≠ 机制验证	OASIS/AgentSociety/ MegaAgent
P28	百万级通信协议	可重放事件流/亚 10ms	RocketMQ-A2A/Bitmask
P29	测试时规模化协同	工具集成与极端分解投票	TUMIX/MAKER/TTI
P30	混合编排与框架-任务匹配	拓扑选型决策树校准	MultiAgentBench/ AutoGen

篇号	标题	一句话主题	外部对话对象
P31	故障安全与恢复	法定中止/漂移回滚/级联遏制	Pillar 3
P32	规则优先于学习	对抗场景谓词鲁棒性边界	H-CSC v2 教训一般化
P33	v7.6.0 架构总纲	八项结构变更统一规格	全卷收束
P34	文献证据台账与预测更新	三级核验 + F6-F10	本文

8 糟粕、失效边界与可证伪条件

8.1 本台账自身的边界

- 三级核验是”存在性核验”，不是”正确性核验”。标 已核验 只代表”这篇论文真的存在、题录对得上”，不代表它的结论是对的；论文内数字一律”论文报告·未独立复核”。
- 核验在摘要级完成。A3 的 SMS 公式、E4 的 96.1% 等”未逐字命中”，只意味着本次核验没在摘要层读到，不等于论文里一定没有——它们应在投稿前逐篇打开正文复核，而非一棍打死。
- 产业传闻时效短。G 组（Kimi/蚂蚁/浪潮/华为/OpenAI/Anthropic）来自官方页与主流媒体，2026-09-21 之后仍可能变动，引用时须带日期。

8.2 可证伪条件

- C-ledger-1: 若读者打开任一 已核验 文献的原文，发现标题/编号/核心机制与本文台账不符，则该条应立即改标 部分核验/查无实据 并更正安全引用句。
- C-ledger-2: 若 F6-F10 在 2027 记分窗口被证伪，则对应的设计提案（P16-P19、P32）应按 P33 的 C1-C5 回滚，而非换话术坚持。

9 结论

一份论文卷的可信度，最终不取决于它引用了多少论文，而取决于它敢不敢公开承认哪些没核到、哪些打了折。v7.6.0 的诚实立场是：核心新论文绝大多数真实、核心命题成立；但凡是流传很广却站不住的数字（MAPF 百万成功率、结算中立性五属性、Hybrid 96.1%、Anthropic 10 亿次），本文一律降级或删除，并写明理由。F6-F10 把八项设计提案从”自我感觉良好”变成”等着被打脸的可证伪命题”。

台账不是装饰品，它是本卷的免责书和记分板——写进去的都要负责，核不到的绝不当成事实。

参考文献

UDOS 论文卷（证据等级随文标注）

1. UDOS v7.5.0: P9 《质量饱和律》、P12 《证据分级驱动的可复现系统工程》、P14 《RSI 的收敛》、P15 《生命起源于结构组织》（F1-F5）。
2. UDOS v7.6.0: P16-P33 全部专篇（篇目见表 6）。

外部文献（存在性已于 2026-09-21 按 EVIDENCE_LEDGER_v76.md 核验；数字为论文报告/公司披露，未独立复核）

1. H-CSC v2 (arXiv:2606.07316) ; EPOB (OpenReview NtPIgzPtOU, 2026) ; ClawArena-Team (arXiv:2606.31174) ; Warp-Cortex (arXiv:2601.01298) ; RSI-Agent (arXiv:2609.15364) ; Ouroboros (arXiv:2608.08311) ; OASIS (arXiv:2411.11581, NeurIPS 2024) ; MAPF-GPT-DDG (arXiv:2506.23793, IROS 2025) 。
2. Theseus Labs (arXiv:2609.11873) ; Dream-RSI (arXiv:2609.14858) ; Gödel Agent (ACL 2025, long.1354) ; HyperAgents (arXiv:2603.19461) ; RSIAIO (Zenodo 15644670) 。
3. AgentLance (arXiv:2608.23867) ; Agent Exchange (arXiv:2507.03904) ; ISONOMIA (Zenodo 21338480) ; When Agent Markets Arrive (arXiv:2604.06688) 。
4. RocketMQ-A2A (ACM FSE 2026 Industry) ; A Survey of AI Agent Protocols (arXiv:2504.16736) 。
5. TUMIX (arXiv:2510.01279) ; MAKER (arXiv:2511.09030) ; Thinking vs Doing (arXiv:2506.07976) ; MultiAgentBench (ACL 2025, long.421) ; AgentSociety (arXiv:2502.08691) ; MegaAgent (ACL 2025 Findings, 259) 。
6. 经典背景: Kaplan 2020 (2001.08361) ; Chinchilla 2022 (2203.15556) ; Attention 2017 (1706.03762) ; AutoGen 2023 (2308.08155) ; Castro & Liskov 1999; HotStuff (1803.05069) ; Switch Transformers (2101.03961) ; Krogh & Vedelsby 1995; Emergence Mirage (2304.15004) ; Conformal Prediction (2107.07511) 。
7. 产业披露 (G 组): Kimi K2.6/K3 (arXiv:2607.24653) ; 蚂蚁 Agentar 2.0 (WAIC 2026) ; 浪潮整机柜 (2026-07) ; 华为 openJiuwen (arXiv:2608.27969) 与 熵(τ)定律 (ISCAS 2026-05-25) ; Anthropic 研发自动化数据 (2026-09) ; OpenAI 自动化研究实习生 (2026-09-06) ; Cyber Strategy Institute AI SAFE² Pillar 3 (2026-05) 。

证据纪律与复现说明

- 本文为证据台账与预测登记论文，无新增实验；三态核验于 2026-09-21 完成，方法为对每条线索独立联网复核。
- 已核验 仅代表文献存在性与题录一致，论文内数字仍”未独立复核”；部分核验 一律以本文实际值为准；查无实据 一律 [CITATION NEEDED] 。
- 被剔除/降级九条（第 5 节）是本卷的硬纪律，任何专篇引用相关数字时不得回退到用户原始线索值。

- F6-F10 为设计提案的可证伪记分条件，标”待 2027 年记分”；投稿前应对 部分核验 条目逐篇打开正文二次复核。