




中国的AI分级：制度&技术设计——面向 教育场景的多维AI分级治理平台

China's AI Classification: Institutional & Technical Design — A Multi-Dimensional AI Classification Governance Platform for Education

UDOS 推演引擎 v7.7.7 · 房文新 · 2026-09-21

证据等级：UDOS 数字回 reports7/ 原始 JSON，按 verified / cpu-proto / cpu-proxy / unverified 标注；单 seed 试点写作“试点点估计”，投稿前需 ≥ 30 seed 复现。

Working Title (EN): China's AI Classification: Institutional & Technical Design — A Multi-Dimensional AI Classification Governance Platform for Education

P38 · 增补卷 v7.7.7 · 孪生地球 Twin Earth · 房文新 · 2026-09-21

一句话先说清：AI 分级不是给模型贴”好/坏”标签，而是给“谁在什么场景下、用什么能力的 AI、做什么任务、受谁监督、用多少额度、在什么时段”做动态授权。本文把中国自上而下的法规谱系（个保法→未保条例→生成式AI办法→标识办法+GB 45438→教育部”分类分级”政策）与国际对照（EU AI Act 四级风险、COPPA、GDPR-K）转译为一套可落地的十维分级编码、PDP/PEP 决策函数、十层系统架构、数据模型与 API、学段策略矩阵，并给出技术选型的精华与糟粕、失效边界与可证伪预测。全文不含新实验；所有设计提案标”设计提案·待实施”，额度/时长数字标”策略示例·可配置”，外部法规与工具均附官方来源与三态标注。

证据口径（全文只声明这一次）：中国法规核至 gov.cn / npc.gov.cn / cac.gov.cn / moe.gov.cn / std/openstd.samr.gov.cn 官方原文，访问日期 2026-09-21；国际制度核至欧盟委员会、FTC/Federal Register、ICO、NIST、OASIS 官方页面；技术组件核至 CNCF、NVIDIA、Meta HF、Microsoft、BerriAI 官方文档与 arXiv。三态：✅已核验（官方原文可访问）／🟡部分核验（存在性确认但个别字段为指导性文件或二手转述）／❌查无实据（标 [CITATION NEEDED]）。UDOS 自有实测数字本篇几乎不引用；凡引用均带 verified/cpu-proto/unverified 三级标注。

摘要

生成式 AI 进入教育场景后，“一刀切禁用”与”无边界放开”都不可持续：前者剥夺学生学习 AI 素养的机会，后者把未成年人暴露在内容安全、数据隐私、过度依赖与学术诚信的多重风险中。中国法规体系已给出”分类分级”的制度方向——《生成式人工智能服务管理暂行办法》（七部门令第15号，2023-08-15 施行）第3条明文”分类分级监管”，2026-04 教育部等五单位《“人工智能+教育”行动计划》正式提出”分类分级确定安全防护标准”，2025 年教指委《中小生成式人工智能使用指南》明确”小学阶段禁止学生独自使用开放式内容生成功能”。但制度方向不等于可执行的技术方案。

本文的核心贡献是把制度方向转译为工程设计：①构建十维分级编码（安全 S0-S4、年龄 A0-A5、内容主题 C0-C4、认知准备度 L0-L5、智能化 I0-I5、内容来源 G0-G4、版本 V0-V3、权限 P0-P5、额度 Q0-Q5、时间 T0-T4），其中用户原始清单中第3/6项重名”内容分级”，本文裁定拆分为”内容主题/风险分级”与”内容来源/原创性分级”；②定义决策函数 $Decision=f(\text{身份,年龄,角色,学段,认知准备度,场景,任务,内容,请求I级,版本,权限,额度,时间,监护人同意,教师监督})$ ，输出九种枚举，拒绝须给教育性替代；③设计十层系统架构（接入→身份组织→分级策略中心→内容安全→模型网关→教育编排→记忆学情→额度时间→审计合规→管理后台），采用 PDP/PEP 分离与 Policy as Code；④给出数据模型、关键 API、学段策略矩阵与教育编排机制（前置任务门、苏格拉底提示、过程证据、AI 使用声明、教师终评、考试禁用）；⑤与 UDOS 治理体系（L0-L5 自主性、证据工程规则优先、TransferBundle 最小权限、BFT-lite 多人复核、质量饱和律）建立映射；⑥对 OPA/Casbin、Llama Guard/NeMo Guardrails/Presidio/LiteLLM、AI 检测工具、年龄保证技术做精华与糟粕批判；⑦给出失效边界、可证伪条件与预测。

关键词：AI分级；教育治理；生成式人工智能；Policy as Code；PDP/PEP；未成年人保护；内容标识；渐进开放；人类在环；可审计

结构化摘要（背景问题 → 方法/论点 → 证据 → 贡献）

- **背景问题：**生成式 AI 进入教育场景后，“一刀切禁用”与“无边界放开”均不可持续；中国法规已提出“分类分级”方向（生成式AI办法第3条、教育部2026行动计划），但缺少从制度到可执行技术方案的转译。
- **方法/论点：**把“分级”从单一年龄开关重构为十维正交的动态授权体系，用 PDP/PEP 分离 + Policy as Code 实现策略与模型解耦，用教育编排层保证“先自己想、AI 做提示教练、教师保留最终判断”。
- **证据线索：**(1) 中国14项法规/政策核至官方原文（含生成式AI办法七部门令第15号、未保条例国务院令第766号、个保法第31条、标识办法国信办通字〔2025〕2号+GB 45438-2025、教育部2026”AI+教育”行动计划）；(2) 国际对照核至 EU AI Act（Annex III 教育高风险、情绪识别 Art.5(1)(f) 禁止）、COPPA 2025修订、GDPR Art.8；(3) 技术组件核至 OPA/CNCF、NIST SP 800-162、Llama Guard 3、NeMo Guardrails、Presidio、LiteLLM、共形预测 arXiv: 2107.07511；(4) AI检测工具偏见有同行评审硬证据 Liang et al. 2023, Patterns 4(7) 100779。
- **贡献：**十维分级编码体系、决策函数与输出枚举、十层系统架构、数据模型与API、学段策略矩阵、与UDOS治理映射、技术选型精华糟粕批判、失效边界与可证伪预测。

1 问题与定位：分级不是给AI贴标签，是给”人—场景—能力”授权

一句话结论：教育场景的 AI 治理失败，本质是把”AI 能不能用”当成了一个布尔开关，而真正需要治理的是”谁、在什么场景、用什么能力、做什么任务、受谁监督”这一组多维约束。

1.1 两种极端都不可持续

当前教育领域对生成式 AI 的态度呈现两极：

- **“一刀切禁用”：**部分学校/地区禁止学生在校使用任何生成式 AI。其代价是剥夺学生学习 AI 素养的机会——而 2024-12 教育部办公厅《关于加强中小学人工智能教育的通知》已明确要求按学段推进 AI 教育（小学低年级感知体验、小学高年级和初中理解与使用、高中项目创作与高阶技术应用），禁用与政策方向相悖。
- **“无边界放开”：**部分平台直接向未成年人开放全功能生成式 AI，不做年龄判定、内容适配、时长限制或过程留痕。这直接违反《未成年人网络保护条例》（国务院令第766号，2024-01-01 施行）要求的”时间管理、权限管理、消费管理”，也违反《生成式人工智能服务管理暂行办法》第10条”防范未成年人过度依赖沉迷”。

两极之间的可行路径是**分级治理**——但”分级”常被简化为”按年龄一刀切”，这同样不够。

1.2 为什么单一年龄分级不够

单一年龄分级至少有四个盲区：

1. **同一年龄，认知准备度差异大：**同样12岁，有的学生可以批判性使用 AI，有的仍需教师全程代理。年龄是门槛，不是能力证明。

- 2. 同一年龄，场景差异大：课堂作业中用 AI 做苏格拉底提示是学习，考试中用 AI 生成答案是作弊。场景必须独立于年龄做分级。
- 3. 同一年龄，任务认知复杂度差异大：用 AI 解释一个概念（L1 理解）和用 AI 写一篇研究论文（L5 创造）需要完全不同的权限与监督。
- 4. 同一年龄，AI 自主性差异大：用 AI 做检索问答（I1）和让 AI 作为多智能体自主执行任务（I5）的风险等级完全不同。

因此，本文把”分级”重构为十维正交的动态授权体系。

1.3 本文定位与边界

本文是一篇制度+技术设计论文，不是实证研究论文。它回答的问题是：在中国现行法规框架下，面向教育场景的 AI 分级治理平台应该如何设计？它不声称已经实现或验证了该平台——所有架构、接口、策略矩阵均为设计提案·待实施，标注 [RESULT NEEDED]。

本文不讨论：通用 AI 安全对齐的技术细节（RLHF、红队训练等）、具体模型的能力评测、教育心理学的学习效果实证。这些是相邻但独立的议题。

本章小结：AI 分级的治理对象不是 AI 本身，而是”人—场景—能力—任务—监督”的多维组合；单一年龄开关有四个盲区，需要十维正交体系。

2 制度依据：中国法规谱系与国际对照

一句话结论：中国已形成”法律（个保法）→行政法规（未保条例）→部门规章（生成式AI办法/算法/深度合成/标识/儿童规定）→国家标准（GB 45438）→教育行业政策（教育部分类分级）“的自上而下法规谱系，”分类分级”已从网信领域的监管原则上升为教育行业的正式政策表述；国际对照中 EU AI Act 把教育招生/评分/考试监控明确列为高风险、情绪识别直接禁止，为中国方案提供了风险分级的参照系。

2.1 中国法规谱系（按法律效力层级）

表 1 中国 AI 分级治理相关法规政策谱系（14项，全部核至官方来源，访问日期 2026-09-21）

层级	法规/政策名称	发布机构	文号/标准号	施行日期	对AI分级的核心含义	核验状态
法律	个人信息保护法	全国人大常委会	主席令第91号	2021-11-01	第31条：不满14周岁须监护人同意+专门规则；第28条敏感个人信息	✓
行政法规	未成年人网络保护条例	国务院	国务院令 第766号	2024-01-01	要求时间管理/权限管理/消费管理；防沉迷/防欺凌专章；	✓

层级	法规/政策名称	发布机构	文号/标准号	施行日期	对AI分级的核心含义	核验状态
					覆盖未满18岁全段	
部门规章	生成式人工智能服务管理暂行办法	七部门	七部门令第15号	2023-08-15	第3条”分类分级监管”；第10条防沉迷；第12条内容标识；第17条算法备案	✓
部门规章	互联网信息服务算法推荐管理规定	四部门	四部门令第9号	2022-03-01	第24条算法备案；未成年人不沉迷模式；关闭算法推荐选项	✓
部门规章	互联网信息服务深度合成管理规定	三部门	三部门令第12号	2023-01-10	深度合成内容显著标识；分类分级备案	✓
部门规章	儿童个人信息网络保护规定	国家网信办	网信办令第4号	2019-10-01	“儿童”=不满14周岁；监护人同意；专人负责；保存记录	✓
部门规章	人工智能生成合成内容标识办法	四部门	国信办通字〔2025〕2号	2025-09-01	显式标识+隐式标识（元数据/水印）为强制要求；对话式生成须提示标识	✓
国家标准	网络安全技术 人工智能生成合成内容标识方法	市场监管总局+国标委	GB 45438-2025	2025-09-01	规定显式/隐式标识技术方法；不符合标准不得对境内公众提供	✓
规范性文件	教育信息化2.0行动计划	教育部	教技〔2018〕6号	2018-04	信息素养测评、网络学习空间（政策源流）	✓
规范性文件	关于加强中小学人工智能教育的通知	教育部办公厅	[CITATION NEEDED]（文号未逐字核对）	2024-12	按学段分层：小学低感知体验→初中理解使用→高中项目创作	●
规范性文件				2025-04		●

层级	法规/政策名称	发布机构	文号/标准号	施行日期	对AI分级的核心含义	核验状态
规范性文件	关于加快推进教育数字化的意见	教育部等九部门	[CITATION NEEDED]		落实算法与大模型备案机制；规范AI进校园	
	“人工智能+教育”行动计划	教育部等五单位	[CITATION NEEDED]	2026-04	第（十六）条”分类分级确定安全防护标准”；教育大模型安全审核	●
	中小生成式人工智能使用指南（2025年版）	教育部基础教育教学指导委员会	无令号	2025-05	“小学阶段禁止学生独自使用开放式内容生成功能”；初中适度探索；高中应用	●
类比参考	关于进一步严格管理 切实防止未成年人沉迷网络游戏的通知	国家新闻出版署	国新出发〔2021〕14号	2021-09-01	仅借”年龄+时长+实名”制度逻辑；类比非直接适用于AI教育	✓

表1注：七部门=网信办、发改委、教育部、科技部、工信部、公安部、广电总局；四部门（算法推荐）=网信办、工信部、公安部、市场监管总局；三部门（深度合成）=网信办、工信部、公安部；四部门（标识办法）=网信办、工信部、公安部、广电总局。事实纠正：算法推荐规定为四部门而非七部门。

2.2 法规谱系的三条制度主线

从表1可以提炼出三条贯穿全谱系的制度主线，它们直接对应本文的技术设计维度：

- 主线一：分类分级监管——生成式AI办法第3条确立”包容审慎和分类分级监管”原则，教育部2026行动计划把它落到教育场景（“分类分级确定安全防护标准”）。这是本文”十维分级编码”的直接法源。
- 主线二：未成年人分层保护——一个保法第31条+儿童规定把”不满14周岁”设为监护人同意的硬门槛；未保条例把保护范围扩展到未满18周岁全段，要求时间/权限/消费管理。这意味着年龄分级不能只切14岁一刀，而应覆盖 A0–A5 全段并差异化设计（<14岁强监护人同意，14–18岁未成年人模式+学校/家长知情）。
- 主线三：内容标识与可追溯——深度合成规定（2023）→标识办法+GB 45438（2025-09-01）形成”显式标识+隐式标识（元数据/数字水印）”的强制技术要求。这是本文”内容来源/原创性分级 G0–G4”和”过程证据”机制的技术法源。

2.3 国际对照：EU AI Act 四级风险与教育定位

表 2 EU AI Act 四级风险与教育场景对照（核至欧盟委员会官方页面，访问日期 2026-09-21）

风险等级	定义要点	教育场景示例	义务要求
不可接受风险 (Art.5)	对基本权利构成明显威胁，直接禁止	教育机构/工作场所中的情绪识别AI (Art.5(1)(f) 明文禁止)；社会评分；推断受保护属性的生物特征分类	禁止投放市场/投入使用
高风险 (Art.6+Annex III)	可能对健康安全或基本权利产生显著不利影响	Annex III 第3类”教育与职业培训”：招生/入学筛选、学习结果评估、教育水平评定、考试过程行为监控	全生命周期合规：风险管理、数据治理、技术文档、记录留存、透明度与人工监督、稳健性与网络安全、合格评定、CE标志、登记
有限风险 (Art.50透明度)	不构成禁止或高风险，但须履行透明度义务	通用教育聊天机器人、AI辅导对话（非用于评分/录取）；AI生成教育材料	告知用户正在与AI交互；披露AI生成/操纵内容
最小风险	绝大多数AI应用，无特定义务	课堂作业辅助建议、个性化练习推荐	无强制义务；鼓励自律与AI素养

表2注：EU AI Act (Regulation (EU) 2024/1689) 2024-08-01 生效；禁止条款与AI素养义务 2025-02-02 起适用；GPAI 模型义务 2025-08-02 起适用；绝大多数高风险义务 2026-08-02 起适用。

EU AI Act 对本文的三个关键启示：

1. **教育不是单一风险等级**：用于招生/评分/考试监控的 AI 是高风险，用于课堂辅导的聊天机器人是有限风险——这印证了本文”场景独立分级”的设计。
2. **情绪识别在教育场景被直接禁止**：Art.5(1)(f) 明文禁止在教育机构和工作场所使用情绪识别 AI。本文的”认知准备度 L0–L5” 必须严格限定为”任务认知复杂度适配标签”，不得走向情绪识别或心理状态推断。
3. **高风险义务的核心是”人工监督+记录留存”**：这与本文”人类在环、可解释可审计”的设计原则完全对齐。

2.4 其他国际制度要点

- **COPPA (美国)**：13岁以下儿童个人信息须取得可验证家长同意 (VPC)；2025-01-16 FTC 通过最终修订规则，新增知识认证 (KBA) 与人脸识别 (须人工复核) 作为 VPC 方式。与中国个保法第31条 (<14岁) 的年龄线不同，但制度逻辑一致——低龄段强监护人同意。
- **GDPR Art.8 (欧盟)**：数字服务同意年龄默认16岁，成员国可在13–16岁区间下调 (英国13、德国16、法国15、奥意西14，后三项为二手学术mapping [CITATION NEEDED])。跨国部署需按最严或逐国适配。
- **Age Assurance (英国 ICO)**：按风险分级的年龄确信度——低风险可自声明，高风险须 hard identifiers (政府ID) /年龄估计等多因子。自声明年龄可被轻易绕过，面部年龄估计对未成年人、不同肤色存在偏见与隐私争议。教育场景应优先采用政府数字身份或家长账户验证，AI 年龄估计仅作辅助信号。
- **FERPA (美国)**：保护学生教育记录隐私；AI 厂商在自有服务器上生成且未回传学校的推断性分析是否构成 FERPA”教育记录”，截至2025年初 DOE 尚无最终明确解释 🟡。

本章小结：中国已形成自上而下的”分类分级”法规谱系，三条主线（分类分级监管、未成年人分层保护、内容标识可追溯）直接对应技术设计维度；EU AI Act 证明教育场景需按用途分级（高风险/有限风险），情绪识别被直接禁止，高风险义务核心是人工监督+记录留存。

3 十维分级编码

一句话结论：十维分级编码把”分级”从模糊的政策口号变为可计算、可版本化、可审计的工程对象；其中用户原始清单中第3/6项重名”内容分级”，本文裁定拆分为”内容主题/风险分级（C0–C4）“与”内容来源/原创性分级（G0–G4）“，避免策略引擎冲突。

图1 十维分级总览：Decision = f(身份, 年龄, 角色, 场景, 内容, 任务, 模型, 版本, 权限, 额度, 时间, 同意, 监督)




图1 十维分级总览：Decision=f(身份,年龄,角色,场景,内容,任务,模型,版本,权限,额度,时间,同意,监督)。十维正交：安全是红线、年龄是门槛、认知是适配、自主性是路由、权限/额度/时间是约束、版本是可回滚。（概念示意）

3.1 十维编码定义大表

表 3 十维分级编码定义与教育映射

#	维度	编码	等级定义	教育映射	技术实现
1	安全分级	S0–S4	S0正常/S1提醒/S2拦截/S3高危转人工/S4危机干预	自伤·暴力·色情·违法·心理危机·隐私；S4不继续生成、转监护人/学校心理老师	多模态审核、分类器、危机干预工单
2	年龄分级	A0–A5	A0学前(0-5)/A1小学低(6-8)/A2小学高(9-11)/A3	低龄默认无自由生成、教师/家长代理；高中逐步开放	IAM、学籍、监护人同意、年龄断言

#	维度	编码	等级定义	教育映射	技术实现
			初中(12-14)/A4高中(15-18)/A5大学成人(18+)		
3	内容主题/风险分级	C0-C4	C0通识/C1学科儿童适宜/C2争议/C3敏感高风险/C4成人专业	标签含适龄性、事实性、争议性、来源可信度；暴力/色情/自伤/隐私按等级拦截或引导	内容标签、分类器、知识库、RAG
4	认知准备度	L0-L5	L0记忆/L1理解/L2应用/L3分析/L4评价/L5创造（布鲁姆分类）	用户明确”智力分级”改名认知准备度；仅内部适配标签，禁止贴标签/排名/分流/预测未来，可申诉可重置	任务模板、学段评估、动态更新
5	智能化/自主性分级	I0-I5	I0无AI/I1检索/I2模板单轮/I3多轮对话/I4工具代理/I5多智能体自主	低龄限I0-I2，高中受控I3-I4试点，教师I4-I5；与UDOS L0-L5、SAE J3016呼应	模型网关、能力注册卡、工具白名单
6	内容来源/原创性分级	G0-G4	G0人工原创/G1 AI辅助/G2 AI生成已审/G3 AI直生/G4 AI代写未声明	水印+原创性检测+过程记录；支撑学术诚信与教学评价	数字水印、原创性检测、过程证据库
7	版本分级	V0-V3	V0实验/V1试点/V2稳定默认/V3强制	策略·模型·标签·SDK版本；灰度/回滚/审计；教育默认稳定版禁止自动升级	版本管理、灰度发布、回滚机制
8	权限分级	P0-P5	P0无/P1只读/P2受限对话/P3生成/P4 API/工具/P5管理	角色：学生/家长/教师/教研/管理员/监管； final_assessment 评价权仅教师	RBAC+ABAC、OPA/Casbin
9	额度分级	Q0-Q5	token/次数/时长/并发/成本/字符/图片	按年龄·学段·任务·信用动态；低龄低额度，教师较高	配额中心、限流、计量
10	时间分级	T0-T4	T0禁用/T1课堂监督/T2家庭时段/T3自由时段/T4考试禁用	时段/连续时长/日累计/冷却/夜间锁/课堂模式；考试模式全局禁用	时钟策略、场景模式、屏幕时间

3.2 关于第3/6项重名的裁定说明

用户原始设计素材中第3项和第6项均命名为“内容分级”，这会导致策略引擎中两个同名字段冲突。本文裁定如下如下：

- **第3项 = 内容主题/风险分级 (C0-C4)**：回答“这段内容在讲什么、风险多高、是否适龄”。它是内容安全与适龄适配的维度。
- **第6项 = 内容来源/原创性分级 (G0-G4)**：回答“这段内容是谁写的、AI 参与了多少、是否声明”。它是学术诚信与过程追溯的维度，直接对应《标识办法》+GB 45438 的显式/隐式标识要求。

另一套草稿中提出的“内容呈现分级 P0-P4 (纯文本/图文/多模态/交互/沉浸)”可作为**备选第十一维**，但本文不纳入核心十维——因为呈现方式更多是交互设计选择，而非治理决策维度。如需纳入，建议命名为“呈现模态分级 M0-M4”以避免与 C/G 混淆。

3.3 三个关键区分

区分一：安全分级 (S) vs 内容主题分级 (C)。S 是红线——S3/S4 直接拦截或转人工，不讨论“是否适龄”；C 是适配——C2 争议内容在高中可以引导讨论，在小学则拦截。S 优先于 C：任何内容先过 S 级红线，再做 C 级适配。

区分二：认知准备度 (L) vs 智能化分级 (I)。L 是任务本身需要多少认知能力（布鲁姆分类），决定 AI 的交互方式（L0-L1 可直接反馈，L2-L3 给提示，L4-L5 辩论/反方）；I 是 AI 被允许有多强自主性，决定模型路由和工具权限。二者正交：一个 L5（创造）任务可以用 I2（模板单轮）AI 来做提示，一个 L1（理解）任务也不应该用 I5（多智能体自主）AI 来执行。

区分三：年龄 (A) vs 认知准备度 (L)。年龄是法律与制度门槛（<14岁须监护人同意），认知准备度是内部适配标签。年龄不可跳过（法律硬约束），认知准备度可动态调整、可申诉、可重置。**严禁**用认知准备度标签对学生进行排名、分流或预测未来——这是伦理红线，也呼应 EU AI Act 对教育场景高风险系统的严格约束。

本章小结：十维编码把分级变为可计算的工程对象；第3/6重名裁定拆分为内容主题 (C) 与内容来源 (G)；三个关键区分 (S vs C、L vs I、A vs L) 保证维度正交、策略无冲突。

4 决策函数与 PDP/PEP 架构

一句话结论：分级决策的核心是一个纯函数 $\text{Decision} = f(\text{输入属性}) \rightarrow \text{输出枚举} + \text{约束}$ ，采用 PDP（策略决策点）与 PEP（策略执行点）分离的架构，策略与模型解耦，每次决策可解释、可版本化、可审计。

4.1 决策函数定义

$\text{Decision} = f(\text{身份, 年龄, 角色, 学段, 认知准备度, 场景, 任务认知级, 内容安全/主题/来源, 请求I级, 版本, 权限, 额度, 时间, 监护人同意, 教师监督})$

输入分为四类：

- **主体属性**：身份(userId)、年龄(A)、角色、学段、认知准备度(L)、监护人同意状态、教师监督状态。
- **场景属性**：场景模式（课堂/作业/考试/家庭/项目）、设备、位置、网络环境。
- **资源属性**：任务类型、任务认知级(L)、内容安全级(S)、内容主题级(C)、内容来源级(G)、请求的智能化级(I)。
- **环境属性**：版本(V)、权限(P)、额度剩余(Q)、时间窗口(T)、当前时钟。

4.2 输出枚举

表 4 决策输出枚举与含义

枚举	含义	典型触发条件
ALLOW	允许，按默认模式执行	所有约束满足
DENY	拒绝，返回教育性替代	安全 S3/S4、考试 T4、低龄无权限、额度耗尽
ALLOW_WITH_GUARDRAILS	允许但加护栏（强制引用/过程记录/不直接给答案）	初中生成作文、高中项目
REQUIRE_SUPERVISION	需教师/家长监督后执行	低龄请求高 I 级、敏感内容 C2/C3
REQUIRE_VERIFICATION	需引用/验证/事实核查后输出	争议内容、高中研究任务
TEACHER_ONLY	仅教师可用，学生端路由到教师代理	学前/低小 A0-A1 生成式请求
DOWNGRADE_CAPABILITY	降级到更低 I 级或更保守模型	请求 I4 但策略只允许 I2
PROXY_TEACHER	教师/家长代理执行，学生不直接交互	低龄特殊需求

关键设计：拒绝不是冷冰冰的”禁止”。当决策为 DENY 时，系统必须返回**教育性替代**，例如：“这个阶段先自己写10分钟提纲，然后我可以帮你检查逻辑和用词。”这是教育场景与通用内容审核的本质区别——审核的目的不是阻止学习，而是引导学习。

4.3 决策输入输出示例

输入（JSON）：

```
{
  "subject": {
    "user_id": "u123", "role": "student", "age": 10, "grade": "小学四年级",
    "guardian_consent": true,
    "readiness": {"knowledge": 0.4, "self_control": 0.5, "risk_understanding": 0.3}
  },
  "scene": {"mode": "homework", "teacher_supervised": false, "exam_mode": false},
  "task": {"type": "writing", "subject": "语文", "cognitive_level": "L2"},
  "content": {"safety_level": "S0", "topic_level": "C1", "source_level": "G2"},
  "model": {"requested_level": "I3"},
  "quota": {"daily_remaining": 8},
```

```
"time": {"current_window": "T2", "used_minutes": 12}
}
```

输出 (JSON) :

```
{
  "decision_id": "d_001",
  "allow": true,
  "mode": "SOCRATIC_HINT",
  "model_level": "I2",
  "permissions": ["chat.limited", "rag.textbook"],
  "constraints": [
    "不直接给作文全文",
    "先提交自己的提纲",
    "必须给引用",
    "记录修改过程"
  ],
  "quota": {"max_tokens": 1200, "remaining_calls": 8},
  "time": {"max_minutes": 15, "cooldown_minutes": 30},
  "human_in_loop": "parent_notify_if_sensitive",
  "policy_version": "v2.3.1",
  "model_version": "edu-llm-v1.8-stable",
  "reasons": ["age_A2_default_I2", "writing_task_require_outline_first", "quota_sufficient"]
}
```

注意输出中包含 `policy_version`、`model_version`、`reasons` ——这是可解释性与可审计性的基础。每次决策都可以追溯到“哪条策略、哪个模型版本、为什么这样决定”。

4.4 PDP/PEP 分离架构

图2 决策流 (PEP→PDP→输出枚举) 与十层系统架构 (概念示意)




图2 决策流 (PEP→PDP→输出枚举) 与十层系统架构。PEP 部署在网关/客户端/LMS入口，负责拦截请求与执行决策；PDP 独立部署，负责策略求值，与业务代码解耦。（概念示意）




图5 核心决策时序八步：客户端请求→身份认证与年龄断言→PDP策略求值→模型网关路由与能力匹配→内容安全输入审核→教育编排（苏格拉底/前置任务门）→输出审核与审计计量→返回决策与教育性替代。旁路：记忆与学情在请求前后异步更新，不阻塞主决策链路。（概念示意）

- **PEP (Policy Enforcement Point, 策略执行点)**：部署在 API 网关、客户端 SDK、LMS 插件入口。职责：拦截所有 AI 请求 → 收集上下文属性 → 调用 PDP → 执行决策（放行/拒绝/降级/加约束）→ 记录审计。PEP 不做策略判断，只做执行。
- **PDP (Policy Decision Point, 策略决策点)**：独立部署的策略引擎。职责：接收属性 → 加载策略版本 → 求值 → 返回决策。PDP 无状态，可水平扩展。
- **PAP (Policy Administration Point, 策略管理点)**：管理后台，负责策略的编写、版本化、灰度发布、回滚。
- **PIP (Policy Information Point, 策略信息点)**：提供属性数据源（身份服务、额度服务、时间服务、学情服务）。

这一架构参考 XACML (OASIS 标准) 的 PDP/PEP/PAP/PIP 四组件分离，在云原生场景下用 OPA/Rego 或 Casbin 实现。**策略与模型解耦**是核心原则——换模型不改教育规则，换教育规则不改模型。

4.5 Policy as Code：策略即代码

分级策略用声明式语言编写 (Rego 或 Casbin 策略文件)，纳入版本控制，支持代码评审、测试、灰度发布、回滚。示例 (Rego 伪代码)：

```

# 小学低段 (A1) 学生端默认关闭自由生成
deny[msg] {
    input.subject.age <= 8
    input.subject.role == "student"
    input.model.requested_level >= "I3"
    msg := "小学低段学生端不开放自由生成，请由教师/家长代理使用"
}

# 考试模式全局禁用
deny[msg] {
    input.scene.exam_mode == true
    
```

```
msg := "考试模式下禁用生成式AI"
}

# 写作任务必须先提交提纲
constraint[c] {
    input.task.type == "writing"
    input.subject.age <= 14
    c := "require_outline_first"
}
```

策略文件本身有版本号（V0-V3），每次决策关联策略版本，支持回滚到任意历史版本。这呼应 UDOS 证据工程的”版本可追溯”原则。

本章小结：决策函数是纯函数，输入四类属性、输出九种枚举+约束；PDP/PEP 分离保证策略与业务/模型解耦；Policy as Code 让策略可版本化、可测试、可回滚；拒绝必须给教育性替代。

5 十层系统架构

一句话结论：十层架构从接入到管理后台逐层递进，核心是”分级策略中心”作为决策大脑、“模型网关”作为能力路由、“教育编排”作为学习过程守护、“审计合规”作为全链路可追溯；每层职责单一、接口明确、可独立替换。

5.1 十层架构总览

表 5 十层系统架构定义

层	名称	核心职责	关键组件
①	接入层	多端接入、协议转换、流量入口	Web/App、学校SSO、API、浏览器插件、教育软件SDK
②	身份与组织层	身份认证、组织管理、年龄断言、监护人关系	IAM(OIDC/SAML/Keycloak)、组织/班级/角色、监护人、年龄断言服务
③	分级策略中心	策略决策、规则引擎、版本管理	PDP/PEP、Policy as Code(OPA/Rego/Casbin)、决策表、灰度/回滚
④	内容安全与分级	输入输出审核、多模态分类、危机干预	多模态审核、分类器(Llama Guard等)、知识库、危机干预工单
⑤	模型网关	模型路由、提示模板、RAG、工具调用、能力注册	LiteLLM路由、提示词模板、RAG白名单知识库、工具白名单、能力注册卡

层	名称	核心职责	关键组件
⑥	教育编排层	任务模板、苏格拉底引导、先答后问、过程记录	任务模板、SOCRATIC_HINT模式、前置任务门、过程证据采集
⑦	记忆与学情层	学习档案、知识图谱、掌握度、认知负荷、原创性检测	学习档案、知识图谱、掌握度模型、认知负荷评估、原创性检测
⑧	额度与时间层	计量、配额、限流、时钟、课堂模式	计量服务、配额中心、限流、时钟策略、课堂模式/考试模式
⑨	审计与合规层	日志、可解释、报告、申诉、数据留存	审计日志、决策可解释、家长/教师报告、申诉通道、数据留存/删除
⑩	管理后台	学校/家长/教师/监管多视角管理	学校管理端、家长控制端、教师工作台、监管报表端

5.2 核心数据流

客户端请求

→ ①接入层 (PEP拦截)

→ ②身份与组织 (认证+年龄断言+监护人同意)

→ ③分级策略中心 (PDP求值 → 决策+约束)

→ ⑤模型网关 (路由到对应I级模型 + 提示模板 + RAG + 工具)

→ ④内容安全 (输入审核 → 生成 → 输出审核)

→ ⑥教育编排 (苏格拉底模式/前置任务门/过程记录)

→ ⑧额度与时间 (扣减配额/更新时长)

→ ⑨审计合规 (记录决策+输入+输出+版本 → 生成报告)

→ 返回客户端 (带decision_id + constraints + citations + audit)

旁路：⑦记忆与学情在请求前后异步更新（掌握度、认知负荷、原创性），不阻塞主决策链路。

5.3 三层关键设计说明

设计一：模型网关的能力注册卡。每个模型/工具/Agent 都有一张”能力注册卡”，记录：智能化级(I)、支持的内容级(C)、适用年龄下限(A)、版本(V)、是否可记忆、是否可联网、是否可生成代码/图片/文件、成本/Token速率、已知局限。模型网关根据 PDP 决策选择满足约束的模型——例如决策要求 I2+C1+A2，则网关只路由到满足这三个条件的模型，不允许”请求什么模型就用什么模型”。这是**能力路由**而非简单的 API 代理。

设计二：教育编排层的”前置任务门”。这是整个平台最核心的教育差异点。学生调用 AI 前，必须先提交自己的思路、提纲、草稿或答案——系统校验”学生已尝试”后，才允许 AI 介入。AI 默认进入 SOCRATIC_HINT（苏格拉底提示）模式，只给问题、线索、检查点，不直接给答案。高中阶段可开放”反方观点模式”，但必须标注证据和来源。这一设计直接呼应 2025 教指委指南”小学禁止独自使用开放式生成”的政策红线，也体现”AI 是提示教练，不是代写工具”的教育哲学。

设计三：审计合规层的”决策可解释”。每次决策记录：谁(userId)、何时、什么场景、用了哪个模型版本、哪个策略版本、输入属性快照、输出决策、理由(reasons)、是否被教师覆盖、覆盖理由。家长/教师/监管可按 decision_id 查询完整决策链。这呼应 EU AI Act 高风险系统的”记录留存”义务，也呼应 UDOS 证据工程的”三层一致”原则。

5.4 技术选型

表 6 技术选型建议（均核至官方文档，访问日期 2026-09-21）

层级	推荐组件	备选	选择理由	局限/注意
策略引擎	OPA/Rego	Casbin、Drools	CNCF毕业项目 (2021-01-29)、PDP/PEP原生支持、Rego 表达力强	Rego学习曲线陡峭；策略正确性需测试
身份	Keycloak(OIDC/SAML)	Auth0、学校SSO对接	开源、支持联邦身份、教育场景常见	需与教育学籍系统对接
网关	Kong/APISIX/Envoy	—	PEP部署点、限流、认证	网关本身成为关注点
模型网关	LiteLLM	自研路由	统一100+提供商(厂商口径)、成本跟踪、fallback	企业级SSO为付费版；不同提供商工具调用支持不一致
内容安全	Llama Guard 3 + NeMo Guardrails + Presidio	Guardrails AI、自研分类器	Llama Guard S1-S13 分类、NeMo编排、Presidio PII脱敏	中文教育敏感词需自微调；不能替代人工审核
知识库/向量	pgvector/Milvus	—	RAG白名单教材库	需定期更新教材版本
事件/工作流	Kafka/Temporal	—	异步审计、额度扣减、重试	增加系统复杂度
数据存储	Postgres/Redis/ClickHouse	—	结构化数据/缓存/审计日志分析	未成年人数据需加密+区域驻留
可观测性	OpenTelemetry/ELK	—	全链路追踪、日志聚合	—
部署	K8s	私有化/混合云	区域数据驻留、弹性伸缩	教育私有化部署需考虑运维能力

本章小结：十层架构职责单一、接口明确；三个关键设计（能力注册卡、前置任务门、决策可解释）是教育场景的核心差异；技术选型优先成熟开源组件，但中文教育敏感词需自微调、AI检测工具不可作为唯一判定依据。

6 数据模型与关键 API

一句话结论：数据模型围绕”决策可追溯”设计，核心实体是 User、Policy、Decision、AuditLog、ProcessEvidence；API 以 `/v1/ai/query` 为核心入口，所有请求带 context、所有返回带 decision_id，保证端到端可审计。

6.1 核心数据模型

表 7 核心数据实体与关键字段

实体	关键字段	说明
User	user_id, role, age, grade, org_id, class_id, status	角色：student/parent/teacher/researcher/admin/regulator
AgeProfile	user_id, age_band(A0-A5), birth_date, age_assertion_method, guardian_verified	年龄断言方法：学籍/家长账户/政府ID/自声明(仅低风险)
GuardianConsent	consent_id, student_id, guardian_id, scope, granted_at, revoked_at, status	可撤销；scope限定数据用途
Role/Permission	role_id, permissions[], data_scope, final_assessment(bool)	final_assessment仅教师为true
Org/Class	org_id, org_type(school/district), class_id, grade	组织层级
Policy	policy_id, name, description, version(V0-V3), status, code(Rego), created_by	策略即代码
PolicyVersion	version_id, policy_id, version_str, changelog, 灰度范围, created_at	支持灰度/回滚
Resource/Content	content_id, content_type, safety_level(S), topic_level(C), source_level(G), labels[], creator	内容标签
ContentLabel	label_id, content_id, label_type, value, confidence, label_version	标签版本化
Model	model_id, name, provider, version, capability_level(I), cost_per_token, status	模型注册
ModelCapability	model_id, capability_card(json), min_age(A), max_content(C), tools[], limitations	能力注册卡
Session	session_id, user_id, scene, started_at, ended_at, duration, mode	会话

实体	关键字段	说明
Request	request_id, session_id, prompt_hash, attachments_hash, task_type, cognitive_level(L), timestamp	请求（内容哈希，不存原文以保护隐私）
Decision	decision_id, request_id, policy_version, model_version, input_snapshot, output(json), reasons[], created_at	核心可追溯实体
Quota	user_id, period, quota_type(token/ calls/time/cost), limit, used, remaining	额度
TimeWindow	user_id, date, window_type(T0- T4), allowed_hours, used_minutes, cooldown_until	时间
AuditLog	log_id, decision_id, actor, action, timestamp, metadata	审计
Consent	consent_id, user_id, type, scope, granted_at, revoked_at	同意管理
Guardian	guardian_id, student_ids[], relationship, contact_verified	监护人
ClassroomMode	class_id, mode(active/exam/ locked), teacher_id, started_at, ended_at	课堂/考试模式
Assessment	assessment_id, student_id, task_id, teacher_id, ai_assisted(bool), process_evidence_ids[], final_score, teacher_notes	教师终评，AI不做最终评价
ProcessEvidence	evidence_id, session_id, type(draft/outline/prompt/ modification/citation), content_hash, timestamp, ai_usage_declaration	过程证据：草稿史/提示/修改轨迹/引用
TeacherOverride	override_id, decision_id, teacher_id, original_decision, new_decision, reason, timestamp	教师可覆盖但留痕

6.2 关键 API

表 8 关键 API 定义

方法	路径	说明	关键输入	关键输出
POST	/v1/ai/query	核心AI查询入口	context(userId,role,age,scene,task,prompt,attachments,requested_I_level)	decision_id, allowed, model, constraints, content, citations, hints, audit
POST	/v1/policy/evaluate	策略求值（调试/审计用）	input_attributes	decision, reason, policy_version
POST	/v1/content/classify	内容分类	content_text/hash	safety_level(S), topic_level(C), source_level(C), labels
POST	/v1/quota/check	额度检查	userId, quota_type	remaining, limit
POST	/v1/quota/consume	额度扣减	userId, quota_type, amount	new_remaining
POST	/v1/time/check	时间窗口检查	userId, scene	allowed, current_window, remaining_min
POST	/v1/audit/log	审计日志写入	decision_id, actor, action, metadata	log_id
POST	/v1/guardian/consent	监护人同意授予/撤销	student_id, guardian_id, scope, action	consent_id, status
POST	/v1/teacher/override	教师覆盖决策	decision_id, new_decision, reason	override_id
GET	/v1/report/guardian/{student_id}	家长报告	student_id, period	usage_summary, decisions, alert, quota
GET	/v1/audit/decision/{decision_id}	决策详情查询	decision_id	full decision context

6.3 /v1/ai/query 的契约

请求必须携带：用户身份、年龄、角色、班级、场景（课堂/作业/考试/家庭/项目）、任务类型、是否教师监督、是否家长同意、请求的模型能力级别、内容附件哈希、隐私标记。

返回必须包含：决策ID、是否允许、教育模式（直接回答/SOCRATIC_HINT/只给线索/拒绝并替代）、引用来源、额度与时间约束、审计ID。

设计提案·待实施 [RESULT NEEDED]: 以上 API 为设计提案，尚未实现。实际实现时需补充：认证中间件、速率限制、错误码规范、WebSocket 流式响应支持、版本化 API 迁移策略。

本章小结：数据模型围绕 Decision 核心可追溯实体设计，ProcessEvidence 和 TeacherOverride 是教育场景特有的实体；API 以 `/v1/ai/query` 为核心，所有请求带 `context`、所有返回带 `decision_id`；均为设计提案·待实施。

7 学段策略矩阵与教育编排

一句话结论：学段策略矩阵把十维编码落到每个年龄段的具体权限与约束，数字均为策略示例·可配置；教育编排层通过”前置任务门、苏格拉底提示、过程证据、AI使用声明、教师终评、考试禁用”六大机制保证”AI 是提示教练，不是代写工具”。

7.1 学段策略矩阵




图3 学段×维度策略矩阵（策略示例·可配置，非实测；颜色越绿开放度越高）。学前/低小锁定，高小受控问答，初中生成+引用+过程，高中开放+批判+项目，教师全功能但不做最终评价。




图4 分级门渐进开放六扇门：年龄轴 A0→A5，权限从”安全红线/教师代理”逐级打开到”全功能/审计”。每扇门对应一组默认策略，可被教师/家长/监管在授权范围内调整，但不可越级跳过安全红线。“分级不是开关，是门：该慢则慢、该放则放。”（策略示例·可配置）

表 9 学段策略矩阵（所有额度/时长数字为策略示例·可配置，非实测）

学段	年龄	默认权限	智能级(I)	典型模式	额度/时间(示例)	监督
学前 A0	0-5	学生端无自由生成	I0–I1	教师/家长代理、白名单内容、故事/识字	Q0, T0/T1	强
低小 A1	6-8	学生端无自由生成	I0–I1	教师/家长代理、白名单问答	Q0, T0/T1	强
高小 A2	9-11	受限问答+教材RAG	I1–I2	苏格拉底提示、先答后问、提示卡	10–20次/日，15–20min	家长同意
初中 A3	12-14	可生成但强制引用+过程记录	I2–I3	辩论、实验、逻辑分析、反代写检测	30–50次/日，30min	教师监督
高中 A4	15-18	开放+批判+项目+API教师监督试点	I3–I4	AI素养、反方观点、验证、项目创作	80–200次/日，60min	教师试点, 考试禁用
教师 A5	18+	全功能但不做最终评价	I4–I5	备课、出题、批改辅助、学情分析	按组织配额	审计
考试场景	任意	全局禁用生成式AI	I0	仅白名单离线工具(计算器/词典)	Q0, T4	监考

表9注：额度/时长数字为策略示例·可配置，实际部署时应由学校/区域根据学情、设备、网络条件调整，并经过试点验证。低龄段的”无自由生成”直接对应 2025 教指委指南”小学阶段禁止学生独自使用开放式内容生成功能”。

7.2 教育编排六大机制

机制一：前置任务门（Pre-task Gate）。学生调用 AI 前，必须先提交自己的思路、提纲、草稿或答案。系统校验”学生已尝试”（通过文本输入、手写拍照识别、或教师确认）后，才允许 AI 介入。这是”先自己想”的技术实现——AI 不能替代思考过程，只能在思考之后提供反馈。

机制二：SOCRATIC_HINT（苏格拉底提示模式）。低龄段默认模式，AI 不直接给答案，只给问题、线索、检查点。例如学生问”这道数学题怎么做”，AI 回复：“你先想想这道题涉及什么运算？已知条件有哪些？第一步可以做什么？”高中阶段可切换为”反方观点模式”，AI 给出对立论证，但必须标注证据和来源。

机制三：过程证据（Process Evidence）。系统保存草稿历史、提示记录、修改轨迹、AI 对话摘要、引用来源。每条过程证据带 content_hash（不存原文以保护隐私）和时间戳。教师可查看学生的完整学习过程——这比”最终作业是否AI生成”更有教育价值，也比 AI 检测分数更可靠。

机制四：AI 使用声明（AI Usage Declaration）。作业中自动附带元数据：用了什么模型、哪个段落用了 AI、提示是什么、AI 参与程度（G0-G4）。这对应《标识办法》+GB 45438 的显式/隐式标识要求，也培养学生的学术诚信意识。

机制五：教师终评（Teacher Final Assessment）。AI 可以辅助批改、给出反馈、分析学情，但 final_assessment 权限仅教师——AI 不能直接决定学生评价。教师可覆盖 AI 决策（TeacherOverride），但必须留痕（覆盖理由、时间）。这是”人类在环”的核心体现。

机制六：考试禁用（Exam Mode Lock）。考试场景下全局 T4/Q0/I0，禁用生成式 AI，仅允许白名单离线工具（计算器、词典）。课堂模式由教师一键切换，考试模式由学校管理员配置时间窗口。这是评价公平的技术保障。

7.3 拒绝的教育性替代示例

场景	系统决策	教育性替代回复
8岁学生请求”帮我写作文”	DENY + TEACHER_ONLY	“这个阶段先自己写10分钟提纲，然后可以让老师或爸爸妈妈帮你看看。”
10岁学生请求”直接给我答案”	ALLOW_WITH_GUARDRAILS + SOCRATIC_HINT	“先说说你是怎么想的？你觉得第一步应该做什么？我可以帮你检查思路。”
14岁学生写作文不提交提纲	DENY + 前置任务门	“请先提交你的作文提纲（至少3个要点），提交后我可以帮你完善逻辑和用词。”
考试期间任何AI请求	DENY + T4	“考试模式下禁用AI，请独立完成。”
高中学生请求”帮我写完整论文”	ALLOW_WITH_GUARDRAILS + 强制引用+过程记录	“我可以帮你列大纲、找文献、检查论证，但论文需要你自已写。每段AI辅助内容会自动标注。”

本章小结：学段策略矩阵把十维编码落到具体年龄段，数字均为策略示例·可配置；教育编排六大机制（前置任务门、苏格拉底提示、过程证据、AI使用声明、教师终评、考试禁用）是” AI 是提示教练不是代写工具” 的技术实现；拒绝必须给教育性替代。

8 与 UDOS 治理体系的映射

一句话结论：本平台的十维分级与 UDOS 治理体系在五个维度上深度同构——I0-I5 对齐 UDOS L0-L5 自主性等级，Policy as Code 对齐证据工程”规则优先于学习”，TransferBundle 最小权限对齐权限分级，BFT-lite 多人复核对齐教师委员会/人审闸门，质量饱和律解释”生成可扩展、教师审查不扩展”的治理天花板。

8.1 五重映射

表 10 本平台与 UDOS 治理体系的五重映射

维度	本平台设计	UDOS 对应	映射含义
自主性分级	智能化 I0-I5（无AI→检索→模板→对话→工具代理→多智能体自主）	UDOS L0-L5 自主性等级；产业篇 SOP 闸门	教育场景限制高自主性（低龄 I0-I2），与 UDOS “自主性越高、治理成本越高”的判断一致
规则优先	内容安全/准入用确定性规则为底、学习分类器为补	证据工程 H-CSC v2：确定性词法谓词 AUROC 0.865–0.982 击败学习编码器 0.621–0.744	教育场景的安全红线（自伤/暴力/违法）必须用确定性规则拦截，不能依赖学习分类器的概率输出
最小权限	权限分级 P0-P5、RBAC+ABAC、final_assessment仅教师	TransferBundle 的 scope 最小权限字段	每次 AI 交互只授予完成任务所需的最小权限，与 UDOS “交接即契约”的最小权限原则同构
多人复核	教师可覆盖决策、教师委员会审查高风险决策、S4危机转人工	BFT-lite 三级类型化最终性；审核门禁（5人审+1红队+1版本）	高风险/高 stakes 决策需要多人复核，单一 AI 决策或单一教师决策都不够
治理天花板	生成可扩展、教师审查不扩展；AI 处理标准化，教师专注个体差异	质量饱和律（验证能力天花板：生成可扩展、审查不扩展，Little’ s Law/WIP=1）	平台的目標是用 AI 扩展”生成/反馈/分析”的产能，把教师从标准化工作中解放出来专注个体判断——但教师审查本身不可扩展，这是治理的硬天花板

8.2 规则优先于学习：H-CSC 证据对本平台的启示

UDOS 第06篇 H-CSC v2 的核心证据是：**确定性词法谓词 AUROC 0.865–0.982 击败学习语义编码器 0.621–0.744**（作者主动撤回 v1”诚实保留优势”主张后的正确口径）。这对本平台的内容安全设计有直接启示：

- **安全红线（S3/S4）用确定性规则**：自伤、暴力、违法、未成年人隐私等红线内容，必须用确定性规则（关键词、正则、模式匹配）拦截，不能依赖学习分类器的概率输出。确定性规则的优势是可解释、可审计、零幻觉——这正是教育场景最需要的。
- **学习分类器作为补充**：内容主题分级（C0–C4）、适龄性判断、争议内容识别等”灰度”决策，可以用学习分类器辅助，但必须给置信度，低置信度转人工。
- **学习编码器的失效边界**：学习分类器在分布外输入、对抗性提示、多语言混合场景下性能显著下降（H-CSC 证据显示学习编码器 AUROC 仅 0.621–0.744）。教育场景中学生会用各种方式尝试绕过（谐音、拆字、多语言），确定性规则的鲁棒性更高。

8.3 质量饱和律：为什么教师终评不可省略

UDOS 第07篇质量饱和律的核心判断是：**生成能力可扩展（加更多模型/更多算力），但验证/审查能力不可扩展（教师时间是硬约束）**，用 Little’ s Law 表达为 WIP=1 时审查吞吐有上限。

这对本平台的含义是：

- **AI 可以扩展”反馈产能”**：自动批改选择题、生成练习题、分析学情数据——这些是标准化工作，AI 可以规模化。
- **教师不可扩展”判断产能”**：学生的最终评价、个性化反馈、心理关怀、伦理判断——这些需要人类教师，AI 不能替代。
- **平台的目标不是”用 AI 替代教师”，而是”用 AI 把教师从标准化工作中解放出来”**，让教师有更多时间做 AI 做不了的事。这就是”AI 提供信息和效率，人保留判断和责任”的经济学基础。

本章小结：本平台与 UDOS 治理体系五重同构（自主性分级、规则优先、最小权限、多人复核、治理天花板）；H-CSC 证据证明安全红线用确定性规则、学习分类器为补；质量饱和律解释教师终评不可省略的经济学原因。

9 精华与糟粕：技术选型批判

一句话结论：不是所有”AI 安全工具”都适合教育场景——LiteLLM/OPA/Presidio 可直接采用，Llama Guard/NeMo Guardrails 需中文教育场景自微调，AI 生成内容检测工具（GPTZero/Turnitin/ZeroGPT）有同行评审证据证明对非英语写作者系统性误判、绝不可作为学术处分唯一依据，年龄估计 AI 有偏见与隐私争议、仅作辅助信号。

9.1 精华：适合直接采用的组件

1. **LiteLLM 作为 LLM 网关层。**把”用哪家模型、走哪个 key、花多少钱、挂了怎么 fallback”从业务代码剥离。教育平台可在不上传学生数据到厂商遥测的前提下自托管；成本跟踪与预算限流对学校/区域采购极有价值。局限：企业级 SSO/SCIM 为付费版；不同提供商对工具调用/流式/JSON Schema 的支持不一致（厂商口径”140+提供商/1800+模型”，引用时标注厂商口径）。

2. **Presidio 做学生数据出域前的 PII 脱敏。**在学生聊天/作业送外部大模型前，先识别姓名、学号、家长手机、学校名等并替换为占位符。这是 FERPA/COPPA/GDPR/个保法合规链路中性价比最高的一层。局限：对中文人名、低资源语言需自训练；脱敏不等于匿名化（链接攻击风险）；治理过渡说法（2026年向 data-privacy-stack 过渡）来自第三方，需 Microsoft 官方公告确认 [CITATION NEEDED]。

3. **OPA/Rego 或 Casbin 做策略层。**把”小学年级禁用开放聊天、中学生仅限白名单模型、考试期间禁止生成式AI”这类分级策略写成代码，PDP 独立部署，与 EU AI Act 高风险义务所需的”人工监督、记录留存”结构天然对齐。OPA 为 CNCF 毕业项目（2021-01-29），Casbin 支持多语言。局限：Rego 学习曲线陡峭；Casbin 的 ABAC 表达能力弱于 OPA/Rego。

4. **XACML/NIST RBAC/ABAC 作为架构术语与对标。**不必落地整套 XACML（XML 笨重，云原生场景多被 OPA 替代），但引用 ANSI/INCITS 359-2012（RBAC）与 NIST SP 800-162（ABAC）可把”分级访问控制”从工程口号提升到标准语言。

9.2 需要定制或二次训练的组件

5. **Llama Guard 3 / NeMo Guardrails / Guardrails AI 作为内容安全护栏。**Llama Guard 3 覆盖 S1-S13 共13类安全风险（暴力犯罪、非暴力犯罪、性犯罪、儿童性剥削、诽谤、专业建议、隐私、知识产权、indiscriminate weapons、仇恨、自杀自残、性内容、选举），但分类体系是为英语成人安全场景设计的。中文教育敏感词（校园暴力、未成年人诱导、考试泄题、超纲内容、价值观引导）需要自微调或自写 validator。建议用 NeMo Guardrails 做编排层，把 Llama Guard 3 作为其中一个内置 risk signal，而非唯一裁判。局限：规则可被多轮对话绕过；幻觉/事实核查依赖外部打分模型。

6. **共形预测做”低置信度自动降级”。**技术原理可靠（分布无关的不确定性量化，split conformal 用校准集分位数给出预测集，提供有限样本覆盖保证，参考 Angelopoulos & Bates 2021, arXiv:2107.07511），但 LLM 开放式输出没有唯一正确标签。建议先在选择题、知识点诊断、作文评分这类有明确答案集的子任务上试点，用 split conformal 给出”该 AI 回答置信度不足→转人工/转更贵模型”的兜底，而非全场景直接套。局限：依赖可交换性（exchangeability）假设，数据漂移下覆盖失效。

9.3 糟粕：有已知失效模式、不可作为唯一判定依据

7. **AI 生成内容检测（GPTZero / Turnitin / ZeroGPT）——有同行评审硬证据的系统性偏见。**

Liang, W., Yuksekgonul, M., Mao, Y., Wu, E., & Zou, J. (2023). “GPT detectors are biased against non-native English writers.” *Patterns*, 4(7), 100779. PMID: 37521038.

实验：7款主流 GPT 检测器 × 91篇中国论坛来源的非母语 TOEFL 作文 + 88篇 Hewlett Foundation ASAP 数据集美国八年级作文。

结论：检测器对非母语英语写作**系统性误判为 AI 生成**；对美国八年级作文准确率接近完美；简单 prompt 策略既缓解偏见也可绕过检测器。

对教育场景的含义：**AI 检测分数不得单独作为学术不端处分依据**。中文写作上的可信度更低（检测器主要训练英语）。本平台最多把检测分数作为”建议教师复核”的弱信号，且必须配合**人工判分、写作过程留痕（ProcessEvidence）、学生自述三重证据**。第三方报道称 Turnitin 自报非母语误判率约6-9%、母语者1-4%（该数字来自 Turnitin 自身研究的二手转述，正式引用前建议核 Turnitin 官方报告 [CITATION NEEDED]）；Vanderbilt 大学 2023-08、Curtin 大学 2026-01 先后停用 Turnitin AI 检测功能（机构决定，可作治理案例引用）。

8. 面部年龄估计 / 自声明年龄门——绕过与偏见。自声明年龄可被轻易绕过（学生随便填一个成年年龄）；面部年龄估计对未成年人、不同肤色、眼镜/口罩场景存在偏见与隐私争议（ICO 2025-2026 进展文件已要求平台”超越自声明”）。教育场景若需区分 13/14/16 岁，应优先采用**政府数字身份或家长账户验证**，把 AI 年龄估计仅作为辅助信号，且不得作为唯一准入依据。

9. “开源=安全/合规”的直觉——开源不等于合规。开源组件（Presidio、NeMo Guardrails、Llama Guard）本身不等于合规；模型训练数据许可、学生数据是否进入微调、跨境传输、日志留存周期仍需在 Policy as Code 层显式声明。Llama Guard 的社区许可需遵守 Meta Llama 社区许可条款。

本章小结：技术选型分三档——直接采用（LiteLLM/OPA/Presidio）、需定制（Llama Guard中文微调/共形预测试点）、不可作为唯一依据（AI检测工具/年龄估计AI）；AI检测工具的系统性偏见有 Liang et al. 2023 同行评审硬证据，绝不可作为学术处分唯一依据。

10 失效边界、可证伪条件与预测

一句话结论：任何分级治理平台都有失效边界——私人设备绕过、第三方教育软件SDK接入、标签无绝对标准、教师负担、误判/标签偏差、家长资源差距、策略碎片化、过度封锁损害学习、认知准备度标签的伦理风险、形式合规绕过；本章给出可证伪条件和具体预测，投稿前需≥30 seed+95%CI 验证。

10.1 失效边界清单

表 11 失效边界与影响等级

#	失效模式	影响等级	说明	缓解措施
1	私人设备绕过	高	学生用个人手机/家用电脑访问未接入策略中心的 AI 产品，平台完全无法管控	学校网络层管控+家长端联动+AI素养教育（教学生”什么场景该用什么”）
2	第三方教育软件SDK接入	高	学校采购的教育软件内嵌 AI，若不接入策略中心则成为治理盲区	SDK/API 强制接入策略中心作为采购准入条件；教育大模型安全审核机制
3	标签无绝对标准	中	内容分级（C0-C4）、认知准备度（L0-L5）的标签边界	标签版本化+多人标注+一致性监控+低置信度转人工

#	失效模式	影响等级	说明	缓解措施
			界是模糊的，不同标注者可能不一致	
4	教师负担增加	中	教师需要复核 AI 决策、查看过程证据、处理申诉，可能增加工作负担	AI 优先处理标准化工作（批改选择题、生成练习），教师只复核高风险/高 stakes 决策；质量饱和律
5	误判/标签偏差	中	内容分类器、认知准备度评估可能对特定群体（非母语、特殊教育需求学生）产生偏差	定期公平性审计+申诉机制+教师复核+不得用标签做排名/分流
6	家长资源差距（数字鸿沟）	中	高学历/高收入家长更能理解和使用平台的家长控制功能，低资源家庭可能无法有效监督	家长端简化设计+学校提供统一默认策略+不得把家长参与度作为学生评价依据
7	策略碎片化	中	不同学校/区域/教师制定不同策略，导致学生跨校体验不一致	区域级基准策略+学校可在基准上微调+策略版本管理+最佳实践共享
8	过度封锁损害学习	中	策略过于保守（如全学段禁用生成式AI）会剥夺学生学习AI素养的机会，与教育部政策相悖	渐进开放原则+定期效果评估+学生/教师反馈渠道
9	认知准备度标签的伦理风险	高	L0-L5 标签若被用于排名、分流、预测未来，会造成标签污名和自我实现预言	仅内部适配标签，禁止对外展示/排名/分流/预测未来；可申诉可重置；EU AI Act 高风险约束
10	形式合规绕过	中	学生/教师可能通过“先提交垃圾提纲再过前置任务门”等方式形式化满足流程，实质仍依赖AI	过程证据质量评估+教师抽查+AI使用声明+学术诚信教育

10.2 可证伪条件

本平台的核心设计主张可以通过以下条件证伪：

- “前置任务门提升学习效果”可证伪：如果 A/B 测试显示，使用前置任务门的学生组在学习成果测试中不优于（或劣于）直接使用 AI 的对照组，则该机制的教育价值被证伪。[RESULT NEEDED]

2. “十维分级优于单一年龄分级”可证伪：如果对比实验显示，十维分级在用户满意度、学习效果、安全事件率上不显著优于简单的年龄分级，则十维的复杂度成本不值得。[RESULT NEEDED]
3. “确定性规则优于学习分类器用于安全红线”可证伪：如果在教育场景的真实数据上，学习分类器的 AUROC 显著高于确定性规则（与 H-CSC 证据相反），则规则优先的设计需要修正。[RESULT NEEDED]
4. “教师终评不可省略”可证伪：如果 AI 自动评价在特定任务（如选择题批改）上与教师评价的一致性超过教师间一致性，则该任务可以由 AI 独立完成，不需要教师终评。[RESULT NEEDED]
5. “渐进开放优于全开放/全禁用”可证伪：如果长期跟踪显示，渐进开放组的 AI 素养和学业表现不优于全开放组，且安全事件率不低于全开放组，则渐进开放的收益不成立。[RESULT NEEDED]

10.3 预测

表 12 可验证预测与记分时点

#	预测	记分时点	验证方法	当前状态
P1	教育场景 AI 分级平台将在2027年前成为中国中小学信息化采购的标配（类似当前的防火墙/上网行为管理）	2027-06	教育部/省级采购目录统计	预测·待验证
P2	“小学禁止独自使用开放式生成”的政策红线将在2026-2027年被更多地区细化为可执行的技术标准	2027-06	地方教育部门文件检索	预测·待验证
P3	AI 生成内容检测工具将在2027年前被更多高校停用（继Vanderbilt/Curtin之后），原因是系统性偏见证据积累	2027-12	高校公告/媒体报道统计	预测·待验证
P4	中国将在2027年前出台教育领域 AI 分级的专门技术标准或行业规范（在 GB 45438基础上延伸到教育场景）	2027-12	国家标准委/教育部标准发布	预测·待验证
P5	认知准备度标签的伦理争议将在2027年前成为公共讨论话题，推动”禁止用AI标签对学生分流”的政策出台	2028-06	媒体/政策文件检索	预测·待验证

#	预测	记分时点	验证方法	当前状态
P6	本平台的前置任务门在 A/B 测试中将显示学习效果提升（效应量 d>0.2）	试点后6个月	随机对照实验，≥30 seed+95%CI	[RESULT NEEDED]

表12注：P1–P5为趋势预测，P6为实验预测。所有预测均为设计提案的推论，尚未验证。投稿前需≥30 seed+95%CI 验证实验类预测。

本章小结：十类失效边界中，私人设备绕过和第三方SDK接入是最高影响；五个可证伪条件明确了设计主张何时需要修正；六个预测（含记分时点）为后续验证提供了路线图。所有实验类预测标 [RESULT NEEDED]。

11 合规清单与落地路线

一句话结论：合规清单把法规要求转译为平台必须实现的技术动作，落地路线分五阶段（标准标签→MVP→试点学校→模型网关+教育编排→规模评估），每阶段有明确的交付物和验证标准，均为设计提案·待实施。

11.1 合规清单

表 13 法规要求→平台技术动作映射

法规要求	来源	平台技术动作	实现层
分类分级监管	生成式AI办法第3条	十维分级编码+PDP决策	③策略中心
防范未成年人过度依赖沉迷	生成式AI办法第10条	时间分级T0–T4+额度分级Q0–Q5+冷却机制	⑧额度时间
生成内容标识	生成式AI办法第12条+标识办法+GB 45438	显式标识(AI使用声明)+隐式标识(元数据/水印)+内容来源分级G0–G4	④内容安全+⑥教育编排
算法备案	生成式AI办法第17条+算法推荐规定第24条	算法备案材料准备+策略版本管理	③策略中心+⑨审计
不满14周岁监护人同意	个保法第31条+儿童规定	年龄断言+监护人同意流程+可撤销+专门规则	②身份组织
时间/权限/消费管理	未保条例	时间分级+权限分级+额度分级+课堂/考试模式	⑧+⑨
个人信息最小必要	个保法+生成式AI办法第11条	数据最小化采集+PII脱敏(Presidio)+内容哈希不存原文	②+④+⑦
投诉举报机制	生成式AI办法第15条	申诉通道+教师/家长复核+决策可查询	⑨审计合规

法规要求	来源	平台技术动作	实现层
小学禁止独自使用开放式生成	2025教指委指南	A0-A1学生端无自由生成+TEACHER_ONLY路由	③策略中心
分类分级确定安全防护标准	2026教育部”AI+教育”行动计划	十维分级+安全分级S0-S4+教育大模型安全审核	全平台

11.2 落地路线

表 14 五阶段落地路线（设计提案·待实施）

阶段	名称	核心交付物	验证标准	预计周期
Phase 0	标准与标签	十维编码规范、内容标签体系、模型能力注册卡模板、策略DSL规范	标签一致性≥85%（多人标注）；策略文件通过语法检查	1-2月
Phase 1	MVP	身份组织+策略中心(PDP/PEP)+安全审核+额度时间+审计日志	决策延迟<200ms(p95)；安全红线拦截率100%（确定性规则）；审计日志完整率100%	2-3月
Phase 2	试点学校	1-2所试点学校（高小+初中），教师/家长控制台，学段策略矩阵落地	教师满意度≥7/10；安全事件率<1/1000请求；学生AI素养前后测提升	3-6月
Phase 3	模型网关+教育编排	LiteLLM路由+RAG教材库+苏格拉底模式+前置任务门+过程证据+AI使用声明	前置任务门完成率≥80%；过程证据完整率≥90%；教师终评覆盖率100%	3-6月
Phase 4	规模评估与监管报表	多校/区域推广；公平性审计；效果评估；家长报告；监管报表；可证伪预测验证	公平性审计无显著群体偏差；可证伪条件验证完成；监管报表按时生成	6-12月

表14注：所有周期和验证标准为设计提案·待实施 [RESULT NEEDED]。实际周期取决于学校配合度、设备条件、教师培训进度。

11.3 最小可行验证路径

如果资源有限，建议优先验证以下三个最小实验：

1. 前置任务门效果实验：在一所初中的两个平行班（随机分配），一个班用前置任务门+苏格拉底提示，一个班直接用AI。6周后比较写作成绩、AI依赖度、学生满意度。≥30 seed+95%CI。
[RESULT NEEDED]

2. **确定性规则vs学习分类器安全红线对比**：在教育场景真实数据（含学生尝试绕过的案例）上，比较确定性规则和学习分类器的 AUROC、误报率、漏报率。验证 H-CSC 证据是否在教育场景成立。
[RESULT NEEDED]
3. **学段策略矩阵的教师接受度调查**：向试点学校教师发放问卷，评估各学段策略的合理性、可操作性、负担程度。收集教师修改建议，迭代策略矩阵。[RESULT NEEDED]

本章小结：合规清单把10项法规要求映射到具体技术动作和实现层；落地路线分五阶段，每阶段有交付物和验证标准；最小可行验证路径优先验证前置任务门效果、规则vs学习分类器、教师接受度三个实验。均为设计提案·待实施。

参考文献

中国法规与政策（核至官方来源，访问日期 2026-09-21）

1. 全国人民代表大会常务委员会. 中华人民共和国个人信息保护法[Z]. 主席令第91号, 2021-08-20通过, 2021-11-01施行. http://www.npc.gov.cn/npc/c2/c30834/202108/t20210820_313088.html
2. 国务院. 未成年人网络保护条例[Z]. 国务院令第766号, 2023-10公布, 2024-01-01施行. https://www.gov.cn/zhengce/zhengceku/202310/content_6911289.htm
3. 国家网信办等七部门. 生成式人工智能服务管理暂行办法[Z]. 七部门令第15号, 2023-07-13公布, 2023-08-15施行. https://www.cac.gov.cn/2023-07/13/c_1690898327029107.htm
4. 国家网信办等四部门. 互联网信息服务算法推荐管理规定[Z]. 四部门令第9号, 2021-12-31发布, 2022-03-01施行. https://www.gov.cn/zhengce/zhengceku/2022-01/04/content_5666429.htm
5. 国家网信办等三部门. 互联网信息服务深度合成管理规定[Z]. 三部门令第12号, 2022-12-11发布, 2023-01-10施行. https://www.gov.cn/gongbao/content/2023/content_5741257.htm
6. 国家互联网信息办公室. 儿童个人信息网络保护规定[Z]. 网信办令第4号, 2019-08-22公布, 2019-10-01施行. https://www.gov.cn/zhengce/zhengceku/2019-08/22/content_5458118.htm
7. 国家网信办等四部门. 人工智能生成合成内容标识办法[Z]. 国信办通字〔2025〕2号, 2025-03-14发布, 2025-09-01施行. https://www.cac.gov.cn/2025-03/14/c_1743654684782215.htm
8. 国家市场监督管理总局, 国家标准化委员会. 网络安全技术 人工智能生成合成内容标识方法[S]. GB 45438-2025, 2025-02-28发布, 2025-09-01实施. <https://openstd.samr.gov.cn/bzgk/std/newGbInfo?hcno=F32EA2A561F1886CD8D606513512D547>
9. 教育部. 教育信息化2.0行动计划[Z]. 教技〔2018〕6号, 2018-04-13. http://www.moe.gov.cn/srcsite/A16/s3342/201804/t20180425_334188.html
10. 教育部办公厅. 关于加强中小学人工智能教育的通知[Z]. 2024-12. http://www.moe.gov.cn/jyb_xwfb/gzdt_gzdt/s5987/202412/t20241202_1165500.html（文号 [CITATION NEEDED]）
11. 教育部等九部门. 关于加快推进教育数字化的意见[Z]. 2025-04. http://www.moe.gov.cn/srcsite/A01/s7048/202504/t20250416_1187476.html
12. 教育部等五单位. “人工智能+教育”行动计划[Z]. 2026-04. <http://www.moe.gov.cn/fbh/live/2026/77927/wj/>（五单位全称与文号 [CITATION NEEDED]）

13. 教育部基础教育教学指导委员会. 中小生成式人工智能使用指南（2025年版）[Z]. 2025-05.（指导性文件，无令号）
14. 国家新闻出版署. 关于进一步严格管理 切实防止未成年人沉迷网络游戏的通知[Z]. 国新出发〔2021〕14号, 2021-08-30.（类比参考，非直接适用于AI教育）

国际制度与技术（核至官方/权威来源，访问日期 2026-09-21）

1. European Union. Regulation (EU) 2024/1689 (AI Act)[Z]. 2024-07-12 OJ发布, 2024-08-01生效. <https://digital-strategy.ec.europa.eu/en/policies/regulatory-framework-ai>
2. Federal Trade Commission. FTC Finalizes Changes to Children’s Privacy Rule[EB/OL]. 2025-01-16. <https://www.ftc.gov/news-events/news/press-releases/2025/01/ftc-finalizes-changes-childrens-privacy-rule-limiting-companies-ability-monetize-kids-data>
3. ICO. Age Assurance for the Children’s Code[EB/OL]. <https://ico.org.uk/about-the-ico/what-we-do/information-commissioners-opinions/age-assurance-for-the-children-s-code/>
4. UK Parliament. Online Safety Act 2023[Z]. c.50, 2023. <https://www.legislation.gov.uk/ukpga/2023/50/enacted>
5. NIST. Guide to Attribute Based Access Control (ABAC)[S]. NIST SP 800-162, 2014（2019-02-25更新）. <https://nvlpubs.nist.gov/nistpubs/specialpublications/NIST.SP.800-162.pdf>
6. INCITS. Role Based Access Control[S]. ANSI/INCITS 359-2012. <https://csrc.nist.gov/Projects/Role-Based-Access-Control>
7. OASIS. eXtensible Access Control Markup Language (XACML)[S]. <https://docs.oasis-open.org/xacml/3.0/xacml-3.0-core-spec-os-en.html>
8. CNCF. Open Policy Agent (OPA)[EB/OL]. <https://www.openpolicyagent.org>（CNCF毕业 2021-01-29）
9. Meta. Llama Guard 3[EB/OL]. <https://huggingface.co/meta-llama>（S1–S13分类）
10. NVIDIA. NeMo Guardrails[EB/OL]. <https://docs.nvidia.com/nemo/guardrails/>
11. Microsoft. Presidio[EB/OL]. <https://microsoft.github.io/presidio/>
12. BerriAI. LiteLLM[EB/OL]. <https://docs.litellm.ai>
13. Angelopoulos, A. N., & Bates, S. A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification[J]. arXiv:2107.07511, 2021.
14. Liang, W., Yuksekgonul, M., Mao, Y., Wu, E., & Zou, J. GPT detectors are biased against non-native English writers[J]. Patterns, 4(7), 100779, 2023. PMID: 37521038.

UDOS 内部引用（同卷）

1. UDOS v7.7.2 第06篇. 共识与停止：BFT-lite三级类型化最终性与规则优先（H-CSC v2 撤回口径：确定性词法谓词 AUROC 0.865–0.982 击败学习编码器 0.621–0.744）.
2. UDOS v7.7.2 第07篇. 质量多样性与仿真效度：质量饱和律（生成可扩展、审查不扩展，Little’s Law/WIP=1）.
3. UDOS v7.7.2 第09篇. 交接即契约：TransferBundle 最小权限与 MCP/A2A 互操作.
4. UDOS v7.7.2 第12篇. 产业级工程架构：五层栈、SOP 闸门、EPOB.

5. UDOS v7.7.2 第13篇. 证据工程与研究方法：三级证据分级、三态台账、修订追溯.

证据台账 (EVIDENCE LEDGER v777 摘要)

完整证据台账见同目录 `EVIDENCE_LEDGER_v777.md`。本摘要列出三态分布与关键事实纠正。

三态分布：中国法规14项——已核验10项、部分核验4项（2024中小学AI教育通知文号、2026” AI+教育” 行动计划五单位全称与文号、2025九部门数字化意见文号、2025教指委指南无令号属指导性文件）、查无实据0项。国际制度7项——已核验5项、部分核验1项（FERPA DOE官方指南）、查无实据1项（澳大利亚OSA一手条文 [CITATION NEEDED]）。技术组件11项——已核验8项、部分核验3项（Guardrails AI GitHub链接、Presidio治理过渡、star数/版本号未实时抓取）。

关键事实纠正：1. 《互联网信息服务算法推荐管理规定》为**四部门**令第9号（网信办、工信部、公安部、市场监管总局），非七部门。2. 《人工智能生成合成内容标识办法》为**四部门**发布（含广电总局），文号国信办通字〔2025〕2号，非单纯网信办。3. GB 45438-2025 与《标识办法》同日（2025-09-01）生效，过渡期6个月。4. EU AI Act 教育场景情绪识别被 Art.5(1)(f) **直接禁止**，非高风险。5. AI检测工具对非英语写作者的系统性偏见有 Liang et al. 2023 Patterns 同行评审硬证据，非传闻。

查无实据披露：- 澳大利亚 Online Safety Act 2021 一手条文本次未检索 [CITATION NEEDED]。- OPA/Casbin/Presidio/LiteLLM 的 GitHub star 数与最新 release 版本号本次未实时抓取，正式稿需补 [CITATION NEEDED]。- DOE《Designing for Education with AI》（2024-07）官方原文 PDF 链接本次未直接取得 [CITATION NEEDED]。- Turnitin 自报误判率（非母语6–9% vs 母语1–4%）为二手转述，需核官方报告 [CITATION NEEDED]。- GDPR Art.8 各成员国同意年龄现行值（FRA 2017 mapping 较旧），正式发表前需对照各国 DPA 官网 [CITATION NEEDED]。

本文为 UDOS 增补卷 v7.7.7 P38，独立增补卷，不并入 v7.7.2 的13篇总卷。全文不含新实验；所有设计提案标”设计提案·待实施”，额度/时长数字标”策略示例·可配置”，外部法规与工具均附官方来源与三态标注。投稿前需≥30 seed+95%CI 验证实验类预测。